

Một khảo sát về Hệ thống Gợi ý Đa phương thức: Những tiến bộ gần đây và Hướng đi tương lai

Jinfeng Xu, Zheyu Chen, Shuo Yang, Jinze Li, Wei Wang,
Xiping Hu, Steven Hoi, *Fellow, IEEE* and Edith Ngai, *Senior Member, IEEE*

Abstract—Việc thu thập dữ liệu có giá trị từ lượng thông tin đang mở rộng nhanh chóng trên internet đã trở thành một mối quan tâm đáng kể, và các hệ thống gợi ý đã nổi lên như một công cụ hiệu quả và được sử dụng rộng rãi để giúp người dùng khám phá các mục (items) mà họ quan tâm. Bản chất của các hệ thống gợi ý nằm ở khả năng dự đoán điểm đánh giá hoặc sở thích của người dùng đối với các mục khác nhau, từ đó đề xuất những mục phù hợp nhất dựa trên dữ liệu tương tác trong quá khứ và thông tin có sẵn công khai. Với sự xuất hiện của các dịch vụ đa phương tiện đa dạng, bao gồm văn bản, hình ảnh, video và âm thanh, con người có thể nhận thức thế giới thông qua nhiều phương thức (modalities) khác nhau. Do đó, một hệ thống gợi ý có khả năng hiểu và diễn giải dữ liệu từ các phương thức khác nhau có thể tham chiếu hiệu quả hơn đến các sở thích cá nhân. Hệ thống Gợi ý Đa phương thức (Multimodal Recommender Systems - MRS) không chỉ nắm bắt thông tin tương tác ẩn qua nhiều phương thức mà còn có tiềm năng khám phá các mối quan hệ tiềm ẩn giữa những phương thức này. Mục tiêu chính của bài khảo sát này là đánh giá toàn diện những tiến bộ nghiên cứu gần đây về MRS và phân tích các mô hình từ góc độ kỹ thuật. Cụ thể, chúng tôi hướng tới việc tóm tắt quy trình chung và những thách thức chính của MRS từ khía cạnh kỹ thuật. Tiếp theo, chúng tôi giới thiệu các mô hình MRS hiện có bằng cách phân loại chúng vào bốn lĩnh vực chính: Trích xuất Đặc trưng (Feature Extraction), Bộ mã hóa (Encoder), Dung hợp Đa phương thức (Multimodal Fusion) và Hàm mất mát (Loss Function). Cuối cùng, chúng tôi thảo luận thêm về các hướng đi tiềm năng trong tương lai để phát triển và nâng cao MRS. Bài khảo sát này đóng vai trò như một cẩm nang hướng dẫn toàn diện cho các nhà nghiên cứu và người thực hành trong lĩnh vực MRS, cung cấp những hiểu biết sâu sắc về hiện trạng của công nghệ MRS và xác định các khu vực cho nghiên cứu tương lai. Chúng tôi hy vọng sẽ đóng góp vào việc phát triển một hệ thống gợi ý đa phương thức tinh vi và hiệu quả hơn. Để truy cập thêm thông tin chi tiết về bài báo này, chúng tôi mã nguồn mở một kho lưu trữ: <https://github.com/Jinfeng-Xu/Awesome-Multimodal-Recommender-Systems>.

Index Terms—Hệ thống thông tin, Khai phá dữ liệu, Hệ thống thông tin đa phương tiện, Hệ thống gợi ý đa phương thức.

Jinfeng Xu, Jinze Li, Shuo Yang, and Edith C. H. Ngai* are with the Department of Electrical and Electronic Engineering, The University of Hong Kong, Hong Kong, China (e-mail: jinfeng, lijnize-hku, shuo.yang, @connect.hku.hk, chngai@eee.hku.hk).

Zheyu Chen is with the Department of Electrical and Electronic Engineering, The Hong Kong Polytechnic University, Hong Kong, China (e-mail: zheyu.chen@connect.polyu.hk).

Wei Wang and Xiping Hu are with the Department of Engineering, Shenzhen MSU-BIT University, Shenzhen, China, and also with the School of Medical Technology, Beijing Institute of Technology, Beijing, China (e-mail: ehomewang@ieee.org, huxp@bit.edu.cn).

Steven Hoi is with the School of Computing and Information Systems, Singapore Management University, Singapore (e-mail: chhoi@smu.edu.sg).

*The corresponding author.

This paper was produced by the IEEE Publication Technology Group. They are in Piscataway, NJ.

Manuscript received XXXX; revised XXXX.

I. GIỚI THIỆU

SỰ mở rộng nhanh chóng của Internet đã dẫn đến một lượng thông tin khổng lồ, khiến người dùng ngày càng gặp khó khăn trong việc xác định những gì hữu ích và phù hợp. Hiện tượng này, được gọi là quá tải thông tin, phát sinh do khả năng kiểm soát việc tạo ra và phổ biến thông tin trong thời đại kỹ thuật số gần như là không thể. Do đó, có một nhu cầu cấp thiết về các cơ chế lọc mạnh mẽ ưu tiên nội dung thích hợp để tạo điều kiện thuận lợi cho các quá trình giao tiếp và ra quyết định hiệu quả. Hệ thống gợi ý, cá nhân hóa các bộ lọc nội dung theo các yêu cầu cụ thể trên nhiều miền khác nhau, đã chứng minh tính hiệu quả của chúng trong việc giảm thiểu các tác động bất lợi của tình trạng quá tải thông tin. Các hệ thống này đã tỏ ra đặc biệt thành công trong các ứng dụng thương mại như thương mại điện tử, quảng cáo và mạng xã hội, nơi tính cá nhân hóa là rất quan trọng đối với sự tương tác và sự hài lòng của người dùng [1]–[4].

Chức năng chính của hệ thống gợi ý là dự đoán điểm đánh giá hoặc sở thích của người dùng đối với các mục khác nhau và đề xuất những mục có khả năng cao nhất và phù hợp nhất dựa trên dữ liệu tương tác trong quá khứ và thông tin công khai. Tuy nhiên, các phương pháp gợi ý dựa trên ID truyền thống, hoạt động theo nguyên tắc rằng người dùng có xu hướng chọn các mục tương tự như những mục họ đã thích trước đây, thường phụ thuộc nhiều vào việc có đủ tương tác giữa người dùng và mục. Mặc dù đạt được những thành công nhất định, hệ thống gợi ý vẫn phải đối mặt với hai thách thức lớn: tính thưa thớt của dữ liệu và bài toán khởi động lạnh (cold start). Tính thưa thớt của dữ liệu phát sinh từ sự thưa thớt tự nhiên của dữ liệu tương tác giữa người dùng và sản phẩm, làm cho việc dự đoán chính xác sở thích của người dùng trở nên khó khăn. Sự thưa thớt này có thể dẫn đến các đề xuất không đáng tin cậy, đặc biệt là trong các hệ thống có danh mục sản phẩm lớn nhưng lại có tương đối ít tương tác của người dùng. Bài toán khởi động lạnh xảy ra vì các mô hình hệ thống gợi ý truyền thống phụ thuộc nhiều vào các nhúng ID (ID embeddings), vốn gặp khó khăn trong việc đưa ra các dự đoán thỏa đáng cho người dùng hoặc sản phẩm mới với ít hoặc không có dữ liệu tương tác trong quá khứ. Thách thức này đặc biệt rõ rệt trong các môi trường động, nơi các mục và người dùng mới liên tục được giới thiệu.

Để giảm thiểu những vấn đề này, thông tin đa phương thức ngày càng được tích hợp nhiều hơn vào các hệ thống gợi ý. MRS tận dụng thông tin đa phương thức bổ trợ, chẳng hạn như văn bản, hình ảnh, video và âm thanh, để bổ sung cho các tương tác lịch sử giữa người dùng và các mục. Cách tiếp

TABLE I
KHẢO SÁT HỆ THỐNG GỢI Ý LIÊN QUAN

Các bài Khảo sát	Những Đóng góp Chính	Sự Khác biệt so với Khảo sát của Chúng tôi
Zhang và cộng sự [6]	cung cấp một cái nhìn toàn cảnh về những tiến bộ trong các hệ thống gợi ý dựa trên học sâu và đưa ra một khảo sát về các hướng đi và thách thức trong tương lai.	Công trình này thể hiện một cách toàn diện sự phát triển tiên tiến trong các hệ thống gợi ý dựa trên học sâu, bao gồm cả MRS nhưng thiếu sự giới thiệu chi tiết về các công nghệ SOTA hiện có.
Guo và cộng sự [7]	cung cấp một khảo sát chi tiết về các cách tiếp cận hiện có sử dụng KG để cải thiện kết quả gợi ý và giới thiệu một số tập dữ liệu được sử dụng trong các kịch bản khác nhau.	Khảo sát của chúng tôi tập trung vào việc phân loại quy trình cho MRS và các công nghệ SOTA của hệ thống gợi ý đa phương thức; KG chỉ được thảo luận như một phần của các kỹ thuật trong công trình của chúng tôi.
Deldjoo và cộng sự [8]	cung cấp một khảo sát toàn diện và sơ lược và một sự phân loại tổng quát theo các phương thức.	Việc phân loại trong công trình này ở mức độ khái quát và ở một mức độ nào đó là chưa hợp lý, trong khi công trình của chúng tôi cung cấp một sự phân loại chi tiết cho các kỹ thuật.
Jannach và cộng sự [9]	khám phá lĩnh vực CRS và cung cấp một khảo sát phân loại về các kỹ thuật hiện có.	Công trình này thảo luận về các cách tiếp cận gần đây trong lĩnh vực CRS nhưng thiếu sự kết hợp với thông tin đa phương thức.
Deldjoo và cộng sự [1]	thảo luận về các cách tiếp cận SOTA đối với MRS dựa trên nội dung và cung cấp một khảo sát về các thách thức và sự tiến hóa lịch sử.	Công trình này tập trung vào MRS dựa trên nội dung thay vì bao quát mọi khía cạnh của MRS.
Wu và cộng sự [10]	cung cấp một khảo sát toàn diện về việc sử dụng các kỹ thuật GNN trong lĩnh vực RS và liệt kê một số hạn chế và hướng đi tương lai.	Khảo sát của chúng tôi tập trung vào lĩnh vực MRS và cung cấp một phân loại chi tiết hơn về các kỹ thuật GNN trong lĩnh vực MRS.
Deldjoo và cộng sự [2]	cung cấp một khảo sát toàn diện về RS trong lĩnh vực thời trang theo tác vụ trên thị trường, và cung cấp một số mục tiêu đánh giá quan trọng trong lĩnh vực thời trang.	Công trình này tập trung vào RS trong lĩnh vực thời trang nhưng thiếu một khảo sát chung và chi tiết cho RS.
Meng và cộng sự [11]	cung cấp một phân tích toàn diện về các gợi ý tin tức được cá nhân hóa thông qua các công nghệ và liệt kê một số hạn chế và hướng đi tương lai.	Khảo sát của chúng tôi tập trung vào việc phân loại quy trình cho MRS nói chung và các công nghệ SOTA, cũng rất hiệu quả trong lĩnh vực tin tức.
Zhou và cộng sự [12]	tóm tắt các phương pháp chính được sử dụng trong MRS và cung cấp một khung chung cho các mô hình MRS thường được sử dụng.	Công trình này thể hiện một cách toàn diện các cách tiếp cận trước đây trong MRS nhưng thiếu một quy trình chi tiết về MRS.
Liu và cộng sự [5]	tóm tắt các phương pháp chính được sử dụng trong MRS và cung cấp một khung chung cho các mô hình MRS thường được sử dụng.	Công trình này phác họa cách tiếp cận MRS từ góc độ quy trình, thay vì góc độ phát triển công nghệ, và không cho phép người đọc hiểu đầy đủ hướng nghiên cứu trong lĩnh vực này.

cận này nâng cao hiệu suất gợi ý bằng cách cung cấp một sự hiểu biết phong phú và toàn diện hơn về sở thích của người dùng. Mục tiêu thiết yếu của hệ thống gợi ý là đáp ứng sở thích của mọi người, và vì nhận thức của con người về thể giới vốn là đa phương thức, việc kết hợp thông tin đa phương thức đa dạng có thể nắm bắt sở thích ở mức độ chi tiết hơn. Điều này dẫn đến các đề xuất chính xác và được cá nhân hóa hơn, qua đó cải thiện sự hài lòng và sự tham gia của người dùng.

Nghiên cứu về gợi ý đa phương thức đang phát triển và tiến hóa một cách nhanh chóng. Để hỗ trợ các nhà nghiên cứu nhanh chóng hiểu về MRS và hỗ trợ sự phát triển của cộng đồng, một đánh giá toàn diện từ góc độ kỹ thuật là rất cần thiết. Một nghiên cứu hiện có [5] cố gắng phân loại MRS từ quan điểm kỹ thuật; tuy nhiên, sự tiến bộ nhanh chóng của lĩnh vực này đã khiến một số phân loại của nó trở nên lỗi thời. Do đó, chúng tôi hướng tới việc thu thập các nghiên cứu gần đây và đề xuất một khung phân loại cập nhật hơn để giúp các nhà nghiên cứu nắm bắt những tiến bộ mới nhất trong cộng đồng MRS. Đánh giá này sẽ cung cấp một cái nhìn tổng quan kỹ lưỡng về các công nghệ MRS hiện tại, làm nổi bật các xu hướng mới nổi và xác định các định hướng tương lai tiềm năng cho nghiên cứu và phát triển trong lĩnh vực năng động này. Bằng cách xem xét một cách có hệ thống các công trình tiên tiến nhất (state-of-the-art - SOTA) trong MRS, chúng tôi hy vọng sẽ đóng góp vào những nỗ lực không ngừng nhằm

nâng cao khả năng và ứng dụng của các hệ thống gợi ý trong một thế giới kỹ thuật số đa phương thức.

A. Chiến lược Tìm kiếm các Bài báo Liên quan

Chúng tôi đã thực hiện một khảo sát toàn diện về Hệ thống Gợi ý Đa phương thức (MRS) bằng cách tìm tậ và phân tích một cách có hệ thống các bài báo từ các hội nghị và tạp chí hàng đầu trong lĩnh vực. Các hội nghị và tạp chí này bao gồm, nhưng không giới hạn ở, MM, KDD, WWW, SIGIR, AACL, ICLR, IJCAI, CIKM, WSDM, TMM, TKDE, TPAMI, và INFFUS. Quy trình lựa chọn nghiêm ngặt này đảm bảo rằng bài khảo sát của chúng tôi bao quát các nghiên cứu có ảnh hưởng và tiên tiến nhất về MRS.

Cách tiếp cận tìm kiếm của chúng tôi được chia một cách có phương pháp thành ba giai đoạn riêng biệt:

- Thu thập các Bài báo Chất lượng cao: Trong giai đoạn đầu, chúng tôi đã tập hợp các bài báo từ các hội nghị và tạp chí hàng đầu kể trên. Việc lựa chọn này dựa trên danh tiếng và hệ số tác động (impact factor) của các nguồn, đảm bảo rằng chỉ những nghiên cứu có chất lượng cao và được bình duyệt mới được đưa vào bài khảo sát của chúng tôi.
- Lọc và Xử lý hậu kỳ: Theo sau giai đoạn thu thập, chúng tôi đã lọc và xử lý hậu kỳ một cách tỉ mỉ các bài báo. Bước này bao gồm việc loại bỏ các bài trùng lặp, đánh giá mức độ liên quan của từng bài báo đối với chủ đề

MRS, và đảm bảo rằng chỉ giữ lại những nghiên cứu thích hợp nhất. Quá trình lọc nghiêm ngặt này rất quan trọng để duy trì trọng tâm và chất lượng của bài khảo sát.

- **Phân tích Kỹ thuật và Tổng hợp:** Trong giai đoạn cuối, chúng tôi đã tiến hành một phân tích chi tiết về các kỹ thuật được sử dụng trong mỗi bài báo. Điều này liên quan đến việc xem xét các phương pháp luận, mô hình và thuật toán được sử dụng, cũng như các động lực đằng sau những cách tiếp cận này. Chúng tôi cũng xem xét các công trình liên quan được trích dẫn trong mỗi bài báo để cung cấp một hiểu biết toàn diện về sự tiến hóa và các xu hướng hiện tại trong MRS. Bằng cách tổng hợp thông tin này, chúng tôi đã có thể tóm tắt các kỹ thuật và động lực chính thúc đẩy lĩnh vực này.

Thông qua cách tiếp cận có hệ thống này, khảo sát của chúng tôi cung cấp một cái nhìn tổng quan kỹ lưỡng và sâu sắc về các công trình SOTA trong Hệ thống Gợi ý Đa phương thức. Nó làm nổi bật những tiến bộ đáng kể, các xu hướng mới nổi, và các định hướng tương lai tiềm năng trong lĩnh vực, mang lại sự hướng dẫn có giá trị cho cả các nhà nghiên cứu và người thực hành.

B. So sánh với các Bài Khảo sát Liên quan

Một số bài khảo sát đã được công bố về các hệ thống gợi ý, đề cập đến các khía cạnh chung hoặc các khía cạnh cụ thể của các hệ thống này. Tuy nhiên, không có bài nào cung cấp một hệ thống phân loại toàn diện và hợp lý về các quá trình và các công nghệ chi tiết được sử dụng trong các công trình SOTA MRS gần đây, vốn là một yêu cầu mới nổi và quan trọng trong lĩnh vực này. Mục tiêu của MRS là nâng cao khả năng trích xuất các tương tác sâu hơn và chính xác hơn giữa người dùng và các mục bằng cách tích hợp thông tin đa phương thức vào các hệ thống gợi ý. Bài báo này thảo luận về các đóng góp chính và hạn chế của các bài khảo sát liên quan hiện có và nhấn mạnh những đóng góp độc đáo của công trình của chúng tôi, như được tóm tắt trong Bảng I.

Zhang và cộng sự [6] đưa ra một cái nhìn toàn cảnh về những tiến bộ trong các hệ thống gợi ý dựa trên học sâu, khảo sát các hướng đi và thách thức trong tương lai, bao gồm học biểu diễn kết hợp (joint representation learning), khả năng giải thích (explainability), các mô hình sâu hơn và suy luận máy (machine reasoning). Tuy nhiên, công trình của họ thiếu một phần giới thiệu chi tiết về các công nghệ SOTA hiện có. Deldjoo và cộng sự [8] cung cấp một khảo sát toàn diện và một sự phân loại tổng quát theo các phương thức, bao gồm các đặc trưng phổ biến như âm thanh, hình ảnh và văn bản, cũng như các đặc trưng đặc biệt như chuyển động, siêu dữ liệu (metadata) và định hướng ngữ nghĩa. Tuy nhiên, sự phân loại này có phần còn sơ lược và thiếu độ chính xác.

Jannach và cộng sự [9] khám phá lĩnh vực hệ thống gợi ý hội thoại (conversational recommender systems - CRS) và đưa ra một khảo sát phân loại các kỹ thuật hiện có, nhưng công trình của họ không tích hợp thông tin đa phương thức. Deldjoo và cộng sự [1] thảo luận về các cách tiếp cận SOTA đối với MRS dựa trên nội dung (content-driven), khảo sát các thách thức và sự tiến hóa trong lịch sử, bao gồm việc tăng tính đa dạng và tính mới mẻ của gợi ý, cung cấp sự minh bạch và các

giải thích, đạt được nhận thức ngữ cảnh, cải thiện khả năng mở rộng và tính hiệu quả, và giảm nhẹ bài toán khởi động lạnh. Tuy nhiên, trọng tâm của họ chủ yếu là MRS dựa trên nội dung, thay vì bao quát bức tranh tổng thể về MRS.

Các công trình trước đây [7], [10] tập trung vào cấu trúc đồ thị trong các hệ thống gợi ý. Guo và cộng sự [7] cung cấp một khảo sát chi tiết về các cách tiếp cận sử dụng đồ thị tri thức (knowledge graphs - KG) để tăng cường kết quả gợi ý, phân loại các phương pháp thành các cách tiếp cận dựa trên nhúng (embedding-based), dựa trên đường đi (path-based) và hợp nhất (unified). Wu và cộng sự [10] đưa ra một khảo sát toàn diện về các kỹ thuật mạng nơ-ron đồ thị (graph neural network - GNN) trong các hệ thống gợi ý, xác định một số hạn chế và định hướng tương lai, bao gồm việc biểu diễn đa dạng và không chắc chắn, khả năng mở rộng, tính động, trường nhận thức (receptive fields), học tự giám sát (self-supervised learning), tính mạnh mẽ (robustness), các phương pháp bảo vệ quyền riêng tư và tính công bằng (fairness).

Deldjoo và cộng sự [2] cung cấp một khảo sát toàn diện về các hệ thống gợi ý trong lĩnh vực thời trang, phân loại các tác vụ trên thị trường và phác thảo các mục tiêu đánh giá quan trọng đặc trưng cho ngành thời trang. Meng và cộng sự [11] trình bày một phân tích kỹ lưỡng về các gợi ý tin tức được cá nhân hóa, thảo luận về các công nghệ và liệt kê một số hạn chế và hướng đi tương lai, bao gồm bảo vệ quyền riêng tư, giảm thiểu tin giả và loại bỏ định kiến (de-biasing).

Zhou và cộng sự [12] tóm tắt các phương pháp chính được sử dụng trong MRS và đề xuất một khung chung cho các mô hình MRS thường được sử dụng. Mặc dù công trình của họ cung cấp một cái nhìn tổng quan toàn diện về các cách tiếp cận trước đây trong MRS, nhưng quy trình được đề xuất cho MRS cần được trình bày chi tiết hơn. Gần đây hơn, Liu và cộng sự [5] cũng tóm tắt các phương pháp chính được sử dụng trong MRS và cung cấp một khung chung cho các mô hình MRS. Tuy nhiên, công trình này vạch ra MRS từ góc độ quy trình thay vì tập trung vào các phát triển công nghệ, làm hạn chế khả năng của người đọc trong việc hiểu đầy đủ các hướng nghiên cứu trong lĩnh vực.

Tóm lại, công trình của chúng tôi nhằm lấp đầy những khoảng trống này bằng cách cung cấp một hệ thống phân loại chi tiết và cập nhật hơn về các quy trình và công nghệ MRS, từ đó thúc đẩy sự hiểu biết và phát triển của lĩnh vực đang tiến hóa nhanh chóng này.

Khảo sát của chúng tôi tập trung vào một sự phân loại tinh chỉnh về MRS từ góc độ công nghệ để cung cấp cho các nhà nghiên cứu cái nhìn sâu sắc về sự phát triển công nghệ của MRS. Cuối cùng, chúng tôi thảo luận về các định hướng tương lai tiềm năng để phát triển và cải thiện các gợi ý đa phương thức.

C. Cấu trúc của Bài Khảo sát

Cấu trúc bài khảo sát của chúng tôi được tổ chức theo các phần sau:

• Phần I: Giới thiệu

Chúng tôi phác thảo ngắn gọn sự phát triển lịch sử của RS và nhấn mạnh tầm quan trọng của việc tận dụng thông tin đa phương thức để nâng cao các gợi ý. Tiếp theo,

chúng tôi trình bày chi tiết về chiến lược tìm kiếm được sử dụng để đảm bảo chất lượng cho công trình của chúng tôi. Ngoài ra, chúng tôi cung cấp một phân tích so sánh với các khảo sát trước đó. Cuối cùng, chúng tôi trình bày cấu trúc của khảo sát này và làm nổi bật những đóng góp chính của nghiên cứu của chúng tôi.

• Phần II: Phân loại Công nghệ (Technological Taxonomy)

Chúng tôi trình bày một hệ thống phân loại công nghệ cho MRS, tóm tắt tất cả các công trình SOTA gần đây, và sau đó tổng quan về bốn công nghệ chính tương ứng.

• Phần III: Trích xuất Đặc trưng (Feature Extraction)

Chúng tôi đã đánh giá toàn diện các công trình MRS gần đây về các kỹ thuật trích xuất đặc trưng cho các phương thức hình ảnh và văn bản, xác định các xu hướng thịnh hành. Phân tích này đã dẫn đến một thiết lập tiêu chuẩn được tinh chọn, giúp các nhà nghiên cứu tiết kiệm được sự phức tạp khi điều hướng qua các phương pháp đa dạng.

• Phần IV: Bộ mã hóa (Encoder)

Chúng tôi phân loại các loại bộ mã hóa MRS từ góc độ kỹ thuật và tóm tắt tất cả các công trình SOTA gần đây. Cái nhìn tổng quan toàn diện này cung cấp những hiểu biết về những khoảng trống nghiên cứu tiềm ẩn và các hướng đi trong tương lai, tạo điều kiện cho sự phát triển và tinh chỉnh liên tục các công nghệ MRS.

• Phần V: Dung hợp Đa phương thức (Multimodal Fusion)

Chúng tôi cung cấp một sự phân loại toàn diện cho việc dung hợp đa phương thức trong MRS, từ cả góc độ thời điểm (timing) và chiến lược (strategy). Chúng tôi cũng tóm tắt tất cả các công trình gần đây từ các góc độ này và tiết lộ sự tương tác giữa hai khía cạnh này. Sự phân loại toàn diện này nhằm mục đích giúp các nhà nghiên cứu chọn ra thời điểm và các chiến lược thích hợp cho việc dung hợp các phương thức.

• Phần VI: Hàm Mất mát (Loss Function)

Chúng tôi cung cấp một phần giới thiệu chi tiết về các hàm mất mát được sử dụng trong MRS, bao gồm cả các khung học có giám sát và tự giám sát. Cụ thể, chúng tôi giới thiệu và phân tích một số hàm mất mát được sử dụng rộng rãi, nêu chi tiết các ứng dụng và tính hiệu quả của chúng trên các kịch bản học khác nhau trong MRS. Sự khám phá này nhằm hỗ trợ các nhà nghiên cứu trong việc lựa chọn và triển khai các hàm mất mát phù hợp nhất.

• Phần VII: Hướng đi Tương lai

Chúng tôi đi sâu vào các hướng đi tương lai tiềm năng của lĩnh vực MRS. Chúng tôi mong muốn kích thích và khuyến khích thêm các nghiên cứu, sự phát triển và sự đổi mới trong lĩnh vực đang phát triển nhanh chóng này.

• Phần VIII: Kết luận

Chúng tôi tóm tắt ngắn gọn các nội dung và những đóng góp của bài khảo sát này.

Hình 1 minh họa một cấu trúc phác thảo chi tiết về khảo sát của chúng tôi (Bao gồm từ Phần III - Phần VI).

Những đóng góp chính của khảo sát của chúng tôi như sau:

- Chúng tôi cung cấp một đánh giá toàn diện về MRS, tóm tắt một lượng lớn các công trình SOTA, và cấu trúc hóa




Fig. 1. Cấu trúc phác thảo bài khảo sát của chúng tôi.

một quy trình chung của MRS để trình bày cách thông tin đa phương thức được sử dụng trong lĩnh vực RS.

- Chúng tôi phân loại và phân tích các kỹ thuật cũng như động lực cho mỗi bước chính của quy trình chung của MRS này, điều này có thể hướng dẫn vô cùng hiệu quả cho các nhà nghiên cứu để tiến hành thêm các nghiên cứu.
- Chúng tôi giới thiệu các tập dữ liệu thường có sẵn cho MRS và cung cấp một mô tả chi tiết về chúng. Và tổ chức các tập dữ liệu được sử dụng trong các công trình SOTA để giúp các nhà nghiên cứu chọn được tập dữ liệu phù hợp.
- Chúng tôi thảo luận về các thách thức hiện có đối với MRS dựa trên các công trình trước đây và liệt kê một số hướng đi trong tương lai đáng được nghiên cứu sâu.

TABLE II
LIST OF ABBREVIATIONS USED THROUGHOUT THIS PAPER

Abbreviation	Term
RS	Recommender Systems
MRS	Multimodal Recommender Systems
CRS	Conversational Recommender Systems
CF	Collaborative Filtering
MF	Matrix Factorization
GCN	Graph Convolution Network
GNN	Graph Neural Network
KG	Knowledge Graphs
SOTA	State-of-the-art
CL	Contrastive Learning
SSL	Self-supervised Learning

Bảng II liệt kê các từ viết tắt được sử dụng xuyên suốt bài báo này.

II. PHÂN LOẠI CÔNG NGHỆ

Dựa trên các công trình MRS ở mức SOTA hiện tại để tóm tắt và tổ chức, chúng tôi phân loại các công nghệ trong MRS thành bốn phần như được thể hiện trong Hình 2. Cụ thể, có bốn phần: **Trích xuất Đặc trưng (Feature Extraction)**, **Bộ mã hóa (Encoder)**, **Dung hợp Đa phương thức (Multimodal Fusion)**, và **Hàm mất mát (Loss Function)**. Chúng tôi tổng quan ngắn gọn về các phần này và thảo luận chi tiết về chúng trong các phần tiếp theo.

A. Trích xuất Đặc trưng

Các kịch bản ứng dụng khác nhau bao gồm nhiều loại thông tin phương thức khác nhau, dẫn đến các tập dữ liệu đa dạng




Fig. 2. Các công nghệ trong MRS nhìn từ góc độ quy trình.

với các đặc trưng đa phương thức riêng biệt. Tuy nhiên, hầu hết các tập dữ liệu đều bao gồm ít nhất ba phương thức chính: tương tác, hình ảnh và văn bản. Ví dụ, các nền tảng lớn như Amazon, Netflix và TikTok cung cấp các tập dữ liệu phong phú về thông tin hình ảnh và văn bản, do đó bao phủ cả hai phương thức hình ảnh và văn bản. Cụ thể, các tập dữ liệu của TikTok thường bao gồm các phương thức bổ sung, chẳng hạn như âm thanh và video [13]–[15]. Hơn nữa, các tập dữ liệu từ các miền chuyên biệt đôi khi có những phương thức hiếm gặp. Ví dụ, các tập dữ liệu trong các lĩnh vực phổ biến như thời trang và chăm sóc sức khỏe thường bao gồm nhiều phương thức chuyên biệt.

Trích xuất đặc trưng là một quá trình quan trọng nhằm biểu diễn các đặc trưng kênh có số chiều thấp, có thể diễn giải được bằng cách sử dụng các kỹ thuật nhúng (embedding). Các phương pháp trích xuất khác nhau được sử dụng cho các phương thức khác nhau. Đối với phương thức hình ảnh, các mô hình như ResNet [16] và ViT [17] được sử dụng để trích xuất đặc trưng. Trong trường hợp phương thức văn bản, các mô hình như BERT [18] và Sentence-Transformer [19] được sử dụng để suy xuất các đặc trưng. Các đặc trưng âm thanh thường được trích xuất bằng các mô hình như LSTM [20] và GRU [21].

Phần giới thiệu chi tiết về trích xuất đặc trưng được cung cấp trong Phần III, nơi chúng tôi đi sâu vào chi tiết cụ thể của từng phương thức và các kỹ thuật trích xuất tương ứng.

B. Bộ mã hóa

Bộ mã hóa sử dụng các đặc trưng được trích xuất từ thông tin đa phương thức và dữ liệu tương tác trong quá khứ để suy luận ra các biểu diễn sở thích của người dùng, sau đó được

sử dụng trong việc dự đoán các tương tác giữa người dùng và các mục để đưa ra các đề xuất. Tương tự như các hệ thống gợi ý truyền thống, các bộ mã hóa cho gợi ý đa phương thức có thể được phân loại rộng rãi thành các phương pháp dựa trên **Phân tích Ma trận (Matrix Factorization - MF [22])** và dựa trên **Mạng nơ-ron Tích chập Đồ thị (Graph Convolutional Network - Graph [23])**. Phương pháp dựa trên MF được biết đến với tính đơn giản và hiệu quả, trong khi phương pháp dựa trên Đồ thị tận dụng đồ thị hai phía vốn có trong các tương tác giữa người dùng và mục để học các đặc trưng láng giềng bậc cao.

Với sự tiến bộ nhanh chóng của MRS, các bộ mã hóa tinh vi hơn đã được đề xuất và sử dụng để khai thác tối đa thông tin đa phương thức phong phú, qua đó nâng cao hiệu suất gợi ý. Các bộ mã hóa tiên tiến này cho phép tích hợp dữ liệu đa phương thức đa dạng, dẫn đến các đề xuất chính xác và được cá nhân hóa hơn.

Trong Phần III, chúng tôi sẽ cung cấp một phần giới thiệu chi tiết về sự phát triển và các động lực đằng sau cả hai loại bộ mã hóa này. Phần này bao gồm việc khám phá cách các phương pháp dựa trên MF nắm bắt hiệu quả các tương tác người dùng - mục và cách các phương pháp dựa trên Đồ thị mở rộng khả năng này bằng cách kết hợp các cấu trúc đồ thị phức tạp. Bằng cách xem xét các phương pháp luận này, chúng tôi nhằm mục đích làm sáng tỏ những điểm mạnh và hạn chế của từng cách tiếp cận, cũng như những đóng góp của chúng cho cộng đồng MRS.

C. Dung hợp Đa phương thức

Một trong những trọng tâm nghiên cứu chính trong MRS là Dung hợp Đa phương thức. Các nghiên cứu gần đây đã chứng

minh rằng thời điểm dung hợp phương thức có thể ảnh hưởng đáng kể đến hiệu quả của các đề xuất. Dung hợp đa phương thức liên quan đến việc tích hợp thông tin từ các phương thức khác nhau ở các giai đoạn khác nhau, và thời điểm này có thể rất quan trọng để đạt được hiệu suất tối ưu.

Dung hợp Sớm (Early Fusion): Dung hợp sớm liên quan đến việc kết hợp các đặc trưng phương thức khác nhau trước khi chúng được xử lý bởi bộ mã hóa. Cách tiếp cận này có thể khám phá hiệu quả các mối quan hệ ẩn giữa các phương thức, vì các đặc trưng đa phương thức được tích hợp cho phép bộ mã hóa học được các biểu diễn phong phú hơn và có chất lượng cao hơn. Dung hợp sớm có thể nắm bắt các tương tác phức tạp giữa các loại dữ liệu khác nhau, chẳng hạn như văn bản, hình ảnh và âm thanh, dẫn đến một sự hiểu biết toàn diện hơn về sở thích của người dùng. Các kỹ thuật cho dung hợp sớm thường bao gồm việc nối (concatenation), các cơ chế chú ý (attention mechanisms), và các phương pháp tích hợp dựa trên mạng nơ-ron, nhằm tạo ra một biểu diễn thống nhất của dữ liệu đa phương thức.

Dung hợp Muộn (Late Fusion): Dung hợp muộn kết hợp các điểm số hoặc dự đoán từ mỗi phương thức sau khi các bộ mã hóa cụ thể cho từng phương thức đã xử lý chúng. Cách tiếp cận này tập trung vào việc tận dụng thế mạnh của từng mô hình cụ thể theo phương thức và sau đó kết hợp các đầu ra của chúng để đưa ra đề xuất cuối cùng. Dung hợp muộn có thể đặc biệt hiệu quả trong các kịch bản mà một số phương thức nhất định chứa nhiều thông tin hoặc đáng tin cậy hơn những phương thức khác. Bằng cách trì hoãn quá trình dung hợp cho đến sau giai đoạn dự đoán, dung hợp muộn cho phép trích xuất thông tin phương thức cụ thể một cách có mục tiêu và tinh tế hơn, nâng cao độ chính xác tổng thể của các đề xuất.

Trong Phần V, chúng tôi sẽ cung cấp một phân loại chi tiết các công trình hiện có dựa trên thời điểm dung hợp, chia chúng thành các phương pháp dung hợp sớm và dung hợp muộn. Sự phân loại này sẽ cung cấp một hiểu biết toàn diện về việc các chiến lược dung hợp khác nhau tác động như thế nào đến hiệu suất của các hệ thống MRS. Chúng tôi sẽ khám phá nhiều phương pháp luận và kỹ thuật khác nhau được sử dụng trong cả dung hợp sớm và muộn, phân tích các ưu điểm, hạn chế và kịch bản ứng dụng của chúng.

D. Hàm Mất mát

MRS tận dụng các hàm mất mát có thể được chia rộng rãi thành hai thành phần: các tác vụ chính và các tác vụ phụ trợ. Các tác vụ chính là học có giám sát (supervised learning), thường liên quan đến các nhãn được xác định rõ ràng để hướng dẫn quá trình học của mô hình. Các tác vụ này đảm bảo rằng mô hình học cách đưa ra các dự đoán chính xác dựa trên dữ liệu có nhãn. Các tác vụ phụ trợ là học tự giám sát (self-supervised learning - SSL) [24]. SSL tạo ra các tín hiệu giám sát từ cấu trúc hoặc các mẫu vốn có trong chính dữ liệu, thay vì chỉ dựa vào dữ liệu được gán nhãn từ bên ngoài. Cách tiếp cận này cho phép các hệ thống gợi ý sử dụng hiệu quả dữ liệu chưa được gán nhãn, trích xuất các biểu diễn có ý nghĩa và đưa ra các dự đoán chính xác ngay cả trong các kịch bản dữ liệu thưa thớt.

Học có Giám sát có thể được chia nhỏ hơn thành Mất mát Điểm (Pointwise Loss) và Mất mát Cặp (Pairwise Loss):

Mất mát Điểm (Pointwise Loss): Tổn thất này được tính toán bằng cách so sánh điểm số dự đoán cho từng mục riêng lẻ với nhãn thực tế của nó. Các hàm mất mát điểm phổ biến bao gồm Sai số Toàn phương Trung bình (Mean Squared Error - MSE) [25] và Mất mát Entropy Chéo (Cross-Entropy Loss - CE) [26], được sử dụng để đánh giá trực tiếp độ chính xác của từng dự đoán riêng lẻ.

Mất mát Cặp (Pairwise Loss): Tổn thất này tập trung vào thứ hạng tương đối của các mục. Nó đánh giá khả năng của mô hình trong việc sắp xếp chính xác từng cặp mục dựa trên sở thích của người dùng. Các hàm mất mát cặp phổ biến bao gồm Xếp hạng Cá nhân hóa Bayesian (Bayesian Personalized Ranking - BPR) [27] và Mất mát Bản lề (Hinge Loss) [28], nhằm tối ưu hóa thứ tự xếp hạng của các mục thay vì điểm số tuyệt đối của chúng.

Học Tự giám sát có thể được phân loại thành các phương pháp dựa trên đặc trưng và dựa trên cấu trúc:

SSL dựa trên Đặc trưng (Feature-based SSL): Phương pháp này bao gồm việc tạo ra các tác vụ phụ trợ để dự đoán hoặc tái tạo lại các đặc trưng nhất định của dữ liệu. Ví dụ, một mô hình có thể được huấn luyện để dự đoán các đặc trưng bị thiếu của một mục hoặc người dùng dựa trên dữ liệu có sẵn, qua đó học được các biểu diễn mạnh mẽ hơn.

SSL dựa trên Cấu trúc (Structure-based SSL): Cách tiếp cận này tận dụng các thuộc tính cấu trúc của dữ liệu, chẳng hạn như các mối quan hệ và tương tác giữa người dùng và các mục. Ví dụ, các phương pháp dựa trên đồ thị có thể sử dụng độ tương đồng của các nút hoặc các mẫu đồ thị con (subgraph patterns) để tạo ra các tín hiệu giám sát, nâng cao khả năng của mô hình trong việc nắm bắt các phụ thuộc và tương tác phức tạp.

Trong Phần VI, chúng tôi sẽ cung cấp một phần giới thiệu chi tiết về các hàm mất mát này. Chúng tôi sẽ khám phá những động lực đằng sau mỗi loại hàm mất mát, các chi tiết triển khai của chúng và tác động của chúng đến hiệu suất của các hệ thống gợi ý đa phương thức. Bằng cách xem xét các chiến lược học cả có giám sát và tự giám sát, chúng tôi nhằm cung cấp một hiểu biết toàn diện về việc các hàm mất mát khác nhau đóng góp như thế nào vào hiệu quả của gợi ý đa phương thức.

III. TRÍCH XUẤT ĐẶC TRƯNG

Chúng tôi đã tóm tắt việc trích xuất đặc trưng trong các phương thức hình ảnh và văn bản ở Bảng III cho các phương pháp MRS tiên tiến trong những năm gần đây. Trong lĩnh vực hình ảnh, các nghiên cứu ban đầu chủ yếu sử dụng các kiến trúc tích chập như CNN, cùng với các mô hình cụ thể như VGG [77], Inception [78], Caffe [79] và ResNet [16], những mô hình này đã chứng minh hiệu quả đáng kể trong việc xử lý các tác vụ nhận dạng hình ảnh khác nhau. Các mô hình này được đánh giá cao nhờ khả năng học sâu, cho phép trích xuất các đặc trưng phức tạp, bậc cao từ hình ảnh thô. Hơn nữa, trong lĩnh vực văn bản, một loạt các kỹ thuật đa dạng đã được sử dụng để trích xuất đặc trưng. Chúng bao gồm các phương pháp truyền thống như TF-IDF [80], cũng như

TABLE III
TÓM TẮT VIỆC TRÍCH XUẤT ĐẶC TRƯNG CỦA MRS CHO CẢ PHƯƠNG THỨC HÌNH ẢNH VÀ VĂN BẢN.

Phương thức			Hình ảnh (Visual)					Văn bản (Textual)										
			Cung cấp sẵn	VGG	Inception	Caffe	ResNet	Cung cấp sẵn	TF-IDF	GRU	PV-DM	PV-DBOW	Glove	Attention	BERT	Word2Vec	Sentence-transformer	Sentence 2Vec
Phương pháp	Năm	Xuất bản																
(V)VBPR [29]	2016	AAAI	✓															
(V)VMCF [30]	2017	WWW	✓															
(V)ACF [31]	2017	SIGIR					✓											
JRL [32]	2017	CIKM	✓									✓						
(V)DVBPR [33]	2017	ICDM					✓											
GraphCAR [34]	2018	SIGIR	✓					✓										
VECF [35]	2019	SIGIR		✓						✓								
UVCAN [36]	2019	WWW			✓													
MAML [37]	2019	MM				✓					✓							
MMGCN [13]	2019	MM	✓					✓										
(V)AMR [38]	2019	TKDE					✓											
MGAT [39]	2020	I&M	✓					✓										
GRCN [40]	2020	MM	✓					✓										
MKGAT [41]	2020	CIKM					✓										✓	
IMRec [42]	2021	MM	✓											✓				
PMGT [43]	2021	MM			✓										✓			
LATTICE [15]	2021	MM	✓														✓	
HHFAN [44]	2021	TMM	✓					✓										
MVGAE [45]	2021	TMM					✓											✓
DualGNN [14]	2021	TMM	✓					✓										
PAMD [46]	2022	WWW		✓									✓					
MMGCL [47]	2022	SIGIR	✓					✓										
(T)ADDVAE [48]	2022	KDD							✓									
EliMRec [49]	2022	MM					✓											✓
EgoGCN [50]	2022	MM	✓															✓
InvRL [51]	2022	MM					✓											✓
A2BM2GL [52]	2022	MM	✓					✓										
HCGCN [53]	2022	MM	✓														✓	
SLMRec [54]	2022	TMM	✓					✓										
DMRL [55]	2022	TMM					✓									✓		
BM3 [56]	2023	WWW	✓														✓	
MMSSL [57]	2023	WWW	✓												✓			
BCCL [58]	2023	MM	✓												✓			
FREEDOM [59]	2023	MM	✓														✓	
MGCN [60]	2023	MM	✓														✓	
PaInvRL [61]	2023	MM					✓											✓
DRAGON [62]	2023	ECAI	✓														✓	
LGMRec [63]	2024	AAAI	✓														✓	
LLMRec [64]	2024	WSDM	✓												✓			
PromptMM [65]	2024	WWW	✓												✓			
MCDRec [66]	2024	WWW	✓														✓	
DiffMM [67]	2024	MM	✓												✓			
SOIL [68]	2024	MM	✓														✓	
CKD [69]	2024	MM	✓														✓	
GUME [70]	2024	CIKM	✓														✓	
POWERec [71]	2024	INFFUS	✓														✓	
DGVAE [72]	2024	TMM	✓														✓	
VMoSE [73]	2024	TMM	✓												✓			
SAND [74]	2024	arXiv	✓														✓	
MENTOR [75]	2025	AAAI	✓														✓	
SMORE [76]	2025	WSDM	✓														✓	

các cách tiếp cận mạng nơ-ron phức tạp hơn như GRU [21], PV-DM (PV-DBOW) [81] và Glove [82]. Việc giới thiệu các cơ chế chú ý (attention mechanisms), cùng với các mô hình như BERT [18], Word2Vec [83], Sentence-Transformer [19] và Sentence2Vec [84], đã cách mạng hóa hơn nữa khả năng hiểu và xử lý ngôn ngữ bằng cách cho phép các biểu diễn văn bản được làm phong phú theo ngữ cảnh.

Khi lĩnh vực này tiến triển, khung mã nguồn mở MMRec¹ minh họa cho xu hướng này bằng cách tiêu chuẩn hóa các phương pháp trích xuất đặc trưng cho cả phương thức hình ảnh và văn bản, qua đó tạo điều kiện cho các thiết lập thử nghiệm được kiểm soát tốt hơn và có thể tái tạo. Hơn nữa, chất lượng dữ liệu đặt ra những thách thức, chẳng hạn như một

¹MMRec: <https://github.com/enoeche/MMRec.git>

số hình ảnh bị hỏng và thiếu trong các tập dữ liệu của Amazon. Do đó, các cách tiếp cận gần đây đã chuyển hướng sang việc sử dụng các đặc trưng được cung cấp sẵn trong phương thức hình ảnh để tránh các vấn đề liên quan đến việc xử lý thủ công. Tương tự, trong phương thức văn bản, việc dựa vào các mô hình được huấn luyện trước như BERT [57], [58], [64], [65], [67], [73] hoặc Sentence-Transformer [15], [53], [55], [56], [59], [60], [62], [63], [66]–[68], [70]–[72], [74], [75] đã trở nên phổ biến. Các mô hình này cung cấp một nền tảng vững chắc cho việc trích xuất đặc trưng, tận dụng các cơ sở tri thức khổng lồ có sẵn để nâng cao độ chính xác và chiều sâu của phân tích văn bản.

Bên cạnh đó, không phải tất cả các nghiên cứu đều tham gia vào cả hai phương thức hình ảnh và văn bản một cách toàn diện. Một số công trình chủ yếu tập trung vào khía cạnh hình ảnh như một dạng thông tin phụ trợ. Ví dụ, VBPR [29] và DVBP [33] nhấn mạnh tầm quan trọng của các đặc trưng hình ảnh trong việc tăng cường các hệ thống gợi ý, trong khi bỏ qua dữ liệu văn bản. Tương tự, VMCF [30] và ACF [31] kết hợp thông tin hình ảnh để cải thiện độ chính xác cho các mô hình của họ, nhưng họ không tích hợp những hiểu biết sâu sắc từ văn bản vốn có tiềm năng làm phong phú thêm sự hiểu biết về ngữ cảnh của dữ liệu. Trên khía cạnh đối kháng, AMR [38] tận dụng phương thức hình ảnh để củng cố tính mạnh mẽ của các mô hình của họ chống lại các cuộc tấn công đối kháng, tuy nhiên phương thức văn bản vẫn chưa được khám phá. Ngược lại, ADDVAE [48] chỉ tập trung hoàn toàn vào phương thức văn bản, do đó cung cấp một sự hiểu biết tinh tế về dữ liệu văn bản nhưng lại bỏ qua sức mạnh mô tả phong phú của thông tin hình ảnh.

IV. BỘ MÃ HÓA (ENCODER)

Trong các hệ thống gợi ý, một bộ mã hóa thường được sử dụng để trích xuất biểu diễn đặc trưng của một người dùng hoặc một mục. Các bộ mã hóa có thể là nhiều loại mô hình, từ các mô hình tuyến tính đơn giản đến các mạng nơ-ron sâu phức tạp. Mục đích chính là chuyển đổi dữ liệu thô (ví dụ: dữ liệu hành vi người dùng, thuộc tính mục, v.v.) thành một nhúng (embedding) có kích thước cố định, có thể nắm bắt được các đặc trưng cốt lõi của dữ liệu đầu vào. Tuy nhiên, trong gợi ý đa phương thức, bộ mã hóa đóng vai trò tương tự, nhưng do sự đa dạng lớn hơn của các đặc trưng, các bộ mã hóa phong phú và được thiết kế đặc biệt hơn đã được đề xuất để tận dụng tốt hơn thông tin đa phương thức và dữ liệu tương tác của người dùng cho các gợi ý chính xác hơn. Từ quan điểm kỹ thuật, chúng tôi phân loại đại khái tất cả các bộ mã hóa thành các bộ mã hóa dựa trên phân tích ma trận (MF-based) và các bộ mã hóa dựa trên đồ thị (Graph-based). Chúng tôi mô tả hai loại bộ mã hóa này trong Hình 3.

Sơ bộ 1 (Preliminary 1): Cho một tập hợp người dùng $\mathcal{U} \in \mathbb{R}^{|\mathcal{U}| \times d}$ và một tập hợp các mục $\mathcal{I} \in \mathbb{R}^{|\mathcal{I}| \times d}$, trong đó d là số chiều ẩn (hidden dimension). Chúng tôi sử dụng $\mathbf{R} = [r_{u,i}]^{|\mathcal{U}| \times |\mathcal{I}|}$ để biểu thị ma trận tương tác người dùng-mục. Đối với bộ mã hóa dựa trên đồ thị $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ là một đồ thị đã cho với tập các nút $\mathcal{V}$ và tập các cạnh $\mathcal{E}$, trong đó $|\mathcal{V}| = |\mathcal{U}| + |\mathcal{I}|$. $\mathbf{U}$ và $\mathbf{I}$ tương ứng biểu thị các nhúng ẩn cho người dùng và các mục. $\mathbf{E} = \{\mathbf{U}|\mathbf{I}\}$ biểu thị nhúng cho $\mathcal{V}$.

Đối với kịch bản MRS, chúng ta cần trình bày lại một khái niệm sơ bộ toàn diện hơn.

Sơ bộ 2 (Preliminary 2): Trình bày lại các tập hợp mục $\mathcal{I}_m \in \mathbb{R}^{|\mathcal{I}| \times d_m}$, trong đó $m \in \mathcal{M}$, $\mathcal{M}$ là tập hợp các phương thức, và d_m là số chiều ẩn cho phương thức m . Bên cạnh đó, $\mathcal{G}_m = (\mathcal{V}_m, \mathcal{E})$ là một đồ thị đã cho với tập các nút $\mathcal{V}_m$ và tập các cạnh $\mathcal{E}$, trong đó $|\mathcal{V}_m| = |\mathcal{U}| + |\mathcal{I}_m|$. $\mathbf{I}_m$ biểu thị các nhúng ẩn của mục cho phương thức m . $\mathbf{E}_m = \{\mathbf{U}|\mathbf{I}_m\}$ biểu thị nhúng cho $\mathcal{V}_m$.

A. Bộ mã hóa dựa trên Phân tích ma trận (MF-based Encoder)

Ý tưởng cốt lõi của các bộ mã hóa dựa trên MF là phân rã ma trận đánh giá người dùng-mục $\mathbf{R}$ thành hai nhúng ẩn hạng thấp $\mathbf{U}$ và $\mathbf{I}$. Xấp xỉ của ma trận đánh giá $\mathbf{R}$ có thể được biểu diễn như sau:

$$\mathbf{R} \approx \hat{\mathbf{R}} = \mathbf{U}\mathbf{I}^T, \quad (1)$$

trong đó T có nghĩa là phép toán chuyển vị cho ma trận. Hàm mất mát có thể được định nghĩa như sau:

$$\min_{\mathbf{U}, \mathbf{I}} \|\mathbf{R} - \hat{\mathbf{R}}\|_F^2 + \lambda(\|\mathbf{E}\|_F^2), \quad (2)$$

trong đó $\|\cdot\|_F$ có nghĩa là chuẩn Frobenius (Frobenius norm) và λ là tham số chuẩn hóa (regularization parameter) để kiểm soát việc học quá mức (overfitting).

Do các đặc trưng đa dạng của mục, chúng tôi phân loại các chiến lược thành một bộ mã hóa dựa trên MF hợp nhất và nhiều bộ mã hóa dựa trên MF. Thiết kế của cả hai phụ thuộc vào sự lựa chọn của việc dung hợp đa phương thức, mà chúng tôi sẽ thảo luận chi tiết trong Phần V. Nói chung, xấp xỉ của ma trận đánh giá $\mathbf{R}$ cho MRS có thể được biểu diễn như sau:

$$\mathbf{R} \approx \hat{\mathbf{R}} = \mathbf{U}\mathbf{I}^T, \quad \mathbf{I} = \text{Aggr}(\mathbf{I}_m), \quad (3)$$

$$\mathbf{R} \approx \hat{\mathbf{R}} = \text{Aggr}(\mathbf{U}\mathbf{I}_m^T), \quad (4)$$

trong đó $\text{Aggr}(\cdot)$ biểu thị sự dung hợp đa phương thức. Hàm mất mát có thể được định nghĩa như sau:

$$\min_{\mathbf{U}, \mathbf{I}} \|\mathbf{R} - \hat{\mathbf{R}}\|_F^2 + \lambda \left(\sum_{m \in \mathcal{M}} \|\mathbf{E}_m\|_F^2 \right). \quad (5)$$

B. Bộ mã hóa dựa trên Đồ thị (Graph-based Encoder)

Ý tưởng cốt lõi của các bộ mã hóa dựa trên Đồ thị là sử dụng các đặc trưng của các nút và thông tin cấu trúc của đồ thị để học biểu diễn của các nút. Chúng tôi giới thiệu mô hình bộ mã hóa dựa trên đồ thị được sử dụng phổ biến Mạng Tích chập Đồ thị (Graph Convolution Network - GCN) [85]. Đối với một đồ thị $\mathcal{G}$ và ma trận kề $\mathbf{A}$ của nó, sự lan truyền của một lớp của GCN có thể được biểu diễn như sau:

$$\mathbf{E}^{(l)} = \sigma(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{E}^{(l-1)} \mathbf{W}^{(l-1)}), \quad (6)$$

trong đó $\mathbf{E}^{(l)}$ là các nhúng ẩn của lớp l cho $\mathcal{V}$, $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$. $\tilde{\mathbf{D}}$ là ma trận bậc (degree matrix) của $\tilde{\mathbf{A}}$, trong đó $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$. $\mathbf{W}^{(l-1)}$ là ma trận trọng số cho lớp $l-1$ và $\sigma(\cdot)$ là hàm kích hoạt. Trong lĩnh vực gợi ý, LightGCN [86] đã chứng minh rằng các ma trận trọng số và các hàm kích hoạt trong GCN là không hữu ích và thậm chí còn làm tăng độ khó khi huấn




Fig. 3. Minh họa về hai loại bộ mã hóa.

luyện. Do đó, một GCN được đơn giản hóa sử dụng rộng rãi có thể được biểu diễn như sau:

$$\mathbf{E}^{(l)} = \tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{E}^{(l-1)}, \quad (7)$$

Sau đó, nó xếp chồng nhiều lớp bằng $\bar{\mathbf{E}} = \text{Stack}_{l \in L}(\mathbf{E}^{(l)})$, trong đó L là tổng số lớp của GCN. Chúng tôi chỉ đơn giản xác định toàn bộ Bộ mã hóa dựa trên Đồ thị này là $\bar{\mathbf{E}} = \text{GCN}(\mathbf{U}, \mathbf{I})$. Toàn bộ biểu diễn $\bar{\mathbf{E}}$ có thể được tách thành các phần người dùng và mục bằng $\tilde{\mathbf{U}}, \tilde{\mathbf{I}} = \text{Sp}(\bar{\mathbf{E}})$. Để khai thác tốt hơn các biểu diễn người dùng và mục, hai đồ thị loại đồng nhất (homogeneous), người dùng-người dùng và mục-mục, được đề xuất. Một phần của các bộ mã hóa dựa trên Đồ thị sẽ sử dụng một hoặc tất cả chúng để học các biểu diễn tốt hơn. Các đồ thị đồng nhất trước tiên giữ lại top- k các mục/người dùng theo mức độ tương đồng:

$$\mathbf{S}_{i,i'}^I = \begin{cases} 1, & \mathbf{S}_{i,i'}^I \in \text{top-}k(\mathbf{S}_{i,i'}^I) \\ 0, & \text{khác} \end{cases}, \quad (8)$$

$$\mathbf{S}_{u,u'}^U = \begin{cases} 1, & \mathbf{S}_{u,u'}^U \in \text{top-}k(\mathbf{S}_{u,u'}^U) \\ 0, & \text{khác} \end{cases}. \quad (9)$$

Để giảm thiểu vấn đề chênh lệch đáng kể trong phân phối đặc trưng giữa các đỉnh có bậc cao và các đỉnh có bậc thấp trong dữ liệu có cấu trúc đồ thị, một thực tiễn phổ biến là áp dụng chuẩn hóa đối xứng (symmetric normalization) cho ma trận kề, được ký hiệu là $\mathbf{S}^U = (\mathbf{D}^U)^{-1/2} \mathbf{S}^U (\mathbf{D}^U)^{-1/2}$ và $\mathbf{S}^I = (\mathbf{D}^I)^{-1/2} \mathbf{S}^I (\mathbf{D}^I)^{-1/2}$, trong đó $\mathbf{D}^U$ và $\mathbf{D}^I$ lần lượt đại diện cho ma trận bậc đường chéo của $\mathbf{S}^U$ và $\mathbf{S}^I$. Quá trình chuẩn hóa này là rất quan trọng vì nó điều chỉnh mức độ ảnh hưởng của mỗi đỉnh dựa trên khả năng kết nối của nó, do đó ngăn chặn các đỉnh có bậc cao hơn chi phối một cách không cân xứng các biểu diễn đặc trưng. Sau đó lan truyền $\tilde{\mathbf{U}}, \tilde{\mathbf{I}}$ qua:

$$\tilde{\mathbf{U}} = (\mathbf{S}^U)^{L_u} \tilde{\mathbf{U}}, \quad \tilde{\mathbf{I}} = (\mathbf{S}^I)^{L_i} \tilde{\mathbf{I}}, \quad (10)$$

trong đó L_u và L_i lần lượt là số lớp của đồ thị người dùng-người dùng và đồ thị mục-mục. Hai biểu diễn này có thể được sử dụng tùy chọn để nâng cao biểu diễn người dùng và mục bằng $\tilde{\mathbf{U}} = \hat{\mathbf{U}} + \tilde{\mathbf{U}}$ và $\tilde{\mathbf{I}} = \hat{\mathbf{I}} + \tilde{\mathbf{I}}$.

Để đơn giản hóa, chúng tôi xác định bộ mã hóa dựa trên Đồ thị tổng hợp bao gồm các đồ thị tùy chọn người dùng-người dùng và mục-mục là:

$$\tilde{\mathbf{U}}, \tilde{\mathbf{I}} = \text{C-GCN}(\mathbf{U}, \mathbf{I}) \quad (11)$$

Xấp xỉ của ma trận đánh giá $\mathbf{R}$ cho MRS có thể được biểu diễn như sau:

$$\mathbf{R} \approx \hat{\mathbf{R}} = \tilde{\mathbf{U}} \tilde{\mathbf{I}}^T, \quad \tilde{\mathbf{U}}, \tilde{\mathbf{I}} = \text{C-GCN}(\mathbf{U}, \mathbf{I}). \quad (12)$$

Hàm mất mát có thể được định nghĩa như Eq 1. Giống như các bộ mã hóa dựa trên MF, các bộ mã hóa dựa trên Đồ thị cũng có thể được phân loại thành một bộ mã hóa dựa trên Đồ thị hợp nhất và nhiều bộ mã hóa dựa trên Đồ thị với các chiến lược dung hợp khác nhau, được nêu chi tiết trong Phần V. Nói chung, xấp xỉ của ma trận đánh giá $\mathbf{R}$ cho MRS có thể được biểu diễn như sau:

$$\mathbf{R} \approx \hat{\mathbf{R}} = \tilde{\mathbf{U}} \tilde{\mathbf{I}}^T, \quad \tilde{\mathbf{U}}, \tilde{\mathbf{I}} = \text{C-GCN}(\mathbf{U}, \text{Aggr}(\mathbf{I}_m)), \quad (13)$$

$$\mathbf{R} \approx \hat{\mathbf{R}} = \text{Aggr}(\tilde{\mathbf{U}} \tilde{\mathbf{I}}_m^T), \quad \tilde{\mathbf{U}}, \tilde{\mathbf{I}}_m = \text{C-GCN}(\mathbf{U}, \mathbf{I}_m). \quad (14)$$

Hàm mất mát có thể được định nghĩa như Eq 5.

C. Phân loại (Taxonomy)

Tiếp theo phân tích này, chúng tôi phân loại các công trình gần đây trong MRS thành các bộ mã hóa dựa trên MF và dựa trên Đồ thị, như được tóm tắt trong Hình 4. Đối với các bộ mã hóa dựa trên Đồ thị, chúng tôi phân loại các loại mối quan hệ, bao gồm quan hệ người dùng-mục (U-I), người dùng-người dùng (U-U), và mục-mục (I-I).

Bộ mã hóa dựa trên MF: VBPR [29] tích hợp các đặc trưng hình ảnh được trích xuất bởi một mô hình CNN sâu đã được huấn luyện trước vào MF để tăng cường khả năng dự đoán sở thích. VMCF [30] xây dựng một mạng lưới mức độ gắn kết sản phẩm kết hợp sự xuất hiện trực quan và các mối quan hệ giữa các mục. ACF [31] giới thiệu các cơ chế chú ý ở cấp độ mục và cấp độ thành phần để xử lý tốt hơn các phản hồi ẩn, đánh dấu lần đầu tiên ứng dụng cơ chế chú ý trong Lọc Cộng tác (CF). JRL [32] và bản mở rộng của nó, eJRL, sử dụng máy học đa góc nhìn (multi-view machine learning) để kết hợp các nguồn thông tin đa dạng, cải thiện các đề xuất top-N mà không cần huấn luyện lại đối với dữ liệu mới. DVBPR [33] và UVCAN [36] nâng cao các đề xuất bằng cách tương ứng tích hợp các tín hiệu hình ảnh và sử dụng các cơ chế đồng chú ý (co-attention). MAML [37] và ADDVAE [48] tập trung vào việc mô hình hóa các sở thích của người dùng bằng cách sử dụng các đầu vào văn bản và hình ảnh được nối lại thông qua các mạng nơ-ron, với ADDVAE cũng khám phá các biểu diễn được gỡ rối (disentangled representations). AMR [38] giải quyết các lỗ hổng trong MRS bằng cách sử




Fig. 4. Phân loại các Bộ mã hóa.

dụng học đối kháng (adversarial learning) để tạo ra các mô hình mạnh mẽ hơn. IMRec căn chỉnh các quá trình đề xuất với thói quen đọc của người dùng bằng cách tập trung vào các chi tiết tin tức cục bộ. EliMRec [49] và DMRL [55] tương ứng sử dụng suy luận nhân quả (causal inference) và các biểu diễn được gỡ rối để giảm thiểu các định kiến (biases) và nắm bắt tốt hơn các yếu tố phương thức độc lập.

Bộ mã hóa dựa trên Đồ thị: GraphCAR [34] kết hợp nội dung đa phương tiện với phương pháp CF truyền thống. MMGCN [13] sử dụng các GCN để học các biểu diễn cho từng phương thức, sau đó được dung hợp với các nhúng ID để tạo thành các biểu diễn mục cuối cùng. Xây dựng trên khung MMGCN, MGAT [39] sử dụng phương pháp tổng hợp GCN tiêu chuẩn và phương pháp dung hợp tương tự để kết hợp các kết quả. GRN [40] tinh chỉnh các đồ thị tương tác người dùng-mục bằng cách xác định và cắt bỏ các cạnh nhiễu. MKGAT [41] xây dựng một đồ thị tri thức đa phương thức bằng phương pháp dựa trên thực thể, sử dụng các bộ mã hóa chuyên biệt cho các loại dữ liệu khác nhau và một lớp chú ý để tổng hợp thông tin hiệu quả từ các thực thể láng giềng. PMGT [43] là một mô hình được huấn luyện trước sử dụng các đặc trưng đa phương thức được dung hợp và các tương tác, sử dụng cơ chế chú ý để tạo ra các nhúng đa phương thức. Những nhúng này sau đó được tăng cường bằng các nhúng dựa trên vị trí và vai trò để khởi tạo các nhúng nút cho giai đoạn huấn luyện trước và các tác vụ hạ nguồn tiếp theo. DualGNN [14] giới thiệu một đồ thị người dùng-người dùng để khám phá các mẫu sở thích ẩn giữa những người dùng. LATTICE [15] phát triển một đồ thị mục-mục để phát hiện các tín hiệu có tương quan về mặt ngữ nghĩa giữa các mục. HHFAN [44] phát triển một đồ thị không đồng nhất (heterogeneous graph) kết hợp thông tin người dùng, mục và đa phương thức, và sử dụng các bước đi ngẫu nhiên (random walks) để lấy mẫu láng giềng dựa trên loại nút. Nó sử dụng một lớp Kết nối Đầy đủ (Fully Connected - FC) để hợp nhất các véc-tơ nút khác nhau vào một không gian duy nhất và sử dụng LSTM để tổng hợp các nhúng của cùng một loại nút trong mạng tổng hợp đặc trưng nội bộ loại. MVGAE [45] là một mô hình mạng tự mã hóa đồ thị biến phân đa phương thức (multimodal variational graph auto-encoder) sử dụng bộ mã hóa biến phân cụ thể theo phương thức để học biểu diễn nút. PAMD [46] sử dụng một

bộ mã hóa được gỡ rối để tách các đặc điểm chung và độc đáo của các đối tượng vào các biểu diễn tương ứng, và sử dụng học đối chiếu (contrastive learning) để căn chỉnh chéo phương thức của các biểu diễn này. MMGCL [47] tích hợp học tự giám sát với các phương pháp dựa trên đồ thị cho gợi ý video ngắn, nổi bật với phương pháp lấy mẫu âm (negative sampling) sáng tạo nhấn mạnh các mối quan hệ liên phương thức. EgoGCN [50] giới thiệu một phương pháp dung hợp đồ thị hiệu quả, không giới hạn ở sự truyền thông tin đồ thị đơn phương thức mà tổng hợp các thông điệp liên phương thức mang nhiều thông tin từ các nút láng giềng. InvRL [51] giải quyết các mối tương quan giả (spurious correlations) trong gợi ý đa phương tiện bằng cách học các biểu diễn mục ổn định trên các môi trường đa dạng. A2BM2GL [52] tích hợp học biểu diễn cộng tác và học biểu diễn ngữ nghĩa để mô hình hóa hiệu quả các nút và đặc trưng video. Một mô-đun chống nghẽn cổ chai (anti-bottleneck) với các cơ chế chú ý làm tăng cường khả năng biểu đạt mối quan hệ giữa các nút. Ngoài ra, một tổn thất gợi ý thích ứng (adaptive recommendation loss) tự động điều chỉnh theo sự biến đổi sở thích của người dùng, giúp cải thiện độ chính xác của gợi ý mục. HCGCN [53] mở rộng khung LATTICE bằng cách sử dụng các mất mát đồng phân cụm (co-clustering) và phân cụm mục (item-clustering) để tinh chỉnh phản hồi sở thích người dùng-mục và điều chỉnh mức độ quan trọng của phương thức. SLMRec [54] đề xuất một khung học tự giám sát cho các gợi ý đa phương thức, thiết lập một tác vụ tự phân biệt nút để bộc lộ các mẫu đa phương thức ẩn của các mục. BM3 [56] đơn giản hóa SLMRec bằng cách thay thế cơ chế lấy mẫu ví dụ âm ngẫu nhiên bằng chiến lược dropout. MMSSL [57] thiết kế một mô hình học cấu trúc tương tác nhận thức phương thức thông qua các nhiễu loạn đối kháng (adversarial perturbations), và đề xuất một phương pháp học so sánh chéo phương thức để gỡ rối các đặc trưng chung và cụ thể giữa các phương thức. BCCL [58] tích hợp một mô-đun ràng buộc định kiến (bias constraint) cho việc tăng cường dữ liệu, một mô-đun nhận thức phương thức và một mô-đun tăng cường tính thưa thớt để hợp tác tạo ra các mẫu chất lượng cao. FREEDOM [59] tinh chỉnh LATTICE bằng cách đồng bộ đồ thị mục-mục và giảm nhiễu trong đồ thị người dùng-mục. MGCN [60] làm sạch các đặc trưng phương thức bằng cách sử dụng thông tin hành vi của mục để

TABLE IV

TÓM TẮT ĐƠN GIẢN HÓA VỀ CHIẾN LƯỢC DUNG HỢP. CHÚNG TÔI THỂ HIỆN CHÚNG MỘT CÁCH ĐƠN GIẢN HÓA VỚI CHỈ HAI PHƯƠNG THỨC HÌNH ẢNH VÀ VĂN BẢN. E_v VÀ E_t LẦN LƯỢT BIỂU THỊ CÁC BIỂU DIỄN CHO PHƯƠNG THỨC HÌNH ẢNH VÀ VĂN BẢN.

Chiến lược Dung hợp	Nối (Concatenation)	Từng phần tử (Element-wise)
Heuristic	$E_v E_t$	$E_v + E_t$
Chú ý (Attentive)	$\alpha_v E_v \alpha_t E_t$	$\alpha_v E_v + \alpha_t E_t$

| biểu thị phép toán nối (concatenation). α_v và α_t biểu thị các trọng số có thể học được cho mỗi phương thức.

giảm ô nhiễm nhiễu và mô hình hóa sở thích phương thức dựa trên hành vi của người dùng. PaInvRL [61] cân bằng thích ứng các mất mát ERM (Giảm thiểu Rủi ro Thực nghiệm - Empirical Risk Minimization) và IRM (Giảm thiểu Rủi ro Bất biến - Invariant Risk Minimization) để đạt được các giải pháp tối ưu Pareto, nâng cao hiệu quả hiệu suất của mô hình bằng cách giảm thiểu các mất mát cho tính tối ưu Pareto. DRAGON [62] học các biểu diễn kép của người dùng và mục bằng cách xây dựng các đồ thị đồng nhất và không đồng nhất. LGMRec [63] tích hợp các nhúng cục bộ (nắm bắt các sắc thái tô pô cục bộ) với các nhúng toàn cục (xem xét các phụ thuộc siêu đồ thị - hypergraph). LLMRec [64] sử dụng ba chiến lược tăng cường đồ thị dựa trên LLM đơn giản nhưng hiệu quả để nâng cao hiệu suất gợi ý. PromptMM [65] tăng cường chứng cất tri thức (knowledge distillation) bằng cách gỡ rối các mối quan hệ cộng tác để cho phép chứng cất được tăng cường. MCDRec [66] tích hợp các đặc trưng nhận thức phương thức với thông tin cộng tác để cải thiện biểu diễn mục và sử dụng biểu diễn nhận thức khuếch tán (diffusion-aware) để khử nhiễu đồ thị tương tác người dùng-mục. DiffMM [67] giới thiệu một mô hình khuếch tán đồ thị nhận thức phương thức được thiết kế tốt để cải thiện việc học biểu diễn người dùng nhận thức phương thức. SOIL [68] khai thác các mục ứng cử viên từ góc độ xây dựng các đồ thị nhận thức sở thích. CKD [69] nhằm giải quyết vấn đề mất cân bằng phương thức và tận dụng tốt nhất tất cả các phương thức. MENTOR [75] tận dụng các phương thức đã được căn chỉnh đồng thời duy trì thông tin tương tác với sự căn chỉnh chéo phương thức đa cấp độ. GUME [70] đạt được hiệu suất vượt trội trong các kịch bản đuôi dài (long-tail) bằng cách kết hợp MGCN và MENTOR. POWERec [71] tận dụng prompt learning để mô hình hóa các sở thích cụ thể theo phương thức. DGVAE [72] sử dụng các GCN để mã hóa và gỡ rối các đánh giá và thông tin đa phương thức, học các biểu diễn mục từ đồ thị mục-mục và tăng cường khả năng diễn giải bằng cách chiếu dữ liệu đa phương thức sang văn bản. VMoSE [73] nâng cao tính mạnh mẽ thông qua việc lấy mẫu thích ứng và dung hợp các tín hiệu đa phương thức có nhiễu dựa trên các ước tính độ không chắc chắn. SAND [74] căn chỉnh các biểu diễn chung cho các phương thức một cách hiệu quả mà không cần lấy mẫu âm và phân tách rõ ràng các biểu diễn độc đáo cho từng phương thức để bảo tồn thông tin độc lập với phương thức.

V. DUNG HỢP ĐA PHƯƠNG THỨC (MULTIMODAL FUSION)

Dung hợp đa phương thức là một lĩnh vực nghiên cứu quan trọng trong MRS. Hiệu quả của việc tích hợp đa phương thức bị ảnh hưởng đáng kể bởi thời điểm (timing) các phương thức khác nhau được dung hợp, cũng như các chiến lược được sử

dụng để thực hiện sự dung hợp này. Do đó, việc phân tích và phân loại các công trình hiện có một cách có hệ thống dựa trên hai góc độ này: thời điểm và chiến lược, trở nên cần thiết.




Fig. 5. Minh họa về Dung hợp Đa phương thức.

A. Góc độ Thời điểm (Timing Perspective)

Đầu tiên, chúng tôi phân loại tất cả các công trình gần đây trong MRS từ góc độ thời điểm. Cụ thể, nó có thể được chia thành các chiến lược **Dung hợp sớm (Early fusion)** và **Dung hợp muộn (Late fusion)**. Về mặt hình thức,

$$\text{Dung hợp sớm: } \bar{E} = \text{Encoder}(U, \text{Aggr}(I_m)), \quad (15)$$

$$\text{Dung hợp muộn: } \bar{E} = \text{Aggr}(\text{Encoder}(U, I_m)), \quad (16)$$

trong đó chúng tôi sử dụng các khái niệm sơ bộ giống như được trình bày chi tiết trong Phần IV. Encoder biểu thị các bộ mã hóa khác nhau. Dung hợp sớm biểu thị việc dung hợp tất cả các phương thức trước khi truyền và tổng hợp thông điệp trên đồ thị. Dung hợp muộn biểu thị việc dung hợp tất cả các phương thức sau khi truyền và tổng hợp thông điệp trên đồ thị. Mặc dù cả thời điểm dung hợp sớm và muộn đều cho thấy hiệu suất đáng khen ngợi trong các kịch bản khác nhau, mỗi cách tiếp cận lại bộc lộ những hạn chế riêng biệt. Cụ thể, dung hợp sớm có xu hướng tích hợp các phương thức ở giai đoạn đầu, điều này có thể dẫn đến việc các đặc trưng riêng của từng phương thức không được khai thác đầy đủ do việc tích hợp quá sớm. Mặt khác, chiến lược dung hợp muộn, kết

hợp các phương thức ở giai đoạn sau, đối mặt với những thách thức trong việc nắm bắt và tận dụng đầy đủ các mối tương quan giữa các phương thức khác nhau. Nó có thể hạn chế khả năng của mô hình trong việc trích xuất mối tương quan giữa các phương thức khác nhau, có khả năng làm giảm hiệu quả tổng thể của việc tận dụng thông tin đa phương thức.

B. Góc độ Chiến lược (Strategy Perspective)

Từ góc độ chiến lược, tất cả các công trình gần đây có thể được phân loại chi tiết theo hai khía cạnh, **Từng phần tử hoặc Nối (Element-wise or Concatenation)** và **Chú ý hoặc Heuristic (Attentive or Heuristic)**. Nhiều công trình trong MRS đã giới thiệu những điều chỉnh tinh tế đối với chiến lược dung hợp. Bất chấp những biến thể này, việc phân loại các cách tiếp cận này một cách tổng quát dựa trên các động lực cơ bản thúc đẩy việc sử dụng chúng thường là khả thi, như được phác họa trong Bảng IV.

Phương pháp dung hợp từng phần tử cung cấp sự tích hợp sâu sắc hơn của các phương thức khác nhau so với phương pháp nối. Tuy nhiên, sự tích hợp sâu hơn này có thể vô tình khuếch đại nhiễu vốn có trong dữ liệu của phương thức. Mặt khác, cách tiếp cận chú ý, trái ngược với các phương pháp heuristic, mang lại sự phân bố động hơn cho các trọng số của phương thức, cho phép xử lý các đặc trưng đầu vào một cách thích ứng và phản hồi nhanh hơn dựa trên mức độ liên quan của chúng với tác vụ cụ thể. Bất chấp những ưu điểm của nó, cơ chế chú ý phải chịu chi phí tính toán cao hơn đáng kể và làm tăng độ phức tạp của giai đoạn huấn luyện.

Chiến lược dung hợp thường tương tác hiệp đồng với thời điểm dung hợp, từ đó ảnh hưởng đáng kể đến hiệu suất của mô hình. Nhận thấy sự tương tác này, chúng tôi tiến hành một bản tóm tắt toàn diện về các chiến lược và thời điểm dung hợp phương thức gần đây trong MRS, như được thể hiện trong Hình 5. Mục tiêu của chúng tôi là cung cấp cho các nhà nghiên cứu một góc nhìn rõ ràng hơn về cách các khía cạnh này kết hợp để ảnh hưởng đến hiệu suất của mô hình.

C. Phân loại (Taxonomy)

Dựa trên phân tích ở trên, chúng tôi phân loại các công trình gần đây từ cả hai góc độ thời điểm dung hợp và chiến lược dung hợp, như được tóm tắt trong Hình 6. Hơn nữa, chúng tôi cung cấp một phân tích cụ thể về tất cả các công trình MRS gần đây từ góc độ thời điểm dung hợp.

Dung hợp Sớm (Early Fusion): VBPR [29] và GraphCAR [34] trực tiếp sử dụng các đặc trưng hình ảnh trong các khung MF. Là một phần mở rộng của cách tiếp cận này, VMCF [30] giới thiệu kỹ thuật đồng phân tích ma trận hình ảnh. DVBPR [33] tận dụng một mạng nơ-ron sâu hơn để nâng cao biểu diễn của dữ liệu hình ảnh. Các cơ chế chú ý ngày càng được áp dụng để phân bổ trọng số động trên các phương thức khác nhau. Các công trình như ACF [31], VECF [35], UVCAN [36], MAML [37], GRCN [40], IMRec [42], PMGT [43], BCCL [58], và MCDRec [66] sử dụng các cơ chế chú ý để phân bổ trọng số một cách hiệu quả cho các phương thức khác nhau. MKGAT [41] xây dựng một đồ thị tri thức đa phương thức dung hợp các đặc trưng phương thức để nâng cao các hệ thống gợi ý. Gần đây hơn, LATTICE [15] khai thác các đặc trưng thô để




Fig. 6. Phân loại Dung hợp Đa phương thức. Ký hiệu ngôi sao năm cánh và hình tròn lần lượt biểu thị dung hợp sớm và dung hợp muộn.

xây dựng các đồ thị mục-mục cho mỗi phương thức và kết hợp các trọng số một cách động bằng cơ chế chú ý để tạo thành các đồ thị cụ thể theo phương thức. Ngoài ra, HCGCN [53] sử dụng đồ thị mục-mục đa phương thức để tăng cường đồ thị người dùng-mục, cho phép khám phá sở thích của người dùng trong các mục tương tự và tạo điều kiện phân cụm đồng thời.

Dung hợp Muộn (Late Fusion): Các mô hình như JRL [32], MMGCN [13], DualGNN [14], MMGCL [47], EgoGCN [50], FREEDOM [59], MGCN [60], DRAGON [62], LGMRec [63], DiffMM [67], SOIL [68], và POWERec [71] đầu tiên xử lý độc lập các phương thức khác nhau và sau đó kết hợp chúng một cách hiệu quả để tăng cường độ chính xác của dự đoán. Hơn nữa, HHFAN [44] sử dụng các mạng nơ-ron nhận thức tự chú ý (self-attention-aware) để tích hợp thông tin từ tất cả các phương thức, tăng cường khả năng của mô hình trong việc tập trung vào các đặc trưng cung cấp nhiều thông tin hơn. Các cơ chế chú ý được áp dụng trong PAMD [46], A2BM2GL [52], và LLMRec [64], giúp điều chỉnh động mức độ ảnh hưởng của từng phương thức đến dự đoán cuối cùng, cung cấp một chiến lược dung hợp linh hoạt và nhạy bén với ngữ cảnh. Tương tự, MVGAE [45] sử dụng một khung tích của các chuyên gia (product-of-experts) để hài hòa các phân phối cụ thể theo phương thức, đảm bảo sự dung hợp hiệu quả của các đầu vào phương thức. Thêm vào đó, một số phương pháp tập trung vào việc tận dụng các tác vụ căn chỉnh phương thức phụ trợ để tích hợp các phương thức tốt hơn. ADDVAE [48], MMSSL [57], PromptMM [65], GUME [70], DGVAE [72], SAND [74], VMOSE [73], và MENTOR [75] đều kết hợp các tác vụ phụ trợ để hỗ trợ dung hợp phương thức. Ngoài ra, EIMRec [49] tích hợp các phương thức từ góc độ nhân quả (causal perspective), và CKD [69] áp dụng chiến lược Hiệu ứng Điều trị Trung bình (Average Treatment Effect - ATE) để dung hợp phương thức, nhằm đánh giá hiệu quả tác động của




Fig. 7. Minh họa về các Hàm Mất mát.

từng phương thức đến kết quả gợi ý. SMORE [76] chiếu các đặc trưng đa phương thức vào miền tần số và tận dụng không gian phổ cho quá trình dung hợp.

Vì mục tiêu của mỗi chiến lược dung hợp tương đối cố định, chúng tôi sẽ không đi sâu vào chi tiết từ góc độ của chiến lược dung hợp.

VI. HÀM MẤT MẤT (LOSS FUNCTION)

MRS sử dụng các hàm mất mát bao gồm hai loại chính: các tác vụ chính và tác vụ phụ trợ, như được thể hiện trong Hình 7. Các tác vụ chính liên quan đến học có giám sát, trong đó các nhãn được xác định rõ ràng hướng dẫn quá trình học của mô hình, đảm bảo dự đoán chính xác từ dữ liệu được gán nhãn. Ngược lại, các tác vụ phụ trợ sử dụng học tự giám sát (self-supervised learning - SSL) [24], tạo ra các tín hiệu giám sát từ cấu trúc vốn có của dữ liệu, độc lập với các nhãn bên ngoài. Phương pháp này cho phép sử dụng hiệu quả dữ liệu chưa được gán nhãn, cho phép hệ thống trích xuất các biểu diễn có ý nghĩa và duy trì độ chính xác, ngay cả khi dữ liệu được gán nhãn bị thưa thớt. Chúng tôi giới thiệu chi tiết hai loại hàm mất mát này.

A. Học có Giám sát (Supervised Learning)

Sơ bộ (Preliminary): Trong kịch bản RS, chúng tôi định nghĩa đơn giản mô hình gợi ý là $f(\cdot)$, nó có thể dự đoán điểm số giữa người dùng u và mục i bằng:

$$y_{u,i} = f(\mathbf{R}, u, i), \quad (17)$$

trong đó $\mathbf{R} = [r_{u,i}]^{|U| \times |I|}$ đại diện cho ma trận tương tác người dùng-mục. Trong kịch bản MRS, mô hình gợi ý đa phương thức sẽ được mở rộng thành $f_m(\cdot)$, nó có thể dự đoán điểm số giữa người dùng u và mục i với thông tin đa phương thức bằng:

$$y_{u,i} = f_m(\mathbf{R}, u, i, \mathbf{M}), \quad (18)$$

trong đó $\mathbf{M}$ kết hợp các thuộc tính mục bên ngoài với các phương thức khác nhau.

Tác vụ học có giám sát là ép điểm số dự đoán giữa bất kỳ người dùng u và mục i nào gần hơn với nhãn thực tế (ground

label). Nó có thể được chia thành **Mất mát Điểm (Pointwise Loss)** và **Mất mát Cặp (Pairwise Loss)**.

Đối với Mất mát Điểm, chúng tôi giới thiệu hai hàm mất mát phổ biến cũng được sử dụng rộng rãi trong nhiều tác vụ hạ nguồn của học máy, chẳng hạn như Thị giác Máy tính và Xử lý Ngôn ngữ Tự nhiên. 1) Sai số Toàn phương Trung bình (Mean Squared Error - MSE) [25] và 2) Mất mát Entropy Chéo (Cross-Entropy Loss - CE) [26].

MSE có thể được định nghĩa là:

$$\frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} (r_{u,i} - y_{u,i})^2, \quad (19)$$

trong đó $\mathcal{D}$ biểu thị tập huấn luyện. Hàm mất mát này kéo điểm số dự đoán cho các cặp người dùng-mục có tương tác xấp xỉ về 1 hơn, và các cặp người dùng-mục không có tương tác xấp xỉ về 0 hơn.

CE có thể được định nghĩa là:

$$-\frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} [r_{u,i} \log(y_{u,i}) + (1 - r_{u,i}) \log(1 - y_{u,i})]. \quad (20)$$

Việc sử dụng CE trong các lĩnh vực RS (MRS) coi hàm dự đoán như một tác vụ phân loại hai lớp, phân loại các cặp người dùng-mục thành các danh mục có tương tác và không có tương tác. Điều này cải thiện độ chính xác của phân loại bằng cách giảm thiểu sự khác biệt giữa phân phối xác suất dự đoán và phân phối nhãn thực tế, cho phép mô hình học tốt hơn phân phối xác suất của các nhãn được phân loại. Tuy nhiên, do tính thưa thớt tự nhiên của dữ liệu tương tác người dùng-mục, chúng ta cần coi trọng dữ liệu có nhãn khan hiếm hơn, và do đó đề xuất thêm Mất mát Cặp (Pairwise Loss).

Đối với Mất mát Cặp, mục tiêu học là kéo các cặp dương (positive pairs) lại gần nhau hơn, trong khi đẩy các cặp âm (negative pairs) ra xa. Chúng tôi giới thiệu hai hàm mất mát phổ biến cũng là những hàm mất mát được sử dụng rộng rãi. 1) Xếp hạng Cá nhân hóa Bayesian (Bayesian Personalized Ranking - BPR) [27] và 2) Mất mát Bản lề (Hinge Loss) [28].

BPR có thể được định nghĩa là:

$$\sum_{(u,i^+,i^-) \in \mathcal{D}} -\log(\sigma(y_{u,i^+} - y_{u,i^-})), \quad (21)$$

trong đó y_{u,i^+} và y_{u,i^-} là điểm đánh giá của người dùng u đối với mục dương i^+ và mục âm i^- . σ là hàm kích hoạt.

Hinge Loss có thể được định nghĩa là:

$$\max(0, 1 - r_{u,i} \cdot y_{u,i}). \quad (22)$$

Hinge nhằm mục đích không chỉ phân loại chính xác các điểm dữ liệu, mà còn tối đa hóa khoảng cách của các biên quyết định phân loại.

B. Học Tự giám sát (Self-supervised Learning)

Sơ bộ (Preliminary): Trong kịch bản RS, học tự giám sát đầu tiên tạo ra hai góc nhìn (views) khác nhau cho học đối chiều (contrastive learning), chúng tôi định nghĩa đơn giản bộ tạo góc nhìn (view creator) này là:

$$w = \mathcal{C}(\mathbf{R}, \mathbf{E}), \quad (23)$$

trong đó $\mathcal{C}(\cdot)$ là một bộ tạo góc nhìn. $\mathbf{R}$ và $\mathbf{E}$ sử dụng cùng định nghĩa như Phần IV. Trong kịch bản MRS, bộ tạo góc nhìn có thể được định nghĩa thêm là:

$$w = \mathcal{C}(\mathbf{R}, \mathbf{E}, \mathbf{M}). \quad (24)$$

Bộ tạo góc nhìn có thể được chia thành hai loại: 1) **SSL dựa trên Đặc trưng (Feature-based SSL)** và 2) **SSL dựa trên Cấu trúc (Structure-based SSL)**.

SSL dựa trên Đặc trưng được thiết kế để tạo ra nhiều góc nhìn của cùng một cá thể dữ liệu bằng cách làm nhiễu loạn (perturbing) các đặc trưng. Cách tiếp cận này được sử dụng một cách có chiến lược để nâng cao tính mạnh mẽ của các biểu diễn được học. Bằng cách đưa ra các biến thể trong các đặc trưng đầu vào, mô hình bị buộc phải tập trung vào các khía cạnh bất biến trên các sửa đổi này, từ đó có được sự hiểu biết sâu sắc hơn, khái quát hơn về tương tác người dùng-mục. Nó có thể được biểu diễn đơn giản là:

$$\omega = \mathcal{C}_{feature}(\mathbf{R}, \mathbf{E}, \mathbf{M}) = (\mathbf{R}, \text{Perturb}(\mathbf{E}), \mathbf{M}), \quad (25)$$

trong đó $\text{Perturb}(\cdot)$ có thể là một MLP, loại bỏ đặc trưng (feature dropout), thêm nhiễu ngẫu nhiên, v.v. Đáng chú ý là các phương thức khác nhau có thể được coi một cách tự nhiên là hai góc nhìn dựa trên đặc trưng. Việc áp dụng SSL dựa trên đặc trưng cho biểu diễn của hai phương thức khác nhau có thể được xem như là sự căn chỉnh phương thức (modality alignments) [75].

SSL dựa trên Cấu trúc được thiết kế để tạo ra nhiều góc nhìn của cùng một cá thể dữ liệu bằng cách làm nhiễu loạn các cấu trúc đồ thị. Cách tiếp cận này được sử dụng để nắm bắt một cách tinh vi các phụ thuộc và tương tác phức tạp vốn có trong các cấu trúc đồ thị, vốn đóng vai trò then chốt trong việc nâng cao tính mạnh mẽ và hiệu suất của các mô hình học dựa trên đồ thị. Những thao tác như vậy cho phép các thuật toán học phân biệt và khái quát hóa từ các đặc trưng cốt yếu của dữ liệu, có khả năng dẫn đến các biểu diễn hiệu quả và sâu sắc hơn trong các miền mà dữ liệu dựa trên đồ thị là phổ biến. Nó có thể được biểu diễn đơn giản là:

$$\omega = \mathcal{C}_{structure}(\mathbf{R}, \mathbf{E}, \mathbf{M}) = (\text{Perturb}(\mathbf{R}), \mathbf{E}, \mathbf{M}), \quad (26)$$

trong đó $\text{Perturb}(\cdot)$ có thể là một MLP, loại bỏ nút/cạnh (node/edge dropout), thêm nhiễu ngẫu nhiên, v.v.

Tác vụ học tự giám sát là ép các góc nhìn được tạo ra gần nhau hơn để tăng cường khả năng biểu diễn của mô hình MRS. Chúng tôi giới thiệu hai hàm mất mát tự giám sát được sử dụng rộng rãi. 1) InfoNCE [87] và 2) Phân kỳ Jensen-Shannon (JS divergence) [88].

InfoNCE là một biến thể của Ước lượng Đối chiếu Nhiễu (Noise Contrastive Estimation) [89], đã được áp dụng rộng rãi như một hàm mất mát học tự giám sát trong RS. Nó có thể được biểu diễn là:

$$\mathbb{E}[-\log \frac{\exp(f(\omega'_i, \omega''_i))}{\sum_{j \neq i} \exp(f(\omega'_i, \omega''_j))}], \quad (27)$$

trong đó $f(\cdot)$ đại diện cho một hàm đánh giá (critic function) tính toán một điểm số chỉ ra mức độ tương đồng giữa hai góc nhìn. Số hạng $\exp f(\omega'_i, \omega''_i)$ tương ứng với điểm số của các cặp dương, trong khi số hạng $\sum \exp(f(\omega'_i, \omega''_j))$ bao gồm cả tử số và điểm số của tất cả các cặp âm.

Ngoài việc sử dụng ước lượng InfoNCE cho thông tin tương hỗ, giới hạn dưới cũng có thể được ước lượng bằng cách sử dụng phân kỳ Jensen-Shannon (JS). Mục tiêu học được dẫn xuất tương tự như việc kết hợp InfoNCE với một hàm mất mát entropy chéo nhị phân tiêu chuẩn [90], áp dụng cho các cặp dương và các cặp âm.

$$\mathbb{E}[-\log \sigma(f(\omega'_i, \omega''_i))] - \mathbb{E}[\log(1 - \sigma(f(\omega'_i, \omega''_j)))], \quad (28)$$

trong đó σ đại diện cho hàm sigmoid được sử dụng để chuẩn hóa đầu ra của hàm đánh giá. Ý tưởng chính đằng sau quá trình tối ưu hóa này là gán nhãn 1 cho các cặp dương và 0 cho các cặp âm, từ đó tăng giá trị dự đoán cho các cặp dương và tăng cường sự tương đồng giữa chúng.

C. Phân loại (Taxonomy)

Để cung cấp cho các nhà nghiên cứu một khung tham chiếu rõ ràng hơn trong việc lựa chọn hàm mất mát hiệu quả nhất cho công trình của họ, chúng tôi đã phân loại một cách có hệ thống các công trình gần đây, như Hình 8. Hầu hết các phương pháp MRS hiện tại tận dụng hàm mất mát cặp (pairwise loss), chỉ có VMCF [30], VECF [35], UVCAN [36], IMRec [42], PMGT [43], ADDVAE [48], A2BM2GL [52], BM3 [56], BCCL [58], DGVAE [72], và VMoSE [73] áp dụng hàm mất mát điểm (pointwise loss). Hơn nữa, chúng tôi cung cấp một phân tích cụ thể cho học tự giám sát của tất cả các công trình MRS gần đây.

SSL dựa trên Đặc trưng (Feature-based SSL): PAMD [46] sử dụng các tín hiệu tự giám sát để hỗ trợ học biểu diễn được gỡ rối (disentangled representation) từ cấp độ đặc trưng. A2BM2GL [52] đề xuất căn chỉnh các yếu tố được gỡ rối học được từ các đánh giá và nội dung văn bản dựa trên cơ chế chuẩn hóa và loại bỏ sự chú ý theo thành phần (compositional de-attention mechanism). BCCL [58] tiếp tục giới thiệu một phương pháp tăng cường dữ liệu bị ràng buộc bởi định kiến để đảm bảo chất lượng của các mẫu tăng cường trong học đối chiều. MGCN [60], LGMRec [63], SOIL [68], GUME [70] sử dụng học đối chiều từ cấp độ đặc trưng để cải thiện chất lượng biểu diễn. PromptMM [65] giới thiệu một mô-đun prompt có thể học được giúp thu hẹp khoảng cách ngữ nghĩa một cách động giữa việc mã hóa ngữ cảnh đa phương thức trong mô




Fig. 8. Phân loại các Hàm Mất mát.

hình giáo viên (teacher model) và mô hình hóa quan hệ cộng tác trong mô hình học sinh (student model). MCDRec [66], DiffMM [67], DGVAE [72], và VMoSE [73] tối ưu hóa phân kỳ KL để buộc phân phối hậu nghiệm (posterior distribution) gần hơn với phân phối tiên nghiệm (prior distribution). SAND [74] sử dụng các tín hiệu tự giám sát để phân biệt các biểu diễn độc đáo theo phương thức (modal-unique) và chung cho các phương thức (modal-generic).

SSL dựa trên Cấu trúc (Structure-based SSL): MMGCL [47] sử dụng che dấu phương thức (modality masking) và loại bỏ cạnh phương thức (modality edge dropout) để tăng cường tính nhất quán phương thức của các biểu diễn thông qua tự giám sát từ góc độ cấu trúc. A2BM2GL [52] sử dụng cơ chế chú ý để học động các trọng số quan trọng của các nút láng giềng trong phạm vi ngắn và phạm vi dài để cùng thu được các biểu diễn có sức biểu đạt cao hơn. HCGCN [53] sử dụng tổn thất đối chiếu (contrastive loss) từ góc độ cấu trúc để điều phối các đặc trưng đa phương thức. SLMRec [54] sử dụng học đối chiếu từ nhiều góc độ cấu trúc chung khác nhau để cải thiện chất lượng biểu diễn.

SSL Hỗn hợp (Mixed SSL): BM3 [56] sử dụng nhiều tín hiệu tự giám sát chung ở cấp độ đặc trưng và cấp độ cấu trúc để tăng cường biểu diễn. MMSSL [57] và MENTOR [75] căn chỉnh các biểu diễn phương thức khác nhau ở cấp độ đặc trưng và tăng cường các biểu diễn bằng cách sử dụng học đối chiếu chung từ góc độ đặc trưng.

VII. HƯỚNG ĐI TƯƠNG LAI (FUTURE DIRECTION)

Trong phần này, chúng tôi khám phá các hướng đi tương lai tiềm năng cho lĩnh vực MRS. Mục tiêu của chúng tôi là kích thích và thúc đẩy hơn nữa việc nghiên cứu, phát triển và đổi mới trong miền đang tiến hóa nhanh chóng này. Bằng cách xác định và thảo luận về các xu hướng mới nổi và các thách thức chưa được giải quyết, chúng tôi hy vọng sẽ truyền cảm hứng cho việc nghiên cứu học thuật và tiến bộ công nghệ liên tục, qua đó thúc đẩy làn sóng đột phá tiếp theo trong MRS.

A. Hướng tới Mô hình MRS Hợp nhất (Towards Unified MRS Model)

Các mô hình hiện tại trong lĩnh vực MRS thường tách biệt việc trích xuất đặc trưng và mã hóa biểu diễn thành hai quá trình riêng biệt. Quá trình đầu thường tận dụng các mô hình

đã được huấn luyện trước hiện có, trong khi quá trình sau nhận được sự chú ý tập trung hơn. Tuy nhiên, quy trình tách biệt này dẫn đến nhiều đa phương thức vốn có, tạo ra sự mất kết nối giữa các đặc trưng được trích xuất và việc mã hóa tiếp theo của chúng. Do đó, có một nhu cầu cấp thiết đối với một mô hình hợp nhất (unified model) tích hợp các quá trình này một cách gắn kết hơn. Một mô hình hợp nhất như vậy sẽ nâng cao mức độ liên quan và tính hiệu quả của dữ liệu đa phương thức, do đó cải thiện độ chính xác tổng thể của các hệ thống gợi ý trong việc tận dụng thông tin đa phương thức phức tạp.

B. Giải quyết Bài toán Khởi động lạnh (Resolves Cold-start Problem)

Các mô hình RS hiện tại thường hoạt động dưới giả định về một số lượng người dùng và mục cố định trong giai đoạn huấn luyện, điều này đặt ra những thách thức khi thích ứng với dòng dữ liệu mới liên tục đổ vào. Trong các bối cảnh thực tế, các mô hình này được triển khai trong các môi trường động, nơi các tương tác người dùng-mục mới, cũng như người dùng và mục mới, thường xuyên được giới thiệu — một hiện tượng thường được gọi là bài toán khởi động lạnh (cold-start problem). Để giải quyết vấn đề này, việc tận dụng thông tin đa phương thức trong các kịch bản khởi động lạnh là rất hữu ích. Việc tích hợp các phương thức dữ liệu đa dạng — chẳng hạn như mô tả văn bản, hình ảnh, và siêu dữ liệu (metadata) liên kết với người dùng và mục — có thể nâng cao đáng kể khả năng của mô hình trong việc hiểu và dự đoán hiệu quả sở thích của người dùng mới và thuộc tính của các mục mới. Bằng cách khai thác thông tin đa phương thức, các mô hình RS có thể tạo ra các gợi ý chính xác và đáng tin cậy hơn ngay cả khi phải đối mặt với dữ liệu tương tác hạn chế, qua đó cải thiện khả năng thích ứng và hiệu suất của chúng trong các môi trường đang tiến hóa động.

C. Hướng tới Sự Đa dạng Phong phú hơn của các Phương thức (Towards Richer Variety of Modalities)

Các mô hình MRS hiện tại thể hiện hiệu quả đáng kể trong việc sử dụng các phương thức văn bản và hình ảnh. Tuy nhiên, sự phong phú ngày càng tăng của thông tin có sẵn trên Internet mang đến những cơ hội để tận dụng một loạt các phương thức rộng lớn hơn. Sự mở rộng này bao gồm dữ liệu âm thanh, khứu giác và động học (kinesthetic), cùng những dữ liệu khác, có

thể làm phong phú thêm khả năng hiểu và cá nhân hóa của các mô hình RS.

Để đáp ứng với bối cảnh đang tiến hóa này, có một nhu cầu cấp thiết về các mô hình MRS có thể tích hợp và tổng hợp hiệu quả thông tin từ các nguồn dữ liệu đa dạng này. Bằng cách khai thác một mảng thông tin phương thức rộng hơn, các mô hình MRS có thể đạt được sự hiểu biết toàn diện hơn về sở thích của người dùng và đặc điểm của mục. Cách tiếp cận toàn diện này không chỉ nâng cao độ chính xác và mức độ liên quan của các gợi ý mà còn cải thiện đáng kể sự tương tác và sự hài lòng của người dùng bằng cách phục vụ cho các sở thích cảm giác và phong cách tương tác đa dạng. Do đó, việc phát triển các mô hình MRS có khả năng xử lý và tích hợp hiệu quả nhiều phương thức là rất quan trọng để thúc đẩy sự phát triển của công nghệ tiên tiến trong RS.

VIII. KẾT LUẬN

Mục tiêu chính của khảo sát này là kiểm tra kỹ lưỡng những tiến bộ gần đây trong MRS và cung cấp một phân tích kỹ thuật về các mô hình khác nhau. Cuộc thảo luận của chúng tôi phân loại các mô hình MRS hiện có thành bốn khía cạnh quan trọng: Trích xuất Đặc trưng (Feature Extraction), Bộ mã hóa (Encoder), Dung hợp Đa phương thức (Multimodal Fusion), và Hàm Mất mát (Loss Function). Hơn nữa, chúng tôi đánh giá các đóng góp kỹ thuật của các công trình hiện tại và khám phá các con đường tiềm năng trong tương lai để thúc đẩy và tinh chỉnh các công nghệ MRS. Những đóng góp của chúng tôi vượt ra ngoài việc chỉ tóm tắt đơn thuần. Chúng tôi đã tinh chỉnh sự phân loại công nghệ và đề xuất các hướng đi tiềm năng cho nghiên cứu trong tương lai. Bài khảo sát này đóng vai trò như một nguồn tài nguyên quý giá cho các nhà nghiên cứu trong lĩnh vực, cung cấp những hiểu biết sâu sắc và sự hướng dẫn về bối cảnh đang tiến hóa của các hệ thống gợi ý đa phương tiện.

REFERENCES

- [1] Y. Deldjoo, M. Schedl, and P. Knees, "Content-driven music recommendation: Evolution, state of the art, and challenges," *arXiv preprint arXiv:2107.11803*, 2021.
- [2] Y. Deldjoo, F. Nazary, A. Ramisa, J. McAuley, G. Pellegrini, A. Bellogin, and T. Di Noia, "A review of modern fashion recommender systems," *arXiv preprint arXiv:2202.02757*, 2022.
- [3] J. Xu, Z. Chen, J. Li, S. Yang, W. Wang, X. Hu, and E. C.-H. Ngai, "Fourierkan-gcf: Fourier kolmogorov-arnold network—an effective and efficient feature transformation for graph collaborative filtering," *arXiv preprint arXiv:2406.01034*, 2024.
- [4] J. Xu, Z. Chen, J. Li, S. Yang, H. Wang, and E. C. Ngai, "Aligngroup: Learning and aligning group consensus with member preferences for group recommendation," in *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management*, 2024, pp. 2682–2691.
- [5] Q. Liu, J. Hu, Y. Xiao, J. Gao, and X. Zhao, "Multimodal recommender systems: A survey," *arXiv preprint arXiv:2302.03883*, 2023.
- [6] S. Zhang, L. Yao, A. Sun, and Y. Tay, "Deep learning based recommender system: A survey and new perspectives," pp. 1–38, 2019.
- [7] Q. Guo, F. Zhuang, C. Qin, H. Zhu, X. Xie, H. Xiong, and Q. He, "A survey on knowledge graph-based recommender systems," *IEEE Transactions on Knowledge and Data Engineering*, vol. 34, no. 8, pp. 3549–3568, 2020.
- [8] Y. Deldjoo, M. Schedl, P. Cremonesi, and G. Pasi, "Recommender systems leveraging multimedia content," *ACM Computing Surveys (CSUR)*, vol. 53, no. 5, pp. 1–38, 2020.
- [9] D. Jannach, A. Manzoor, W. Cai, and L. Chen, "A survey on conversational recommender systems," *ACM Computing Surveys (CSUR)*, vol. 54, no. 5, pp. 1–36, 2021.
- [10] S. Wu, F. Sun, W. Zhang, X. Xie, and B. Cui, "Graph neural networks in recommender systems: a survey," *ACM Computing Surveys*, vol. 55, no. 5, pp. 1–37, 2022.
- [11] X. Meng, H. Huo, X. Zhang, W. Wang, and J. Zhu, "A survey of personalized news recommendation," *Data Science and Engineering*, pp. 1–21, 2023.
- [12] H. Zhou, X. Zhou, Z. Zeng, L. Zhang, and Z. Shen, "A comprehensive survey on multimodal recommender systems: Taxonomy, evaluation, and future directions," *arXiv preprint arXiv:2302.04473*, 2023.
- [13] Y. Wei, X. Wang, L. Nie, X. He, R. Hong, and T.-S. Chua, "Mmgcn: Multi-modal graph convolution network for personalized recommendation of micro-video," in *Proceedings of the 27th ACM international conference on multimedia*, 2019, pp. 1437–1445.
- [14] Q. Wang, Y. Wei, J. Yin, J. Wu, X. Song, and L. Nie, "Dualgnn: Dual graph neural network for multimedia recommendation," *IEEE Transactions on Multimedia*, 2021.
- [15] J. Zhang, Y. Zhu, Q. Liu, S. Wu, S. Wang, and L. Wang, "Mining latent structures for multimedia recommendation," in *Proceedings of the 29th ACM International Conference on Multimedia*, 2021, pp. 3872–3880.
- [16] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [17] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations*, 2020.
- [18] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," *arXiv preprint arXiv:1810.04805*, 2018.
- [19] N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," *arXiv preprint arXiv:1908.10084*, 2019.
- [20] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [21] K. Cho, B. Van Merriënboer, D. Bahdanau, and Y. Bengio, "On the properties of neural machine translation: Encoder-decoder approaches," *arXiv preprint arXiv:1409.1259*, 2014.
- [22] A. Mnih and R. R. Salakhutdinov, "Probabilistic matrix factorization," *Advances in neural information processing systems*, vol. 20, 2007.
- [23] F. Wu, A. Souza, T. Zhang, C. Fifty, T. Yu, and K. Weinberger, "Simplifying graph convolutional networks," in *International conference on machine learning*. PMLR, 2019, pp. 6861–6871.
- [24] X. Liu, F. Zhang, Z. Hou, L. Mian, Z. Wang, J. Zhang, and J. Tang, "Self-supervised learning: Generative or contrastive," *IEEE transactions on knowledge and data engineering*, vol. 35, no. 1, pp. 857–876, 2021.
- [25] H. Marmolin, "Subjective mse measures," *IEEE transactions on systems, man, and cybernetics*, vol. 16, no. 3, pp. 486–489, 1986.
- [26] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [27] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, "Bpr: Bayesian personalized ranking from implicit feedback," *arXiv preprint arXiv:1205.2618*, 2012.
- [28] C. Cortes and V. Vapnik, "Support-vector networks," *Machine learning*, vol. 20, pp. 273–297, 1995.
- [29] R. He and J. McAuley, "Vbpr: visual bayesian personalized ranking from implicit feedback," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 30, no. 1, 2016.
- [30] C. Park, D. Kim, J. Oh, and H. Yu, "Do" also-viewed" products help user rating prediction?" in *Proceedings of the 26th International Conference on World Wide Web*, 2017, pp. 1113–1122.
- [31] J. Chen, H. Zhang, X. He, L. Nie, W. Liu, and T.-S. Chua, "Attentive collaborative filtering: Multimedia recommendation with item-and component-level attention," in *Proceedings of the 40th International ACM SIGIR conference on Research and Development in Information Retrieval*, 2017, pp. 335–344.
- [32] Y. Zhang, Q. Ai, X. Chen, and W. B. Croft, "Joint representation learning for top-n recommendation with heterogeneous information sources," in *Proceedings of the 2017 ACM on Conference on Information and Knowledge Management*, 2017, pp. 1449–1458.
- [33] W.-C. Kang, C. Fang, Z. Wang, and J. McAuley, "Visually-aware fashion recommendation and design with generative image models," in *2017 IEEE international conference on data mining (ICDM)*. IEEE, 2017, pp. 207–216.
- [34] Q. Xu, F. Shen, L. Liu, and H. T. Shen, "Graphcar: Content-aware multimedia recommendation with graph autoencoder," in *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, 2018, pp. 981–984.

- [35] X. Chen, H. Chen, H. Xu, Y. Zhang, Y. Cao, Z. Qin, and H. Zha, "Personalized fashion recommendation with visual explanations based on multimodal attention network: Towards visually explainable recommendation," in *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2019, pp. 765–774.
- [36] S. Liu, Z. Chen, H. Liu, and X. Hu, "User-video co-attention network for personalized micro-video recommendation," in *The world wide web conference*, 2019, pp. 3020–3026.
- [37] F. Liu, Z. Cheng, C. Sun, Y. Wang, L. Nie, and M. Kankanhalli, "User diverse preference modeling by multimodal attentive metric learning," in *Proceedings of the 27th ACM international conference on multimedia*, 2019, pp. 1526–1534.
- [38] J. Tang, X. Du, X. He, F. Yuan, Q. Tian, and T.-S. Chua, "Adversarial training towards robust multimedia recommender system," *IEEE Transactions on Knowledge and Data Engineering*, vol. 32, no. 5, pp. 855–867, 2019.
- [39] Z. Tao, Y. Wei, X. Wang, X. He, X. Huang, and T.-S. Chua, "Mgat: Multimodal graph attention network for recommendation," *Information Processing & Management*, vol. 57, no. 5, p. 102277, 2020.
- [40] Y. Wei, X. Wang, L. Nie, X. He, and T.-S. Chua, "Graph-refined convolutional network for multimedia recommendation with implicit feedback," in *Proceedings of the 28th ACM international conference on multimedia*, 2020, pp. 3541–3549.
- [41] R. Sun, X. Cao, Y. Zhao, J. Wan, K. Zhou, F. Zhang, Z. Wang, and K. Zheng, "Multi-modal knowledge graphs for recommender systems," in *Proceedings of the 29th ACM international conference on information & knowledge management*, 2020, pp. 1405–1414.
- [42] J. Xun, S. Zhang, Z. Zhao, J. Zhu, Q. Zhang, J. Li, X. He, X. He, T.-S. Chua, and F. Wu, "Why do we click: visual impression-aware news recommendation," in *Proceedings of the 29th ACM International Conference on Multimedia*, 2021, pp. 3881–3890.
- [43] Y. Liu, S. Yang, C. Lei, G. Wang, H. Tang, J. Zhang, A. Sun, and C. Miao, "Pre-training graph transformer with multimodal side information for recommendation," in *Proceedings of the 29th ACM International Conference on Multimedia*, 2021, pp. 2853–2861.
- [44] D. Cai, S. Qian, Q. Fang, and C. Xu, "Heterogeneous hierarchical feature aggregation network for personalized micro-video recommendation," *IEEE Transactions on Multimedia*, vol. 24, pp. 805–818, 2021.
- [45] J. Yi and Z. Chen, "Multi-modal variational graph auto-encoder for recommendation systems," *IEEE Transactions on Multimedia*, vol. 24, pp. 1067–1079, 2021.
- [46] T. Han, P. Wang, S. Niu, and C. Li, "Modality matches modality: Pretraining modality-disentangled item representations for recommendation," in *Proceedings of the ACM Web Conference 2022*, 2022, pp. 2058–2066.
- [47] Z. Yi, X. Wang, I. Ounis, and C. Macdonald, "Multi-modal graph contrastive learning for micro-video recommendation," in *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2022, pp. 1807–1811.
- [48] N.-T. Tran and H. W. Lauw, "Aligning dual disentangled user representations from ratings and textual content," in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2022, pp. 1798–1806.
- [49] X. Liu, Z. Tao, J. Shao, L. Yang, and X. Huang, "Elimrec: Eliminating single-modal bias in multimedia recommendation," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 687–695.
- [50] F. Chen, J. Wang, Y. Wei, H.-T. Zheng, and J. Shao, "Breaking isolation: Multimodal graph fusion for multimedia recommendation by edge-wise modulation," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 385–394.
- [51] X. Du, Z. Wu, F. Feng, X. He, and J. Tang, "Invariant representation learning for multimedia recommendation," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 619–628.
- [52] D. Cai, S. Qian, Q. Fang, J. Hu, and C. Xu, "Adaptive anti-bottleneck multi-modal graph learning network for personalized micro-video recommendation," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 581–590.
- [53] Z. Mu, Y. Zhuang, J. Tan, J. Xiao, and S. Tang, "Learning hybrid behavior patterns for multimedia recommendation," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 376–384.
- [54] Z. Tao, X. Liu, Y. Xia, X. Wang, L. Yang, X. Huang, and T.-S. Chua, "Self-supervised learning for multimedia recommendation," *IEEE Transactions on Multimedia*, 2022.
- [55] F. Liu, H. Chen, Z. Cheng, A. Liu, L. Nie, and M. Kankanhalli, "Disentangled multimodal representation learning for recommendation," *IEEE Transactions on Multimedia*, 2022.
- [56] X. Zhou, H. Zhou, Y. Liu, Z. Zeng, C. Miao, P. Wang, Y. You, and F. Jiang, "Bootstrap latent representations for multi-modal recommendation," in *Proceedings of the ACM Web Conference 2023*, 2023, pp. 845–854.
- [57] W. Wei, C. Huang, L. Xia, and C. Zhang, "Multi-modal self-supervised learning for recommendation," in *Proceedings of the ACM Web Conference 2023*, 2023, pp. 790–800.
- [58] W. Yang, Z. Fang, T. Zhang, S. Wu, and C. Lu, "Modal-aware bias constrained contrastive learning for multimodal recommendation," in *Proceedings of the 31st ACM International Conference on Multimedia*, 2023, pp. 6369–6378.
- [59] X. Zhou and Z. Shen, "A tale of two graphs: Freezing and denoising graph structures for multimodal recommendation," in *Proceedings of the 31st ACM International Conference on Multimedia*, 2023, pp. 935–943.
- [60] P. Yu, Z. Tan, G. Lu, and B.-K. Bao, "Multi-view graph convolutional network for multimedia recommendation," in *Proceedings of the 31st ACM International Conference on Multimedia*, 2023, pp. 6576–6585.
- [61] S. Huang, H. Li, Q. Li, C. Zheng, and L. Liu, "Pareto invariant representation learning for multimedia recommendation," in *Proceedings of the 31st ACM International Conference on Multimedia*, 2023, pp. 6410–6419.
- [62] H. Zhou, X. Zhou, L. Zhang, and Z. Shen, "Enhancing dyadic relations with homogeneous graphs for multimodal recommendation," in *ECAI 2023*. IOS Press, 2023, pp. 3123–3130.
- [63] Z. Guo, J. Li, G. Li, C. Wang, S. Shi, and B. Ruan, "Lgmrec: Local and global graph learning for multimodal recommendation," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 8, 2024, pp. 8454–8462.
- [64] W. Wei, X. Ren, J. Tang, Q. Wang, L. Su, S. Cheng, J. Wang, D. Yin, and C. Huang, "Llmrec: Large language models with graph augmentation for recommendation," in *Proceedings of the 17th ACM International Conference on Web Search and Data Mining*, 2024, pp. 806–815.
- [65] W. Wei, J. Tang, L. Xia, Y. Jiang, and C. Huang, "Promptmm: Multi-modal knowledge distillation for recommendation with prompt-tuning," in *Proceedings of the ACM on Web Conference 2024*, 2024, pp. 3217–3228.
- [66] H. Ma, Y. Yang, L. Meng, R. Xie, and X. Meng, "Multimodal conditioned diffusion model for recommendation," in *Companion Proceedings of the ACM on Web Conference 2024*, 2024, pp. 1733–1740.
- [67] Y. Jiang, L. Xia, W. Wei, D. Luo, K. Lin, and C. Huang, "Diffmm: Multi-modal diffusion model for recommendation," in *Proceedings of the 32nd ACM International Conference on Multimedia*, 2024.
- [68] H. Su, J. Li, F. Li, K. Lu, and L. Zhu, "Soil: Contrastive second-order interest learning for multimodal recommendation," in *Proceedings of the 32nd ACM International Conference on Multimedia*, 2024.
- [69] J. Zhang, G. Liu, Q. Liu, S. Wu, and L. Wang, "Modality-balanced learning for multimedia recommendation," in *Proceedings of the 32nd ACM International Conference on Multimedia*, 2024.
- [70] G. Lin, Z. Meng, D. Wang, Q. Long, Y. Zhou, and M. Xiao, "Gume: Graphs and user modalities enhancement for long-tail multimodal recommendation," in *Proceedings of the 33th ACM international conference on information & knowledge management*, 2024.
- [71] X. Dong, X. Song, M. Tian, and L. Hu, "Prompt-based and weak-modality enhanced multimodal recommendation," *Information Fusion*, vol. 101, p. 101989, 2024.
- [72] X. Zhou and C. Miao, "Disentangled graph variational auto-encoder for multimodal recommendation with interpretability," *IEEE Transactions on Multimedia*, 2024.
- [73] J. Yi and Z. Chen, "Variational mixture of stochastic experts auto-encoder for multi-modal recommendation," *IEEE Transactions on Multimedia*, 2024.
- [74] Z. He, Z. Wang, Y. Yang, H. Bai, and L. Wu, "Boosting multimedia recommendation via separate generic and unique awareness," *arXiv preprint arXiv:2406.08270*, 2024.
- [75] J. Xu, Z. Chen, S. Yang, J. Li, H. Wang, and E. C.-H. Ngai, "Mentor: Multi-level self-supervised learning for multimodal recommendation," *arXiv preprint arXiv:2402.19407*, 2024.
- [76] R. K. Ong and A. W. Khong, "Spectrum-based modality representation fusion graph convolutional network for multimodal recommendation," *arXiv preprint arXiv:2412.14978*, 2024.
- [77] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv preprint arXiv:1409.1556*, 2014.

- [78] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 1–9.
- [79] Y. Jia, E. Shelhamer, J. Donahue, S. Karayev, J. Long, R. Girshick, S. Guadarrama, and T. Darrell, "Caffe: Convolutional architecture for fast feature embedding," in *Proceedings of the 22nd ACM international conference on Multimedia*, 2014, pp. 675–678.
- [80] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information processing & management*, vol. 24, no. 5, pp. 513–523, 1988.
- [81] Y. Koren, "The bellkor solution to the netflix grand prize," *Netflix prize documentation*, vol. 81, no. 2009, pp. 1–10, 2009.
- [82] J. Pennington, R. Socher, and C. D. Manning, "Glove: Global vectors for word representation," in *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, 2014, pp. 1532–1543.
- [83] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado, and J. Dean, "Distributed representations of words and phrases and their compositionality," *Advances in neural information processing systems*, vol. 26, 2013.
- [84] S. Arora, Y. Liang, and T. Ma, "A simple but tough-to-beat baseline for sentence embeddings," in *International conference on learning representations*, 2017.
- [85] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *International Conference on Learning Representations*, 2017.
- [86] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, "Lightgcn: Simplifying and powering graph convolution network for recommendation," in *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval*, 2020, pp. 639–648.
- [87] A. v. d. Oord, Y. Li, and O. Vinyals, "Representation learning with contrastive predictive coding," *arXiv preprint arXiv:1807.03748*, 2018.
- [88] R. D. Hjelm, A. Fedorov, S. Lavoie-Marchildon, K. Grewal, P. Bachman, A. Trischler, and Y. Bengio, "Learning deep representations by mutual information estimation and maximization," *arXiv preprint arXiv:1808.06670*, 2018.
- [89] M. Gutmann and A. Hyvärinen, "Noise-contrastive estimation: A new estimation principle for unnormalized statistical models," in *Proceedings of the thirteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings*, 2010, pp. 297–304.
- [90] X. Xia, H. Yin, J. Yu, Q. Wang, L. Cui, and X. Zhang, "Self-supervised hypergraph convolutional networks for session-based recommendation," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 35, no. 5, 2021, pp. 4503–4511.