

Paper

“latex

1 Summary

Bài báo *Deep Context-Aware Recommender System Utilizing Sequential Latent Context* nghiên cứu bài toán *Context-Aware Recommender System* (CARS), trong đó hệ gợi ý không chỉ sử dụng thông tin người dùng và item, mà còn khai thác thêm ngữ cảnh tại thời điểm tương tác. Ngữ cảnh có thể bao gồm thời gian, vị trí, thời tiết, trạng thái thiết bị, ánh sáng, âm thanh, pin, hoạt động của người dùng hoặc các tín hiệu cảm biến từ thiết bị di động. Mục tiêu của bài báo là cải thiện chất lượng gợi ý bằng cách học biểu diễn ngữ cảnh tốt hơn, đặc biệt là biểu diễn được sự thay đổi của ngữ cảnh theo thời gian.

Vấn đề chính của CARS là khi đưa thêm ngữ cảnh vào mô hình, không gian đặc trưng thường tăng rất nhanh và dữ liệu trở nên thưa hơn. Nếu biểu diễn ngữ cảnh bằng các đặc trưng tường minh như *time*, *location*, *day of week* hoặc *weather*, mô hình dễ giải thích nhưng khó bao phủ hết các trạng thái thực tế. Nếu học ngữ cảnh ẩn bằng mô hình nén như autoencoder, mô hình có thể giảm chiều và học quan hệ phi tuyến giữa các đặc trưng, nhưng thường chỉ phản ánh ngữ cảnh tại một thời điểm. Vì vậy, bài báo đề xuất học biểu diễn ngữ cảnh theo chuỗi, vì hành vi hiện tại của người dùng có thể bị ảnh hưởng bởi các ngữ cảnh đã xảy ra trước đó.

Về mặt kỹ thuật, bài báo sử dụng ba dạng biểu diễn ngữ cảnh. Dạng thứ nhất là *explicit context*, tức các đặc trưng ngữ cảnh được định nghĩa sẵn như thời gian, vị trí hoặc ngày trong tuần. Dạng thứ hai là *latent context*, được học bằng *autoencoder* từ vector ngữ cảnh hiện tại. Autoencoder gồm tầng input, tầng nén và tầng output; mô hình được huấn luyện theo kiểu không giám sát để tái tạo lại vector ngữ cảnh đầu vào. Vector ở tầng nén được lấy làm biểu diễn ngữ cảnh ẩn có kích thước thấp. Dạng thứ ba là *sequential latent context*, được học bằng *LSTM encoder-decoder* từ chuỗi các vector ngữ cảnh theo thời gian.

Để tạo dữ liệu đầu vào cho mô hình tuần tự, các tương tác trong hệ thống được sắp xếp theo *timestamp*. Sau đó, bài báo tạo các chuỗi ngữ cảnh bằng cửa sổ trượt, ví dụ với chuỗi độ dài 3 thì các vector ngữ cảnh tại thời điểm $t - 2$, $t - 1$ và t được gom thành một sequence. Một điểm đáng chú ý là chuỗi ngữ cảnh không nhất thiết chỉ thuộc về một

người dùng, mà có thể được tạo từ các tương tác liên tiếp trong toàn hệ thống. Cách này giúp mô hình học các pattern ngữ cảnh chung xuất hiện trong dữ liệu, đồng thời giảm phụ thuộc vào lịch sử cá nhân của từng user.

Trước khi huấn luyện các mô hình encoder-decoder, các đặc trưng ngữ cảnh dạng categorical được biến đổi thành dạng nhị phân bằng kỹ thuật tương tự *one-hot encoding*. Với bộ dữ liệu CARS, quá trình này tạo ra 268 đặc trưng ngữ cảnh; với bộ dữ liệu Yelp, quá trình này tạo ra 9 đặc trưng ngữ cảnh. Autoencoder và LSTM encoder-decoder đều được huấn luyện với mục tiêu tái tạo lại đầu vào, sử dụng *Mean Squared Error* làm loss function. Mô hình được tối ưu bằng Adam với learning rate giảm dần, batch size 512 và số vòng huấn luyện là 500.

Trong mô hình *LSTM encoder-decoder*, phần encoder đọc chuỗi vector ngữ cảnh theo thứ tự thời gian và nén thông tin vào trạng thái ẩn. Phần decoder nhận biểu diễn nén này và cố gắng tái tạo lại chuỗi đầu vào. Sau khi mô hình được huấn luyện, vector ở tầng nén hoặc hidden representation được lấy làm *sequential latent context*. Biểu diễn này có ý nghĩa là một vector cô đọng mô tả diễn biến ngữ cảnh gần đây, thay vì chỉ mô tả ngữ cảnh hiện tại. Đây là điểm kỹ thuật quan trọng nhất của bài báo.

Sau bước trích xuất ngữ cảnh, bài báo tích hợp vector ngữ cảnh vào mô hình gợi ý dựa trên *Neural Collaborative Filtering* (NCF), cụ thể là mở rộng kiến trúc *Neural Matrix Factorization* (NeuMF). NeuMF kết hợp hai nhánh chính: nhánh *GMF* học tương tác kiểu matrix factorization thông qua phép nhân element-wise giữa user embedding và item embedding; nhánh *MLP* học tương tác phi tuyến bằng cách nối embedding của user và item rồi đưa qua nhiều tầng neural network. Bài báo mở rộng nhánh MLP bằng cách nối thêm vector context vào user vector và item vector, từ đó mô hình học hàm tương tác phi tuyến giữa ba thành phần: user, item và context.

Ba mô hình neural context-aware được đề xuất gồm *Explicit Neural Context Model* (ENCM), *Latent Neural Context Model* (LNCM) và *Sequential Latent Context Model* (SLCM). ENCM đưa trực tiếp vector ngữ cảnh tường minh vào NeuMF. LNCM đưa vector ngữ cảnh ẩn được học từ autoencoder vào NeuMF. SLCM đưa vector *sequential latent context* được học từ LSTM encoder-decoder vào NeuMF. Trong cả ba trường hợp, context vector đóng vai trò như một thành phần bổ sung trong tầng MLP để mô hình học tác động của ngữ cảnh đến rating hoặc ranking score.

Về bài toán dự đoán, mô hình nhận đầu vào gồm user, item và context, sau đó dự đoán điểm tương tác $\hat{r}_{uic}$. Kiến trúc neural sử dụng tầng sigmoid ở đầu ra và được huấn luyện bằng *log loss* trong framework NeuMF. Ý tưởng của cách huấn luyện này là mô hình không cố định tương tác user-item bằng tích vô hướng tuyến tính như matrix factorization truyền thống, mà cho phép neural network tự học hàm tương tác phức tạp hơn giữa user, item và context.

Thực nghiệm được tiến hành trên hai bộ dữ liệu là CARS và Yelp. Bộ CARS có 98 users, 1,918 items, 38,900 ratings, 15 context dimensions và 247 context conditions. Đây

là bộ dữ liệu có ngữ cảnh phong phú từ cảm biến điện thoại. Bộ Yelp có quy mô lớn hơn với 150,770 users, 60,852 items và 588,253 interactions, nhưng số chiều ngữ cảnh ít hơn. Dữ liệu được chia theo thời gian, trong đó 70% tương tác cũ dùng để huấn luyện và 30% tương tác mới hơn dùng để kiểm thử. Cách chia này gần với tình huống thực tế, vì hệ gợi ý thường dùng dữ liệu quá khứ để dự đoán tương tác tương lai.

Các baseline được sử dụng gồm *Matrix Factorization* (MF), *Explicit Context Model* (ECM), *Latent Context Model* (LCM) và *NeuMF*. MF là baseline truyền thống chỉ học tương tác user-item. ECM mở rộng MF bằng cách thêm bias theo ngữ cảnh tường minh. LCM sử dụng latent context được học bằng autoencoder. NeuMF là baseline neural collaborative filtering nhưng chưa sử dụng context. Các mô hình đề xuất ENCM, LNCM và SLCM được so sánh với các baseline này để đánh giá hiệu quả của việc đưa context vào neural recommender system.

Metric đánh giá gồm RMSE, MAE và Hit@k. RMSE và MAE được dùng để đo sai số dự đoán rating, trong đó RMSE phạt lỗi lớn mạnh hơn MAE. Hit@k được dùng để đánh giá chất lượng danh sách gợi ý top-k, đặc biệt trên bộ CARS. Kết quả cho thấy các mô hình neural có context đều vượt qua các baseline truyền thống. Trong đó, SLCM đạt kết quả tốt nhất trên hầu hết các chỉ số. Điều này chứng minh rằng việc học ngữ cảnh theo chuỗi có ích hơn so với chỉ dùng context hiện tại hoặc chỉ dùng user-item interaction.

Bài báo cũng thực hiện *sensitivity analysis* để kiểm tra ảnh hưởng của độ dài chuỗi ngữ cảnh. Kết quả cho thấy chuỗi ngắn, ví dụ độ dài 2, 3 hoặc 4, thường cho kết quả tốt hơn chuỗi dài. Điều này cho thấy các ngữ cảnh gần thời điểm hiện tại có ảnh hưởng mạnh hơn đến hành vi người dùng, trong khi chuỗi quá dài có thể đưa thêm nhiễu vào mô hình. Vì vậy, trong bài toán CARS, không phải cứ tăng độ dài lịch sử ngữ cảnh là hiệu quả sẽ tốt hơn.

2 Conclusion

Hướng đi đã làm của bài báo là chuyển việc mô hình hóa ngữ cảnh trong recommender system từ dạng tĩnh hoặc đơn thời điểm sang dạng tuần tự. Cụ thể, bài báo xây dựng một pipeline kỹ thuật gồm hai bước chính. Bước thứ nhất là học biểu diễn ngữ cảnh bằng encoder-decoder, bao gồm autoencoder cho latent context hiện tại và LSTM encoder-decoder cho sequential latent context. Bước thứ hai là tích hợp vector context đã học vào NeuMF để mô hình học tương tác phi tuyến giữa user, item và context.

Về mặt kỹ thuật, đóng góp quan trọng nhất là cách xây dựng *Sequential Latent Context Model*. Mô hình này tạo chuỗi ngữ cảnh bằng cách sắp xếp tương tác theo thời gian, nén chuỗi bằng LSTM encoder-decoder, sau đó lấy hidden representation làm context vector cho recommender model. Nhờ vậy, hệ thống không chỉ biết trạng thái ngữ cảnh hiện tại, mà còn học được các pattern chuyển đổi ngữ cảnh trước khi người dùng đưa ra hành vi. Đây là điểm khác biệt chính so với các mô hình context-aware chỉ dùng explicit context

hoặc latent context đơn thời điểm.

Kết quả thực nghiệm cho thấy SLCM vượt trội hơn MF, ECM, LCM, NeuMF cũng như các biến thể neural context-aware khác. Điều này chứng minh rằng context nên được xem là một tín hiệu động có tính thời gian, không chỉ là một tập thuộc tính phụ tại thời điểm tương tác. Việc kết hợp representation learning, sequence modeling và neural collaborative filtering giúp mô hình vừa giảm chiều dữ liệu ngữ cảnh, vừa học được tương tác phức tạp giữa user, item và context.

Hướng kế thừa trực tiếp từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng mô hình cho bài toán *cold-start* hoặc *new user* bằng cách học pattern ngữ cảnh theo nhóm người dùng hoặc nhóm hành vi thay vì phụ thuộc vào lịch sử cá nhân. Thứ hai, có thể bổ sung biểu diễn nội dung item như văn bản, hình ảnh, thumbnail, metadata hoặc mô tả sản phẩm để mô hình không chỉ dựa vào user ID và item ID. Thứ ba, có thể thay LSTM encoder-decoder bằng các kiến trúc mạnh hơn như Transformer, self-attention, temporal convolution hoặc graph neural network để học quan hệ dài hạn và phức tạp hơn giữa các ngữ cảnh.

Ngoài ra, bài báo cũng mở ra hướng kế thừa cho các recommender system có yếu tố chu kỳ theo thời gian. Trong thực tế, hành vi người dùng thường phụ thuộc vào giờ trong ngày, ngày trong tuần, mùa, kỳ nghỉ hoặc sự kiện đặc biệt. Vì vậy, có thể kết hợp *sequential latent context* với các đặc trưng *temporal/cyclic context* để mô hình vừa nắm được chuỗi ngữ cảnh gần nhất, vừa học được các pattern lặp lại dài hạn. Đây là hướng phù hợp để phát triển các hệ gợi ý nhạy theo thời điểm, ví dụ gợi ý địa điểm, phim, nhạc, sản phẩm hoặc nội dung theo từng ngữ cảnh sử dụng cụ thể. ““