

Paper

“latex

1 Summary

Bài báo *Learning Heterogeneous Temporal Patterns of User Preference for Timely Recommendation* nghiên cứu bài toán *time-aware recommender system*, trong đó hệ thống không chỉ dự đoán user sẽ thích item nào, mà còn xét đến thời điểm nào item đó nên được gợi ý. Khác với các hệ recommender truyền thống chỉ học tương tác giữa user và item, bài báo cho rằng thông tin thời gian đóng vai trò quan trọng vì sở thích của user thường thay đổi theo thời điểm, theo chu kỳ, hoặc theo các sự kiện gần đây.

Vấn đề chính mà bài báo đặt ra là các phương pháp time-aware trước đây thường xem time information như một loại feature đơn lẻ. Cách xử lý này chưa đủ vì temporal pattern trong hành vi người dùng có tính không đồng nhất. Cụ thể, sở thích của user đối với một item có thể tăng theo chu kỳ, ví dụ nghe một loại nhạc vào buổi tối, xem phim vào cuối tuần, mua đồ vào ngày nhận lương hoặc mua áo khoác vào mùa đông. Đồng thời, sở thích cũng có thể thay đổi theo thời gian do các sự kiện gần đây, ví dụ user vừa mua một item liên quan hoặc một item đang có khuyến mãi và trở thành xu hướng.

Bài báo phân biệt hai nhóm temporal pattern chính. Nhóm thứ nhất là *periodic pattern*, tức hành vi lặp lại theo các chu kỳ thời gian. Nhóm này có ba đặc điểm quan trọng: có nhiều mức độ chu kỳ khác nhau như tháng, ngày trong tuần, ngày trong tháng và giờ trong ngày; hành vi có thể lệch nhẹ khỏi chu kỳ thông thường; và cùng một thời điểm có thể mang ý nghĩa khác nhau đối với từng user. Nhóm thứ hai là *evolving pattern*, tức sở thích thay đổi do ảnh hưởng của các tương tác gần đây hoặc do trend của item tại một giai đoạn thời gian cụ thể.

Để giải quyết vấn đề trên, bài báo đề xuất mô hình *TimelyRec*. Đây là một mô hình time-aware recommender có đầu vào là bộ ba (u, i, t) gồm user u , item i và timestamp t . Mục tiêu của mô hình là dự đoán xác suất user u sẽ tương tác với item i tại thời điểm t . Kiến trúc của *TimelyRec* gồm hai encoder chính được mắc nối tiếp: *Multi-Aspect Time Encoder* (MATE) để học periodic pattern từ timestamp, và *Time-Aware History Encoder* (TAHE) để học evolving pattern từ lịch sử tương tác gần đây của user.

Thành phần đầu tiên, *MATE*, dùng để biểu diễn timestamp t theo nhiều khía cạnh thời gian khác nhau. Timestamp được tách thành các granularity như *month*, *day of week*, *date* và *hour*. Mỗi granularity được ánh xạ thành embedding riêng. Tuy nhiên, cùng một thời điểm có thể có ý nghĩa khác nhau với từng user, nên MATE cá nhân hóa time embedding bằng user embedding. Ví dụ, cùng là tối thứ sáu nhưng với một user có thể là thời điểm xem phim, còn với user khác có thể là thời điểm mua sắm.

Về mặt kỹ thuật, với một granularity như *month*, MATE tạo personalized period information bằng phép Hadamard product giữa time-slot embedding và user-transformed embedding:

$$E_{Month}^u(t) = (W_{Month}U_u) \circ E_{Month}(t)$$

Trong đó, U_u là user embedding, $E_{Month}(t)$ là embedding của month tại timestamp t , W_{Month} là ma trận biến đổi, và $\circ$ là phép nhân Hadamard. Cách này cho phép mô hình học ý nghĩa thời gian theo từng user mà không cần tạo thêm một bộ tham số riêng biệt cho mỗi user.

Một đóng góp kỹ thuật quan trọng của MATE là *gradual attention*. Bài báo nhận xét rằng periodic behavior thường không hoàn toàn chính xác tuyệt đối mà có thể lệch nhẹ. Ví dụ, user thường mua áo khoác vào tháng 11 nhưng cũng có thể mua vào tháng 10 hoặc tháng 12. Vì vậy, thay vì chỉ dùng đúng time slot mục tiêu, gradual attention còn xét các time slot lân cận trong một phạm vi nhất định. Các slot gần timestamp mục tiêu thường có ảnh hưởng lớn hơn các slot xa hơn.

Với gradual attention, mô hình tạo nhiều representation ứng với các vùng lân cận có bán kính khác nhau quanh target time slot, sau đó dùng scaled dot-product attention để kết hợp chúng. Cơ chế này giúp mô hình học được sự lệch nhẹ trong hành vi chu kỳ. Sau khi áp dụng gradual attention cho từng granularity, MATE tiếp tục dùng multiplicative attention để kết hợp các granularity khác nhau. Điều này quan trọng vì mỗi dataset hoặc mỗi user có thể phụ thuộc vào một loại chu kỳ khác nhau. Ví dụ, trong music domain thì hour có thể quan trọng, còn trong shopping domain thì month hoặc date có thể quan trọng hơn.

Thành phần thứ hai, *TAHE*, dùng để học evolving pattern từ các tương tác gần đây của user. Ý tưởng của TAHE là không phải mọi tương tác gần đây đều có ảnh hưởng như nhau đến target time. Một tương tác gần đây xảy ra tại thời điểm có periodic pattern giống với target time có thể quan trọng hơn một tương tác chỉ gần về mặt thời gian nhưng khác về pattern. Vì vậy, TAHE sử dụng output của MATE để so sánh độ tương đồng giữa thời điểm của từng recent interaction và target timestamp.

Cụ thể, TAHE sử dụng *time-based attention*. Với mỗi recent interaction thứ j của user u , mô hình tính cosine similarity giữa representation thời gian của interaction đó và representation của target time:

$$c_j^u(t) = \frac{\cos(T^u(t), T^u(t_j^u)) + 1}{2}$$

Sau đó, item embedding của các recent interactions được tổng hợp theo trọng số $c_j^u(t)$ để tạo ra history representation:

$$H^u(t) = \sum_{j=1}^l c_j^u(t) I_{i_j^u}(t)$$

Trong đó, $H^u(t)$ là biểu diễn lịch sử tương tác của user tại target time t , i_j^u là item trong recent interaction thứ j , và l là số lượng recent interactions được xét. Cách này làm cho lịch sử user trở thành một biểu diễn phụ thuộc vào target time, phù hợp với mục tiêu timely recommendation.

Ngoài recent interactions, TAHE còn xét *temporal position* của item. Bài báo cho rằng item cũng có trend theo thời gian, ví dụ một phim mới ra mắt, một sản phẩm đang thịnh hành, hoặc một item đang trong giai đoạn được tiêu thụ nhiều. Để biểu diễn temporal position, mô hình sử dụng *sinusoidal positional encoding*, tương tự Transformer. Điểm mạnh của sinusoidal encoding là không cần học embedding riêng cho từng timestamp, nên có thể khái quát tốt hơn cho các thời điểm chưa xuất hiện trong training.

Item embedding tại timestamp t được biểu diễn bằng cách cộng item embedding gốc với temporal encoding:

$$I_i(t) = I_i + \alpha TE(t)$$

Trong đó, I_i là item embedding, $TE(t)$ là sinusoidal temporal position encoding, và α là tham số học được để điều chỉnh mức độ ảnh hưởng của temporal encoding. Thành phần này giúp mô hình không chỉ biết item là gì, mà còn biết item đó đang nằm ở vị trí thời gian nào trong toàn bộ chuỗi tương tác.

Sau khi có các representation từ MATE và TAHE, TimelyRec nối bốn thành phần lại với nhau: user embedding, item-time representation, timestamp representation và time-aware history representation. Vector tổng hợp này được đưa qua MLP để học tương tác phi tuyến giữa user, item, time và history:

$$x_{uit} = [U_u, I_i(t), T^u(t), H^u(t)]$$

$$\hat{y}_{uit} = \sigma(MLP(x_{uit}))$$

Trong đó, $\hat{y}_{uit}$ là xác suất user u tương tác với item i tại thời điểm t . Mô hình được huấn luyện bằng *binary cross entropy loss*, với positive interactions là các tương tác thật và negative interactions được sinh bằng negative sampling.

Một điểm mới của bài báo là ngoài bài toán *item recommendation*, tác giả còn đề xuất

bài toán *item-timing recommendation*. Trong item recommendation, mô hình cần chọn đúng item phù hợp với một timestamp đã cho. Trong item-timing recommendation, mô hình phải đồng thời dự đoán đúng item và đúng thời điểm nên gợi ý item đó. Đây là setting khó hơn vì mô hình phải phân biệt cả negative item, negative timestamp và cặp negative item–timestamp.

Cụ thể, với một test interaction (u, i, t) , bài báo tạo ba loại negative samples: (u, i^-, t) , tức sai item nhưng đúng thời điểm; (u, i, t^-) , tức đúng item nhưng sai thời điểm; và (u, i^-, t^-) , tức sai cả item lẫn thời điểm. Sau đó, mô hình phải rank interaction thật cao hơn các negative interactions. Cách đánh giá này phù hợp với timely recommendation vì hệ thống thực tế không chỉ cần biết gợi ý cái gì, mà còn cần biết gợi ý khi nào.

Thực nghiệm được tiến hành trên ba bộ dữ liệu: MovieLens, Amazon Books và LastFM. MovieLens đại diện cho movie recommendation, Amazon Books đại diện cho shopping/purchase recommendation, còn LastFM đại diện cho music listening recommendation. Các metric đánh giá gồm HR@K và NDCG@K với $K = 1, 5, 10$. Các baseline được so sánh gồm LMF, PITF, TimeLSTM, SASRec, CoNCARS, NTF, SLi-Rec, GRec và TiSASRec.

Kết quả thực nghiệm cho thấy TimelyRec vượt trội hơn các baseline trên cả hai setting item recommendation và item-timing recommendation. Đặc biệt, mức cải thiện rõ hơn trong item-timing recommendation, cho thấy mô hình học temporal pattern tốt hơn khi phải dự đoán đồng thời cả item và thời điểm. Kết quả ablation study cũng cho thấy từng thành phần của TimelyRec đều có vai trò quan trọng: personalization, gradual attention, time-based attention, temporal position encoding, timestamp representation và history representation đều giúp cải thiện hiệu năng.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một mô hình time-aware recommender system có khả năng học đồng thời nhiều loại temporal pattern khác nhau. Thay vì xem thời gian như một feature đơn giản, bài báo phân tách temporal behavior thành hai nhóm: *periodic pattern* và *evolving pattern*. Với periodic pattern, bài báo dùng MATE để học các chu kỳ theo nhiều granularity như month, day of week, date và hour, đồng thời cá nhân hóa ý nghĩa thời gian theo từng user và xử lý sự lệch nhẹ bằng gradual attention. Với evolving pattern, bài báo dùng TAHE để tổng hợp recent interactions theo mức độ tương đồng thời gian với target timestamp, đồng thời thêm temporal position encoding để nắm bắt trend của item.

Về mặt kỹ thuật, đóng góp chính của bài báo nằm ở kiến trúc TimelyRec gồm hai encoder mắc nối tiếp. MATE tạo biểu diễn thời gian cá nhân hóa và đa khía cạnh cho target timestamp. TAHE sử dụng biểu diễn này để chọn lọc recent interactions phù hợp với target time. Cuối cùng, MLP học tương tác phi tuyến giữa user embedding, item-time embedding, timestamp representation và history representation. Cách thiết kế này giúp

mô hình vừa học được chu kỳ dài hạn, vừa học được ảnh hưởng của các sự kiện gần đây.

Bài báo cũng đóng góp một hướng đánh giá quan trọng là *item-timing recommendation*. Đây là bài toán gần với thực tế hơn so với item recommendation thông thường, vì nhiều hệ thống cần chủ động gợi ý item tại thời điểm phù hợp, ví dụ push notification, e-commerce promotion, music recommendation theo thời điểm hoặc content recommendation theo thói quen sử dụng. Việc tạo negative samples sai item, sai time và sai cả item-time giúp đánh giá rõ hơn khả năng học temporal preference của mô hình.

Hướng kế thừa từ bài báo có thể phát triển theo nhiều hướng. Thứ nhất, có thể mở rộng TimelyRec sang các mô hình sequential hoặc session-based mạnh hơn, ví dụ Transformer-based recommender, để học lịch sử dài hơn và quan hệ phức tạp hơn giữa các tương tác. Thứ hai, có thể bổ sung thêm ngữ cảnh ngoài thời gian như location, device, weather, activity hoặc mood để mô hình chuyển từ time-aware sang context-aware recommendation đầy đủ hơn. Thứ ba, có thể khai thác item content như text, image, audio hoặc category embedding để xử lý tốt hơn cold-start item và các domain có metadata phong phú.

Ngoài ra, hướng nghiên cứu này rất phù hợp với các hệ recommender có bias theo thời điểm hoặc hành vi lặp lại theo chu kỳ. MATE có thể được mở rộng để học thêm các chu kỳ như season, holiday, payday, school term hoặc event-specific time. TAHE có thể được cải tiến bằng attention phức tạp hơn để phân biệt recent interaction nào là tín hiệu ngắn hạn, interaction nào phản ánh sở thích dài hạn. Khi kết hợp periodic pattern, evolving pattern và context bên ngoài, hệ thống có thể gợi ý không chỉ đúng item, mà còn đúng thời điểm và đúng hoàn cảnh sử dụng. ““