

Paper

“latex

1 Summary

Bài báo *Persona Conditioning of Brand Recommendations in Retrieval-Augmented Commercial Chat: A Prominence-Stratified Cross-Provider Audit* nghiên cứu tác động của *persona* lên các recommendation do AI assistant tạo ra trong bối cảnh thương mại. Ví dụ, cùng một prompt như “best CRM software”, nhưng nếu người hỏi được mô tả là solo founder, enterprise VP, UK SMB owner hoặc EU finance manager, mô hình có thể đưa ra các brand khác nhau. Vấn đề chính của bài báo là kiểm tra xem sự thay đổi persona này có làm thay đổi recommendation set ở mức đáng kể hay không.

Bài báo đặt vấn đề rằng trong production chat, AI assistant không chỉ trả lời dựa trên prompt literal và retrieval results, mà còn dựa trên những thông tin về người dùng hoặc ngữ cảnh người dùng. Thông tin này có thể đến từ system prompt, prior turns, account metadata, hoặc persona được prefix vào user message. Nếu persona effect nhỏ, có thể xem AI commercial recommendation là gần như persona-agnostic. Nhưng nếu effect lớn, brand-side optimization không thể chỉ dựa trên một trang “best [category]” chung, mà phải tối ưu theo từng buyer segment.

Về thiết kế thực nghiệm, bài báo audit khoảng 2000 runs trên không gian gồm:

$$10 \text{ personas} \times 8 \text{ prompts} \times 3 \text{ model cells} \times N = 10 \text{ repetitions}$$

Ba model cells gồm OpenAI *gpt-5.4-mini / low*, OpenAI *gpt-5.4-mini / high*, và Anthropic *claude-sonnet-4-6 / low*. Hai OpenAI cells có đủ 8-prompt coverage, còn Anthropic sonnet cell chỉ có 4-prompt coverage, nên các kết luận so sánh provider cần được đọc thận trọng hơn.

Persona corpus gồm 10 personas được thiết kế thủ công, bao phủ các thuộc tính như industry vertical, company size, role và geography. Một số persona tiêu biểu gồm:

`solo_founder_us_bootstrapped`

`enterprise_vp_us_procurement`

consumer_value_shopper_uk

uk_smb_owner_london

eu_finance_manager_germany

Mỗi persona được đưa vào prompt bằng cùng một template prefix cố định, ví dụ “I’m a [persona description].” Cách này giúp kiểm soát nhiễu do khác phrasing; mô hình chỉ thay đổi theo persona attribute, không thay đổi theo cách viết prefix.

Bài báo dùng *cross-judge consensus brand extraction* để xác định brand nào được recommend. Hai LLM judges chạy song song, gồm *claude-haiku-4-5 / low* và *gpt-5-mini*. Một brand chỉ được tính là recommended nếu cả hai judge cùng đánh dấu là recommended. Đây là protocol bảo thủ, tương tự các paper trước trong chuỗi audit này, nhằm giảm bias từ từng judge riêng lẻ.

Đơn vị phân tích chính là *consensus recommendation set*. Với mỗi tổ hợp persona, prompt và model cell, paper lấy union của các brand được consensus-recommended qua 10 reruns. Sau đó, tác giả đo độ giống nhau giữa các recommendation sets bằng Jaccard similarity:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Nếu Jaccard cao, hai persona tạo ra recommendation sets giống nhau. Nếu Jaccard thấp, recommendation set thay đổi mạnh khi persona thay đổi.

Paper định nghĩa hai loại Jaccard. Thứ nhất là *within-persona Jaccard*, đo độ ổn định khi giữ nguyên persona và chạy lại nhiều lần. Với mỗi persona, 10 reruns được chia thành hai nửa độc lập, rồi tính Jaccard giữa hai nửa. Đây là baseline cho mức ổn định nội tại của cùng một persona. Thứ hai là *cross-persona Jaccard*, đo độ giống nhau giữa recommendation sets của hai persona khác nhau, trong khi giữ nguyên prompt và model cell.

Metric chính của paper là *persona-shift effect size*:

$$\Delta = J_{\text{cross-persona}} - J_{\text{within-persona}}$$

Nếu Δ âm, nghĩa là đổi persona làm giảm overlap so với việc giữ nguyên persona. Giá trị $|\Delta|$ càng lớn thì persona effect càng mạnh.

Kết quả tổng hợp cho thấy persona effect rõ ràng trên cả ba model cells. Với *gpt-5.4-mini / low*, within-persona Jaccard là 0.467, cross-persona Jaccard là 0.346, nên:

$$\Delta = -0.12$$

Với *gpt-5.4-mini / high*, within-persona Jaccard là 0.505, cross-persona Jaccard là 0.343,

nên:

$$\Delta = -0.16$$

Với *claude-sonnet-4-6 / low*, within-persona Jaccard là 0.424, cross-persona Jaccard là 0.222, nên:

$$\Delta = -0.20$$

Các clustered 95% confidence intervals đều không chứa 0, cho thấy persona-shift signal là đáng kể.

Điểm quan trọng là persona effect này lớn hơn rerun noise thông thường. Paper dùng rerun-stability baseline từ paper trước, trong đó same-prompt rerun Jaccard nằm khoảng 0.50–0.61. Cross-persona Jaccard chỉ nằm khoảng 0.22–0.35, thấp hơn rõ rệt. Điều này cho thấy sự khác biệt recommendation không chỉ là ngẫu nhiên do rerun, mà thực sự do persona attribute gây ra.

Paper cũng phân tích khác biệt giữa provider. Anthropic sonnet / low có point estimate persona effect lớn nhất:

$$\Delta = -0.20$$

so với OpenAI mini / high:

$$\Delta = -0.16$$

và OpenAI mini / low:

$$\Delta = -0.12$$

Tuy nhiên, bài báo thận trọng vì sonnet cell chỉ có 4 prompt clusters, confidence interval rộng hơn, và CI của sonnet với mini / high có overlap. Vì vậy, paper không khẳng định chắc chắn rằng Anthropic luôn persona-sensitive hơn OpenAI, mà xem đây là một point-estimate signal cần kiểm tra thêm.

Một điểm thảo luận quan trọng là kết quả này mâu thuẫn với trực giác “stronger model = more deterministic”. Trong một số nghiên cứu về temperature robustness, model mạnh hơn có thể ổn định hơn trước sampling variation. Nhưng paper cho rằng persona conditioning không phải sampling noise; nó là deterministic input variation. Một model mạnh hơn có thể ít random hơn nhưng lại phản hồi mạnh hơn với user context. Do đó, persona responsiveness có thể là một feature chứ không nhất thiết là bug.

Paper đưa ra một giả thuyết cơ chế: persona effect có thể mạnh hơn khi model dựa nhiều vào parametric priors hơn là retrieval evidence. Theo các paper audit trước trong cùng chuỗi, Anthropic có tỷ lệ recommendation không có evidence rõ từ retrieval layer cao hơn OpenAI. Nếu persona tác động mạnh lên priors-driven generation, thì model nào dựa nhiều vào priors hơn có thể có persona effect lớn hơn. Đây mới là giả thuyết, vì paper chưa đo trực tiếp pure-priors share và persona movement trong cùng runs.

Phần quan trọng nhất của paper là phân tích *prominence* $\times$ *persona interaction*. Paper sử dụng cùng prominence ladder L1–L5 như các bài trước: L1 là category leaders, L2 là

established challengers, L3 là mid-market, L4 là long-tail specialists, và L5 là regional players. Với mỗi tier, paper đo:

$$1 - J_{\text{cross-persona}}$$

được hiểu là recommendation swap rate theo persona ở tier đó.

Kết quả cho thấy L1 category leaders tương đối persona-resistant. Swap rate của L1 nằm trong khoảng 0.20–0.29 tùy cell. Nghĩa là các brand lớn như Salesforce, HubSpot hoặc Datadog thường vẫn được recommend cho nhiều persona khác nhau. Điều này phù hợp với kết quả của prominence audit trước đó: L1 gần như đã giải quyết được visibility, và failure mode chính của L1 là compellingness/positioning, không phải persona-mediated substitution.

L2 có tín hiệu hỗn hợp. Trên OpenAI cells, L2 swap rate rất thấp, khoảng 0.05–0.13, thậm chí thấp hơn cả L1. Trên Anthropic sonnet / low, L2 swap rate tăng lên 0.23. Paper chưa kết luận chắc nguyên nhân, nhưng đưa ra khả năng rằng trên OpenAI, L2 được retrieval anchor mạnh hơn, còn trên Anthropic, L2 có thể bị priors và persona context ảnh hưởng nhiều hơn.

L3 là tier có persona effect lớn nhất. Với *mini / high*, L3 swap rate đạt 0.75; với *mini / low*, đạt 0.67; với *sonnet / low*, đạt 0.39. Đây là kết quả trung tâm của paper: mid-market brands là nơi recommendation set thay đổi mạnh nhất khi persona thay đổi. Nói cách khác, head brands được recommend cho hầu hết mọi người, tail brands thường không được recommend cho ai, còn mid-market brands là nơi user context thật sự quyết định brand nào được chọn.

L4 bị undersampled trong cả ba cells, nên paper không báo cáo point estimate. Đây là lựa chọn đúng về mặt phương pháp, vì số lượng L4 recommendation events quá ít; nếu tính Jaccard trên tập quá thưa sẽ bị chi phối bởi zero-zero comparisons và không ổn định. Paper nhấn mạnh không nên suy luận rằng L4 persona-resistant; đơn giản là dữ liệu chưa đủ.

L5 có effect trung bình, khoảng 0.27 trên *mini / high* và 0.33 trên *mini / low*. Tuy nhiên, cơ chế ở L5 khác L3. L5 là regional players, nên persona effect chủ yếu đến từ *geographic gating*. Ví dụ, persona UK có thể kéo các brand UK vào recommendation, persona Germany có thể kéo các brand Đức vào. Do đó, L5 effect không hẳn là positioning/persona fit rộng, mà phần lớn là do region cues trong persona.

Paper cũng phân tích sự khác biệt giữa các personas. Một số personas tạo recommendation set rất tập trung, thể hiện qua within-persona Jaccard cao. Ví dụ:

`us_ecommerce_operator` : 0.65

`enterprise_vp_us_procurement` : 0.57

`consumer_value_shopper_uk` : 0.55

solo_founder_us_bootstrapped : 0.54

Các persona này mô tả buyer archetype khá rõ, nên model thường hội tụ vào một consideration set hẹp.

Ngược lại, một số personas tạo recommendation set phân tán hơn, chẳng hạn:

eu_finance_manager_germany : 0.27

uk_smb_owner_london : 0.39

Các persona này kết hợp nhiều thuộc tính rộng, khiến model dao động giữa global category leaders, region-specific brands và local alternatives. Do đó, recommendation set kém ổn định hơn.

Từ góc nhìn thực tiễn, paper cho rằng brand-side optimization trong AI commercial recommendation phải được phân đoạn theo persona. Một trang content chung kiểu “best CRM software” có thể không đủ, vì cùng một category nhưng mỗi buyer segment sẽ kích hoạt một consideration set khác nhau. Vì vậy, hướng content hợp lý hơn là *segment-targeted positioning*, ví dụ:

best [category] for [segment]

hoặc các trang so sánh theo persona cụ thể như SMB, enterprise buyer, founder, regional operator, value shopper.

2 Conclusion

Hướng đi đã làm của bài báo là audit tác động của persona conditioning lên brand recommendation trong retrieval-augmented commercial chat. Bài báo giữ prompt, temperature, system prompt template và persona-prefix syntax cố định, chỉ thay đổi persona attribute, sau đó đo sự thay đổi của consensus recommendation set bằng Jaccard similarity. Cách thiết kế này giúp tách riêng persona effect khỏi prompt wording effect và rerun noise.

Đóng góp kỹ thuật quan trọng nhất của bài báo là định nghĩa và đo *persona-shift effect size*:

$$\Delta = J_{\text{cross-persona}} - J_{\text{within-persona}}$$

Trên ba model cells, Δ nằm trong khoảng -0.12 đến -0.20 , với clustered confidence intervals loại trừ 0. Điều này chứng minh rằng persona không chỉ là chi tiết phụ trong prompt, mà là một tín hiệu đủ mạnh để làm thay đổi recommendation set.

Kết quả chính của paper là persona effect có tính *prominence-stratified*. L1 category leaders tương đối ổn định qua các persona. L2 có tín hiệu hỗn hợp và phụ thuộc cell. L3 mid-market là điểm inflection, nơi persona effect mạnh nhất, với swap rate lên tới 0.75.

L4 không đủ dữ liệu để kết luận. L5 có effect trung bình nhưng phần lớn được giải thích bởi geographic gating. Điều này nổi trực tiếp với logic của recommender system truyền thống: personalization thường quan trọng nhất ở nhóm item trung bình, không phải head items hoặc tail items.

Ý nghĩa thực tiễn là việc đo “AI brand perception” hoặc “AI visibility” không nên bỏ qua buyer persona. Cùng một prompt nhưng persona khác nhau có thể tạo ra recommendation sets khác nhau. Nếu một measurement protocol gom mọi persona lại hoặc chỉ đo một persona chung chung, nó sẽ che mất variation thật sự giữa các buyer segments. Vì vậy, AI visibility tracking và AEO/GEO strategy cần thiết kế theo persona hoặc segment, không chỉ theo category keyword.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, cần mở rộng full-power measurement cho L4 vì long-tail specialists hiện bị undersampled. Thứ hai, cần thêm các model cells như sonnet / high và opus để kiểm tra provider effect rõ hơn. Thứ ba, cần chạy persona-syntax ablation để tách tác động của persona attribute khỏi cách viết persona prefix. Thứ tư, cần đo cùng lúc pure-priors share và persona movement trong cùng runs để kiểm tra giả thuyết rằng persona effect mạnh hơn trên priors-driven generation.

Ngoài ra, paper này có thể kế thừa trực tiếp cho hướng nghiên cứu recommender system theo ngữ cảnh. Trong CARS truyền thống, user context đã được xem là yếu tố quan trọng để cá nhân hóa recommendation. Paper này cho thấy trong LLM/RAG commercial chat, persona đóng vai trò tương tự một context dimension mới, nhưng được biểu diễn bằng natural language. Một hướng nghiên cứu tiếp theo là xây dựng evaluation framework cho *persona-aware AI recommendation*, trong đó hệ thống không chỉ được đánh giá theo accuracy hoặc visibility tổng thể, mà còn theo độ ổn định, fairness và coverage giữa các persona segments. ““