

Paper

1 Summary

Bài báo *CFaiRLLM: Consumer Fairness Evaluation in Large-Language Model Recommender System* nghiên cứu bài toán đánh giá công bằng ở phía người dùng trong *LLM-based recommender systems* hay *RecLLMs*. Bối cảnh của bài báo là các LLM như ChatGPT ngày càng được sử dụng như recommender trực tiếp: user đưa lịch sử sở thích hoặc prompt tự nhiên, sau đó LLM sinh ra danh sách top- k item được đề xuất. Tuy nhiên, vì LLM được huấn luyện trên dữ liệu Internet rất lớn và không hoàn toàn kiểm soát được, chúng có thể mang theo bias liên quan đến gender, age, race, brand popularity hoặc các thuộc tính nhạy cảm khác.

Vấn đề chính mà bài báo đặt ra là các nghiên cứu trước về fairness trong RecLLM, đặc biệt framework FaiRLLM, thường đánh giá consumer fairness bằng cách so sánh recommendation list sinh ra từ prompt trung lập với recommendation list sinh ra từ prompt có thêm sensitive attribute. Nếu hai list khác nhau nhiều, hệ thống bị xem là unfair. Bài báo cho rằng cách đánh giá này chưa đủ, vì khác biệt giữa hai recommendation lists không nhất thiết là bias. Nó có thể là personalization hợp lý nếu recommendation mới vẫn align tốt hơn với sở thích thật của user.

Ví dụ, một user có lịch sử thích phim action và comedy. Với prompt trung lập, LLM có thể recommend một số phim action/comedy. Khi thêm sensitive attribute như “Female”, LLM có thể thay đổi danh sách. Theo cách đo cũ, thay đổi này có thể bị xem là unfair vì item list khác nhau. Tuy nhiên, nếu danh sách mới vẫn chứa nhiều item đúng với ground-truth preference của user, hoặc thậm chí tốt hơn, thì không nên kết luận ngay là unfair. Ngược lại, nếu danh sách có vẻ giống list trung lập nhưng lại không match với ground truth, thì similarity cao cũng không đảm bảo fairness.

Từ đó, paper đề xuất *CFaiRLLM*, một framework đánh giá consumer fairness trong RecLLM bằng hai trục chính. Trục thứ nhất là *true preference alignment*: recommendation có align với sở thích thật của user trong test data hay không. Trục thứ hai là *intersectional fairness*: fairness không chỉ được đo trên một sensitive attribute riêng lẻ như gender hoặc age, mà còn trên tổ hợp nhiều thuộc tính như *Teen Female*, *Young Adult Male*, v.v. Đây là điểm quan trọng vì bias thường xuất hiện mạnh hơn ở các nhóm giao nhau giữa nhiều đặc tính xã hội.

Về mặt khái niệm, paper phân biệt hai loại benefit dùng để đánh giá fairness. Loại thứ nhất là:

$$B_{item}$$

tức *alignment of information items*. Đây là cách đo cũ, đánh giá mức độ giống nhau giữa recommendation list trung lập và recommendation list có sensitive attribute. Nếu hai list giống nhau, hệ thống được xem là ổn định trước sensitive attribute.

Loại benefit thứ hai là:

$$B_{pref}$$

tức *true preference alignment*. Đây là đóng góp chính của paper. Thay vì chỉ hỏi hai list có giống nhau không, framework hỏi: các item trong hai list có thật sự phù hợp với sở thích user không? Sở thích thật được lấy từ ground-truth test interactions. Như vậy, fairness được đo theo chất lượng lợi ích mà user nhận được, không chỉ theo độ ổn định hình thức của output.

Paper định nghĩa hai ranking list chính. Với một user instruction I_m , recommendation list trung lập là:

$$R_m$$

được sinh từ prompt không chứa sensitive attribute. Recommendation list có sensitive attribute a là:

$$R_m^a$$

được sinh từ prompt có thêm thuộc tính như gender hoặc age. Với intersectional attribute, list được ký hiệu:

$$R_m^{ab}$$

trong đó a và b có thể là gender và age.

Trong framework cũ, fairness được đánh giá chủ yếu bằng similarity giữa R_m và R_m^a . CFaiRLLM mở rộng bằng cách lọc hai list này qua ground-truth preference. Cụ thể:

$$R'_m$$

là tập item trong R_m thật sự phù hợp với user theo test data, còn:

$$R_m'^a$$

là tập item trong R_m^a thật sự phù hợp với user. Khi đó, fairness dựa trên true preference alignment được đo bằng similarity giữa các refined lists thay vì raw recommendation lists.

Về sensitive groups, paper phân biệt *independent groups* và *intersectional groups*. Với một sensitive attribute A có các giá trị:

$$\{a_1, a_2, \dots, a_n\}$$

các independent groups là:

$$G_{indep} = \{G_{a_1}, G_{a_2}, \dots, G_{a_n}\}$$

Ví dụ gender có thể gồm Male và Female; age có thể gồm Teen, Young, Adult.

Với intersectional analysis, paper xét tổ hợp của nhiều sensitive attributes:

$$A_{int} = \{a_i \cap b_j \mid a_i \in A, b_j \in B, A \neq B\}$$

và tạo các group:

$$G_{inters} = \{G_{a_1b_1}, G_{a_1b_2}, \dots, G_{a_nb_m}\}$$

Ví dụ các group như Teen Female, Adult Male, Young Female. Cách này quan trọng vì một hệ thống có thể tương đối fair khi xét gender riêng và age riêng, nhưng vẫn unfair khi xét tổ hợp gender-age.

Về prompt construction, CFaiRLLM xây dựng instruction gồm ba phần. Phần thứ nhất là *sensitive demographic information*, ví dụ “The user is Female” hoặc “The user is Young Adult Female”. Phần thứ hai là *user profile*, gồm *passion profile* và *actual consumption profile*. Passion profile tóm tắt sở thích tổng quát của user, ví dụ user thích các genres Drama, Sci-Fi, Comedy, Romance trong một khoảng năm nhất định. Actual consumption profile liệt kê một số item user đã thích hoặc rating cao, ví dụ các movie title, year, genre và rating. Phần thứ ba là *recommendation request*, yêu cầu LLM đề xuất K item mà user sẽ thích.

Một điểm kỹ thuật quan trọng là paper đề xuất các *user profile sampling strategies*. Vì lịch sử user có thể rất dài và prompt của LLM có giới hạn token, không thể đưa toàn bộ lịch sử vào prompt. Do đó, CFaiRLLM thử ba cách chọn item đại diện cho user profile:

random sampling, top-rated sampling, recent sampling

Random sampling chọn ngẫu nhiên từ lịch sử user, giúp có cái nhìn đa dạng nhưng không ổn định. Top-rated sampling chọn các item user đánh giá cao nhất, giúp nhấn mạnh sở thích mạnh nhất. Recent sampling chọn item gần đây nhất, giúp phản ánh preference hiện tại hoặc preference drift.

Paper chuẩn hóa số item trong profile:

$$N_{prof} = 10$$

để so sánh công bằng giữa các sampling strategies. Ngoài ra, paper cũng nghiên cứu ảnh hưởng của việc tăng scope sampling, tức tăng số lượng item được đưa vào prompt, nhằm xem profile dài hơn có làm metric fairness và similarity ổn định hơn hay không.

Về evaluation procedure, CFaiRLLM thực hiện ba bước. Bước thứ nhất là thu recommendation

từ prompt trung lập và prompt có sensitive attribute. Bước thứ hai là đo item-level similarity giữa hai list bằng các metrics như Jaccard và PRAG. Bước thứ ba là lọc recommendation theo ground truth rồi đo true preference alignment bằng cùng các metrics đó. Nhờ vậy, framework so sánh được hai cách hiểu fairness: output stability và benefit alignment.

Metric item similarity đầu tiên là *Jaccard Similarity at K*:

$$JS@K = \frac{1}{M} \sum_{m=1}^M \frac{|R_m^a \cap R_m|}{|R_m^a \cup R_m|}$$

Trong đó M là số instruction/user cases. $JS@K$ càng cao nghĩa là list trung lập và list có sensitive attribute càng giống nhau.

Metric thứ hai là *PRAG*, được điều chỉnh từ Pairwise Ranking Accuracy Gap để xét cả thứ tự ranking. Nếu Jaccard chỉ xem item overlap, PRAG kiểm tra liệu thứ tự tương đối giữa các item có nhất quán giữa hai ranking lists hay không. Ý tưởng là hai list có thể chứa cùng nhiều item nhưng thứ tự khác nhau; PRAG nhạy hơn với sự thay đổi ranking position.

Để chuyển các similarity scores thành fairness disparity, paper dùng hai metrics:

$$SNSR@K = \max_{a \in A} Sim(a) - \min_{a \in A} Sim(a)$$

và:

$$SNSV@K = \sqrt{\frac{1}{|A|} \sum_{a \in A} \left(Sim(a) - \frac{1}{|A|} \sum_{a' \in A} Sim(a') \right)^2}$$

Trong đó $Sim(a)$ là average similarity score của sensitive group a . $SNSR$ đo khoảng cách giữa group tốt nhất và group kém nhất, còn $SNSV$ đo độ phân tán giữa các group. Giá trị càng cao nghĩa là disparity giữa groups càng lớn, tức fairness càng kém.

Điểm khác biệt của CFaiRLLM là $Sim(a)$ có thể được tính theo hai cách. Nếu dùng B_{item} , $Sim(a)$ dựa trên similarity giữa raw lists R_m và R_m^a . Nếu dùng B_{pref} , $Sim(a)$ dựa trên similarity giữa refined lists R'_m và R'_m^a , tức chỉ xét các item thật sự match với ground-truth preference. Đây là khác biệt cốt lõi giữa đánh giá surface-level fairness và true-benefit fairness.

Thực nghiệm được tiến hành trên hai dataset: *MovieLens-1M* và *LastFM-1K*. MovieLens dùng explicit movie ratings; LastFM ban đầu là implicit play counts, sau đó được chuyển sang explicit feedback theo thang 1–5 để đồng nhất với setting movie. Dữ liệu được chia theo thời gian, trong đó train interactions dùng để xây user profile, còn test interactions dùng làm ground truth để đánh giá preference alignment.

Do chi phí tương tác với OpenAI API và số lượng prompt lớn, paper dùng một subset 150 users. Với mỗi user, framework tạo nhiều instruction khác nhau theo sampling

strategy, sensitive attribute configuration và model setting. Sensitive attributes gồm gender, age group và intersectional group. Paper cũng so sánh nhiều RecLLM models/datasets, gồm MovieLens với GPT-3.5, LastFM với GPT-3.5 và LastFM với GPT-4o mini.

Kết quả cho RQ1 cho thấy true preference alignment và item-level similarity có thể đưa ra kết luận khác nhau. True preference alignment thường có similarity score thấp hơn vì nó chỉ xét các recommended items thật sự nằm trong ground truth. Tuy nhiên, khi xét fairness disparity bằng SNSR/SNSV, true preference alignment có thể cho thấy unfairness thấp hơn so với item-level similarity. Điều này nghĩa là recommendation lists có thể thay đổi khi thêm sensitive attribute, nhưng chất lượng thật sự đối với user không nhất thiết thay đổi xấu.

Một ví dụ cụ thể trong paper là với random sampling, Jaccard similarity cho category Sex là:

0.0313

theo true preference alignment, trong khi item-level similarity là:

0.1680

Với Age, true preference alignment cho Teen, Young, Adult lần lượt là:

0.0226, 0.0199, 0.0181

thấp hơn nhiều so với item-level similarity:

0.1669, 0.1847, 0.1421

Điều này cho thấy hai cách đo đang nhìn vào hai lớp hiện tượng khác nhau: raw output overlap và actual preference benefit.

Kết quả cho RQ2 cho thấy không có sampling strategy nào thắng tuyệt đối. Với Jaccard item-level similarity, random sampling đôi khi cho SNSR thấp hơn, tức nhìn bề ngoài có vẻ fair hơn. Nhưng với PRAG hoặc true preference alignment, random có thể kém hơn vì nó tạo profile ít ổn định và ít đại diện cho preference mạnh. Top-rated sampling thường giúp profile phản ánh sở thích rõ ràng hơn, còn recent sampling phù hợp hơn khi user preference thay đổi theo thời gian.

Điều này có ý nghĩa kỹ thuật quan trọng: trong RecLLM, fairness không chỉ phụ thuộc vào model mà còn phụ thuộc vào cách tạo prompt profile. Nếu profile sampling không đại diện tốt cho user, LLM có thể sinh recommendation khác biệt không phải vì sensitive bias, mà vì prompt đã cung cấp tín hiệu preference thiếu hoặc lệch. Vì vậy, fairness evaluation trong RecLLM cần báo cáo rõ profile construction strategy.

Kết quả cho RQ3 cho thấy fairness variability khác nhau theo model và dataset. Đặc

biệt, intersectional attributes thường tạo disparity lớn nhất. Khi prompt chỉ nói “Female”, recommendation có thể thay đổi nhẹ. Nhưng khi prompt nói “Young Adult Female”, model nhận thêm nhiều demographic cues, dễ kích hoạt stereotype mạnh hơn. Paper nhận xét rằng intersectional attributes amplify fairness gaps rõ hơn, đặc biệt trong domain ít cấu trúc hơn như music recommendation ở LastFM.

Một điểm đáng chú ý là GPT-3.5 và GPT-4o mini có thể thể hiện pattern khác nhau. GPT-3.5 đôi khi có recommendation list ổn định hơn theo item similarity, nhưng không nhất thiết align tốt với true preference. GPT-4o mini có thể thay đổi list nhiều hơn khi thêm sensitive attribute, nhưng lại tạo recommendation gần hơn với sở thích thật của user trong một số trường hợp. Điều này củng cố luận điểm của paper: similarity cao không đồng nghĩa với fairness cao nếu không xét ground truth preference.

Kết quả cho RQ4 liên quan đến scope của profile sampling. Khi tăng số lượng item được đưa vào user profile, LLM có nhiều tín hiệu preference hơn, nên recommendation có thể trở nên ổn định và chính xác hơn. Tuy nhiên, profile dài hơn cũng làm prompt dài hơn, tăng chi phí và có thể đưa thêm nhiều nếu lịch sử user rất đa dạng. Vì vậy, cần cân bằng giữa profile coverage, token budget và độ đại diện của profile.

Từ toàn bộ kết quả, paper rút ra một kết luận quan trọng: fairness evaluation trong RecLLM cần phân biệt *recommendation difference* với *unfairness*. Một hệ thống không nên bị xem là unfair chỉ vì list thay đổi khi thêm sensitive attribute. Nó chỉ nên bị đánh giá unfair nếu sự thay đổi đó làm giảm benefit thật sự cho một nhóm user, hoặc nếu nó làm recommendation lệch khỏi sở thích thật của group đó theo cách không công bằng.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một framework đánh giá consumer fairness cho LLM-based recommender systems. CFaiRLLM kế thừa FaiRLLM nhưng sửa hai hạn chế lớn: không đánh đồng list difference với unfairness, và không chỉ xét sensitive attribute đơn lẻ. Thay vào đó, framework đánh giá fairness dựa trên true preference alignment và intersectional sensitive attributes.

Đóng góp kỹ thuật quan trọng nhất là đưa *true preference alignment* vào fairness evaluation. Thay vì chỉ so sánh raw recommendation lists R_m và R_m^a , CFaiRLLM lọc các recommendation theo ground-truth preference để tạo R'_m và $R_m'^a$. Sau đó, fairness được đánh giá dựa trên việc các nhóm user có nhận được recommendation quality tương đương hay không. Cách này phản ánh đúng hơn bản chất consumer fairness: user cần nhận được recommendation phù hợp với sở thích thật, không chỉ một danh sách giống với baseline trung lập.

Đóng góp thứ hai là đưa *intersectional fairness* vào RecLLM evaluation. Paper cho thấy các tổ hợp sensitive attributes như gender–age có thể làm fairness gap lớn hơn so với từng attribute riêng lẻ. Điều này đặc biệt quan trọng với LLM vì natural-language

prompt có thể kích hoạt stereotype phức tạp hơn khi chứa nhiều demographic cues cùng lúc.

Đóng góp thứ ba là phân tích ảnh hưởng của *user profile sampling strategies*. Vì LLM có giới hạn token, người nghiên cứu phải chọn một phần lịch sử user để đưa vào prompt. Random, top-rated và recent sampling tạo ra các profile khác nhau, từ đó ảnh hưởng đến cả recommendation quality và fairness metrics. Do đó, profile construction không phải là chi tiết phụ, mà là một biến thực nghiệm quan trọng trong đánh giá RecLLM.

Ý nghĩa chính của paper là thay đổi cách hiểu fairness trong LLM-based recommendation. Nếu chỉ dùng item-list similarity, ta có thể kết luận sai: một list khác đi có thể là personalization tốt, còn một list rất giống baseline vẫn có thể không match sở thích thật của user. Vì vậy, fairness nên được đo theo benefit mà user nhận được, đặc biệt là alignment với true preference.

Hạn chế của paper là framework vẫn tập trung vào static group fairness và consumer-side fairness. Nó chưa xử lý đầy đủ producer fairness, long-term fairness, dynamic user preference, hoặc fairness trong feedback loop. Ngoài ra, evaluation dựa trên subset 150 users và API-based RecLLM, nên mở rộng quy mô và tái lập trên nhiều model open-source/closed-source khác vẫn là hướng cần tiếp tục.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng CFaiRLLM sang producer fairness, ví dụ đo xem RecLLM có ưu tiên brand, artist hoặc item provider nổi tiếng hơn nhóm long-tail hay không. Thứ hai, có thể xây dựng dynamic CFaiRLLM, trong đó user preference và recommendation được đánh giá qua nhiều vòng tương tác thay vì một snapshot. Thứ ba, có thể kết hợp true preference alignment với explanation fairness, kiểm tra không chỉ item được recommend có fair không mà cả lý do LLM đưa ra có stereotype hoặc demographic bias không.

Ngoài ra, paper này rất phù hợp để kế thừa trong hướng *fairness-aware LLM-based recommender systems*. Các nghiên cứu trước về LLM recommender thường tập trung vào accuracy, personalization hoặc prompt engineering, nhưng CFaiRLLM chỉ ra rằng evaluation cần xét sensitive attributes, intersectionality và ground-truth preference benefit. Một hướng phát triển hợp lý là xây dựng benchmark RecLLM có đầy đủ user history, sensitive attributes, ground-truth test preference, item/provider metadata và multi-turn feedback, để đánh giá đồng thời consumer fairness, producer fairness, personalization quality và long-term fairness. ““