

Paper

1 Tóm tắt paper: Revisiting Recommendation Loss Functions through Contrastive Learning

1.1 Ý tưởng trung tâm

Paper này khảo sát và phân tích lại các **loss functions** trong **recommender systems** dưới góc nhìn của **contrastive learning**.

Các loss recommendation được xem xét gồm:

pointwise losses, pairwise losses, listwise losses.

Cụ thể:

MSE, CCL, BPR, Softmax, InfoNCE.

Ý tưởng chính là: nhiều recommendation losses thực chất có cấu trúc rất giống contrastive losses. Chúng đều cố gắng kéo user embedding lại gần positive items và đẩy xa negative items.

Recommendation loss có thể được hiểu như một dạng contrastive objective.

1.2 Bối cảnh

Trong recommender systems, với user u và item i , mô hình thường học embedding:

$$v_u, \quad v_i,$$

sau đó tính score:

$$\hat{y}_{ui} = \langle v_u, v_i \rangle$$

hoặc cosine similarity:

$$\hat{y}_{ui} = \left\langle \frac{v_u}{\|v_u\|}, \frac{v_i}{\|v_i\|} \right\rangle.$$

Với implicit feedback:

$$r_{ui} = 1$$

nếu user u đã tương tác với item i , và:

$$r_{ui} = 0$$

nếu interaction chưa được quan sát.

Tuy nhiên, tương tự các paper BPR và NCF, paper này nhấn mạnh rằng:

$$r_{ui} = 0$$

không nhất thiết là negative thật. Nó có thể là missing value hoặc item mà user chưa được exposed.

Do đó, negative sampling có thể tạo ra bias, vì một số sampled negative items thật ra có thể là positive chưa được quan sát.

1.3 Các loại recommendation loss được khảo sát

Paper chia các loss phổ biến thành các nhóm sau.

1.3.1 Pairwise loss: BPR

BPR là pairwise ranking loss kinh điển:

$$\mathcal{L}_{\text{BPR}} = \mathbb{E}_u \mathbb{E}_{i \sim p_u^+} \sum_{j=1}^N \log(1 + \exp(\hat{y}_{uj} - \hat{y}_{ui})).$$

Trong đó:

$$i \sim p_u^+$$

là positive item của user u , còn:

$$j \sim p_i$$

là sampled negative item.

BPR muốn:

$$\hat{y}_{ui} > \hat{y}_{uj}.$$

Tức là positive item phải được xếp cao hơn negative item.

1.3.2 Listwise loss: Softmax

Softmax loss mô hình hóa xác suất chọn item i cho user u :

$$p(i|u) = \frac{\exp(\hat{y}_{ui})}{\sum_{j \in I} \exp(\hat{y}_{uj})}.$$

Loss dạng negative log-likelihood:

$$\mathcal{L}_{\text{soft}} = -\mathbb{E}_u \log \frac{\sum_{i \in I_u^+} \exp(\hat{y}_{ui})}{\sum_{j \in I} \exp(\hat{y}_{uj})}.$$

Vấn đề là tổng trên toàn bộ item set I thường rất lớn, nên cần sampled softmax hoặc approximation.

1.3.3 Contrastive loss: InfoNCE

InfoNCE trong recommendation có dạng:

$$\mathcal{L}_{\text{info}} = -\mathbb{E}_u \sum_{i \in I_u^+} \log \frac{\exp(\hat{y}_{ui})}{\exp(\hat{y}_{ui}) + \sum_{j=1}^N \exp(\hat{y}_{uj})}.$$

InfoNCE kéo positive pair (u, i) lại gần và đẩy negative pairs (u, j) ra xa.

Paper nhấn mạnh rằng InfoNCE thường được dùng như một dạng sampled softmax, nhưng về bản chất nó là contrastive objective: nó học cách nhận ra positive item giữa một tập negative/noise items.

1.4 InfoNCE+

Paper đề xuất một dạng tổng quát hơn của InfoNCE, gọi là:

InfoNCE+.

Công thức:

$$\mathcal{L}_{\text{InfoNCE}+} = -\mathbb{E}_u \sum_{i \in I_u^+} (\hat{y}_{ui} - \lambda \log N_0),$$

với:

$$N_0 = \epsilon \exp(\hat{y}_{ui}) + \sum_{j=1}^N \exp(\hat{y}_{uj}).$$

InfoNCE+ thêm hai hệ số:

$$\lambda, \quad \epsilon.$$

Trong đó:

- λ điều chỉnh trọng số của noise/negative term;
- ϵ điều chỉnh việc positive term có xuất hiện trong denominator hay không.

InfoNCE thông thường tương ứng với:

$$\lambda = 1, \quad \epsilon = 1.$$

Một phát hiện quan trọng của paper là performance tốt nhất thường xảy ra khi:

$$\epsilon = 0.$$

Điều này nghĩa là loại bỏ positive term khỏi denominator.

Bỏ positive term khỏi denominator có thể cải thiện recommendation performance.

1.5 Liên hệ với Decoupled Contrastive Learning

Khi:

$$\lambda = 1, \quad \epsilon = 0,$$

InfoNCE+ trở thành Decoupled Contrastive Learning loss:

$$\mathcal{L}_{\text{DCL}} = -\mathbb{E}_u \sum_{i \in I_u^+} \left(\hat{y}_{ui} - \log \sum_{j=1}^N \exp(\hat{y}_{uj}) \right).$$

DCL loại bỏ coupling giữa positive và negative trong denominator.

Trong InfoNCE gốc, denominator gồm cả positive và negative:

$$\exp(\hat{y}_{ui}) + \sum_j \exp(\hat{y}_{uj}).$$

Trong DCL, denominator chỉ gồm negative:

$$\sum_j \exp(\hat{y}_{uj}).$$

Ý nghĩa trực quan:

positive item được kéo lên trực tiếp,

negative items được đẩy xuống riêng biệt.

Điều này giúp tránh hiện tượng negative-positive coupling và có thể làm representation tốt hơn.

1.6 MINE và MINE+

Paper kết nối DCL với **Mutual Information Neural Estimator**.

MINE đo mutual information giữa user và item:

$$\hat{I}(u, i) = \sup \mathbb{E}_{p_{u,i}}[\hat{y}_{ui}] - \log \mathbb{E}_{p_u \otimes p_i}[\exp(\hat{y}_{ui})].$$

Trong recommendation, MINE loss có thể viết là:

$$\mathcal{L}_{\text{MINE}} = -\mathbb{E}_u \mathbb{E}_{i \sim p_u^+} [\hat{y}_{ui} - \log \mathbb{E}_{j \sim p_i}[\exp(\hat{y}_{uj})]].$$

Paper chỉ ra MINE tương đương với DCL trong recommendation setting.

Từ đó, paper đề xuất simplified loss:

$$\mathcal{L}_{\text{MINE}+} = -\mathbb{E}_u \sum_{i \sim p_u^+} \left[\hat{y}_{ui} - \lambda \log \sum_{j=1}^N \exp(\hat{y}_{uj}) \right].$$

Nếu dùng cosine similarity với temperature:

$$\hat{y}_{ui} = \frac{\left\langle \frac{v_u}{\|v_u\|}, \frac{v_i}{\|v_i\|} \right\rangle}{t},$$

thì t là temperature hyperparameter như trong contrastive learning.

Thông điệp:

MINE+ là một contrastive recommendation loss dựa trên mutual information.

1.7 Liên hệ giữa InfoNCE, MINE và BPR

Paper phân tích lower bound để so sánh BPR với InfoNCE/MINE.

Với InfoNCE và MINE, paper cho thấy chúng liên quan đến việc giảm:

$$\max_j (\hat{y}_{uj} - \hat{y}_{ui}),$$

tức là giảm mức mà negative item tốt nhất vượt qua positive item.

Trong khi BPR có dạng:

$$\mathcal{L}_{\text{BPR}} = \mathbb{E}_u \mathbb{E}_{i \sim p_u^+} \sum_j \log(1 + \exp(\hat{y}_{uj} - \hat{y}_{ui})).$$

BPR chủ yếu tối ưu từng positive-negative pair.

Vì vậy, paper cho rằng contrastive losses như InfoNCE/MINE có một bound chặt hơn theo hướng tập trung vào negative item khó nhất trong sampled negatives.

Trực quan:

BPR $\rightarrow$ pairwise comparison,

InfoNCE/MINE $\rightarrow$ contrast positive against a set of negatives.

1.8 Debiased InfoNCE

Một vấn đề lớn trong recommendation là sampled negatives không chắc là true negatives.

Với user u , paper giả sử item distribution gồm hai lớp:

$$c = +, \quad c = -.$$

Xác suất user thích một item:

$$\rho_u(c = +) = \tau_u^+,$$

và xác suất không thích:

$$\rho_u(c = -) = \tau_u^- = 1 - \tau_u^+.$$

Phân phối item tổng quát:

$$p_u(i) = \tau_u^+ p_u^+(i) + \tau_u^- p_u^-(i).$$

Trong đó:

$$p_u^+(i)$$

là positive item distribution và:

$$p_u^-(i)$$

là true negative item distribution.

Vấn đề là ta thường sample từ $p_u(i)$, không phải từ $p_u^-(i)$. Vì vậy negative samples có thể chứa hidden positives.

Paper dùng debiased contrastive learning để ước lượng negative expectation bằng cách trừ phần positive contamination:

$$p_u^-(i) = \frac{1}{\tau_u^-} (p_u(i) - \tau_u^+ p_u^+(i)).$$

Từ đó xây dựng Debiased InfoNCE, giúp giảm bias do false negatives.

1.9 Cosine Contrastive Loss và Debiased CCL

Paper cũng phân tích **Cosine Contrastive Loss**:

$$\mathcal{L}_{\text{CCL}} = \mathbb{E}_u \left[\sum_{i \in I_u^+} (1 - \hat{y}_{ui}) + \frac{w}{N} \sum_{j \in I} \text{ReLU}(\hat{y}_{uj} - \epsilon_0) \right].$$

Trong đó:

$$\hat{y}_{ui}$$

là cosine similarity, w là negative weight, và ϵ_0 là margin.

CCL muốn:

$$\hat{y}_{ui} \rightarrow 1$$

cho positive items, và:

$$\hat{y}_{uj} < \epsilon_0$$

cho negative items.

Tuy nhiên, nếu sampled negatives có hidden positives, CCL cũng bị bias.

Paper định nghĩa ideal CCL:

$$\mathcal{L}_{\text{CCL}}^{\text{ideal}} = \mathbb{E}_u [\tau_u^+ \mathbb{E}_{i \sim p_u^+} (1 - \hat{y}_{ui}) + \lambda_n \tau_u^- \mathbb{E}_{j \sim p_u^-} [\text{ReLU}(\hat{y}_{uj} - \epsilon_0)]] .$$

Sau đó xây dựng Debiased CCL:

$$\mathcal{L}_{\text{CCL}}^{\text{debiased}} = \mathbb{E}_u [\tau_u^+ \mathbb{E}_{i \sim p_u^+} (1 - \hat{y}_{ui}) + \lambda_n (\mathbb{E}_{j \sim p_u} [\text{ReLU}(\hat{y}_{uj} - \epsilon_0)] - \tau_u^+ \mathbb{E}_{k \sim p_u^+} [\text{ReLU}(\hat{y}_{uk} - \epsilon_0)])] .$$

Ý nghĩa:

negative term được chỉnh lại để loại bớt phần hidden positives.

1.10 iALS và EASE là inherently debiased

Một kết quả thú vị của paper là các linear models dùng MSE như:

$$\text{iALS}, \quad \text{EASE}$$

có thể được xem là đã có tính chất debiased trong một số điều kiện hợp lý.
MSE pointwise loss có dạng:

$$l_{\text{MSE}}^+(\hat{y}_{ui}) = (1 - \hat{y}_{ui})^2,$$

$$l_{\text{MSE}}^-(\hat{y}_{ui}) = \hat{y}_{ui}^2.$$

Ideal pointwise loss:

$$\mathcal{L}_{\text{point}} = \mathbb{E}_u \left[\tau_u^+ \mathbb{E}_{i \sim p_u^+} l^+(\hat{y}_{ui}) + \lambda \tau_u^- \mathbb{E}_{j \sim p_u^-} l^-(\hat{y}_{uj}) \right].$$

Paper phân tích debiased MSE và chỉ ra rằng nghiệm của iALS và EASE có thể hấp thụ dạng debiased loss bằng cách thay đổi hyperparameters.

Do đó:

iALS và EASE có thể được xem là inherently debiased dưới một số giả định.

Điều này giúp giải thích vì sao các mô hình tuyến tính đơn giản đôi khi vẫn rất mạnh trong recommendation benchmarks.

1.11 Thí nghiệm

Paper đánh giá trên ba dataset:

Yelp2018, Gowalla, Amazon-Books.

Dataset statistics:

Dataset	#Users	#Items	#Interactions
Yelp2018	31,668	38,048	1,561,406
Gowalla	29,858	40,981	1,027,370
Amazon-Books	52,643	91,599	2,984,108

Metrics:

Recall@20, NDCG@20.

Paper chủ yếu dùng Matrix Factorization làm backbone để so sánh loss functions công bằng, vì mục tiêu là phân tích loss chứ không phải kiến trúc model.

Các loss/methods được so sánh gồm:

iALS, MF-BPR, MF-CCL, MF-CCL-debiased, MF-MINE+.

Paper cũng so sánh với nhiều deep learning based models như:

NeuMF, LightGCN, NGCF, YouTubeNet, MultiVAE.

1.12 Kết quả thực nghiệm chính

Kết quả cho thấy:

- MF-MINE+ đạt top performance trên nhiều cột metric.
- MF-CCL-debiased thường tốt hơn MF-CCL.
- Debiased InfoNCE tốt hơn biased InfoNCE.
- Debiased CCL cải thiện trung bình khoảng 2.33% so với CCL gốc.
- Debiased InfoNCE cải thiện trung bình khoảng 1.72% so với InfoNCE gốc.
- MINE cải thiện trung bình khoảng 4.80% so với biased InfoNCE.
- MINE+ cải thiện trung bình khoảng 13.63% so với biased InfoNCE.

Một kết quả đáng chú ý trong bảng thí nghiệm:

MF-MINE+

đạt:

$\text{Recall@20} = 7.20, \quad \text{NDCG@20} = 5.92$

trên Yelp, cao hơn nhiều baseline deep learning.

Trên Gowalla:

$\text{Recall@20} = 18.53, \quad \text{NDCG@20} = 15.70.$

Điều này cho thấy chỉ thay loss function, ngay cả với backbone đơn giản như MF, cũng có thể đạt performance rất mạnh.

1.13 Phân tích hyperparameter

Paper phân tích các hyperparameter như:

λ_n , λ , number of negative samples, number of positive samples, temperature.

Một số kết luận:

- Tăng số negative samples thường giúp performance tốt hơn.
- Số positive samples trong debiased formula ảnh hưởng ít hơn số negative samples.
- Noise weight λ trong MINE+ thường tối ưu quanh:

$$1.1 \sim 1.2.$$

- Hyperparameter quá lớn có thể làm performance giảm.

1.14 Liên hệ với các paper trước

Paper này nối tiếp ba hướng trước đó:

- **BPR**: xem recommendation là pairwise ranking.
- **NCF**: xem implicit recommendation là binary classification với log loss.
- **Contrastive learning**: xem recommendation là kéo positive user-item pairs lại gần và đẩy negatives ra xa.

Nếu BPR loss là:

$$\text{positive item} > \text{negative item},$$

và NCF loss là:

$$\text{classify interaction as 1 or 0},$$

thì paper này xem recommendation như:

$$\text{contrast user with positive and negative items in embedding space.}$$

1.15 Ý nghĩa đối với câu hỏi về loss trong recommender systems

Paper này rất phù hợp để chứng minh rằng loss trong recommender systems là một vấn đề nghiên cứu riêng, vì:

- cùng một backbone MF nhưng loss khác nhau tạo ra performance rất khác nhau;
- pointwise, pairwise, listwise và contrastive losses tối ưu các mục tiêu khác nhau;
- negative sampling tạo ra bias do false negatives;
- debiased losses có thể cải thiện recommendation quality;
- contrastive learning cung cấp framework thống nhất để hiểu nhiều recommendation losses;
- các loss mới như MINE+ và Debiased CCL có thể outperform nhiều loss truyền thống.

Tóm lại:

Trong recommender systems, chọn loss không chỉ là kỹ thuật training mà quyết định cách model hiểu

1.16 Kết luận chính

Paper kết luận rằng:

- Recommendation losses có thể được hiểu thống nhất qua contrastive learning.
- InfoNCE, Softmax, BPR, CCL và MSE có liên hệ chặt chẽ nhưng tối ưu các dạng khác nhau của user-item preference.
- InfoNCE+ tổng quát hóa InfoNCE bằng cách thêm hệ số λ và ϵ .
- Khi bỏ positive term khỏi denominator, InfoNCE+ liên hệ với Decoupled Contrastive Learning.
- MINE+ là một loss mới dựa trên mutual information và đạt performance mạnh.
- Debiasing negative sampling giúp cải thiện InfoNCE và CCL.
- iALS và EASE có thể được xem là inherently debiased trong một số điều kiện.
- Loss function có thể quan trọng ngang hoặc hơn architecture trong recommender systems.

1.17 Thông điệp quan trọng nhất

Recommender loss functions có thể được hiểu như contrastive objectives giữa users và items.

Negative samples trong implicit recommendation có thể bị bias vì chứa hidden positives.

Debiased và mutual-information-based losses như Debiased CCL và MINE+ có thể cải thiện recommender models.

Một Matrix Factorization đơn giản với loss tốt có thể cạnh tranh hoặc vượt nhiều mô hình phức tạp hơn.