

Paper

1 Tóm tắt paper: A Comprehensive Survey of Loss Functions and Metrics in Deep Learning

1.1 Ý tưởng trung tâm

Paper này khảo sát toàn diện các **loss functions** và **performance metrics** trong deep learning. Điểm chính của paper là: lựa chọn loss và metric không chỉ là bước kỹ thuật, mà là một quyết định thiết kế ảnh hưởng trực tiếp đến quá trình huấn luyện, khả năng tổng quát hóa, và cách ta đánh giá mô hình.

Loss function được dùng trong quá trình huấn luyện để tối ưu tham số mô hình:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(\theta).$$

Performance metric được dùng sau hoặc trong quá trình đánh giá để đo mô hình hoạt động tốt đến đâu trên dữ liệu mới.

Paper nhấn mạnh rằng loss và metric phục vụ hai vai trò khác nhau:

Loss function $\rightarrow$ optimize model parameters,

Performance metric $\rightarrow$ evaluate generalization and compare models.

Do đó, một vấn đề quan trọng trong deep learning là làm sao chọn hoặc kết hợp loss và metric sao cho chúng phù hợp với mục tiêu thật của bài toán.

1.2 Đóng góp chính của paper

Paper đưa ra ba đóng góp lớn:

- Một framework thống nhất để hiểu cách loss functions và metrics tương ứng với các learning objectives khác nhau.
- Một thảo luận chi tiết về **multi-loss setups**, tức các hệ thống huấn luyện cân cân bằng nhiều mục tiêu cùng lúc.

- Một khảo sát các metric chuyên biệt cho các ứng dụng hiện đại như **retrieval-augmented generation** (RAG), nơi các yếu tố như faithfulness, context relevance và answer relevance rất quan trọng.

Paper cũng nêu các hướng nghiên cứu mở như tự động tìm loss function, thiết kế metric robust hơn, và xây dựng các phương pháp đánh giá dễ diễn giải hơn cho các hệ thống deep learning ngày càng phức tạp.

1.3 Loss function và performance metric

Loss function đo độ lệch giữa output dự đoán và output mong muốn trong lúc training:

$$\mathcal{L} = \mathcal{L}(y, \hat{y}).$$

Mục tiêu của training là:

$$\min_{\theta} \mathcal{L}(y, f_{\theta}(x)).$$

Trong khi đó, performance metric đo hiệu năng sau training:

$$M(y, \hat{y}).$$

Một số khác biệt chính:

- Loss được tối ưu trực tiếp bằng gradient descent.
- Metric thường dùng để đánh giá, so sánh mô hình hoặc chọn model checkpoint.
- Loss thường phụ thuộc mạnh vào architecture và task.
- Metric thường dễ diễn giải hơn và dùng để báo cáo kết quả.
- Có khi loss giảm nhưng metric không tăng, hoặc metric tăng nhưng loss không phản ánh đúng chất lượng thực tế.

Đây là một điểm rất quan trọng:

Loss là thứ mô hình tối ưu, còn metric là thứ con người thường quan tâm khi đánh giá.

1.4 Các tính chất cần xét khi chọn loss function

Paper liệt kê nhiều tính chất quan trọng của loss function:

- **Convexity**: nếu loss lồi, mọi local minimum cũng là global minimum.

- **Differentiability:** loss khả vi cho phép dùng gradient-based optimization.
- **Robustness:** loss không nên bị chi phối quá mạnh bởi outliers.
- **Smoothness:** gradient liên tục giúp quá trình tối ưu ổn định hơn.
- **Sparsity:** một số loss khuyến khích output hoặc representation thưa.
- **Monotonicity:** loss nên giảm khi dự đoán tiến gần ground truth.

Trong deep learning, dù một loss có thể lồi theo prediction, nó thường không lồi theo tham số θ vì neural network là hàm phi tuyến:

$$\mathcal{L}(y, \hat{y}) \quad \text{có thể convex theo } \hat{y},$$

nhưng:

$$\mathcal{L}(y, f_{\theta}(x)) \quad \text{thường non-convex theo } \theta.$$

1.5 Regression losses

Với regression, dữ liệu có dạng:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n,$$

trong đó:

$$y_i \in \mathbb{R}, \quad \hat{y}_i = f_{\theta}(x_i).$$

Mục tiêu là:

$$\min_{\theta} L(\{(x_i, y_i)\}_{i=1}^n, \theta).$$

1.5.1 Mean Squared Error

$$\text{MSE}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

MSE còn gọi là L_2 loss. Nó phổ biến vì đơn giản, trơn và dễ tối ưu. Gradient theo prediction là:

$$\frac{\partial}{\partial \hat{y}_i} (y_i - \hat{y}_i)^2 = -2(y_i - \hat{y}_i).$$

Ưu điểm:

- Differentiable và smooth.

- Phạt lỗi lớn mạnh hơn lỗi nhỏ.
- Phù hợp khi nhiễu gần Gaussian và không có outlier nặng.

Nhược điểm:

- Rất nhạy với outliers.
- Scale-dependent, khó so sánh giữa các bài toán khác scale.
- Có thể ưu tiên giảm lỗi rất lớn thay vì cải thiện lỗi nhỏ phổ biến.

1.5.2 Mean Absolute Error

$$\text{MAE}(\theta) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

MAE còn gọi là L_1 loss. Nó phạt lỗi tuyến tính nên robust hơn MSE với outliers.

Ưu điểm:

- Ít nhạy với outliers hơn MSE.
- Dễ diễn giải như lỗi tuyệt đối trung bình.
- Phù hợp với dữ liệu skewed hoặc có moderate outliers.

Nhược điểm:

- Không khả vi tại lỗi bằng 0.
- Gradient không phản ánh độ lớn lỗi như MSE.
- Có thể tối ưu chậm hơn trong một số trường hợp.

1.5.3 Huber Loss

$$L_{\text{Huber}}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| \leq \delta, \\ \delta (|y - \hat{y}| - \frac{1}{2}\delta), & |y - \hat{y}| > \delta. \end{cases}$$

Huber loss kết hợp MSE và MAE:

small error $\Rightarrow$ MSE-like,

large error $\Rightarrow$ MAE-like.

Ưu điểm:

- Robust hơn MSE.
- Smooth hơn MAE.
- Phù hợp khi dữ liệu có một số outlier nhưng vẫn cần gradient ổn định.

Nhược điểm:

- Cần chọn hyperparameter δ .
- Không scale-invariant.

1.5.4 Log-Cosh Loss

$$L_{\text{LogCosh}} = \frac{1}{n} \sum_{i=1}^n \log [\cosh(y_i - \hat{y}_i)].$$

Đạo hàm của một sample loss là:

$$\frac{\partial}{\partial \hat{y}} \log[\cosh(y - \hat{y})] = -\tanh(y - \hat{y}).$$

Log-Cosh giống MSE với lỗi nhỏ và ít nhạy hơn với lỗi lớn:

$$\log(\cosh z) \approx \frac{z^2}{2} \quad \text{khi } z \text{ nhỏ.}$$

Ưu điểm:

- Smooth và differentiable mọi nơi.
- Robust với moderate outliers.
- Không piecewise như Huber.

1.5.5 Quantile Loss

Với quantile level:

$$0 < q < 1,$$

quantile loss được định nghĩa:

$$L_{\text{quantile}}(y, \hat{y}) = q \max(y - \hat{y}, 0) + (1 - q) \max(\hat{y} - y, 0).$$

Khi:

$$q = 0.5,$$

quantile loss trở thành MAE.

Ý nghĩa:

- Dùng để dự đoán quantile thay vì mean.
- Cho phép phạt over-estimation và under-estimation khác nhau.
- Hữu ích cho predictive intervals và uncertainty estimation.

Ví dụ, nếu under-prediction nguy hiểm hơn, chọn:

$$q > 0.5.$$

1.5.6 Poisson Loss

Poisson loss dùng cho count data:

$$y_i \in \{0, 1, 2, \dots\}.$$

Nếu:

$$y_i \sim \text{Poisson}(\lambda_i),$$

thì negative log-likelihood bỏ hằng số là:

$$\ell_i(\lambda_i) = \lambda_i - y_i \log(\lambda_i).$$

Trong thực tế:

$$L_{\text{Poisson}} = \frac{1}{n} \sum_{i=1}^n [\hat{y}_i - y_i \log(\hat{y}_i)].$$

Để đảm bảo prediction không âm, thường dùng exponential link:

$$\hat{y}_i = \exp(w^\top x_i + b).$$

Poisson loss phù hợp cho traffic counts, disease counts, insurance claims, website visits, manufacturing defects, crime counts.

1.6 Regression metrics

Các metric phổ biến cho regression gồm:

$$\text{RMSE}, \quad \text{MAPE}, \quad \text{SMAPE}, \quad R^2, \quad \text{Adjusted } R^2.$$

1.6.1 Root Mean Squared Error

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

RMSE có cùng đơn vị với target y , nên dễ diễn giải hơn MSE. Tuy nhiên, nó vẫn nhạy với outliers do dựa trên squared error.

1.6.2 Mean Absolute Percentage Error

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left(\frac{|y_i - \hat{y}_i|}{y_i} \times 100 \right).$$

MAPE scale-independent và dễ diễn giải theo phần trăm. Tuy nhiên, nó có vấn đề nếu:

$$y_i = 0 \quad \text{hoặc} \quad y_i \approx 0.$$

1.6.3 Symmetric MAPE

$$\text{SMAPE} = \frac{2}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \times 100.$$

SMAPE xử lý over-prediction và under-prediction đối xứng hơn MAPE, nhưng vẫn có thể gặp vấn đề khi cả y_i và $\hat{y}_i$ gần 0.

1.6.4 Coefficient of Determination

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

R^2 đo tỷ lệ variance của target được mô hình giải thích. Nếu:

$$R^2 \approx 1,$$

mô hình giải thích được phần lớn biến thiên của dữ liệu. Nhưng R^2 có thể misleading trong nonlinear settings, small samples hoặc khi có outliers.

1.6.5 Adjusted R^2

$$\text{Adjusted } R^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1},$$

trong đó n là số mẫu, k là số predictors.

Adjusted R^2 phạt việc thêm predictors không hữu ích, nên phù hợp hơn R^2 khi so sánh nhiều mô hình có số feature khác nhau.

1.7 Classification losses

Với classification, mô hình học ánh xạ:

$$f_{\theta} : \mathbb{R}^d \rightarrow \mathcal{Y}.$$

Các trường hợp phổ biến:

$$\mathcal{Y} = \{0, 1\} \quad \text{binary classification,}$$

$$\mathcal{Y} = \{1, \dots, C\} \quad \text{multi-class classification,}$$

$$\mathcal{Y} \subseteq \{0, 1\}^C \quad \text{multi-label classification.}$$

1.7.1 Binary Cross-Entropy

Với label:

$$y_i \in \{0, 1\},$$

và xác suất dự đoán:

$$\hat{p}_i = f_{\theta}(x_i),$$

Binary Cross-Entropy là:

$$L(y_i, \hat{p}_i) = -[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Loss trung bình:

$$L_{\text{BCE}}(\theta) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{p}_i).$$

BCE phạt mạnh các dự đoán sai nhưng rất tự tin. Ví dụ:

$$y = 1, \quad \hat{p} \rightarrow 0 \quad \Rightarrow \quad L_{\text{BCE}} \rightarrow \infty.$$

1.7.2 Categorical Cross-Entropy

Với multi-class classification và one-hot label:

$$y_i \in \{0, 1\}^C,$$

Categorical Cross-Entropy là:

$$L_{\text{CCE}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^C y_{i,j} \log(\hat{p}_{i,j}).$$

Softmax biến logits thành phân phối xác suất:

$$\hat{p}_{i,j} = \frac{\exp(z_{i,j})}{\sum_{k=1}^C \exp(z_{i,k})}.$$

CCE tương đương maximizing log-likelihood của correct class.

1.7.3 Sparse Categorical Cross-Entropy

Khi label là integer:

$$y_i \in \{1, 2, \dots, C\},$$

Sparse CCE là:

$$L_{\text{SparseCCE}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log(\hat{p}_{i,y_i}).$$

Nó tương đương CCE nhưng không cần one-hot encoding, nên tiết kiệm bộ nhớ khi số class rất lớn.

1.7.4 Weighted Cross-Entropy

Weighted Cross-Entropy dùng cho class imbalance hoặc cost-sensitive learning.

Binary case:

$$L_{\text{WCE}}(y_i, \hat{p}_i) = -[\alpha_1 y_i \log(\hat{p}_i) + \alpha_0 (1 - y_i) \log(1 - \hat{p}_i)].$$

Multi-class case:

$$L_{\text{WCE}}(y_i, \hat{p}_i) = -\sum_{c=1}^C \alpha_c y_{i,c} \log(\hat{p}_{i,c}).$$

Thông thường:

$$\alpha_c \propto \frac{1}{f_c},$$

trong đó f_c là frequency của class c .

Ưu điểm:

minority classes có ảnh hưởng lớn hơn lên gradient.

Nhược điểm:

weights quá lớn có thể làm training không ổn định.

1.7.5 Label Smoothing

Label smoothing thay one-hot label bằng soft target:

$$\tilde{y}_{i,j} = (1 - \epsilon)y_{i,j} + \frac{\epsilon}{C}.$$

Sau đó dùng cross-entropy:

$$L_{\text{labelSmooth}} = - \sum_{j=1}^C \tilde{y}_{i,j} \log(\hat{p}_{i,j}).$$

Mục tiêu là giảm overconfidence:

$$\hat{p}_{\text{true}} \not\rightarrow 1 \quad \text{quá cực đoan.}$$

Label smoothing thường giúp generalization tốt hơn, đặc biệt trong large-scale classification.

1.7.6 Negative Log-Likelihood

Nếu ground truth là one-hot, cross-entropy trở thành:

$$H(p, q) = -\log(q_{y_t}),$$

hay:

$$\text{NLL}(x, y_t) = -\log p(y_t|x).$$

Do đó:

Cross-entropy với one-hot labels tương đương Negative Log-Likelihood.

1.7.7 PolyLoss

PolyLoss biểu diễn loss như tổ hợp các lũy thừa của:

$$1 - p_t,$$

trong đó p_t là xác suất dự đoán cho true class:

$$L = \sum_{n=0}^N \alpha_n (1 - p_t)^n.$$

Một dạng phổ biến là Poly-1:

$$L_{\text{Poly-1}} = \text{CE}(y, \hat{p}) + \epsilon(1 - p_t).$$

PolyLoss cho phép điều chỉnh độ nhạy với hard examples hoặc confident mistakes.

1.7.8 Hinge Loss

Với binary labels:

$$y \in \{-1, +1\},$$

Hinge loss là:

$$L(y, f(x)) = \max(0, 1 - yf(x)).$$

Hinge loss không chỉ yêu cầu phân loại đúng mà còn yêu cầu margin đủ lớn:

$$yf(x) \geq 1 \Rightarrow L = 0.$$

Nó phù hợp với maximum-margin learning như SVM, nhưng không trực tiếp cho xác suất dự đoán.

1.8 Classification metrics

Các metric classification thường được xây dựng từ confusion matrix.

Với binary classification:

	Predicted Positive	Predicted Negative
Actual Positive	TP	FN
Actual Negative	FP	TN

1.8.1 Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}.$$

Accuracy dễ hiểu nhưng có thể misleading khi class imbalance. Ví dụ nếu 99% dữ liệu là negative, mô hình luôn đoán negative vẫn đạt:

$$99\% \text{ accuracy,}$$

nhưng không phát hiện được positive class.

1.8.2 Balanced Accuracy

Với C classes:

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FN_i}.$$

Metric này cho mỗi class trọng số như nhau, phù hợp khi dữ liệu mất cân bằng.

1.8.3 Precision

$$\text{Precision} = \frac{TP}{TP + FP}.$$

Precision đo trong các mẫu được dự đoán positive, có bao nhiêu mẫu thật sự positive.

Precision quan trọng khi false positives tốn kém, ví dụ fraud detection hoặc medical screening.

1.8.4 Recall

$$\text{Recall} = \frac{TP}{TP + FN}.$$

Recall đo trong các positive thật, mô hình phát hiện được bao nhiêu.

Recall quan trọng khi false negatives nguy hiểm, ví dụ phát hiện bệnh hoặc phát hiện gian lận.

1.8.5 F1-score

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

F1 là harmonic mean của precision và recall. Nó hữu ích khi dữ liệu mất cân bằng và cần cân bằng false positives với false negatives.

Dạng tổng quát:

$$F_\beta = (1 + \beta^2) \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}}.$$

Nếu:

$$\beta > 1,$$

metric ưu tiên recall. Nếu:

$$\beta < 1,$$

metric ưu tiên precision.

1.8.6 Specificity và False Positive Rate

$$\text{Specificity} = \frac{TN}{TN + FP}.$$

$$\text{FPR} = \frac{FP}{TN + FP} = 1 - \text{Specificity}.$$

Specificity quan trọng khi muốn giảm false alarms.

1.8.7 Precision-Recall Curve

Precision-Recall curve biểu diễn trade-off giữa precision và recall khi thay đổi threshold.

Nó đặc biệt hữu ích khi positive class hiếm.

Average Precision hoặc AUC-PR tóm tắt diện tích dưới PR curve.

1.8.8 ROC Curve và AUC-ROC

ROC curve vẽ:

$$\text{TPR} = \frac{TP}{TP + FN}$$

theo:

$$\text{FPR} = \frac{FP}{TN + FP}.$$

AUC-ROC gần 1 nghĩa là mô hình phân biệt class tốt. Tuy nhiên, với dữ liệu mất cân bằng nặng, AUC-ROC có thể quá lạc quan, và PR curve thường hữu ích hơn.

1.9 Computer vision losses và metrics

Paper khảo sát nhiều task computer vision:

- Image classification
- Object detection
- Semantic segmentation
- Instance segmentation
- Panoptic segmentation
- Face recognition

- Monocular depth estimation
- Image generation

1.9.1 Image Classification

Loss thường dùng:

BCE, CCE, Weighted CE, Focal Loss, Hinge Loss.

Với large-scale classification như ImageNet, cross-entropy vẫn phổ biến nhưng thường kết hợp:

label smoothing, focal loss, regularization.

Metrics gồm:

Accuracy, Top- k Accuracy, Precision, Recall, F_1 , AUC.

Top- k accuracy xem dự đoán là đúng nếu true class nằm trong k class có xác suất cao nhất.

1.9.2 Object Detection

Object detection cần tối ưu đồng thời:

classification + localization.

Loss tổng quát:

$$L = L_{\text{class}} + \lambda L_{\text{reg}}.$$

Các localization losses gồm:

Smooth L1, Balanced L1, IoU, GIoU, DIoU, CIoU.

IoU

$$\text{IoU} = \frac{\text{Area}(B_p \cap B_t)}{\text{Area}(B_p \cup B_t)}.$$

IoU loss:

$$L_{\text{IoU}} = 1 - \text{IoU}.$$

Vấn đề của IoU loss là nếu hai box không overlap:

$$B_p \cap B_t = \emptyset,$$

thì gradient có thể không hữu ích.

GIoU

$$L_{\text{GIoU}} = 1 - \text{IoU} + \frac{\text{Area}(C \setminus (B_p \cup B_t))}{\text{Area}(C)},$$

trong đó C là bounding box nhỏ nhất chứa cả predicted box và ground-truth box. GIoU xử lý tốt hơn trường hợp non-overlap.

DIoU

$$L_{\text{DIoU}} = 1 - \text{IoU} + \frac{d^2(B_p, B_t)}{c^2},$$

trong đó d là khoảng cách giữa centroid của hai box, còn c là đường chéo của enclosing box.

CIoU

$$L_{\text{CIoU}} = L_{\text{DIoU}} + \alpha v,$$

với:

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w_t}{h_t} - \arctan \frac{w_p}{h_p} \right)^2.$$

CIoU bổ sung aspect-ratio consistency, nên tốt hơn khi box overlap nhưng shape khác nhau.

Focal Loss Focal loss xử lý class imbalance trong object detection:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t).$$

Nếu example dễ:

$$p_t \rightarrow 1,$$

thì:

$$(1 - p_t)^\gamma \rightarrow 0,$$

loss bị giảm trọng số. Vì vậy mô hình tập trung vào hard examples.

1.9.3 Segmentation

Semantic segmentation thường dùng:

CCE, IoU Loss, Dice Loss, Tversky Loss, Lovasz Loss, Focal Loss.

Dice coefficient:

$$\text{Dice} = \frac{2 \sum_i p_i y_i}{\sum_i p_i + \sum_i y_i}.$$

Dice loss:

$$L_{\text{Dice}} = 1 - \text{Dice}.$$

Tversky index:

$$T = \frac{TP}{TP + \alpha FP + \beta FN}.$$

Tversky loss cho phép điều chỉnh trade-off giữa false positives và false negatives:

$$L_{\text{Tversky}} = 1 - T.$$

Metrics cho segmentation gồm:

IoU, Pixel Accuracy, Boundary F_1 , Average Precision, Average Recall.

Panoptic segmentation dùng:

Panoptic Quality.

1.9.4 Face Recognition

Face recognition cần học embedding sao cho identity khác nhau tách xa, identity giống nhau gần nhau.

Loss phổ biến:

A-Softmax, Center Loss, CosFace, ArcFace, Triplet Loss, Contrastive Loss, Circle Loss, E

Triplet loss:

$$L_{\text{triplet}} = \max(0, d(a, p) - d(a, n) + m),$$

trong đó a là anchor, p là positive, n là negative.

Mục tiêu:

$$d(a, p) + m < d(a, n).$$

1.9.5 Monocular Depth Estimation

Loss dùng trong depth estimation gồm:

Pointwise Error, Scale Invariant Error, SSIM, Photometric Loss, Disparity Smoothness, App

Một loss tổng hợp có thể có dạng:

$$L = L_{\text{ssi}} + \alpha L_{\text{reg}},$$

trong đó L_{ssi} đảm bảo alignment toàn cục, còn L_{reg} giúp làm sắc nét biên và chi tiết local.

Metrics depth estimation gồm:

AbsRel, RMSE, log RMSE, Threshold Accuracy, Mean Log10 Error, %Pixels with High Error

1.9.6 Image Generation

Loss cho image generation gồm:

Reconstruction Loss, D_{KL} , Perceptual Loss, Adversarial Loss, Wasserstein Loss, Negative Log

Ví dụ với VAE:

$$L_{\text{VAE}} = L_{\text{recon}} + D_{\text{KL}}(q_{\phi}(z|x)||p(z)).$$

GAN dùng adversarial objective, còn WGAN thay divergence bằng Wasserstein distance để ổn định training hơn.

Metrics generation gồm:

PSNR, SSIM, Inception Score, FID.

FID đánh giá khoảng cách giữa phân phối feature của ảnh sinh và ảnh thật:

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}).$$

1.10 Natural Language Processing losses và metrics

Paper khảo sát các task NLP:

- Text classification
- Language modeling
- Machine translation
- Named entity recognition
- Part-of-speech tagging
- Sentiment analysis
- Text summarization
- Question answering
- Language detection
- Speech recognition

1.10.1 Token-level Cross-Entropy

Trong language modeling, model dự đoán token tiếp theo:

$$p_{\theta}(x_t|x_{<t}).$$

Loss là:

$$L_{\text{LM}} = - \sum_{t=1}^T \log p_{\theta}(x_t|x_{<t}).$$

Đây là token-level cross-entropy, dùng rộng rãi cho language modeling, translation, QA, summarization và nhiều task NLP khác.

1.10.2 Perplexity

Perplexity là metric phổ biến cho language models:

$$\text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log p_{\theta}(x_t|x_{<t}) \right).$$

Perplexity càng thấp thì mô hình càng gần xác suất cao cho sequence thật.

1.10.3 BLEU và ROUGE

BLEU thường dùng cho machine translation:

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right),$$

trong đó p_n là n-gram precision, còn BP là brevity penalty.

ROUGE thường dùng cho summarization, đo overlap giữa generated summary và reference summary, đặc biệt recall-oriented overlap.

1.10.4 Minimum Risk Training

Minimum Risk Training tối ưu trực tiếp expected risk theo metric sequence-level:

$$L_{\text{MRT}} = \mathbb{E}_{\hat{y} \sim p_{\theta}(\hat{y}|x)}[\Delta(\hat{y}, y)].$$

Vì không thể tính tổng trên toàn bộ sequence space, paper mô tả approximation bằng sampled set:

$$L_{\text{MRT}} \approx \sum_{\hat{y} \in \mathcal{Y}_s} \frac{\exp(\alpha \log p_{\theta}(\hat{y}|x))}{\sum_{\hat{y}' \in \mathcal{Y}_s} \exp(\alpha \log p_{\theta}(\hat{y}'|x))} \Delta(\hat{y}, y).$$

Ví dụ:

$$\Delta(\hat{y}, y) = 1 - \text{BLEU}(\hat{y}, y)$$

cho machine translation, hoặc:

$$\Delta(\hat{y}, y) = 1 - \text{ROUGE}(\hat{y}, y)$$

cho summarization.

Ý nghĩa:

MRT giúp training objective gần hơn với evaluation metric.

1.10.5 REINFORCE

REINFORCE xem sequence generation như policy optimization. Model sinh sequence như một stochastic policy:

$$\pi_{\theta}(\tau),$$

và nhận reward từ output cuối cùng, ví dụ BLEU hoặc ROUGE.

Mục tiêu:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau)].$$

Gradient policy:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau) \nabla_\theta \log \pi_\theta(\tau)].$$

REINFORCE hữu ích khi metric không khả vi, nhưng thường có variance cao.

1.11 Retrieval-Augmented Generation

RAG có hai thành phần:

retriever + generator.

Do đó loss và metric phải đánh giá cả retrieval quality và generation quality.

Loss thường dùng:

CE, Contrastive Loss, Marginal Ranking, NLL, D_{KL} .

Metrics cho RAG gồm:

Answer Semantic Similarity, Answer Correctness, Answer Relevance, Context Precision, Context Recall

1.11.1 Answer Relevance

Answer Relevance đo câu trả lời có bám sát câu hỏi hay không. Một cách tính là tạo các câu hỏi ngược từ answer, embedding chúng, rồi so với embedding của câu hỏi gốc:

$$\text{AnswerRelevance} = \frac{1}{N} \sum_{i=1}^N \cos(E_{g_i}, E_o).$$

Metric này đo topical relevance, nhưng không đảm bảo factual correctness.

1.11.2 Context Precision

Context Precision đo liệu các chunks liên quan có được xếp ở vị trí cao trong retrieved context không.

Với K context chunks:

$$\{c_1, \dots, c_K\},$$

và $v_k = 1$ nếu chunk c_k relevant, Context Precision@K là:

$$\text{CP@K} = \frac{\sum_{k=1}^K (\text{Precision@k} \cdot v_k)}{\text{Total relevant items in top } K}.$$

Metric này quan trọng vì trong RAG, chỉ top- K chunks thường được đưa vào generator.

1.11.3 Faithfulness

Faithfulness đo câu trả lời có được hỗ trợ bởi retrieved context hay không.

Một answer có thể relevant nhưng không faithful nếu nó hallucinate hoặc đưa thông tin không có trong context.

Do đó RAG cần đồng thời:

answer relevance và faithfulness.

1.12 Combining multiple metrics và multi-loss setups

Paper nhấn mạnh rằng nhiều bài toán hiện đại không thể được tối ưu bằng một loss duy nhất.

Một objective tổng quát:

$$L_{\text{total}} = \sum_{k=1}^K \lambda_k L_k.$$

Ví dụ trong object detection:

$$L = L_{\text{class}} + \lambda L_{\text{bbox}}.$$

Trong depth estimation:

$$L = L_{\text{photometric}} + \lambda_1 L_{\text{smoothness}} + \lambda_2 L_{\text{consistency}}.$$

Trong RAG:

$$L = L_{\text{retrieval}} + \lambda L_{\text{generation}}.$$

Vấn đề chính là chọn trọng số:

$$\lambda_k.$$

Nếu chọn sai, mô hình có thể tối ưu một mục tiêu phụ quá mạnh và làm giảm mục tiêu chính.

1.13 Challenges và future directions

Paper nêu một số thách thức lớn:

- **Loss-metric mismatch:** loss huấn luyện không trùng với metric đánh giá.
- **Class imbalance:** accuracy hoặc CE có thể không phản ánh đúng minority class.
- **Outliers:** MSE và RMSE dễ bị chi phối bởi extreme errors.
- **Non-differentiable metrics:** BLEU, ROUGE, IoU, F1 thường khó tối ưu trực tiếp.
- **Multi-objective learning:** nhiều task cần cân bằng classification, localization, reconstruction, ranking, faithfulness.
- **Interpretability:** loss value thường khó diễn giải.
- **Evaluation for LLM/RAG:** cần metrics đo factuality, faithfulness, context relevance, answer correctness.
- **Automation:** cần phương pháp tự động tìm hoặc thiết kế loss function phù hợp.

Một hướng mở quan trọng là **automatic loss-function search**:

$$\mathcal{L}^* = \arg \max_{\mathcal{L} \in \mathcal{S}} \text{Metric}(\text{Train}(f_{\theta}, \mathcal{L})).$$

Tức là thay vì chọn loss thủ công, ta tìm loss giúp mô hình đạt metric mong muốn tốt nhất.

1.14 Liên hệ với câu hỏi: vì sao giải thích loss là vấn đề của ML?

Paper này hỗ trợ trực tiếp luận điểm rằng loss là vấn đề trung tâm của ML vì:

- Loss quyết định gradient mà mô hình nhận được.
- Loss quyết định mô hình ưu tiên loại lỗi nào.
- Loss phải phù hợp với data characteristics như outliers, imbalance, noise, sparsity.
- Loss có thể khác metric, tạo ra mismatch giữa training objective và evaluation objective.
- Với các task phức tạp, một loss đơn lẻ thường không đủ.
- Trong các hệ thống hiện đại như RAG, metric không chỉ là accuracy mà còn gồm faithfulness, relevance, correctness và context quality.

Nói cách khác:

Loss là cách ta biến mục tiêu thực tế thành tín hiệu tối ưu hóa.

Nếu loss sai hoặc không phù hợp:

$$\min_{\theta} \mathcal{L}(\theta) \not\Rightarrow \max_{\theta} \text{Utility}(\theta).$$

1.15 Kết luận chính

Paper kết luận rằng lựa chọn loss và metric là một phần quan trọng trong thiết kế deep learning pipeline.

Một lựa chọn tốt cần xét:

- task type: regression, classification, detection, segmentation, generation, NLP, RAG;
- data properties: outliers, imbalance, noise, sparsity, scale;
- optimization properties: differentiability, smoothness, convexity, gradient stability;
- evaluation goals: accuracy, calibration, overlap, perceptual quality, semantic quality, faithfulness;
- deployment constraints: robustness, interpretability, cost of false positives/false negatives.

1.16 Thông điệp quan trọng nhất

Không có loss function hoặc metric tốt nhất cho mọi bài toán.

Loss phải được chọn theo dữ liệu, task, architecture và mục tiêu đánh giá.

Trong deep learning hiện đại, vấn đề không chỉ là giảm loss, mà là làm cho loss phù hợp với mục tiêu