

Paper

1 Tóm tắt paper: BPR – Bayesian Personalized Ranking from Implicit Feedback

1.1 Bài toán chính

Paper nghiên cứu bài toán **item recommendation** từ **implicit feedback**, ví dụ:

clicks, purchases, views, watch history.

Khác với explicit feedback như rating 1-5 sao, implicit feedback chỉ cho biết user đã tương tác với item nào. Nếu user chưa tương tác với một item, ta không biết đó là vì user không thích item đó hay vì user chưa từng thấy item đó.

Do đó, dữ liệu implicit feedback chỉ có positive observations:

$$S \subseteq U \times I,$$

trong đó U là tập user, I là tập item, và:

$$(u, i) \in S$$

nghĩa là user u đã tương tác với item i .

Mục tiêu của recommender system không phải chỉ là dự đoán user có tương tác với item hay không, mà là tạo ra một **personalized ranking**:

$$>_u \subset I^2,$$

tức là một thứ tự xếp hạng item riêng cho từng user u .

1.2 Vấn đề với cách học truyền thống

Cách phổ biến trước đó là biến bài toán implicit feedback thành bài toán classification:

$$(u, i) \in S \Rightarrow y_{ui} = 1,$$

$$(u, i) \notin S \Rightarrow y_{ui} = 0.$$

Tức là tất cả item chưa được user tương tác đều bị xem là negative.

Paper chỉ ra đây là giả định sai, vì các item chưa observed gồm hai loại:

true negative và missing value.

Nếu coi toàn bộ missing values là negative, model sẽ học rằng tất cả item chưa tương tác đều không được thích. Điều này đặc biệt nguy hiểm vì chính các item chưa tương tác là những item cần được xếp hạng trong tương lai.

Do đó, paper cho rằng tối ưu pointwise loss như MSE hoặc logistic classification không phản ánh đúng mục tiêu recommendation.

1.3 Ý tưởng chính của BPR

BPR thay vì học trên từng cặp user-item (u, i) , nó học trên từng bộ ba:

$$(u, i, j),$$

trong đó:

$$i \in I_u^+,$$

$$j \in I \setminus I_u^+.$$

Ở đây:

$$I_u^+ = \{i \in I : (u, i) \in S\}$$

là tập item mà user u đã tương tác.

BPR giả định rằng nếu user u đã tương tác với item i , nhưng chưa tương tác với item j , thì user thích i hơn j :

$$i >_u j.$$

Tập training triples được định nghĩa là:

$$D_S = \{(u, i, j) \mid i \in I_u^+ \wedge j \in I \setminus I_u^+\}.$$

Ý nghĩa:

$$(u, i, j) \in D_S \quad \Rightarrow \quad \text{user } u \text{ prefers item } i \text{ over item } j.$$

Đây là điểm quan trọng nhất của paper:

BPR tối ưu ranking giữa các item, thay vì tối ưu score tuyệt đối của từng item.

1.4 Mô hình scoring

Một recommender model dự đoán score:

$$\hat{x}_{ui},$$

thể hiện mức độ user u thích item i .

Để so sánh hai item i và j , BPR dùng hiệu score:

$$\hat{x}_{uij} = \hat{x}_{ui} - \hat{x}_{uj}.$$

Nếu:

$$\hat{x}_{uij} > 0,$$

thì model xếp item i cao hơn item j cho user u .

BPR định nghĩa xác suất user u thích i hơn j là:

$$p(i >_u j \mid \Theta) = \sigma(\hat{x}_{uij}),$$

trong đó σ là sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

1.5 Bayesian Personalized Ranking Objective

Paper xây dựng BPR từ góc nhìn Bayesian.

Mục tiêu là tìm tham số Θ tối đa hóa posterior:

$$p(\Theta \mid >_u) \propto p(>_u \mid \Theta)p(\Theta).$$

Với giả định các pairwise preferences độc lập, likelihood là:

$$p(>_u \mid \Theta) = \prod_{(u,i,j) \in D_S} p(i >_u j \mid \Theta).$$

Thay công thức sigmoid vào:

$$p(>_u | \Theta) = \prod_{(u,i,j) \in D_S} \sigma(\hat{x}_{uij}).$$

Paper dùng Gaussian prior cho tham số:

$$p(\Theta) \sim \mathcal{N}(0, \lambda_\Theta I).$$

Lấy log posterior, ta được objective BPR-Opt:

$$\text{BPR-Opt} = \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{uij}) - \lambda_\Theta \|\Theta\|^2.$$

Vì thường ta tối thiểu hóa loss, BPR loss có thể viết là:

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) + \lambda_\Theta \|\Theta\|^2.$$

Ý nghĩa:

$$\hat{x}_{ui} \gg \hat{x}_{uj} \Rightarrow \sigma(\hat{x}_{ui} - \hat{x}_{uj}) \approx 1 \Rightarrow \text{loss nhỏ.}$$

Ngược lại, nếu model xếp negative item j cao hơn positive item i :

$$\hat{x}_{ui} < \hat{x}_{uj},$$

thì:

$$\sigma(\hat{x}_{ui} - \hat{x}_{uj}) < 0.5,$$

và loss tăng.

1.6 Liên hệ với AUC

Paper chỉ ra BPR có liên hệ gần với tối ưu AUC.

AUC cho user u đo xác suất model xếp một positive item cao hơn một unobserved item:

$$\text{AUC}(u) = \frac{1}{|I_u^+| |I \setminus I_u^+|} \sum_{i \in I_u^+} \sum_{j \in I \setminus I_u^+} \delta(\hat{x}_{uij} > 0).$$

Trong đó:

$$\delta(\hat{x}_{uij} > 0) = \begin{cases} 1, & \hat{x}_{uij} > 0, \\ 0, & \text{otherwise.} \end{cases}$$

Vấn đề là hàm indicator này không khả vi, nên khó tối ưu trực tiếp.
BPR thay indicator bằng hàm khả vi:

$$\ln \sigma(\hat{x}_{uij}).$$

Do đó, BPR có thể được hiểu là một surrogate differentiable cho AUC optimization.

BPR tối ưu một phiên bản trơn, khả vi của mục tiêu ranking/AUC.

1.7 Thuật toán LearnBPR

Vì số lượng training triples rất lớn:

$$|D_S| = O(|S||I|),$$

không thể tính gradient đầy đủ trên toàn bộ D_S .

Paper đề xuất thuật toán **LearnBPR**, dùng stochastic gradient descent với bootstrap sampling.

Ở mỗi bước:

$$(u, i, j) \sim D_S,$$

sau đó cập nhật tham số:

$$\Theta \leftarrow \Theta + \alpha \left(\frac{e^{-\hat{x}_{uij}}}{1 + e^{-\hat{x}_{uij}}} \frac{\partial \hat{x}_{uij}}{\partial \Theta} + \lambda_{\Theta} \Theta \right).$$

Ý tưởng là lấy ngẫu nhiên một triple (u, i, j) thay vì duyệt theo user hoặc item.

Paper cho rằng sampling ngẫu nhiên giúp hội tụ tốt hơn vì tránh việc update quá nhiều lần liên tiếp trên cùng một user-item pair.

1.8 Áp dụng BPR cho Matrix Factorization

Với Matrix Factorization, score được tính bằng dot product giữa vector user và vector item:

$$\hat{x}_{ui} = \langle w_u, h_i \rangle = \sum_{f=1}^k w_{uf} h_{if}.$$

Trong đó:

$$w_u$$

là latent vector của user u , và:

$$h_i$$

là latent vector của item i .

Với BPR, ta tối ưu hiệu:

$$\hat{x}_{uij} = \hat{x}_{ui} - \hat{x}_{uj} = \langle w_u, h_i - h_j \rangle.$$

Gradient cho một triple là:

$$\frac{\partial \hat{x}_{uij}}{\partial w_{uf}} = h_{if} - h_{jf},$$

$$\frac{\partial \hat{x}_{uij}}{\partial h_{if}} = w_{uf},$$

$$\frac{\partial \hat{x}_{uij}}{\partial h_{jf}} = -w_{uf}.$$

Model này được gọi là:

BPR-MF.

1.9 Áp dụng BPR cho adaptive kNN

Paper cũng áp dụng BPR cho item-based k-nearest-neighbor.

Với item-based kNN, score của user u với item i là:

$$\hat{x}_{ui} = \sum_{l \in I_u^+, l \neq i} c_{il},$$

trong đó c_{il} là similarity giữa item i và item l .

Thay vì dùng heuristic similarity như cosine similarity:

$$c_{ij}^{\text{cosine}} = \frac{|U_i^+ \cap U_j^+|}{\sqrt{|U_i^+| |U_j^+|}},$$

paper học trực tiếp similarity matrix C bằng BPR.

Model này được gọi là:

BPR-kNN.

1.10 So sánh với Weighted Regularized Matrix Factorization

Paper so sánh BPR với Weighted Regularized Matrix Factorization, gọi tắt là WR-MF.

WR-MF tối ưu squared loss:

$$\sum_{u \in U} \sum_{i \in I} c_{ui} (\langle w_u, h_i \rangle - 1)^2 + \lambda \|W\|_F^2 + \lambda \|H\|_F^2.$$

Điểm khác biệt:

WR-MF là pointwise objective,

còn:

BPR là pairwise ranking objective.

Paper lập luận rằng recommendation từ implicit feedback là bài toán ranking/classification hơn là regression, nên BPR phù hợp hơn squared loss.

1.11 Thí nghiệm

Paper đánh giá trên hai dataset:

- **Rossmann**: online shopping dataset, gồm 10,000 users, 4,000 items và 426,612 purchases.
- **Netflix subsample**: 10,000 users, 5,000 items và 565,738 rating actions, nhưng rating scores bị bỏ đi để tạo implicit feedback.

Metric đánh giá là average AUC với leave-one-out evaluation.

Mỗi user được giữ lại một interaction làm test:

$$S_{\text{test}},$$

còn phần còn lại dùng để train:

$$S_{\text{train}}.$$

AUC được tính bằng:

$$\text{AUC} = \frac{1}{|U|} \sum_u \frac{1}{|E(u)|} \sum_{(i,j) \in E(u)} \delta(\hat{x}_{ui} > \hat{x}_{uj}).$$

1.12 Kết quả chính

Kết quả thực nghiệm cho thấy:

- BPR-MF outperform SVD-MF và WR-MF.

- BPR-kNN outperform cosine-kNN.
- Với cùng model class, cách tối ưu khác nhau dẫn đến chất lượng ranking rất khác nhau.
- BPR-MF với số chiều nhỏ có thể đạt chất lượng tương đương hoặc tốt hơn WR-MF với số chiều lớn.
- Personalized ranking outperform non-personalized ranking rất rõ.

Hình 6 trong paper cho thấy trên cả Rossmann và Netflix, các đường BPR-MF và BPR-kNN nằm cao hơn các baseline như WR-MF, SVD-MF, cosine-kNN và most-popular.

Thông điệp thực nghiệm quan trọng là:

Chất lượng recommender không chỉ phụ thuộc vào model, mà phụ thuộc rất mạnh vào loss/optimization.

1.13 Kết luận chính

Paper đưa ra các kết luận sau:

- Trong implicit feedback, không nên coi tất cả missing user-item pairs là negative examples.
- Personalized recommendation nên được xem là bài toán ranking.
- BPR tạo training data dưới dạng pairwise preferences (u, i, j) .
- BPR-Opt được suy ra từ maximum posterior estimation.
- BPR loss là surrogate khả vi cho ranking/AUC optimization.
- LearnBPR dùng stochastic gradient descent với bootstrap sampling để tối ưu hiệu quả.
- BPR có thể áp dụng cho nhiều model class, như matrix factorization và adaptive kNN.
- Thực nghiệm cho thấy BPR cải thiện rõ rệt ranking quality so với các phương pháp tối ưu pointwise.

1.14 Thông điệp quan trọng nhất

Với recommender system từ implicit feedback, mục tiêu đúng không phải là dự đoán interaction, mà là

BPR biến recommendation thành bài toán học pairwise preference: positive item nên đứng trên unobserved

Chọn đúng loss function có thể quan trọng ngang hoặc hơn chọn model architecture.