

Paper

1 Tóm tắt paper: Advancing Loss Functions in Recommender Systems

1.1 Ý tưởng trung tâm

Paper nghiên cứu vai trò của **loss functions trong recommender systems**, đặc biệt là hai loss hiện đại và hiệu quả:

Softmax Loss (SL)

và

Cosine Contrastive Loss (CCL).

Paper chỉ ra rằng mặc dù SL và CCL có dạng công thức rất khác nhau, cả hai đều có thể được hiểu như các biến thể của **Distributionally Robust Optimization**:

DRO.

Tức là thay vì chỉ tối ưu trên phân phối training quan sát được, mô hình tối ưu trên một họ phân phối bị nhiễu hoặc bị dịch chuyển quanh phân phối training.

Thông điệp chính là:

SL và CCL hiệu quả vì chúng có tính chất robust optimization.

Tuy nhiên, mỗi loss cũng có hạn chế riêng:

SL $\rightarrow$ nhạy với false negatives,

CCL $\rightarrow$ sử dụng dữ liệu kém vì filter quá nhiều negatives.

Để khắc phục, paper đề xuất một loss mới:

DrRL = Distributional Robust Rényi Loss.

DrRL dùng **Rényi-divergence-constrained DRO** để tổng quát hóa SL và CCL, giữ ưu điểm của cả hai nhưng giảm nhược điểm của từng loss.

1.2 Bài toán recommendation

Paper tập trung vào **collaborative filtering**.

Gọi:

$$U$$

là tập user, và:

$$I$$

là tập item.

Tập interaction quan sát được:

$$O \subset U \times I.$$

Nếu:

$$(u, i) \in O,$$

nghĩa là user u đã tương tác với item i , ví dụ click hoặc purchase.

Với mỗi user u , positive item set là:

$$I_u^+ = \{i \in I : (u, i) \in O\}.$$

Negative hoặc unobserved item set là:

$$I_u^- = I \setminus I_u^+.$$

Mục tiêu của recommender system là xếp hạng các item trong I_u^- sao cho những item user có thể quan tâm được đưa lên cao.

1.3 Embedding-based recommender model

Paper xét các mô hình embedding-based.

Mỗi user u được ánh xạ thành embedding:

$$e_u \in \mathbb{R}^d.$$

Mỗi item i được ánh xạ thành embedding:

$$e_i \in \mathbb{R}^d.$$

Score dự đoán được tính bằng similarity:

$$f(u, i).$$

Paper chủ yếu dùng cosine similarity:

$$f(u, i) = \frac{e_u^\top e_i}{\|e_u\| \|e_i\|}.$$

Score này càng cao thì mô hình càng tin rằng user u thích item i .

1.4 Softmax Loss

Softmax Loss cố gắng làm score của positive item cao hơn score của negative items.

Với user u , loss là:

$$L_{\text{SL}}(u) = -\frac{1}{|I_u^+|} \sum_{i \in I_u^+} \log \left(\frac{\exp(f(u, i)/\tau)}{\sum_{j \in I_u^-} \exp(f(u, j)/\tau)} \right).$$

Có thể viết lại thành:

$$L_{\text{SL}}(u) = -\frac{1}{|I_u^+|} \sum_{i \in I_u^+} \frac{f(u, i)}{\tau} + \log \left(\sum_{j \in I_u^-} \exp(f(u, j)/\tau) \right).$$

Trong đó:

$$\tau$$

là temperature parameter.

SL có ưu điểm là tập trung mạnh vào negative items có score cao. Nhưng chính điều này cũng gây nhược điểm: nếu một negative item thật ra là **false negative**, tức user có thể thích nó nhưng chưa tương tác, thì SL có thể phạt quá mạnh.

1.5 Cosine Contrastive Loss

Cosine Contrastive Loss có dạng:

$$L_{\text{CCL}}(u) = -\frac{1}{|I_u^+|} \sum_{i \in I_u^+} f(u, i) + \frac{\alpha}{|I_u^-|} \sum_{j \in I_u^-} (f(u, j) - \beta)_+.$$

Trong đó:

$$(x)_+ = \max(x, 0),$$

$$\beta$$

là margin hoặc truncation threshold, và:

$$\alpha$$

điều chỉnh trọng số của negative term.

CCL chỉ phạt negative item nếu:

$$f(u, j) > \beta.$$

Nếu:

$$f(u, j) \leq \beta,$$

negative item bị bỏ qua trong training.

Vì vậy, CCL có cơ chế truncation:

low-score negatives bị filter out.

Ưu điểm là CCL có thể robust hơn với nhiều negative dễ. Nhưng nhược điểm là nó có thể bỏ quá nhiều dữ liệu.

Paper cho thấy CCL thường filter hơn:

$$90\%$$

negative instances, gây **low data utilization**.

1.6 Distributionally Robust Optimization

DRO tối ưu mô hình trong trường hợp phân phối test có thể khác phân phối training.

DRO objective tổng quát:

$$L_{\text{DRO}} = \max_Q \mathbb{E}_{x \sim Q}[L(x; \theta)] \quad \text{s.t.} \quad D(Q, Q_0) \leq \eta.$$

Trong đó:

$$Q_0$$

là phân phối training quan sát được, còn:

Q

là phân phối bị perturb nhưng vẫn nằm gần Q_0 .

Ý nghĩa:

mô hình được train để tốt trong worst-case distribution gần training distribution.

Điều này hữu ích trong recommender systems vì dữ liệu thường có distribution shift:

user preference thay đổi theo thời gian,

bias trong dữ liệu interaction,

false negatives,

exposure bias.

1.7 SL và CCL đều là DRO-enhanced losses

Một đóng góp lý thuyết quan trọng của paper là chứng minh SL và CCL đều có thể được viết dưới dạng DRO.

Gọi:

P_u^-

là phân phối negative item quan sát được của user u , tức uniform distribution trên I_u^- .

Paper chỉ ra SL và CCL đều tương đương với objective:

$$L_{\text{DRO}}(u) = -\frac{1}{|I_u^+|} \sum_{i \in I_u^+} f(u, i) + \max_{Q_u} \mathbb{E}_{j \sim Q_u} [f(u, j)].$$

Điểm khác nhau là constraint trên Q_u .

1.7.1 SL dùng KL-divergence

Với SL:

$$D_{\text{KL}}(Q_u, P_u^-) = \sum_{j \in I_u^-} Q_u(j) \log \frac{Q_u(j)}{P_u^-(j)} \leq \eta.$$

Do đó SL tương ứng với:

KL-divergence-constrained DRO.

1.7.2 CCL dùng worst-case regret divergence

Với CCL:

$$D_{\text{WR}}(Q_u, P_u^-) = \sup_{j \in I_u^-} \log \frac{Q_u(j)}{P_u^-(j)} \leq \log(\alpha).$$

Do đó CCL tương ứng với:

worst-case-regret-divergence-constrained DRO.

1.8 Vì sao SL nhạy với false negatives?

Với SL, worst-case distribution gán weight cho negative item j :

$$Q_u^*(j) = w_{uj} P_u^-(j),$$

trong đó:

$$w_{uj} \propto \exp(f(u, j)/\tau).$$

Vì exponential function tăng rất nhanh, negative item có score cao sẽ nhận trọng số rất lớn.

Nếu một item j bị xem là negative nhưng thật ra user có thể thích nó, tức là:

$$j = \text{false negative},$$

thì item này thường có score cao:

$$f(u, j) \text{ lớn.}$$

Khi đó SL sẽ gán weight rất lớn cho nó và ép model đẩy nó xuống mạnh.

Đây là lý do:

SL có thể bị ảnh hưởng nghiêm trọng bởi false negatives.

Paper cho thấy empirically, noisy data trong SL có thể nhận weight lớn hơn average weight hơn 20 lần.

1.9 Vì sao CCL sử dụng dữ liệu kém?

CCL dùng truncation:

$$(f(u, j) - \beta)_+.$$

Nếu:

$$f(u, j) \leq \beta,$$

negative item đó không đóng góp gradient.

Cơ chế này giúp tập trung vào hard negatives, nhưng nếu threshold β quá cao hoặc score distribution lệch, phần lớn negatives sẽ bị bỏ.

Paper quan sát rằng CCL có thể filter hơn:

$$90\%$$

negative instances.

Điều này gây ra:

CCL bỏ lỡ nhiều training signals từ các negative items có score thấp nhưng số lượng lớn.

Ngoài ra, CCL dùng cùng một β cho mọi user, trong khi user preference distribution khác nhau. Có user thích rộng, có user kén chọn hơn. Vì vậy threshold nên được cá nhân hóa:

$$\beta_u.$$

1.10 Đề xuất: Distributional Robust Rényi Loss

Paper đề xuất DrRL:

DrRL = Distributional Robust Rényi Loss.

Ý tưởng là giữ dạng DRO:

$$L_{\text{DrRL}}(u) = -\frac{1}{|I_u^+|} \sum_{i \in I_u^+} f(u, i) + \max_{Q_u} \mathbb{E}_{j \sim Q_u} [f(u, j)],$$

nhưng thay constraint bằng **Rényi divergence**:

$$D_\gamma(Q_u, P_u^-) = \sum_{j \in I_u^-} P_u^-(j) \phi_\gamma \left(\frac{Q_u(j)}{P_u^-(j)} \right) \leq \eta.$$

Trong đó:

$$\phi_\gamma(t) = \frac{1}{\gamma(\gamma-1)}(t^\gamma - \gamma t + \gamma - 1).$$

Tham số:

$$\gamma$$

điều khiển dạng divergence.

Rényi divergence là một họ divergence tổng quát, có thể bao gồm hoặc gần với nhiều divergence quen thuộc như KL-divergence và các dạng divergence khác.

1.11 Dạng đơn giản của DrRL

Paper chứng minh DrRL có thể viết lại thành dạng dễ tối ưu:

$$L_{\text{DrRL}}(u) = -\frac{\sum_{i \in I_u^+} f(u, i)}{|I_u^+|} + c_\gamma(\eta) \left[\frac{1}{|I_u^-|} \sum_{j \in I_u^-} (f(u, j) - \beta_u)_+^{\gamma^*} \right]^{1/\gamma^*}.$$

Trong đó:

$$\gamma^* = \frac{\gamma}{\gamma-1},$$

và:

$$c_\gamma(\eta) = (1 + \gamma(\gamma-1)\eta)^{1/\gamma}.$$

Threshold cá nhân hóa:

$$\beta_u$$

được học bằng:

$$\beta_u = \arg \min_{\beta} \left\{ \beta + c_\gamma(\eta) \left[\frac{1}{|I_u^-|} \sum_{j \in I_u^-} (f(u, j) - \beta)_+^{\gamma^*} \right]^{1/\gamma^*} \right\}.$$

Điều này rất quan trọng vì DrRL không cần chọn thủ công một margin β chung cho mọi user như CCL.

DrRL học personalized truncation threshold β_u .

1.12 DrRL tổng quát hóa SL và CCL

Paper chỉ ra DrRL có thể suy biến thành SL hoặc CCL trong các giới hạn khác nhau:

$$\text{DrRL} \rightarrow \text{SL} \quad \text{khi} \quad \gamma \rightarrow 1.$$

$$\text{DrRL} \rightarrow \text{CCL} \quad \text{khi} \quad \gamma \rightarrow +\infty.$$

Do đó:

DrRL là một framework thống nhất giữa SL và CCL.

Nó kết hợp:

weighting strategy của SL

và:

truncation strategy của CCL.

1.13 Vì sao DrRL robust hơn SL?

DrRL gán weight cho negative item theo:

$$w_{uj} \propto (f(u, j) - \beta_u)_+^{\frac{1}{\gamma-1}}.$$

Khác với SL:

$$w_{uj}^{\text{SL}} \propto \exp(f(u, j)/\tau),$$

DrRL dùng polynomial weighting thay vì exponential weighting.

Polynomial function tăng nhẹ hơn exponential function, nên false negatives có score cao không bị phóng đại quá mức.

Do đó:

DrRL giảm tác động quá lớn của false negatives so với SL.

1.14 Vì sao DrRL dùng dữ liệu tốt hơn CCL?

DrRL vẫn có truncation, nhưng threshold được học và weighting mềm hơn.

Thay vì bỏ quá nhiều negative items như CCL, DrRL giữ lại nhiều training signal hơn.

Paper cho thấy DrRL filter ít hơn CCL khoảng:

10%

negative instances trung bình.

Do đó:

DrRL có data utilization tốt hơn CCL.

1.15 Thí nghiệm

Paper đánh giá DrRL trên các dataset:

Gowalla, AmazonKitchen, AmazonElectronics, AmazonBeauty.

Các backbone được dùng:

MF, LightGCN, XSimGCL.

Các loss baseline gồm:

MSE, BCE, BPR, CCL, SL, BSL, AdvInfoNCE, LLPAUC.

Metrics:

Recall@20, NDCG@20.

1.16 Kết quả chính

Paper cho thấy DrRL đạt kết quả tốt nhất trên hầu hết dataset và backbone.

Ví dụ với backbone MF:

Gowalla Recall@20: DrRL = 0.1785,

cao hơn CCL:

0.1652,

và cao hơn SL:

0.1623.

Với LightGCN trên Gowalla:

$$\text{DrRL} = 0.1788$$

vượt các baseline khác.

Với XSimGCL trên AmazonElectronics:

$$\text{DrRL} = 0.0907$$

cao hơn các loss còn lại.

Paper báo cáo rằng trên Gowalla, DrRL cải thiện trung bình khoảng:

$$6.9\%$$

về Recall@20 và:

$$5.2\%$$

về NDCG@20 trên ba backbone.

1.17 Thí nghiệm với noisy data

Paper kiểm tra robustness bằng cách inject false negatives trong negative sampling.

Kết quả cho thấy DrRL vẫn outperform các loss khác khi noise ratio tăng.

Một quan sát quan trọng:

CCL robust khi noise thấp, nhưng suy giảm nhanh khi noise cao.

Lý do là khi noise cao, những negative còn được giữ lại sau truncation có thể chứa nhiều false negatives. Khi đó CCL gần như train trên noisy data.

DrRL ổn định hơn vì nó dùng polynomial weighting và personalized threshold.

1.18 Thí nghiệm với distribution shifts

Paper cũng kiểm tra temporal distribution shift bằng cách chia train/test theo thời gian interaction.

Kết quả cho thấy DrRL đạt performance tốt nhất hoặc rất cạnh tranh dưới temporal shift.

Ví dụ trên AmazonKitchen:

$$\text{DrRL Recall@20} = 0.02077,$$

cao hơn CCL:

0.02053.

Trên AmazonElectronics:

DrRL Recall@20 = 0.05199,

cao hơn CCL:

0.05013.

Điều này hỗ trợ luận điểm rằng Rényi-divergence DRO giúp DrRL robust hơn với OOD/distribution shift.

1.19 Ablation study

Paper kiểm tra hai biến thể:

DrRL-w/o-P

bỏ personalized β_u , và:

DrRL-w/o-LP

bỏ learnable-personalized strategy.

Kết quả cho thấy bản đầy đủ DrRL tốt nhất.

Điều này chứng minh:

personalized và learnable threshold β_u là thành phần quan trọng.

1.20 Vai trò của tham số γ

Paper phân tích ảnh hưởng của:

$$\gamma^* = \frac{\gamma}{\gamma - 1}.$$

Khi γ^* gần 1, DrRL gần với CCL.

Khi γ^* rất lớn, DrRL gần với SL.

Performance tốt nhất xuất hiện ở giá trị trung gian:

không quá giống CCL, cũng không quá giống SL.

Điều này xác nhận rằng DrRL hiệu quả vì nó kết hợp cân bằng:

noise robustness

và:

data utilization.

1.21 Liên hệ với các paper trước

Paper này nối tiếp trực tiếp hướng nghiên cứu về loss trong recommender systems:

- **BPR**: tối ưu pairwise ranking.
- **NCF**: dùng binary cross-entropy/log loss cho implicit feedback.
- **Contrastive recommendation losses**: dùng InfoNCE, CCL, MINE+ để học user-item representation.
- **DrRL**: giải thích SL và CCL bằng DRO rồi tổng quát hóa bằng Rényi divergence.

Nếu paper trước về MINE+ nhìn recommendation loss qua contrastive learning, paper này nhìn SL và CCL qua:

Distributionally Robust Optimization.

Vì vậy, nó bổ sung một góc nhìn quan trọng:

Loss tốt trong recommender systems không chỉ cần ranking tốt, mà còn cần robust với noise và distri

1.22 Ý nghĩa đối với câu hỏi về loss trong recommender systems

Paper này rất phù hợp để chứng minh rằng loss trong recommender systems là một vấn đề nghiên cứu trung tâm, vì:

- SL và CCL outperform loss truyền thống như MSE, BCE, BPR.
- Các loss khác nhau tương ứng với các giả định robust optimization khác nhau.
- SL tốt nhưng dễ bị false negatives chi phối.
- CCL robust hơn nhưng bỏ quá nhiều negative samples.
- DrRL cho thấy có thể thiết kế loss mới bằng cách phân tích lý thuyết hạn chế của loss cũ.

- Loss ảnh hưởng đến cả accuracy, noise robustness và OOD robustness.

Tóm lại:

Trong recommender systems, loss function quyết định cách mô hình xử lý negatives, false negatives, v

1.23 Kết luận chính

Paper kết luận rằng:

- Loss functions đóng vai trò then chốt trong recommender systems.
- SL và CCL là hai loss rất hiệu quả nhưng có cấu trúc khác nhau.
- Cả SL và CCL đều có thể được hiểu như DRO-enhanced losses.
- SL dùng KL-divergence DRO nên nhạy với false negatives.
- CCL dùng worst-case-regret DRO nên có truncation mạnh và data utilization thấp.
- DrRL dùng Rényi-divergence DRO để tổng quát hóa SL và CCL.
- DrRL dùng polynomial weighting thay vì exponential weighting, nên robust hơn với false negatives.
- DrRL học personalized truncation threshold β_u , giúp dùng dữ liệu tốt hơn CCL.
- Thực nghiệm cho thấy DrRL cải thiện cả accuracy và robustness trên nhiều backbone và dataset.

1.24 Thông điệp quan trọng nhất

SL và CCL mạnh vì chúng ngầm thực hiện distributionally robust optimization.

Nhược điểm của SL là quá nhạy với false negatives; nhược điểm của CCL là bỏ quá nhiều dữ liệu.

DrRL dùng Rényi divergence để kết hợp ưu điểm của SL và CCL, đồng thời giảm nhược điểm của cả

Loss function trong recommender systems là một lựa chọn thiết kế ảnh hưởng trực tiếp đến accuracy,