

Paper

“latex

1 Summary

Bài báo *Time-Aware Music Recommender Systems: Modeling the Evolution of Implicit User Preferences and User Listening Habits in A Collaborative Filtering Approach* nghiên cứu bài toán gợi ý nhạc trong các nền tảng streaming, nơi người dùng thường nghe lặp lại một bài hát nhiều lần và hành vi nghe nhạc thay đổi theo thời gian. Khác với các domain như sách hoặc phim, một bài hát có thể được phát rất nhiều lần bởi cùng một người dùng, nên việc suy ra mức độ yêu thích từ implicit feedback không thể chỉ dựa trên một hành động đơn lẻ như mua hàng hoặc xem một lần.

Vấn đề chính của bài báo là trong music recommender system thường không có explicit rating. Do đó, hệ thống phải suy ra rating từ lịch sử nghe nhạc, chủ yếu là số lần phát bài hát. Tuy nhiên, nếu chỉ dùng số lượt nghe thô thì mô hình sẽ không phản ánh được sự thay đổi sở thích theo thời gian. Một bài hát được nghe nhiều trong quá khứ nhưng gần đây không còn được nghe nữa không nên có trọng số cao như một bài hát được nghe nhiều gần đây. Vì vậy, bài báo đề xuất một cách tính implicit rating có xét đến độ mới của từng lượt nghe.

Về mặt kỹ thuật, bài báo đề xuất khái niệm *decay play*. Mỗi lượt nghe của user u_i đối với song s_j tại thời điểm $t_{i,j,p}$ được gán một trọng số suy giảm theo thời gian. Lượt nghe càng gần thời điểm hiện tại thì trọng số càng lớn, lượt nghe càng xa hiện tại thì trọng số càng nhỏ. Hàm suy giảm được dùng là hàm mũ:

$$dPlay(u_i, s_j, p) = e^{-\lambda(t_{max} - t_{i,j,p})/T_u}$$

Trong đó, t_{max} là thời điểm gần nhất trong dữ liệu, $t_{i,j,p}$ là thời điểm phát bài hát, λ là hệ số điều chỉnh tốc độ suy giảm, và T_u dùng để chuẩn hóa đơn vị thời gian. Cách làm này khác với các time-aware recommender truyền thống ở chỗ hàm decay không áp dụng lên explicit rating, mà áp dụng trực tiếp lên từng lượt nghe.

Sau khi tính trọng số cho từng lượt nghe, bài báo tính *decay play frequency* cho từng cặp user-song bằng cách cộng các decay play của bài hát đó và chuẩn hóa theo tổng decay play của user. Từ đó, hệ thống suy ra *implicit decay rating*. Ý tưởng là bài hát nào có

tần suất nghe đã được suy giảm theo thời gian cao hơn thì được xem là có mức độ yêu thích cao hơn. Rating cuối cùng được ánh xạ về khoảng giá trị $(0, 4)$ dựa trên thứ hạng percentile của decay frequency:

$$r_{i,j} = 4 \left(1 - \sum_{k'=1}^{k-1} dPlay_{k'}(u_i) \right)$$

Trong đó, k là thứ hạng của bài hát s_j trong danh sách các bài hát đã nghe của user u_i sau khi sắp xếp theo decay frequency. Cách tính này phù hợp với phân phối power-law trong nghe nhạc, vì thường chỉ có một số ít bài hát được nghe rất nhiều, còn phần lớn bài hát được nghe ít.

Bên cạnh việc mô hình hóa sự thay đổi sở thích, bài báo còn khai thác *time context*, cụ thể là thời điểm trong ngày khi người dùng nghe nhạc. Thời gian trong ngày được chia thành các khoảng ngữ cảnh như *morning* và *evening*. Khi tạo recommendation cho một ngữ cảnh cụ thể, bài báo sử dụng contextual pre-filtering, tức là chỉ lấy các lượt nghe thuộc đúng khoảng thời gian đó để xây dựng dữ liệu gợi ý. Ví dụ, khi gợi ý nhạc cho buổi sáng, hệ thống chỉ dùng dữ liệu nghe nhạc vào buổi sáng để tính implicit rating và tạo recommendation.

Tuy nhiên, contextual pre-filtering có thể làm dữ liệu thưa hơn vì dữ liệu bị chia nhỏ theo từng ngữ cảnh. Do đó, bài báo bổ sung thêm một hướng kỹ thuật khác là mô hình hóa *user listening behavior*. Thay vì chỉ xem thời gian như một bộ lọc ngữ cảnh, bài báo còn tính đặc trưng mô tả thói quen nghe nhạc của từng user, ví dụ thời điểm trung bình trong ngày mà user thường nghe nhạc. Đặc trưng này được đưa vào quá trình tính similarity giữa users.

Phương pháp gợi ý chính của bài báo dựa trên *user-based collaborative filtering*. Trong collaborative filtering truyền thống, độ tương đồng giữa hai user thường được tính dựa trên rating vector, ví dụ bằng Pearson correlation hoặc cosine similarity. Bài báo mở rộng cách tính này bằng cách kết hợp thêm yếu tố thời gian nghe nhạc. Như vậy, hai user không chỉ được xem là giống nhau nếu họ thích các bài hát tương tự, mà còn nếu họ có thói quen nghe nhạc vào các thời điểm tương tự trong ngày.

Về pipeline kỹ thuật, bài báo có thể được tóm tắt thành các bước chính. Đầu tiên, từ log nghe nhạc có timestamp, hệ thống tính decay play cho từng lượt nghe. Tiếp theo, hệ thống cộng và chuẩn hóa decay play để thu được decay play frequency cho từng cặp user-song. Sau đó, decay frequency được chuyển thành implicit decay rating. Nếu xét time context, dữ liệu được chia thành các contextual segment như morning và evening, rồi quá trình tính rating được thực hiện riêng cho từng segment. Cuối cùng, user-based KNN collaborative filtering được áp dụng để dự đoán rating hoặc tạo danh sách top-N recommendation.

Thực nghiệm được thực hiện trên dữ liệu Last.fm, gồm hơn 80,000 bài hát, 50 users và hơn 420,000 lượt nghe có timestamp trong khoảng thời gian hai năm. Dữ liệu được

chia theo thời gian: 15 tháng đầu dùng làm training set và 2 tháng cuối dùng làm test set. Cách chia này phù hợp với time-aware recommendation vì mô hình cần dùng dữ liệu quá khứ để dự đoán hành vi tương lai. Các user-song pair đã xuất hiện trong training set được loại khỏi test recommendation list, vì mục tiêu là gợi ý bài hát mới mà user chưa nghe trong training.

Bài báo đánh giá mô hình theo hai nhóm nhiệm vụ. Nhóm thứ nhất là rating prediction, dùng các metric như MAE và RMSE để đo sai số dự đoán rating. Nhóm thứ hai là top-N recommendation, dùng các metric như precision@N, recall@N, MAP, NDCG và AUC để đánh giá chất lượng danh sách gợi ý. Ngoài recommendation không xét context, bài báo còn đánh giá recommendation theo time-of-day context, cụ thể là gợi ý trong buổi sáng và buổi tối.

Kết quả thực nghiệm cho thấy việc sử dụng decay rating giúp mô hình phản ánh tốt hơn sự tiến hóa sở thích của người dùng so với cách tính implicit rating thông thường chỉ dựa trên số lượt nghe. Khi bổ sung thêm đặc trưng listening behavior vào user-based KNN, hiệu năng tiếp tục được cải thiện, đặc biệt ở các chỉ số rating prediction và một số chỉ số ranking như AUC và NDCG. Điều này cho thấy thời gian không chỉ nên được xem là một biến ngữ cảnh để chia dữ liệu, mà còn có thể được dùng như một đặc trưng hành vi để mô tả user.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một phương pháp *time-aware music recommender system* dựa trên collaborative filtering, trong đó thời gian được khai thác theo hai hướng chính. Hướng thứ nhất là mô hình hóa sự thay đổi sở thích người dùng bằng *decay play* và *implicit decay rating*. Hướng thứ hai là mô hình hóa thói quen nghe nhạc trong ngày bằng cách đưa đặc trưng thời gian nghe nhạc vào quá trình tính similarity giữa users.

Đóng góp kỹ thuật quan trọng nhất của bài báo là thay vì áp dụng decay function lên explicit rating như các mô hình recency-based truyền thống, bài báo áp dụng decay function trực tiếp lên từng lượt nghe nhạc. Điều này phù hợp với music domain vì dữ liệu streaming thường không có explicit rating, trong khi mỗi bài hát có thể được nghe nhiều lần. Từ các lượt nghe đã được suy giảm theo thời gian, mô hình suy ra implicit rating phản ánh cả mức độ yêu thích và độ mới của sở thích.

Bài báo cũng cho thấy cách kết hợp giữa *time-aware recommendation* và *context-aware recommendation*. Khi xét thời điểm trong ngày như morning hoặc evening, mô hình có thể tạo recommendation phù hợp hơn với ngữ cảnh nghe nhạc cụ thể. Đồng thời, bằng cách đưa listening habit vào user similarity, hệ thống có thể tìm các neighbor không chỉ giống nhau về bài hát yêu thích mà còn giống nhau về thói quen nghe nhạc.

Hướng kế thừa từ bài báo có thể phát triển theo nhiều hướng. Thứ nhất, có thể thay user-based KNN bằng các mô hình mạnh hơn như matrix factorization, neural

collaborative filtering hoặc sequential recommender để học quan hệ user-song-time phức tạp hơn. Thứ hai, có thể mở rộng time context từ hai khoảng morning/evening sang các chu kỳ chi tiết hơn như giờ trong ngày, ngày trong tuần, cuối tuần, mùa hoặc dịp lễ. Thứ ba, có thể kết hợp thêm metadata của bài hát như artist, genre, lyrics, audio features hoặc embedding âm thanh để cải thiện recommendation khi dữ liệu nghe còn thưa.

Ngoài ra, hướng nghiên cứu này có thể kế thừa trực tiếp cho các hệ recommender có bias theo thời điểm. Vì hành vi nghe nhạc thường có tính chu kỳ, mô hình có thể được mở rộng bằng các đặc trưng temporal/cyclic như hour-of-day, day-of-week hoặc seasonal pattern. Khi kết hợp implicit decay rating với cyclic temporal features, hệ thống có thể vừa nắm được sự thay đổi dài hạn trong sở thích người dùng, vừa học được các thói quen lặp lại theo thời gian, từ đó tạo ra recommendation phù hợp hơn với từng thời điểm sử dụng. ““