

Paper

“latex

1 Summary

Bài báo *HTP: Exploiting Holistic Temporal Patterns for Sequential Recommendation* nghiên cứu bài toán *sequential recommendation*, trong đó hệ thống dự đoán item tiếp theo mà user có khả năng tương tác dựa trên chuỗi lịch sử tương tác trước đó. Các mô hình *sequential recommendation* truyền thống thường tập trung vào thứ tự tương tác, tức là item nào xảy ra trước, item nào xảy ra sau. Tuy nhiên, bài báo cho rằng chỉ dùng thứ tự là chưa đủ, vì trong dữ liệu thực tế còn có nhiều thông tin thời gian quan trọng khác có thể giúp cải thiện dự đoán.

Vấn đề chính mà bài báo đặt ra là nhiều mô hình trước đây chỉ khai thác một phần của temporal information. Một số mô hình dùng khoảng cách thời gian giữa các item liên tiếp, một số mô hình dùng khoảng cách giữa thời điểm recommendation và các interaction trước đó, một số mô hình dùng absolute timestamp. Tuy nhiên, chưa có mô hình nào khai thác đồng thời đầy đủ các dạng temporal pattern này. Vì vậy, bài báo đề xuất một cách nhìn tổng thể hơn, gọi là *holistic temporal patterns*.

Bài báo xác định ba loại temporal pattern có lợi cho *sequential recommendation*. Loại thứ nhất là *absolute time information*. Đây là thông tin thời gian tuyệt đối, ví dụ tháng, tuần hoặc ngày. Điểm mới của bài báo là khai thác *item-oriented absolute time pattern*, tức là mỗi item có thể có pattern phổ biến riêng theo thời gian. Ví dụ, dép lê thường được mua nhiều vào mùa hè, còn áo khoác ấm thường được mua nhiều vào mùa lạnh. Như vậy, thời điểm recommendation có thể ảnh hưởng đến xác suất item được gợi ý.

Loại thứ hai là *relative item time interval*. Đây là khoảng cách thời gian giữa các item trong chuỗi tương tác của user. Khoảng cách này giúp mô hình học quan hệ thời gian giữa các item. Ví dụ, user có thể mua ốp điện thoại ngay sau khi mua điện thoại, hoặc có thể có hành vi tiêu thụ lặp lại sau một khoảng thời gian nhất định. Loại pattern này không chỉ xét thứ tự item, mà còn xét khoảng cách thời gian giữa các item.

Loại thứ ba là *relative recommendation time interval*. Đây là khoảng cách giữa thời điểm recommendation hiện tại và thời điểm các item trước đó được user tương tác. Ý tưởng là ảnh hưởng của một interaction cũ đến recommendation hiện tại không chỉ phụ

thuộc vào item đó là gì, mà còn phụ thuộc vào nó xảy ra cách thời điểm recommendation bao lâu. Một item được tương tác quá xa trong quá khứ có thể ít ảnh hưởng hơn, nhưng nếu nó có chu kỳ hoặc trùng với một granularity thời gian quan trọng thì vẫn có thể mang thông tin hữu ích.

Để khai thác đồng thời ba loại temporal pattern này, bài báo đề xuất mô hình *HTP* hay *Holistic Temporal Pattern based sequential recommender*. Mô hình gồm ba module chính: *Absolute Time Module* (ATM), *Item Time Interval Module* (ITIM), và *Recommendation Time Interval Module* (RTIM). Mỗi module phụ trách một loại temporal pattern khác nhau, sau đó các biểu diễn được kết hợp để tạo profile dự đoán item tiếp theo.

Đầu vào của bài toán là chuỗi tương tác của user:

$$S_u = [(s_1, t_1), (s_2, t_2), \dots, (s_{|S_u|}, t_{|S_u|})]$$

trong đó s_i là item và t_i là timestamp tương ứng. Mục tiêu là dự đoán item tiếp theo mà user u có thể tương tác tại một timestamp tương lai. Nếu chuỗi dài hơn độ dài tối đa L , mô hình chỉ lấy L item gần nhất; nếu ngắn hơn thì padding để đưa về cùng độ dài.

Ở tầng embedding, item được ánh xạ thành vector embedding và được cộng thêm positional embedding để giữ thông tin thứ tự trong chuỗi:

$$e_i^s = e_i + e_i^p$$

trong đó e_i là item embedding và e_i^p là positional embedding. Timestamp cũng được ánh xạ thành embedding nhưng theo nhiều granularity khác nhau. Bài báo sử dụng month-level, week-level và day-level embedding, sau đó cộng lại để tạo timestamp embedding:

$$e_{t_i} = e_{t_i}^m + e_{t_i}^w + e_{t_i}^d$$

Cách biểu diễn đa mức này giúp mô hình nhận ra sự tương đồng thời gian ở nhiều cấp độ, ví dụ hai timestamp có thể giống nhau vì cùng tháng, cùng tuần hoặc cùng ngày.

Module đầu tiên, *Absolute Time Module* (ATM), học absolute time pattern của từng item từ góc nhìn toàn cục. Với mỗi item i , mô hình lấy tất cả timestamp mà item đó được tương tác bởi mọi user, sau đó tổng hợp timestamp embedding theo tần suất xuất hiện để tạo absolute time pattern của item:

$$e_i^t = \sum_{t_j \in T_i} \alpha_{t_j} e_{t_j}$$

trong đó α_{t_j} là trọng số chuẩn hóa dựa trên số lần item i được tương tác tại timestamp t_j . Điểm quan trọng là pattern này được học theo item trên toàn bộ dữ liệu, nên ổn định hơn so với pattern theo từng user vốn dễ bị thừa dữ liệu.

Sau khi có absolute time pattern của item, ATM dùng scaled dot-product attention

để so khớp recommendation timestamp t_{L+1} với absolute time pattern của các item trong chuỗi. Nếu recommendation time phù hợp với pattern thời gian của một item, item đó sẽ có ảnh hưởng lớn hơn trong việc tạo profile cho next item. Output của ATM là vector e_p^a , biểu diễn dự đoán từ góc nhìn absolute time.

Module thứ hai, *Item Time Interval Module* (ITIM), học relative item time interval giữa các item trong chuỗi. Mục tiêu của ITIM là tăng cường item representation bằng thông tin khoảng cách thời gian giữa item này với các item khác. ITIM sử dụng nhiều lớp aggregation, trong đó mỗi item được cập nhật bằng cách tổng hợp thông tin từ top- K item liên quan nhất. Việc chỉ lấy top- K giúp giảm nhiễu từ các item ít liên quan.

Trọng số attention giữa item i và item j trong ITIM được tính bằng một hàm cosine similarity có xét đến time interval:

$$a_{ij}^h = \cos(e_i^{s_h} W_2^h, e_j^{s_h} W_3^h + W_t^h r_{ji})$$

trong đó $r_{ji} = e_{t_i} - e_{t_j}$ là relative time interval giữa hai item, được tính trên timestamp embedding đa granularity thay vì timestamp scalar. Cách này giúp interval được biểu diễn mềm hơn và có khả năng tổng quát tốt hơn.

Bên cạnh việc cập nhật item embedding, ITIM còn tạo explicit time interval information cho từng item:

$$r_i^{h+1} = \sum_{j=1}^K a_{ij}^h r_{ji}$$

Sau H aggregation layers, mô hình thu được item representation cuối cùng e_i^c và interval representation r_i . Hai biểu diễn này mô tả item không chỉ bằng danh tính của nó, mà còn bằng quan hệ thời gian của nó với các item liên quan trong chuỗi.

Module thứ ba, *Recommendation Time Interval Module* (RTIM), học ảnh hưởng của khoảng cách giữa recommendation time và các interaction trước đó. Với item i trong lịch sử, recommendation time interval được biểu diễn là:

$$r_{i,L+1} = e_{t_{L+1}} - e_{t_i}$$

RTIM không chỉ xét khoảng cách này một cách độc lập, mà còn xét sự tương thích giữa recommendation time interval $r_{i,L+1}$ và item interval information r_i đã học từ ITIM. Đây là điểm kỹ thuật quan trọng, vì ảnh hưởng của một item cũ đến recommendation hiện tại phụ thuộc đồng thời vào khoảng cách từ item đó đến hiện tại và pattern khoảng cách thời gian của item đó với các item khác.

RTIM tính hai loại trọng số. Trọng số thứ nhất đo ảnh hưởng trực tiếp của recommendation time interval:

$$\phi(i) = \frac{\exp(c_i)}{\sum_{j=1}^L \exp(c_j)}, \quad c_i = r_{i,L+1} w$$

Trong đó w là vector học được, giúp mô hình không mặc định rằng interval càng dài thì ảnh hưởng càng yếu. Nếu interaction cũ có cùng tháng, cùng tuần hoặc cùng ngày với recommendation time thì nó vẫn có thể quan trọng.

Trọng số thứ hai đo alignment giữa recommendation time interval và item interval representation:

$$\varphi(i) = \frac{\exp(g_i)}{\sum_{j=1}^L \exp(g_j)}, \quad g_i = r_{i,L+1}^\top W_r r_i$$

Sau đó, RTIM dùng cascading function để kết hợp hai trọng số này:

$$e_p^r = \sum_{i=1}^L \varphi(i) \phi(i) e_i^c$$

Cách kết hợp dạng nhân này giúp mô hình cân bằng hai yếu tố: ảnh hưởng của khoảng cách đến recommendation time và sự phù hợp với interval pattern đã học từ lịch sử item. Nó cũng tránh việc một yếu tố đơn lẻ chi phối hoàn toàn prediction.

Cuối cùng, HTP kết hợp output từ ATM, output từ RTIM và item gần nhất trong chuỗi để tạo profile của next item:

$$e_u = e_p^a + e_p^r + e_L^c$$

Trong đó e_p^a đến từ absolute time pattern, e_p^r đến từ relative interval pattern, và e_L^c biểu diễn item gần nhất, thường phản ánh short-term interest của user. Sau đó, mô hình tính điểm cho candidate item bằng dot product:

$$r_o = e_u e_o^\top$$

Các candidate items được xếp hạng theo điểm này để tạo top- M recommendation list.

Mô hình được huấn luyện bằng binary cross entropy loss với positive item thật và negative item được sample từ các item mà user chưa tương tác tại thời điểm đó:

$$- \sum_{(u,t,i,j) \in D} \log(\sigma(r_{ui}^t)) + \log(1 - \sigma(r_{uj}^t)) + \lambda \|\Theta\|_F^2$$

Trong đó i là positive item, j là negative item, và Θ gồm các embedding matrix của item, time và position.

Thực nghiệm được tiến hành trên ba bộ dữ liệu thực tế: Tafeng, Amazon-Cloth và Amazon-Sports. Dữ liệu được xử lý theo setting sequential recommendation phổ biến: mỗi user cần có ít nhất 5 interactions, item cũng cần có ít nhất 5 interactions. Item cuối cùng trong chuỗi được dùng làm test set, item áp cuối dùng làm validation set. Các metric đánh giá gồm HR@10, NDCG@10 và AUC.

Bài báo so sánh HTP với nhiều baseline, gồm BPR, FPMC, STAMP, GRU4Rec,

SASRec, RepeatNet, GCE-GNN, TiSASRec, OAR, Chorus, SLRC+, TimelyRec và TGSRec. Kết quả cho thấy HTP đạt hiệu năng tốt nhất hoặc gần tốt nhất trên hầu hết các dataset và metric. Điều này chứng minh rằng việc khai thác đồng thời ba loại temporal pattern giúp mô hình ổn định và hiệu quả hơn so với các phương pháp chỉ dùng thứ tự, chỉ dùng interval, hoặc chỉ dùng một phần absolute time information.

Ablation study cho thấy từng module trong HTP đều có vai trò quan trọng. Khi bỏ ATM hoặc bỏ nhóm ITIM+RTIM, hiệu năng đều giảm. Điều này xác nhận rằng absolute time pattern và relative interval pattern mang thông tin bổ sung cho nhau. Ngoài ra, khi bỏ từng granularity như month, week hoặc day, hiệu năng cũng giảm ở các mức khác nhau tùy dataset. Ví dụ, month-level quan trọng hơn với Cloth vì quần áo có tính mùa vụ, trong khi week-level và day-level có thể quan trọng hơn ở các dataset khác. Điều này cho thấy multi-granularity time modeling là cần thiết.

2 Conclusion

Hướng đi đã làm của bài báo là mở rộng sequential recommendation từ việc chỉ khai thác thứ tự item sang việc khai thác toàn diện các temporal pattern trong lịch sử tương tác. Bài báo xác định ba loại temporal information quan trọng: *item-oriented absolute time pattern*, *relative item time interval*, và *relative recommendation time interval*. Từ đó, tác giả đề xuất mô hình HTP với ba module tương ứng: ATM, ITIM và RTIM.

Đóng góp kỹ thuật nổi bật nhất của bài báo là cách kết hợp holistic temporal patterns. ATM học pattern thời gian tuyệt đối của item từ toàn bộ user để nắm bắt tính mùa vụ hoặc tính thời điểm của item. ITIM học quan hệ thời gian giữa các item trong chuỗi bằng time-interval-aware aggregation. RTIM học ảnh hưởng của các item lịch sử đối với recommendation time, đồng thời căn chỉnh recommendation time interval với item interval information đã học từ ITIM. Thiết kế cascading giữa $\phi(i)$ và $\varphi(i)$ là điểm quan trọng giúp mô hình xử lý mối quan hệ phức tạp giữa hai loại interval.

Kết quả thực nghiệm cho thấy HTP vượt trội hơn nhiều baseline mạnh trong sequential recommendation và time-aware recommendation. Điều này chứng minh rằng temporal information không nên chỉ được xem là thứ tự tương tác hoặc một feature thời gian đơn giản. Thay vào đó, cần khai thác nhiều dạng temporal pattern ở nhiều granularity khác nhau để mô hình hóa đầy đủ hành vi người dùng và đặc tính thời gian của item.

Hướng kế thừa trực tiếp từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng HTP sang các kiến trúc Transformer-based để học interaction dài hơn và kết hợp self-attention với ba loại temporal pattern mà bài báo đề xuất. Thứ hai, có thể bổ sung thêm user-oriented temporal pattern bên cạnh item-oriented pattern, nhưng cần xử lý vấn đề sparsity ở cấp user. Thứ ba, có thể đưa thêm contextual information như location, device, weather, activity hoặc campaign event để mô hình không chỉ time-aware mà còn context-aware đầy đủ hơn.

Ngoài ra, HTP rất phù hợp để kế thừa cho các hệ recommender có bias theo mùa vụ hoặc theo chu kỳ. Ví dụ, trong e-commerce, một số item phụ thuộc mạnh vào mùa, tuần lễ khuyến mãi hoặc ngày đặc biệt; trong media recommendation, một số nội dung phụ thuộc vào giờ trong ngày hoặc ngày trong tuần. Nếu kết hợp HTP với các đặc trưng sự kiện như holiday, payday, promotion hoặc school season, hệ thống có thể dự đoán tốt hơn không chỉ item tiếp theo, mà còn thời điểm item đó có khả năng được user quan tâm nhất. ““