

Paper

“latex

1 Summary

Bài báo *Deep Learning-Based Context-Aware Recommender System Considering Change in Preference* nghiên cứu bài toán *Context-Aware Recommender System* (CARS), trong đó hệ thống gợi ý không chỉ dựa trên user và item, mà còn sử dụng thêm thông tin ngữ cảnh như thời gian, thời tiết, vị trí, ngày trong tuần hoặc nhiệt độ. Mục tiêu của CARS là dự đoán sở thích của user chính xác hơn bằng cách xét hoàn cảnh mà user đang tương tác với item.

Vấn đề chính mà bài báo đặt ra là các context-aware recommender system truyền thống thường giả định rằng trong cùng một ngữ cảnh, user sẽ có sở thích tương đối ổn định. Ví dụ, nếu user thường ăn một món vào buổi sáng, hệ thống có thể tiếp tục gợi ý món đó mỗi sáng. Tuy nhiên, trên thực tế, sở thích của user có thể thay đổi theo thời gian do nhiều nguyên nhân như xu hướng mới, thay đổi môi trường cá nhân, thay đổi chế độ ăn, thay đổi gia đình hoặc thói quen tiêu dùng mới. Vì vậy, chỉ dùng context hiện tại là chưa đủ.

Một điểm quan trọng của bài báo là phân biệt hai cách dùng thông tin thời gian. Trong CARS truyền thống, time thường được dùng như một feature categorical, ví dụ *breakfast/lunch/dinner*, *morning/afternoon*, hoặc *weekday/weekend*. Khi đó, time chỉ đóng vai trò là một loại context tại thời điểm tương tác. Ngược lại, bài báo đề xuất dùng time theo nghĩa tuần tự, tức dữ liệu được sắp xếp theo các giai đoạn thời gian để học sự dịch chuyển sở thích của user từ quá khứ đến hiện tại. Hình 1 trong paper minh họa cách dùng time như feature, còn Hình 2 minh họa cách dùng time theo nghĩa sequential.

Để giải quyết vấn đề thay đổi sở thích, bài báo đề xuất một mô hình kết hợp giữa *Dynamic Recommender System* và *Context-Aware Recommender System*. Thành phần dynamic được xây dựng dựa trên *Matrix Factorization* có thêm *preference transition matrix*. Thành phần context-aware được xây dựng bằng neural network/autoencoder để học biểu diễn user, item và context trong không gian ẩn. Cuối cùng, output của hai nhánh được kết hợp để dự đoán điểm preference cuối cùng.

Trước hết, bài báo sử dụng *Matrix Factorization* để phân rã ma trận preference thành user latent matrix và item latent matrix. Với ma trận preference R , công thức cơ bản là:

$$R = UV$$

Trong đó U là user latent matrix, V là item latent matrix. Bài báo sử dụng hướng *Non-negative Matrix Factorization* (NMF), tức các latent factors không âm:

$$R_{i,j} = UV, \quad U \geq 0, \quad V \geq 0$$

Tuy nhiên, MF truyền thống giả định latent factors tương đối tĩnh. Điều này không phù hợp với dữ liệu có thay đổi sở thích theo thời gian. Vì vậy, bài báo chia dữ liệu thành nhiều time periods không chồng lấn, ví dụ $t, t-1, t-2$, rồi học preference matrix ở từng thời điểm:

$$R^t = U^t V^t$$

$$R^{t-1} = U^{t-1} V^{t-1}$$

$$R^{t-T} = U^{t-T} V^{t-T}$$

Để mô hình hóa sự thay đổi preference giữa hai thời điểm liên tiếp, bài báo đưa vào *preference transition matrix* S^t . Ma trận này biểu diễn cách user latent vector ở thời điểm trước chuyển sang user latent vector ở thời điểm hiện tại:

$$U^t = S^t U^{t-1}$$

Nếu S^t gần với identity matrix, điều đó có nghĩa là sở thích user gần như không thay đổi. Nếu S^t lệch khỏi identity matrix, điều đó thể hiện user preference đang dịch chuyển theo một hướng nào đó trong latent space. Ví dụ, nếu một latent factor tăng mạnh hơn các factor khác, có thể hiểu là user đang chuyển sang quan tâm nhiều hơn đến một nhóm item hoặc thuộc tính ẩn nào đó.

Khi đưa preference transition matrix vào MF, preference tại thời điểm t được dự đoán bằng:

$$R^t = U^{t-1} S^t V^t$$

Công thức này cho thấy preference hiện tại không chỉ được học từ user/item latent factors tại thời điểm hiện tại, mà còn phản ánh sự chuyển tiếp từ sở thích ở thời điểm trước. Đây là thành phần quan trọng giúp mô hình bắt được *preference change over time*.

Hàm mục tiêu cho phần dynamic recommendation gồm nhiều thành phần. Thành

phần đầu tiên là reconstruction loss của MF tại từng thời điểm:

$$\sum_{t=1}^T \|R^t - U^t V^t\|_F^2$$

Thành phần thứ hai buộc user latent vector ở thời điểm hiện tại phải phù hợp với latent vector ở thời điểm trước sau khi đi qua transition matrix:

$$\sum_{t=2}^T \|U^t - S^t U^{t-1}\|_F^2$$

Ngoài ra, mô hình dùng l_1 regularization để làm thưa các factor matrix U^t , V^t , S^t , và dùng thêm regularization để kiểm soát mức độ lệch của transition matrix so với identity matrix:

$$\lambda_2 \sum_{n=1}^N \|S^{t-1} - I\|_F^2$$

Toàn bộ objective được viết dưới dạng:

$$L = \min_{U^t, S^t, V^t} \sum_{t=1}^T \|R^t - U^t V^t\|_F^2 + \sum_{t=2}^T \|U^t - S^t U^{t-1}\|_F^2 + \lambda_1 (\|U^t\|_1 + \|V^t\|_1 + \|S^t\|_1) + \lambda_2 \sum_{n=1}^N \|S^{t-1} - I\|_F^2$$

Trong đó λ_1 điều chỉnh mức độ sparse regularization, còn λ_2 điều chỉnh mức độ mô hình được phép thay đổi khỏi sở thích cũ. Nếu λ_2 lớn, transition matrix bị ép gần identity hơn, nghĩa là mô hình giả định preference thay đổi chậm. Nếu λ_2 nhỏ, mô hình cho phép preference dịch chuyển mạnh hơn.

Sau khi mô hình hóa preference change bằng MF và transition matrix, bài báo tiếp tục xây dựng nhánh *context-aware recommendation* bằng deep learning. Lý do là CARS có dữ liệu user-item-context thường rất thưa, đặc biệt khi số contextual dimensions và contextual conditions tăng lên. Vì vậy, bài báo sử dụng autoencoder để học latent representation cho user, item và context, từ đó giảm chiều và học đặc trưng ẩn tốt hơn.

Ở nhánh context-aware, input gồm user vector, item vector và context vector. Các trường categorical được biểu diễn bằng one-hot encoding. Autoencoder được huấn luyện để tái tạo lại input:

$$L_{AE} = \min_{\theta} \sum_{v \in V} \|X - X'\|^2 + \alpha \sum_l (\|w_{AE}\|^2 + \|b_{AE}\|^2)$$

Trong đó X là input gồm user, item và context, X' là output tái tạo, còn α là regularization weight. Bài báo sử dụng activation function *ELU* để giúp quá trình học ổn định hơn. Hidden layer của autoencoder được xem là latent representation của context-

aware input.

Từ hidden representation, neural network tiếp tục dự đoán score mà user u gán cho item i trong context c :

$$\hat{y}_{uic} = \sigma(wx_{k/2} + b)$$

Trong đó $x_{k/2}$ là representation ở tầng giữa của mạng, σ là activation function, và $\hat{y}_{uic}$ là predicted score. Loss cho phần prediction là:

$$L_{NN} = \min_{\theta} \sum_{y \in Y} (y_{uic} - \hat{y}_{uic})^2 + \beta \sum_l (\|w_{NN}\|^2 + \|b_{NN}\|^2)$$

Hai loss L_{AE} và L_{NN} được huấn luyện đồng thời. Mô hình sử dụng Adam optimizer để cập nhật tham số.

Kiến trúc cuối cùng của bài báo kết hợp hai nhánh. Nhánh thứ nhất là *MF layer*, tức phần Matrix Factorization có preference transition matrix để học sự thay đổi sở thích theo thời gian. Nhánh thứ hai là *CA layer*, tức phần context-aware neural recommender học từ user, item và context latent vectors. Output của hai nhánh được concatenate, sau đó đưa qua các layer tiếp theo để dự đoán score cuối cùng $\hat{r}_{uic}$. Hình 5 trong paper minh họa kiến trúc tổng thể này.

Thực nghiệm được tiến hành trên hai dataset: *University Cafeteria* và *Instacart*. University Cafeteria là dữ liệu mua món ăn tại food court của Chungnam National University, gồm 37,289 users, 97 items và 725,438 orders. Dataset này có bốn contextual dimensions: time, day, weather và temperature, với tổng cộng 16 contextual conditions. Instacart là dữ liệu đặt hàng thực phẩm trực tuyến, gồm 206,209 users, 49,688 items và 3,421,083 orders. Dataset này có ba contextual dimensions: day of week, time of day và weekday/weekend, với 13 contextual conditions.

Bài báo sử dụng 5-fold cross validation, với 80% users làm training set và 20% users làm test set. Các metric đánh giá gồm $Precision@N$ và $MAP@N$. $Precision@N$ đo tỷ lệ item relevant trong top- N recommendation list:

$$Precision@N = \frac{|\{relevant\ items\} \cap \{top - N\ items\}|}{N}$$

$MAP@N$ đo chất lượng ranking có xét thứ tự item trong danh sách recommendation:

$$MAP@N = \frac{1}{|U|} \sum_{u=1}^{|U|} (AP@N)_u$$

Trong đó $AP@N$ là Average Precision của từng user.

Các baseline được chia thành ba nhóm. Nhóm *non-contextual recommender systems* gồm UserKNN, SVD++, PMF và FM. Nhóm *context-aware recommender systems* gồm CAMF, ItemSplitting và CSLIM. Nhóm *dynamic recommender systems* gồm TimeSVD,

TMF, BTMF và TimeTrustSVD. Nhờ vậy, bài báo có thể kiểm tra liệu mô hình đề xuất có tốt hơn hệ gợi ý truyền thống, tốt hơn CARS chỉ dùng context, và tốt hơn DRS chỉ xét preference change hay không.

Kết quả thực nghiệm cho thấy proposed method đạt Precision@10 và MAP@10 cao nhất trên cả hai dataset. Trên University Cafeteria, proposed method đạt Precision@10 là 0.114865, cao hơn các baseline như PMF, ItemSplitting và BTMF. Trên Instacart, proposed method đạt Precision@10 là 0.085116, cũng cao hơn các nhóm baseline. Với MAP@10, proposed method đạt 0.223674 trên University Cafeteria và 0.197563 trên Instacart, tiếp tục vượt các phương pháp so sánh.

Một điểm đáng chú ý là nhóm DRS thường cho kết quả tốt hơn nhóm CARS trong nhiều trường hợp, đặc biệt BTMF là baseline gần với proposed method nhất. Điều này củng cố luận điểm của bài báo rằng việc xét preference change theo thời gian có thể quan trọng hơn chỉ thêm contextual information. Tuy nhiên, proposed method vẫn tốt hơn DRS thuần túy vì nó kết hợp cả hai: preference transition theo thời gian và context-aware representation.

Bài báo cũng phân tích ảnh hưởng của độ dài time period. Khi chia dữ liệu theo khoảng 1 tháng, dữ liệu quá thừa nên mô hình khó học pattern preference change. Khi dùng các khoảng dài hơn như 6 tháng hoặc 12 tháng, performance cải thiện rõ hơn. Điều này cho thấy mô hình học tốt preference change dài hạn, nhưng còn hạn chế trong việc bắt các thay đổi ngắn hạn do sparsity.

2 Conclusion

Hướng đi đã làm của bài báo là mở rộng context-aware recommender system bằng cách bổ sung khả năng học sự thay đổi preference theo thời gian. Thay vì chỉ dùng time như một feature ngữ cảnh categorical, bài báo dùng time theo nghĩa sequential/dynamic để chia dữ liệu thành các giai đoạn và học preference transition giữa các giai đoạn đó. Đây là điểm khác biệt chính so với CARS truyền thống.

Đóng góp kỹ thuật quan trọng nhất của bài báo là đưa *preference transition matrix* vào Matrix Factorization. Ma trận S^t mô hình hóa cách user latent vector chuyển từ thời điểm $t - 1$ sang thời điểm t . Nếu S^t gần identity matrix, sở thích gần như ổn định; nếu S^t thay đổi mạnh, mô hình nhận ra user preference đang dịch chuyển. Cách làm này giúp recommender system phản ánh các thay đổi dài hạn trong hành vi user.

Bên cạnh đó, bài báo kết hợp nhánh dynamic MF với nhánh deep context-aware recommender. Autoencoder được dùng để học latent representation từ user, item và context vector, giúp giảm ảnh hưởng của data sparsity trong CARS. Output của nhánh MF và nhánh context-aware được nối lại để tạo prediction cuối cùng. Nhờ đó, mô hình vừa hiểu được ngữ cảnh hiện tại, vừa hiểu được hướng thay đổi sở thích theo thời gian.

Kết quả thực nghiệm trên University Cafeteria và Instacart cho thấy proposed method

vượt các baseline thuộc ba nhóm: recommender system truyền thống, context-aware recommender system và dynamic recommender system. Điều này chứng minh rằng việc kết hợp context với preference change có thể cải thiện chất lượng recommendation, đặc biệt cho long-term users, những người có lịch sử đủ dài để mô hình học được sự dịch chuyển preference.

Hạn chế chính của bài báo là mô hình phụ thuộc vào việc chia dữ liệu thành các time units. Khi time window quá nhỏ, ví dụ theo tuần hoặc theo tháng ngắn, dữ liệu trở nên thưa và accuracy giảm. Vì vậy, mô hình hiện tại phù hợp hơn với long-term preference change, nhưng chưa thực sự mạnh với short-term preference change. Đây cũng là hướng future work mà bài báo đề cập.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể thay preference transition matrix bằng recurrent model, temporal attention hoặc Transformer để học thay đổi sở thích ở mức ngắn hạn tốt hơn. Thứ hai, có thể kết hợp với sequential recommender như SASRec hoặc TiSASRec để vừa học thứ tự item, vừa học context và preference transition. Thứ ba, có thể bổ sung cyclic temporal features như hour-of-day, day-of-week, season hoặc holiday để mô hình nắm được cả preference drift dài hạn và pattern lặp lại theo chu kỳ.

Ngoài ra, bài báo này rất phù hợp để kế thừa cho hướng recommender system có bias theo thời điểm. Trong các domain như food recommendation, grocery shopping, e-commerce hoặc content recommendation, user preference vừa phụ thuộc vào context hiện tại, vừa thay đổi theo thời gian. Một hướng mở rộng hợp lý là xây dựng mô hình kết hợp ba thành phần: *context-aware representation*, *dynamic preference transition*, và *cyclic temporal pattern*. Khi đó hệ thống có thể gợi ý không chỉ đúng item theo ngữ cảnh, mà còn phù hợp với xu hướng thay đổi dài hạn và chu kỳ hành vi của user. ““