

Paper

“‘latex

1 Summary

Bài báo *Prominence-Stratified Failure Modes in Retrieval-Augmented Commercial Recommendation: A 37,000-Run Audit* nghiên cứu cách các AI assistants như ChatGPT và Claude hoạt động như một dạng *commercial recommender system*. Khác với search engine truyền thống trả về danh sách link, AI assistant thường trực tiếp tổng hợp thông tin và nêu tên một số brand được khuyến nghị. Vì vậy, đối với brand, vấn đề không chỉ là “có xuất hiện trên search hay không”, mà còn là liệu brand có được retrieval, có được nhắc trong câu trả lời, và cuối cùng có được chọn làm recommendation hay không.

Bài báo cho rằng recommendation trong AI assistant có thể được xem như một funnel nhiều tầng. Với một commercial query, mô hình trước hết cần truy xuất được nguồn có nhắc đến brand. Sau đó, brand phải được đưa từ retrieval pool vào completion text. Cuối cùng, brand phải được endorsement như một lựa chọn được khuyến nghị, thay vì chỉ được nhắc như một ví dụ, một alternative, hoặc một brand không được chọn. Do đó, cùng là “không được recommend”, nhưng nguyên nhân có thể khác nhau hoàn toàn: không được retrieve, được retrieve nhưng không được mention, hoặc được mention nhưng không được recommend.

Về dữ liệu audit, bài báo thực hiện khoảng 37,000 production runs trên bốn model configurations, gồm OpenAI và Anthropic ở các mức reasoning effort khác nhau. Prompt corpus gồm 215 commercial prompts trải trên 19 sectors. Các brand được lấy từ một reference catalog gồm 533 brands và được chia thành năm prominence tiers. L1 là category leaders như Salesforce, HubSpot hoặc Datadog. L2 là established challengers. L3 là mid-market brands. L4 là long-tail specialists. L5 là regional players. Prominence ladder này không được hiểu là revenue hay market share trực tiếp, mà là proxy cho mức độ nhận diện/awareness footprint của brand trong sector.

Về mặt kỹ thuật, bài báo sử dụng một *funnel-stage classification* gồm bốn stage. Với mỗi cặp *run* và *sector-relevant brand*, brand được gán vào một trong bốn trạng thái:

S1 : No retrieval, no mention

S2 : Retrieved, but not mentioned

S3 : Mentioned, but not recommended

S4 : Recommended

Trong đó, *S1* nghĩa là brand không xuất hiện trong issued queries, retrieved domains, snippet texts, snippet titles, và cũng không xuất hiện trong completion. *S2* nghĩa là brand xuất hiện ở retrieval layer nhưng không được đưa vào câu trả lời. *S3* nghĩa là brand được nhắc trong completion nhưng không được hai judge đồng thuận là recommendation. *S4* là trạng thái thành công, tức brand được consensus-recommended.

Bài báo nhấn mạnh rằng các stage label này là mô tả quan sát được, không phải causal label tuyệt đối. Tuy nhiên, paper đề xuất một cách diễn giải thực dụng: *S1* thường tương ứng với *discoverability failure*, *S2* thường tương ứng với *compellingness failure*, và *S3* thường tương ứng với *positioning failure*. Nói cách khác, nếu brand không được retrieve thì vấn đề chính là visibility/discoverability. Nếu đã được retrieve nhưng không được mention thì nguồn retrieved có thể chưa đủ compelling. Nếu đã được mention nhưng không được recommend thì brand có thể chưa được position tốt so với competitors trong buying context cụ thể.

Để nhận diện brand trong completion, snippets, titles và queries, bài báo sử dụng *cross-judge consensus brand extraction*. Hai LLM judges chạy song song, gồm một judge từ Anthropic và một judge từ OpenAI. Một brand chỉ được tính là mentioned nếu cả hai judge cùng nhận diện. Đây là lựa chọn bảo thủ vì có thể under-count mentions, nhưng giúp tăng độ tin cậy khi so sánh cross-provider. Với recommendation slot, per-run cross-judge Jaccard khoảng 0.65–0.67.

Một kết quả chính của bài báo là *surface rate* thay đổi rất mạnh theo prominence level. Với per-query in-sector surface rate trên cấu hình premium production AI commerce surface, L1 brands xuất hiện trong khoảng 77% relevant queries, L2 khoảng 60%, L3 chỉ còn 23%, L4 còn 8%, và L5 chỉ 3%. Điều này cho thấy khi đi xuống long-tail và regional brands, khả năng brand được mô hình nhìn thấy giảm rất mạnh.

Tuy nhiên, bài báo cũng phân biệt *per-query surface rate* với *aggregate surface rate*. Aggregate surface rate đo xem một brand có từng surface trong bất kỳ in-sector run nào trong toàn bộ khoảng 37,000 runs hay không. Kết quả aggregate cho thấy L1 và L2 đạt 100%, L3 đạt 88%, nhưng L4 chỉ 52% và L5 chỉ 48%. Nói cách khác, khoảng một nửa L4/L5 brands không bao giờ xuất hiện trong toàn bộ audit. Đây là bằng chứng mạnh cho vấn đề long-tail invisibility trong retrieval-augmented commercial recommendation.

Bài báo tiếp tục đo *Stage-4 conversion rate when surfaced*, tức nếu brand đã surface thì xác suất nó được recommend cuối cùng là bao nhiêu. Kết quả đáng chú ý là L1

brands tuy gần như luôn retrieve được, nhưng conversion không cao tuyệt đối. Khi đã surfaced, L1 chỉ convert thành recommendation khoảng 25%–41% tùy model cell. Điều này cho thấy với category leaders, vấn đề không phải là visibility mà là cạnh tranh ở tầng comparison/positioning. Mô hình đã biết brand, nhưng vẫn có thể chọn competitor khác.

L2 brands có conversion rate cao nhất trong nhiều cell, khoảng 37%–52%. Điều này cho thấy established challengers có thể rất mạnh khi đã vào được consideration set, vì chúng đủ nổi bật để được mô hình nhận ra nhưng vẫn có thể được xem là phù hợp hơn L1 trong một số segment hoặc persona. Tuy nhiên, L2 cũng có tín hiệu không ổn định giữa các provider, đặc biệt liên quan đến persona-mediated substitution.

L3 được xem là điểm inflection. L3 có aggregate coverage giảm xuống 88%, per-query surface chỉ 23%, conversion khoảng 34%–40%, và persona effects đạt mức cao nhất. Điều này nghĩa là mid-market brands không chỉ gặp một lỗi đơn lẻ, mà có thể fail ở cả ba tầng: không được retrieve, được retrieve nhưng không được mention, hoặc được mention nhưng không được recommend. Vì vậy, L3 cần chiến lược kết hợp, không thể chỉ tối ưu một khía cạnh.

L4 và L5 là hai nhóm bị ảnh hưởng nặng nhất bởi Stage-1 failure. L4 brands chỉ surface trong 8% relevant per-query searches và khoảng 48% không bao giờ surface. L5 brands chỉ surface trong 3% relevant per-query searches và khoảng 52% không bao giờ surface. Với L4/L5, vấn đề chính là hệ thống không nhìn thấy brand từ đầu, nên các nỗ lực như viết nội dung positioning tốt hơn có thể không có tác dụng nếu brand chưa thể lọt vào retrieval pool.

Một phân tích quan trọng khác là ảnh hưởng của retrieval substrate. Bài báo so sánh native web search của provider với external retrieval như Exa và Brave. Kết quả cho thấy agreement giữa Native và Exa giảm theo prominence: L1 có Jaccard khoảng 0.83, L2 khoảng 0.75, L3 khoảng 0.58, L4 khoảng 0.56, và L5 khoảng 0.50. Điều này có nghĩa là retrieval system choice ảnh hưởng mạnh hơn ở long-tail. Một brand L1 gần như sẽ xuất hiện bất kể retrieval substrate nào, nhưng một brand L5 có thể xuất hiện hoặc biến mất tùy hệ thống retrieval.

Bài báo cũng đo *only-via-external share*, tức tỷ lệ brand surfaced chỉ qua external retrieval chứ không qua native search. Tỷ lệ này tăng mạnh ở long-tail: L3 là 38%, L4 là 60%, L5 là 56%. Điều này củng cố nhận định rằng native web-search tools của AI assistants bỏ sót nhiều long-tail và regional brands. Những brand này phụ thuộc nhiều vào neural retrieval hoặc conventional keyword search để được phát hiện.

Về persona effect, bài báo đo mức độ recommendation set thay đổi khi persona thay đổi nhưng prompt được giữ cố định. Metric được dùng là:

$$1 - Jaccard$$

tức fraction của recommendations bị swap giữa các persona. L3 có persona effect cao nhất,

khoảng 0.67–0.75 trong các OpenAI cells được báo cáo. L1 tương đối persona-resistant, chỉ khoảng 0.20–0.29. Điều này cho thấy mid-market brands chịu ảnh hưởng mạnh nhất bởi cách mô hình hiểu buyer context.

Từ các kết quả trên, bài báo xây dựng *five-mode failure taxonomy*. L1 category leaders chủ yếu fail ở *S2–S3*, tức brand đã được retrieve nhưng không được chọn cuối cùng. L2 established challengers có failure mode hỗn hợp, phụ thuộc provider và persona. L3 mid-market fail ở cả *S1*, *S2*, và *S3*. L4 long-tail specialists chủ yếu fail ở *S1*, tức discoverability. L5 regional players cũng fail ở *S1*, nhưng còn chịu thêm geographic gating, tức phải có region cues trong prompt thì mới có cơ hội surface.

Về practical prescription, paper cho rằng không có một công thức AEO/GEO chung cho mọi brand. Với L1, đầu tư thêm discoverability ít có tác dụng vì brand đã gần như luôn visible; cần tập trung vào differentiation, comparison content và positioning against named competitors. Với L2, cần segment-targeted positioning, đặc biệt trong các buyer persona cụ thể. Với L3, cần đầu tư hybrid: authority sources để tăng retrieval, segment content để tăng mention, và recommendation framing để tăng conversion. Với L4, trọng tâm là authority-list seeding và third-party coverage để vượt qua *S1*. Với L5, cần region-specific authority, native-language content và tín hiệu địa lý rõ ràng.

Bài báo cũng kiểm tra robustness theo model class, generation và multi-turn setting. Một kết quả đáng chú ý là trong OpenAI, chuyển từ mini sang non-mini hoặc generation mới hơn làm tăng brand mention density, ví dụ distinct brands per run tăng từ 7.7 lên 10.6 hoặc 16.4 tùy comparison. Tuy nhiên, hiệu ứng tương tự không rõ trên Anthropic. Dù vậy, prominence-stratified failure taxonomy vẫn giữ ổn định: L4/L5 vẫn bị Stage-1 invisibility rất cao.

Với multi-turn measurement, bài báo cho thấy hội thoại nhiều lượt không cứu được long-tail invisibility trong cấu hình được đo. Buyer-led iteration chủ yếu đào sâu vào các brand đã được nêu ở turn 1, thay vì mở rộng retrieval pool để đưa thêm long-tail brands mới. Do đó, nếu brand L4/L5 không được surface ở turn đầu, việc user hỏi tiếp không đảm bảo brand sẽ xuất hiện sau đó.

2 Conclusion

Hướng đi đã làm của bài báo là audit AI commercial recommendation như một hệ recommender nhiều tầng, thay vì chỉ xem nó là search visibility. Bài báo xây dựng một brand catalog 533 brands theo năm prominence levels, chạy khoảng 37,000 production runs trên OpenAI và Anthropic, rồi phân tích brand đi qua các stage: retrieved, mentioned, recommended. Cách tiếp cận này giúp tách rõ các failure modes khác nhau trong AI-mediated recommendation.

Đóng góp kỹ thuật quan trọng nhất của bài báo là *funnel-stage taxonomy* kết hợp với *prominence-stratified analysis*. Thay vì chỉ hỏi “brand có xuất hiện trong AI answer

không”, paper hỏi brand rơi ở stage nào: không được retrieve, được retrieve nhưng không được mention, được mention nhưng không được recommend, hay được recommend. Khi kết hợp với prominence ladder L1–L5, bài báo chỉ ra rằng mỗi tầng brand có dominant failure mode khác nhau.

Kết quả chính cho thấy L1 và L2 brands gần như đã giải quyết được visibility ở mức aggregate, nhưng vẫn cần tối ưu positioning và conversion. L3 là vùng bất ổn nhất, nơi brand vừa có vấn đề visibility, vừa có vấn đề persona fit và recommendation conversion. L4 và L5 bị long-tail invisibility rất nặng, với khoảng một nửa brands không bao giờ surface trong toàn bộ audit. Điều này cho thấy retrieval-augmented LLMs không tự động giải quyết long-tail problem.

Bài báo cũng cho thấy retrieval-system choice là yếu tố quan trọng, đặc biệt với low-prominence brands. Native web search và external retrieval như Exa/Brave đồng thuận cao ở L1/L2 nhưng giảm mạnh ở L4/L5. Vì vậy, brand nhỏ hoặc regional brand không chỉ cạnh tranh với brand lớn, mà còn phụ thuộc vào retrieval infrastructure của AI assistant mà buyer đang dùng.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng audit sang các hệ AI commerce khác như Gemini, Perplexity hoặc domain-specific assistants để kiểm tra liệu prominence-stratified failure modes có giữ nguyên không. Thứ hai, có thể thực hiện intervention experiments, ví dụ thêm brand vào authority lists hoặc tạo third-party comparison pages, rồi đo pre/post lift ở S1, S2, và S3. Thứ ba, có thể xây dựng causal model để phân biệt rõ hơn giữa discoverability, relevance, compellingness, persona fit và positioning.

Ngoài ra, paper này có thể kế thừa cho hướng recommender system nói chung ở khía cạnh *exposure fairness* và *long-tail recommendation*. Trong các hệ recommender truyền thống, popularity bias thường khiến head items được over-expose và tail items bị under-expose. Paper này cho thấy một dạng tương tự xuất hiện trong retrieval-augmented LLM recommendation, nhưng với cấu trúc funnel phức tạp hơn. Vì vậy, một hướng nghiên cứu tiếp theo là thiết kế AI recommender có khả năng kiểm soát exposure theo prominence tier, giảm invisibility cho long-tail brands, nhưng vẫn đảm bảo recommendation quality và user trust. ““