

Paper

“‘latex

1 Summary

Bài báo *Paraphrase Brittleness in Production Retrieval-Augmented Commercial Recommendation: Reproducibility Below the Rerun-Stability Baseline* nghiên cứu độ ổn định của các AI assistant khi trả lời các truy vấn thương mại. Trong bối cảnh này, ChatGPT hoặc Claude không chỉ là công cụ hỏi đáp, mà hoạt động như một *commercial recommendation engine*: khi user hỏi “best CRM”, “top CRM”, hoặc “best CRM for a SaaS startup”, mô hình sẽ trực tiếp nêu tên các brand được đề xuất. Vì vậy, nếu cùng một ý định mua hàng nhưng cách diễn đạt khác nhau lại tạo ra danh sách brand khác nhau, thì việc đo “AI visibility” bằng một vài prompt cố định sẽ trở nên rất không ổn định.

Vấn đề chính của bài báo là kiểm tra giả định phổ biến trong các công cụ AEO/GEO monitoring. Các công cụ này thường chọn một số prompt cố định, ví dụ “best CRM software”, chạy định kỳ, rồi đếm brand mention hoặc share-of-voice. Giả định ngầm là prompt đó đại diện cho một buying intent rộng hơn. Tuy nhiên, bài báo cho thấy prompt string không chỉ là nhãn đại diện cho intent, mà là một yếu tố quyết định trực tiếp brand nào được retrieve và recommend.

Bài báo phân biệt hai loại biến động. Loại thứ nhất là *rerun instability*, tức chạy lại cùng một prompt nhiều lần trong cùng một ngày nhưng recommendation set vẫn khác nhau. Loại thứ hai là *paraphrase brittleness*, tức cùng một buying intent nhưng đổi cách diễn đạt prompt thì recommendation set thay đổi. Nếu paraphrase brittleness lớn hơn rerun instability, thì biến động do chọn prompt còn lớn hơn noise tự nhiên khi chạy lại mô hình. Khi đó, một tracking prompt đơn lẻ không thể đại diện ổn định cho toàn bộ buyer intent.

Về mặt thực nghiệm, bài báo đo *rerun-stability baseline* trên 50 commercial prompts, bốn model cells, và mỗi prompt được chạy lại $N = 30$ lần trong cùng một ngày, tổng cộng khoảng 6000 rerun baseline runs. Các model cells gồm OpenAI *gpt-5.4-mini* ở low/high reasoning effort và Anthropic *claude-sonnet-4-6* ở low/high reasoning effort.

Đối với paraphrase brittleness, bài báo xây dựng một paraphrase corpus từ khoảng 20 base prompts thương mại thuộc các lĩnh vực như B2B SaaS, professional services và

consumer products. Mỗi base prompt được mở rộng theo năm trục paraphrase. Trục thứ nhất là *synonym swap*, ví dụ “best CRM” thành “top CRM”. Trục thứ hai là *structural rewrite*, ví dụ “what are the best CRMs?” thành “recommend a CRM”. Trục thứ ba là *modifier substitution*, ví dụ thêm hoặc đổi modifier như “AI CRM”, “modern CRM”. Trục thứ tư là *region/language*, ví dụ “best CRM in the UK” hoặc prompt bằng ngôn ngữ khác. Trục thứ năm là *specificity ladder*, ví dụ “CRM” → “CRM for SaaS” → “CRM for SaaS startup under 50 people”.

Bài báo gom *synonym swap* và *structural rewrite* thành nhóm *cosmetic rewordings*, vì về cơ bản intent vẫn ổn định, chỉ thay đổi bề mặt câu chữ. Các trục *modifier substitution*, *region/language*, và *specificity ladder* được gom thành nhóm *constraint-adding rewordings*, vì chúng không chỉ đổi câu chữ mà còn làm intent hẹp hơn hoặc thay đổi buyer segment.

Để đo độ giống nhau giữa hai recommendation sets, bài báo sử dụng *Jaccard similarity*:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Trong đó A và B là hai tập brand được recommend bởi hai runs hoặc hai paraphrases. Nếu J cao, hai danh sách recommendation giống nhau. Nếu J thấp, chỉ một phần nhỏ brand được giữ lại giữa hai lần đo.

Bài báo sử dụng *cross-judge consensus brand extraction* để xác định brand mentions và recommendation slots. Hai LLM judges chạy song song, gồm một judge từ Anthropic và một judge từ OpenAI. Một brand chỉ được tính là mentioned hoặc recommended nếu cả hai judge cùng đồng ý. Đây là cách đo bảo thủ, có thể bỏ sót một số mention, nhưng giúp giảm bias của từng judge riêng lẻ và tăng độ tin cậy khi so sánh.

Kết quả đầu tiên là cùng một prompt khi rerun vẫn có độ bất ổn nhất định. Trong 50 prompts, within-cell same-prompt recommendation-slot Jaccard nằm trong khoảng:

$$0.50\text{--}0.61$$

Tức là ngay cả khi không đổi prompt, recommendation set cũng chỉ trùng nhau khoảng một nửa đến hơn một nửa. Đây là baseline noise của production retrieval-augmented commercial recommendation.

Tuy nhiên, khi chỉ đổi cách diễn đạt prompt, độ giống nhau giảm mạnh hơn nhiều. Với nhóm *cosmetic rewordings*, cross-paraphrase consensus-recommendation Jaccard chỉ đạt:

$$0.288$$

với clustered 95% CI:

$$[0.215, 0.361]$$

Điều này nghĩa là hai cách diễn đạt gần như tương đương, ví dụ “best CRM” và “top

CRM”, có thể tạo ra hai recommendation sets chỉ giao nhau khoảng 28.8% theo Jaccard. Giá trị này thấp hơn rất nhiều so với rerun baseline 0.50–0.61.

Với nhóm *constraint-adding rewordings*, kết quả còn thấp hơn. Jaccard trung bình chỉ khoảng:

$$0.135$$

với clustered 95% CI:

$$[0.098, 0.175]$$

Riêng specificity-ladder subset đạt khoảng 0.133, còn region/language subset đạt khoảng 0.138. Điều này cho thấy khi buyer thêm ràng buộc như region, ngôn ngữ, hoặc segment cụ thể, danh sách brand được recommend thay đổi rất mạnh. Theo diễn giải của bài báo, Jaccard 0.135 tương đương per-list turnover khoảng 76% nếu hai set có kích thước tương đương.

Một kết quả rất quan trọng là paraphrase brittleness còn thấp hơn cả cross-provider rerun anchor. Same-prompt cross-provider Jaccard giữa OpenAI và Anthropic khoảng:

$$0.33$$

Trong khi cosmetic paraphrase trong cùng một provider chỉ khoảng 0.288. Điều này nghĩa là đổi cách diễn đạt prompt trong cùng một hệ thống đôi khi còn làm recommendation set khác hơn cả việc giữ nguyên prompt nhưng đổi provider.

Bài báo cũng kiểm tra liệu tăng *reasoning effort* có làm recommendation ổn định hơn không. Kỳ vọng tự nhiên là nếu mô hình suy luận nhiều hơn, output có thể nhất quán hơn. Tuy nhiên, kết quả cho thấy low-to-high reasoning effort gần như không cải thiện rerun stability hoặc paraphrase robustness. Với rerun stability, ảnh hưởng chỉ nằm khoảng:

$$-0.015 \text{ đến } +0.005$$

Với paraphrase robustness, hiệu ứng bị chặn trong khoảng ± 0.05 . Các mức này quá nhỏ so với khoảng cách giữa rerun baseline và paraphrase Jaccard. Vì vậy, bài báo kết luận rằng tăng reasoning effort không giải quyết được vấn đề brittleness trong commercial recommendation.

Về cơ chế, bài báo cho rằng retrieval-augmented generation có thể khuếch đại prompt sensitivity. Một thay đổi nhỏ trong prompt có thể làm retriever chọn nguồn khác, từ đó làm candidate brand pool khác, và cuối cùng model sinh ra recommendation set khác. Đây là điểm khác biệt với các task hỏi đáp đơn giản hơn. Trong commercial recommendation, câu trả lời không có một đáp án đúng duy nhất; có nhiều brand hợp lý, nên mô hình không hội tụ về một answer cố định dù reasoning effort cao hơn.

Từ kết quả này, bài báo phê phán cách đo *AI visibility* bằng một prompt cố định. Nếu một công cụ chỉ chạy “best CRM software” rồi báo cáo brand share-of-voice, metric đó chỉ

do visibility với đúng chuỗi prompt đó, không đại diện ổn định cho toàn bộ buying intent “CRM”. Với cùng một intent, buyer thật có thể dùng rất nhiều phrasing khác nhau, và mỗi phrasing có thể tạo ra brand set rất khác nhau. Do đó, biến động của metric có thể đến từ prompt-choice artifact chứ không phải do brand thực sự tăng hay giảm visibility.

Bài báo cũng cho rằng chỉ tăng số lượng paraphrases không phải là giải pháp hoàn chỉnh. Về lý thuyết, lấy mẫu nhiều paraphrases hơn sẽ giảm artifact, nhưng không gian diễn đạt tự nhiên của buyer rất lớn, vượt xa số prompt mà các commercial trackers thường dùng cho mỗi brand-intent pair. Vì vậy, paper cho rằng prompt-by-prompt mention tracking là một đơn vị đo lường không ổn định về cấu trúc; có thể cần chuyển sang đơn vị đo khác, chẳng hạn đo trên phân phối intent rộng hơn hoặc downstream outcome metrics.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một audit thực nghiệm để kiểm tra độ ổn định của AI commercial recommendation trước các biến thể paraphrase. Thay vì chỉ hỏi mô hình recommend brand nào cho một prompt cố định, bài báo so sánh ba mức: cùng prompt chạy lại nhiều lần, cùng prompt nhưng khác provider, và cùng buying intent nhưng khác paraphrase. Cách thiết kế này cho phép xác định liệu prompt string có phải là nguồn biến động chính trong recommendation set hay không.

Đóng góp kỹ thuật quan trọng nhất của bài báo là đưa ra *rerun-stability baseline* và dùng nó làm mốc để đánh giá paraphrase brittleness. Same-prompt rerun đạt Jaccard 0.50–0.61, nhưng cosmetic paraphrase chỉ đạt 0.288, còn constraint-adding paraphrase chỉ đạt 0.135. Điều này chứng minh rằng paraphrase variation không phải noise nhỏ, mà là yếu tố lớn hơn cả run-to-run instability thông thường.

Bài báo cũng chỉ ra rằng tăng reasoning effort không phải lời giải cho vấn đề này. Trong các task có một đáp án đúng, inference-time reasoning có thể giúp tăng accuracy hoặc giảm variance. Nhưng trong commercial recommendation, nơi có nhiều brand hợp lý và output phụ thuộc mạnh vào retrieval pool, reasoning effort không làm các paraphrase hội tụ về cùng một recommendation set. Do đó, brittleness bắt nguồn từ cấu trúc của RAG-based recommendation và multi-plausible-answer task, không chỉ từ việc mô hình “suy nghĩ chưa đủ”.

Ý nghĩa thực tiễn của paper là các metric kiểu “AI visibility” hoặc “share of AI voice” dựa trên một số prompt cố định cần được diễn giải rất cẩn thận. Một thay đổi tuần này so với tuần trước có thể không phản ánh brand thật sự mạnh hơn hay yếu hơn trong mắt AI assistant, mà có thể chỉ phản ánh lựa chọn prompt. Nếu không công bố prompt set và không đo trên nhiều paraphrase/intent variants, kết quả tracking rất khó tái lập và khó so sánh.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng audit sang nhiều ngày hoặc nhiều tuần để tách biệt paraphrase brittleness với temporal drift của

model và retrieval index. Thứ hai, có thể kiểm tra multilingual paraphrases rõ hơn, tách riêng trong-language paraphrase và cross-language paraphrase. Thứ ba, có thể nghiên cứu query rewriting hoặc intent canonicalization trước retrieval để xem liệu việc chuẩn hóa prompt có làm giảm brittleness hay không.

Ngoài ra, paper này có thể kế thừa trực tiếp cho hướng đánh giá recommender system dựa trên LLM/RAG. Khi hệ thống recommendation nhận input bằng natural language, evaluation không nên chỉ dùng một prompt đại diện cho một intent. Thay vào đó, cần đánh giá trên một phân phối paraphrases hoặc một representation ổn định hơn của intent. Với commercial recommendation, điều này đặc biệt quan trọng vì brand exposure, long-tail visibility, và AEO/GEO strategy đều có thể bị kết luận sai nếu metric bị chi phối bởi prompt wording. ““