

Paper

“latex

1 Summary

Bài báo *GEO-BENCH: Benchmarking Ranking Manipulation in Generative Engine Optimization* nghiên cứu bài toán thao túng thứ hạng trong các hệ thống dựa trên LLM, nơi mô hình không chỉ sinh văn bản mà còn đóng vai trò như một *ranker* hoặc *recommendation engine*. Trong các hệ thống này, LLM có thể xếp hạng sản phẩm, tài liệu hoặc nội dung để trả lời truy vấn của người dùng. Vì vậy, nếu một bên có thể chỉnh sửa nội dung mô tả sản phẩm hoặc tài liệu để làm item của mình được xếp cao hơn, vấn đề này sẽ ảnh hưởng trực tiếp đến fairness, user experience và market dynamics.

Vấn đề chính mà bài báo đặt ra là các nghiên cứu về *Generative Engine Optimization* (GEO) trước đây đã đề xuất nhiều phương pháp ranking manipulation, nhưng mỗi phương pháp thường được đánh giá trên dataset riêng, metric riêng và experimental setup riêng. Do đó, rất khó biết phương pháp nào thật sự mạnh hơn, phương pháp nào chỉ hiệu quả trên một dataset cụ thể, và phương pháp nào dễ bị phát hiện hơn. Bài báo đề xuất *GEO-BENCH* để chuẩn hóa quá trình đánh giá này.

Mục tiêu của GEO-BENCH là đánh giá các phương pháp thao túng ranking dưới cùng một protocol. Benchmark này thống nhất ba yếu tố: dataset, attack implementation và metric. Nhờ vậy, các phương pháp thuộc nhiều nhóm khác nhau như black-box prompt-based attacks, white-box gradient-based attacks và white-hat content optimization strategies có thể được so sánh trực tiếp.

Về mặt threat model, bài báo chia các phương pháp theo *access model*. Nhóm thứ nhất là *black-box prompt-based methods*, tức attacker chỉ cần query access tới ranking LLM hoặc dùng một LLM khác để sinh nội dung adversarial. Nhóm này thực tế hơn đối với commercial LLM API vì attacker không cần biết weights hoặc gradients của mô hình. Nhóm thứ hai là *white-box gradient-based methods*, yêu cầu truy cập gradient hoặc model internals để tối ưu adversarial token sequence. Nhóm thứ ba là các *white-hat C-SEO strategies*, tức các chiến lược viết lại nội dung theo hướng hợp pháp hơn như tăng authority, cải thiện fluency, thêm statistics hoặc hướng dẫn LLM hiểu nội dung tốt hơn.

GEO-BENCH đánh giá trên năm dataset lấy từ các nghiên cứu GEO và ranking manipulation gần đây: *Ragroll*, *STSDData*, *RewriteToRank*, *LLM Rank Optimizer*, và *C-SEO Bench*. Các dataset này chủ yếu thuộc product/content ranking, trong đó C-SEO Bench bao gồm nhiều domain như books, debate, news, retail, videogames và web. Việc dùng nhiều dataset giúp kiểm tra khả năng generalize của từng phương pháp, thay vì chỉ đánh giá trên một bộ dữ liệu duy nhất.

Các phương pháp được benchmark gồm nhiều nhóm. Với nhóm prompt-based adversarial attacks, bài báo đánh giá *Zero-Shot* và *TAP*. Zero-Shot là baseline đơn giản, dùng một LLM call để sinh adversarial suffix gắn vào mô tả sản phẩm. TAP sử dụng tree-structured prompt search, trong đó attacker LLM sinh nhiều candidate prompts, đánh giá chúng bằng target ranker, rồi prune và refine qua nhiều vòng.

Với nhóm gradient-based attacks, GEO-BENCH đánh giá *STS*, *RAF* và *StealthRank*. STS tối ưu một token sequence ngắn bằng gradient để tăng thứ hạng target item. RAF dùng quy trình hai giai đoạn để vừa tăng rank vừa giữ readability. StealthRank tối ưu đồng thời ba mục tiêu: rank promotion, linguistic fluency và tránh promotional keywords. Nhóm này có ưu điểm là tối ưu trực tiếp trên mô hình, nhưng yêu cầu white-box hoặc grey-box access.

Với nhóm white-hat C-SEO, bài báo đánh giá mười chiến lược content rewriting, nhưng trong main results tập trung vào ba phương pháp mạnh: *Authoritative*, *Content Improvement*, và *LLM Guidance*. Authoritative viết lại nội dung theo hướng tăng tính thuyết phục và độ tin cậy. Content Improvement kết hợp nhiều cải thiện như fluency, structure, authority và citation. LLM Guidance tạo markdown summary hoặc phần hướng dẫn để giúp ranking LLM hiểu nội dung tài liệu.

Target ranking model trong thí nghiệm là *Llama-3.1-8B-Instruct*. Việc dùng một open-weight ranker cố định giúp benchmark có thể tái lập và giúp so sánh giữa các phương pháp trở nên công bằng hơn. Perplexity ratio được tính bằng *Vicuna-7B* làm reference language model. Với C-SEO methods, các rewrites được sinh bằng GPT-4o-mini theo protocol của C-SEO Bench.

Bài báo đánh giá các phương pháp theo hai nhóm metric chính: *effectiveness* và *stealth*. Effectiveness đo liệu phương pháp có thật sự đẩy target item lên cao hơn trong ranking hay không. Stealth đo liệu nội dung sau manipulation có tự nhiên, ít bị phát hiện, và không chứa dấu hiệu quảng cáo/thao túng rõ ràng hay không.

Metric effectiveness đầu tiên là *Normalized Rank Gain* (NRG), đo mức cải thiện thứ hạng của target item trước và sau manipulation:

$$NRG = \frac{r_{before} - r_{after}}{L - 1}$$

Trong đó r_{before} là thứ hạng trước manipulation, r_{after} là thứ hạng sau manipulation, và L là độ dài candidate list. Giá trị dương nghĩa là target item được đẩy lên cao hơn, giá

trị 0 nghĩa là không đổi, còn giá trị gần 1 nghĩa là promotion rất mạnh.

Metric thứ hai là $Success@α$, đo liệu target item sau manipulation có nằm trong top- $α$ fraction của ranking hay không:

$$Success@α = \mathbb{I}[r_{after} \leq \lceil αL \rceil]$$

Ví dụ, với $α = 0.1$, metric này kiểm tra liệu target item có lọt vào top 10% hay không.

Metric thứ ba là $Promote@α$, chặt hơn $Success@α$ vì chỉ tính những trường hợp target item ban đầu nằm ngoài top- $α$ nhưng sau manipulation được đẩy vào top- $α$:

$$Promote@α = \mathbb{I}[r_{before} > \lceil αL \rceil \wedge r_{after} \leq \lceil αL \rceil]$$

Metric này giúp tách hiệu quả thật sự của attack khỏi các trường hợp target item vốn đã có rank cao từ đầu.

Về stealth, bài báo dùng *Keyword Violation Rate* (KVR) để đo tỷ lệ nội dung manipulated chứa các từ hoặc cụm từ bị xem là quá promotional/manipulative:

$$KVR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[adv_text_i \cap W_{bad} \neq \emptyset]$$

Trong đó W_{bad} là tập restricted keywords như các cụm yêu cầu mô hình rank item đầu tiên hoặc recommend item một cách lộ liễu. KVR càng thấp thì nội dung càng stealthy theo tiêu chí keyword.

Metric stealth thứ hai là *Perplexity Ratio* (PPL-R), đo độ tự nhiên của manipulated text so với original text:

$$PPL-R = \frac{PPL(adv_text)}{PPL(orig_text)}$$

Nếu PPL-R gần 1, nội dung sau manipulation vẫn có độ tự nhiên gần với bản gốc. Nếu PPL-R lớn, nội dung có khả năng bị suy giảm fluency hoặc trở nên bất thường.

Kết quả thực nghiệm cho thấy có một trade-off rõ ràng giữa effectiveness và stealth đối với adversarial attacks. TAP thường promote rất tốt nhưng có KVR rất cao, nghĩa là nó dễ bị phát hiện vì dùng nhiều từ ngữ promotional. STS có KVR thấp hơn nhưng làm giảm fluency mạnh, thể hiện qua PPL-R cao. RAF và Zero-Shot stealthier hơn ở một số tín hiệu nhưng hiệu quả promotion lại yếu hơn. Nói cách khác, các adversarial attacks khó đạt đồng thời ba mục tiêu: rank promotion mạnh, keyword-stealthy và fluent.

Một phát hiện quan trọng là access model không dự đoán trực tiếp attack strength. Trực giác ban đầu có thể cho rằng white-box gradient-based attacks sẽ mạnh hơn vì có quyền truy cập gradient. Tuy nhiên, kết quả cho thấy các phương pháp black-box semantic rewriting như TAP, Authoritative và Content Improvement lại nằm trong nhóm có average NRG cao nhất. Điều này có thể do ranking LLM hoạt động ở mức semantic,

nên các rewrite tự nhiên và thuyết phục có thể phù hợp hơn so với token-level gradient perturbation.

Bài báo cũng cho thấy white-hat rewriting có thể nguy hiểm hơn hoặc khó phát hiện hơn adversarial perturbation. Trên C-SEO Bench, Authoritative rewriting đạt NRG rất cao, khoảng 0.83, đồng thời có KVR bằng 0 và PPL-R khoảng 0.74. Điều này nghĩa là nội dung vừa promote mạnh, vừa không vi phạm keyword detector, vừa vẫn fluent. Đây là điểm rất quan trọng: hệ thống phòng thủ không chỉ nên tập trung vào prompt-injection thô hoặc adversarial suffix, mà còn phải xử lý cả các chiến lược content optimization hợp pháp nhưng có thể làm lệch ranking.

Một kết quả khác là method rankings không ổn định giữa các dataset. Ví dụ, TAP có average NRG mạnh nhất nhưng không đứng đầu trên mọi dataset. Authoritative rất mạnh trên C-SEO Bench nhưng có thể yếu trên LLM Rank Optimizer. STS có thể đạt NRG tốt ở một dataset nhưng giảm mạnh ở dataset khác. Điều này chứng minh rằng đánh giá trên một dataset duy nhất dễ tạo ra kết luận sai về generalizability của phương pháp.

Về mặt phòng thủ, bài báo cho rằng keyword detector và perplexity detector là chưa đủ. Keyword detector có thể bắt các attack dùng từ ngữ lộ liễu như TAP, nhưng có thể bỏ sót các rewrite fluent và ít keyword. Perplexity detector có thể phát hiện token-level perturbation làm văn bản kém tự nhiên như STS, nhưng lại không bắt được content rewriting trôi chảy. Vì vậy, hai tín hiệu này bổ sung cho nhau nhưng vẫn chưa đủ để phát hiện mọi dạng ranking manipulation.

Từ kết quả này, GEO-BENCH đưa ra hàm ý rằng detection nên chuyển sang mức semantic hoặc intent-level. Thay vì chỉ kiểm tra xem text có chứa keyword cấm hay có perplexity bất thường không, hệ thống cần phát hiện liệu nội dung có đang cố tình hướng ranker đến một kết luận promotional cụ thể hay không. Đây là vấn đề khó hơn vì white-hat content optimization có thể hợp pháp, tự nhiên, và vẫn làm tăng ranking rất mạnh.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một benchmark thống nhất để đánh giá các phương pháp ranking manipulation trong GEO. Thay vì so sánh các kết quả rời rạc từ nhiều paper với dataset và metric khác nhau, GEO-BENCH đưa black-box attacks, white-box gradient-based attacks và white-hat C-SEO strategies vào cùng một evaluation protocol trên năm dataset và một target ranker cố định.

Đóng góp kỹ thuật quan trọng nhất của bài báo là chuẩn hóa cả metric effectiveness và metric stealth. Effectiveness được đo bằng NRG, Success@ α và Promote@ α , giúp phân biệt giữa rank improvement liên tục, khả năng lọt vào vùng high-visibility, và promotion thật sự từ ngoài top region vào top region. Stealth được đo bằng KVR và PPL-R, giúp đánh giá liệu manipulation có lộ dấu hiệu promotional hoặc làm giảm naturalness của

văn bản hay không.

Kết quả chính cho thấy không có một phương pháp nào thống trị hoàn toàn trên cả effectiveness và stealth. Các adversarial attacks thường phải đánh đổi: hoặc promote mạnh nhưng dễ bị phát hiện, hoặc stealthy hơn nhưng promotion yếu. Tuy nhiên, white-hat content rewriting lại có thể vừa hiệu quả vừa khó bị phát hiện bởi keyword/perplexity detectors, đặc biệt trong trường hợp Authoritative trên C-SEO Bench. Điều này làm thay đổi trọng tâm threat model: nguy cơ không chỉ đến từ adversarial prompt injection, mà còn từ semantic content optimization rất tự nhiên.

Bài báo cũng bác bỏ giả định rằng white-box access luôn tạo ra attack mạnh hơn. Trong thí nghiệm, các phương pháp black-box như TAP và các chiến lược rewrite dạng Authoritative/Content Improvement có thể match hoặc vượt gradient-based attacks. Điều này cho thấy đối với LLM rankers, semantic-level rewriting có thể phù hợp với cơ chế đánh giá của mô hình hơn token-level gradient optimization.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng GEO-BENCH sang nhiều target rankers khác như Qwen, Mistral, Llama phiên bản lớn hơn hoặc production APIs để kiểm tra tính ổn định của kết quả. Thứ hai, có thể bổ sung human evaluation hoặc trained detectors để đánh giá stealth tốt hơn, thay vì chỉ dùng keyword violation và perplexity ratio. Thứ ba, có thể mở rộng benchmark sang các ngôn ngữ khác, domain khác, và RAG pipeline đầy đủ có retrieval, reranking và generation.

Ngoài ra, paper này có thể kế thừa trực tiếp cho hướng nghiên cứu *AI commercial recommendation* và *AEO/GEO*. Nếu các AI assistants ngày càng đóng vai trò như ranker/recommender, thì ranking manipulation cần được đánh giá như một bài toán benchmark nghiêm túc, không thể chỉ dựa vào case study. GEO-BENCH cung cấp nền tảng ban đầu để đo cả mức độ promotion và mức độ detectability, từ đó hỗ trợ thiết kế defense tốt hơn cho LLM-based ranking systems. ““