

Paper

“`latex id="recdistillsummary`”

1 Summary

Bài báo *Rec-Distill: An Industrial Distillation Pipeline for Large-Scale Recommendation Models* nghiên cứu bài toán *knowledge distillation* trong hệ recommender công nghiệp quy mô lớn. Bối cảnh chính là các mô hình recommendation lớn tuân theo *scaling laws*: khi tăng số tham số, độ dài chuỗi hành vi và lượng dữ liệu huấn luyện, model có thể đạt performance tốt hơn. Tuy nhiên, các mô hình rất lớn này khó deploy trực tiếp trong production vì hệ recommender online có ràng buộc nghiêm ngặt về latency, throughput và chi phí serving.

Vấn đề trung tâm của paper là khoảng cách giữa *offline model scaling* và *online deployment*. Teacher model có thể được scale lên rất lớn để học được nhiều pattern phức tạp trong user-item interaction, nhưng student model phục vụ online phải nhẹ hơn nhiều. Vì vậy, cần một framework có thể truyền càng nhiều gain của teacher sang student càng tốt, nhưng không làm tăng chi phí inference của hệ thống online.

Paper gọi framework đề xuất là *Rec-Distill*. Đây là một pipeline distillation công nghiệp, trong đó teacher và student được huấn luyện tách rời. Teacher model có thể tiếp tục scale và học streaming data, còn output logits của teacher được ghi vào storage để student đọc lại trong quá trình training. Nhờ vậy, hệ thống tránh được co-training tốn kém, tức không cần chạy teacher tại mỗi student training step, đồng thời vẫn giữ được khả năng cập nhật theo dữ liệu mới.

Bài báo phân tích distillation gain bằng công thức:

$$\Delta Gain_{distill} = \Delta Gain_{scale} \times \eta$$

Trong đó:

$$\Delta Gain_{scale} = P_T - P_S^{raw}$$

là phần gain do teacher scale lớn hơn student, còn:

$$\eta = \frac{P_S^{distill} - P_S^{raw}}{P_T - P_S^{raw}}$$

là *distillation transferability*, tức tỷ lệ gain của teacher mà student hấp thụ được. Theo cách nhìn này, để distillation hiệu quả cần tối ưu đồng thời hai phần: tăng performance của teacher P_T để làm lớn $\Delta Gain_{scale}$, và tăng η để student hấp thụ được nhiều hơn.

Để tăng $\Delta Gain_{scale}$, Rec-Distill scale teacher theo ba hướng. Thứ nhất là tăng *dense parameter size*. Paper sử dụng kiến trúc *TokenMixer-Large*, một hướng thay thế attention bằng token-mixing operations hiệu quả hơn, cho phép scale teacher tới khoảng $24B$ dense parameters. Thứ hai là scale *sequence modeling*. Paper sử dụng kiến trúc *LONGER* để xử lý chuỗi hành vi người dùng rất dài, lên đến $20K$ behavior sequence length, nhờ sequence compression và mixed attention. Thứ ba là scale *training data volume*, trong đó teacher có thể dùng nhiều dữ liệu hơn student để học pattern tốt hơn, rồi truyền lại tri thức cho student qua distillation.

Để tăng η , paper thiết kế ba thành phần chính: *black-box distillation*, *decoupled-tower student architecture*, và *debiasing mechanism*. Với black-box distillation, student chỉ học từ final output logits của teacher, không dùng intermediate representations hay gradients. Cách này đơn giản, phổ quát và dễ triển khai trong production hơn các white-box methods, vì không cần truyền hidden states rất lớn hoặc phụ thuộc kiến trúc teacher.

Formulation KD cơ bản được viết như sau. Với teacher logit:

$$z_T = f_T(x)$$

và student logit:

$$z_S = f_S(x)$$

xác suất softened là:

$$p_T = \sigma(z_T/\tau), \quad p_S = \sigma(z_S/\tau)$$

Distillation loss theo KL divergence:

$$L_{distill} = \tau^2 D_{KL}(p_T || p_S)$$

Student objective thường là:

$$L_S = \alpha L_{task} + (1 - \alpha) L_{distill}$$

Tuy nhiên, trong Rec-Distill, paper không giữ ràng buộc hai trọng số phải cộng thành 1. Thay vào đó, paper dùng:

$$L_S = L_{task} + \alpha L_{distill}$$

và tune α để scale của task loss và distillation loss nằm cùng bậc độ lớn. Đây là điểm thực tế quan trọng, vì trong binary classification như CTR/CVR, distillation loss có thể nhỏ hơn task loss tới vài bậc, làm tín hiệu distillation quá yếu nếu dùng weighting mặc định.

Paper cũng so sánh MSE loss và CE loss cho distillation. Với MSE, gradient có dạng:

$$\frac{\partial L_{MSE}}{\partial \theta} = (p_S - p_T)p_S(1 - p_S)\frac{\partial z_S}{\partial \theta}$$

Trong khi với CE:

$$\frac{\partial L_{CE}}{\partial \theta} = (p_S - p_T)\frac{\partial z_S}{\partial \theta}$$

CE tránh được hệ số $p_S(1 - p_S)$ nên ít bị vanishing gradient hơn khi p_S gần 0 hoặc 1. Vì vậy paper chọn CE loss cho black-box logit distillation.

Thành phần kiến trúc quan trọng nhất là *decoupled-tower student*. Student gồm một shared backbone và hai tower độc lập. *Main Task Tower* là tower phục vụ online, được train chỉ bằng ground-truth task loss:

$$L_{main} = L_{task}$$

Auxiliary Tower là tower dành riêng cho distillation, được train bằng:

$$L_{aux} = L_{task} + \alpha L_{distill}$$

Shared backbone nhận gradient từ cả hai tower, nên representation học được vẫn hưởng lợi từ teacher signal. Nhưng output dùng online chỉ đến từ Main Task Tower, do đó nếu teacher signal bị delay, bị shift hoặc pipeline distillation lỗi tạm thời, online serving vẫn được cách ly khỏi rủi ro.

Theo diagram ở trang 4, kiến trúc tổng thể có teacher ở bên trái, high-speed storage ở giữa và nhiều student ở bên phải. Teacher nhận features, đi qua TokenMixer và task tower, sau đó ghi teacher logits vào storage. Mỗi student đọc teacher label từ storage, đồng thời dùng ground-truth label để train main tower. Thiết kế này hỗ trợ mô hình *1-to-N distillation*, tức một teacher có thể supervise nhiều students khác nhau, thậm chí ở các stage khác nhau trong recommendation pipeline.

Một vấn đề kỹ thuật quan trọng khác là *student debias design*. Trong recommender/ad systems, dữ liệu training thường đến từ non-uniform sampling. Teacher và student có thể dùng sampling policy khác nhau, vì teacher có thể dùng nhiều dữ liệu hơn hoặc sampling aggressive hơn để tăng performance, trong khi student bị giới hạn bởi chi phí training. Điều này tạo distribution mismatch giữa teacher output và student target space.

Paper dùng sampling-aware correction để biến raw logit z thành posterior ít bias hơn:

$$\hat{y} = \frac{1}{1 + \frac{r_s}{p_X}(e^{-z} + 1 - r_+ + b_s)}$$

Trong đó r_s là negative sampling ratio, r_+ là nominal retention rate của positive samples, p_X là effective retention probability theo task và traffic condition, còn b_s là additive bias

term do sampling strategy.

Vì teacher và student có thể có debias function khác nhau, paper phân biệt teacher raw logit T_1 , teacher debiased output:

$$T_2 = f_T(T_1)$$

student raw logit S_1 , và student debiased output:

$$S_2 = f_S(S_1)$$

Nếu trực tiếp distill từ T_2 sang S_2 , hai giá trị này có thể không nằm trong cùng corrected probability space vì $f_T \neq f_S$. Do đó, Rec-Distill đưa teacher raw logit qua student-side correction:

$$T'_2 = f_S(T_1)$$

rồi distill bằng:

$$L_{distill} = D(T'_2, S_2)$$

Cách này đặt teacher prediction và student prediction vào cùng không gian hiệu chỉnh, giảm bias do khác sampling strategy.

Về system design, paper đề xuất *hybrid batch-streaming distillation pipeline*. Theo diagram ở trang 6, pipeline có hai pha. *Batch distillation phase* dùng dữ liệu batch lớn để giúp student hội tụ nhanh đến baseline tốt. *Streaming distillation phase* xử lý dữ liệu mới liên tục, trong đó teacher ghi logits của streaming data vào low-latency storage, sau đó student data processing pipeline join original data stream với distillation signals để tạo supplementary data stream cho student.

Batch phase quan trọng vì nếu chỉ train bằng streaming distillation từ đầu thì model hội tụ quá chậm cho deployment thực tế. Streaming phase quan trọng vì recommender system là môi trường non-stationary: user behavior, item catalog và data distribution liên tục thay đổi. Nếu student sau batch phase chỉ học ground-truth labels mà không tiếp tục nhận teacher signals, distillation gain sẽ bị suy giảm theo thời gian.

Thực nghiệm được thực hiện trên nhiều scenario công nghiệp của Douyin và TikTok, gồm *E-commerce Ads*, *Multi-scenario recommendation*, và *Live-streaming recommendation*. Với E-commerce Ads, task là CVR prediction, dữ liệu gồm ad clicks, orders và purchase behaviors, với hơn một nghìn features và long user behavior sequences có raw length hơn 20K. Multi-scenario recommendation dùng khoảng 7B samples mỗi ngày. Live-streaming recommendation có hàng nghìn features và nhiều prediction targets.

Kết quả chính cho thấy Rec-Distill đạt transferability cao ở nhiều scenario. Trong Ads, teacher gain là +0.69% AUC, student gain là +0.44%, nên:

$$\eta = 64\%$$

Trong Recommendation, teacher gain là +0.57%, student gain +0.26%, transferability 45%. Trong Live, teacher gain là +0.74%, student gain +0.37%, transferability 50%. Điều này cho thấy phần lớn gain từ teacher scaling có thể được chuyển sang student nhẹ hơn.

Paper cũng phân tích ảnh hưởng của student capacity. Khi teacher cố định ở 7B dense parameters, student 1B đạt transferability 73%. Khi giảm student xuống 376M, transferability còn 65%. Khi giảm tiếp xuống 184M, transferability còn 48%. Điều này cho thấy distillation vẫn có ích với student nhỏ, nhưng capacity gap quá lớn làm giảm khả năng hấp thụ teacher knowledge.

Khi tăng teacher từ 7B lên 24B nhưng giữ student 1B, transferability giảm từ 73% xuống 65%. Tuy vậy, mức 65% vẫn đủ cao để biến additional teacher gain thành practical student improvement. Đây là kết quả quan trọng vì nó cho thấy Rec-Distill vẫn hoạt động trong bối cảnh teacher rất lớn.

Paper cũng kiểm tra student architecture. Với cùng khoảng 616M parameters, student 4-layer, dim 480 đạt transferability 68%, trong khi student 2-layer, dim 640 chỉ đạt 63%. Điều này cho thấy không chỉ tổng số tham số mà cách phân bổ depth/width và FLOPs cũng ảnh hưởng đến khả năng transfer.

Một kết quả đáng chú ý là distillation không phá student scaling law. Khi student lớn dần, đường performance sau distillation gần như song song với đường Base model. Nói cách khác, distillation nâng cả curve lên thay vì thay thế vai trò của student capacity. Điều này rất quan trọng cho production vì student vẫn có thể tiếp tục được cải tiến theo hướng kiến trúc bình thường.

Ablation về decoupled-tower cho thấy thiết kế này cần thiết. Single-tower chỉ dùng $L_{distill}$ đạt gain rất nhỏ, khoảng +0.03%. Single-tower dùng $L_{task} + L_{distill}$ đạt +0.36%. Decoupled-tower với main tower train bằng L_{task} và auxiliary tower train bằng $L_{distill}$ đạt +0.41%. Khi auxiliary tower dùng cả $L_{task} + L_{distill}$, main tower đạt gain tốt nhất +0.44%. Điều này chứng minh cả risk isolation và representation alignment đều quan trọng.

Ablation teacher scaling cho thấy từng hướng scale đều tạo teacher gain có thể transfer. Khi scale dense parameters từ 1B lên 7B, teacher gain +0.30%, student gain +0.22%, transferability 73%. Khi scale sequence length từ 5K lên 20K, teacher gain +0.19%, student gain +0.11%, transferability 61%. Khi scale data, teacher gain tăng từ +0.42% lên +0.69%, còn student gain tăng từ +0.28% lên +0.44%, dù student không trực tiếp dùng enlarged dataset.

Ablation về hybrid pipeline cũng xác nhận cả batch và streaming đều cần thiết. Nếu sau batch convergence student không tiếp tục nhận streaming distillation signals, sau 5 ngày gain chỉ còn +0.05% thay vì +0.10%. Ngược lại, nếu bỏ batch distillation và chỉ dùng streaming từ đầu, mô hình hội tụ quá chậm, thậm chí sau hơn 5 tháng vẫn kém hơn nhóm có batch distillation. Điều này chứng minh batch giúp tạo performance ceiling ban đầu, còn streaming giúp duy trì adaptation.

Ablation debias cho thấy nếu bỏ debiasing, AUC gain giảm từ +0.44% xuống +0.34%.

Điều này xác nhận distribution mismatch giữa teacher và student sampling là một vấn đề thật trong production distillation, và correction theo student-side debias function giúp tăng transferability.

Online A/B test cho thấy Rec-Distill tạo impact thực tế trên nhiều business metrics. Trong Ads, mô hình đạt +1.00% ADVV, +1.10% ADSS, +0.68% Order và +0.62% GMV. Trong recommendation, các chỉ số như StayDuration, Play/U và Finish/U đều tăng, trong đó Finish/U tăng +1.2725%. Trong Live, Watch Duration/U tăng +0.24% và Gift Revenue/U tăng +0.78%. Điều này chứng minh gain offline có thể chuyển thành business improvement online.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một pipeline distillation công nghiệp để đưa lợi ích của large-scale recommendation model vào student model nhẹ có thể deploy online. Rec-Distill không cố deploy teacher lớn trực tiếp, mà scale teacher offline để tăng $\Delta Gain_{scale}$, sau đó tối ưu pipeline và student design để tăng distillation transferability η . Đây là cách giải quyết thực tế cho mâu thuẫn giữa scaling law và serving efficiency.

Đóng góp kỹ thuật quan trọng nhất gồm bốn phần. Thứ nhất là *decoupled teacher-student training*, trong đó teacher liên tục sinh logits và ghi vào storage, còn student đọc tín hiệu này để train mà không cần co-training. Thứ hai là *decoupled-tower student architecture*, tách main task tower phục vụ online khỏi auxiliary distillation tower để vừa học được từ teacher, vừa cô lập rủi ro production. Thứ ba là *student-side debias correction*, giúp teacher và student nằm cùng corrected probability space khi sampling strategy khác nhau. Thứ tư là *hybrid batch-streaming pipeline*, kết hợp batch convergence nhanh với streaming adaptation theo dữ liệu mới.

Kết quả thực nghiệm cho thấy Rec-Distill có thể distill teacher rất lớn, lên đến 24B dense parameters và 20K behavior sequence length, sang student nhẹ hơn với transferability cao. Trong setting tốt nhất, η vượt 60%, và trong nhiều scenario công nghiệp vẫn đạt khoảng 45%–64%. Điều này chứng minh scaling teacher không chỉ có ý nghĩa offline, mà có thể đem lại gain thực tế cho online system nếu pipeline distillation được thiết kế đúng.

Bài báo cũng chỉ ra rằng transferability phụ thuộc mạnh vào student capacity và architecture. Student nhỏ vẫn hưởng lợi từ distillation, nhưng capacity gap càng lớn thì η càng giảm. Tuy nhiên, distillation không làm mất student scaling behavior; nó nâng performance curve của student lên. Vì vậy, Rec-Distill có thể song song với các hướng cải tiến student model trong production.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể kết hợp Rec-Distill với các kênh transfer giàu thông tin hơn như LoopFM, tức ngoài scalar/logit distillation còn truyền historical teacher embeddings hoặc structured representations. Thứ hai, có thể mở rộng sang multimodal recommendation, nơi teacher dùng video, audio, text hoặc image

features giàu hơn student. Thứ ba, có thể nghiên cứu adaptive transferability control, tự động điều chỉnh α , debias correction và sampling strategy theo data drift trong streaming environment.

Ngoài ra, paper này rất phù hợp để kế thừa cho hướng recommender system quy mô lớn có nhiều context và long user history. Teacher có thể học từ chuỗi dài, dữ liệu nhiều hơn và feature phong phú hơn, còn student chỉ cần nhận distillation signals để hưởng lợi mà không trả toàn bộ chi phí training/serving. Một hướng phát triển hợp lý là xây dựng framework kết hợp *teacher scaling*, *structured historical representation transfer*, và *streaming distillation* để vừa tăng khả năng cá nhân hóa, vừa giữ được latency thấp trong production. “