

Paper

“latex

1 Summary

Bài báo *Fine-Tuned LLM as a Complementary Predictor Improving Ads System* nghiên cứu cách đưa Large Language Model vào hệ thống quảng cáo công nghiệp mà không thay thế toàn bộ pipeline recommender truyền thống. Trong các hệ thống ads/recommendation production, pipeline thường gồm nhiều tầng: candidate generation hoặc retrieval tạo danh sách ứng viên ban đầu, sau đó ranking model chính xác hơn sẽ xếp hạng các ứng viên này. Các mô hình ranking truyền thống thường dựa nhiều vào sparse ID features, user behavior, advertiser ID, campaign ID, creative ID, conversion history và nhiều feature cross phức tạp.

Vấn đề chính mà bài báo đặt ra là mặc dù LLM có khả năng hiểu ngôn ngữ, kiến thức thế giới và suy luận semantic tốt, việc đưa LLM trực tiếp vào hệ ads production rất khó. Thứ nhất, ads recommender phụ thuộc nhiều vào ID-centric sparse features, trong khi LLM hoạt động tự nhiên hơn với text tokens. Thứ hai, ranking model công nghiệp cần học deep cross-feature interactions và calibration objectives phức tạp, vốn không dễ ánh xạ trực tiếp sang LLM. Thứ ba, LLM có chi phí inference và decoding lớn, khó đáp ứng strict latency SLO trong hệ thống ads quy mô lớn.

Vì vậy, bài báo không dùng LLM làm ranker trực tiếp. Thay vào đó, paper đề xuất dùng một open-source LLM đã fine-tune như một *ads-specific ancillary predictor*. Nhiệm vụ của LLM là đọc profile và lịch sử hành vi của user, sau đó dự đoán các advertiser mà user có khả năng convert trong tương lai. Output này được dùng như một tín hiệu bổ sung cho hai tầng: retrieval và ranking.

Pipeline tổng thể gồm bốn stage chính: *user selection*, *feature compilation*, *prompt-based advertiser prediction*, và *downstream consumption*. Ở stage user selection, hệ thống không chạy LLM cho tất cả user, mà giới hạn daily inference cho nhóm user có giá trị cao, cụ thể là active Pinterest users ở U.S. có past conversions trong 90 ngày gần nhất. Cách này giúp cân bằng giữa coverage, cost và inference speed.

Ở stage *feature compilation*, hệ thống chuyển nhiều loại tín hiệu user thành một prompt text có cấu trúc. Các feature gồm profile như age, gender, user state; onsite

searches; offsite attributed conversions; offsite matched conversions; offsite searches liên quan đến conversion; offsite URLs; top categories/interests; onsite/offsite categories; item brands và brands trích xuất từ URL. Ngoài ra, prompt còn chứa hai nhóm advertiser pool: các advertiser mà user từng convert trước đó và preset advertiser pool từ top-revenue U.S. shopping advertisers.

Nhân chính của bài toán là *next advertiser*. Với một snapshot tại ngày x , label được định nghĩa là advertiser đầu tiên mà user convert trong cửa sổ từ ngày $x+1$ đến $x+7$. Công thức này biến bài toán thành next-advertiser prediction thay vì multi-label prediction. Điều này phù hợp với mục tiêu tạo advertiser prior cho retrieval và ranking.

Paper thiết kế nhiều prompt khác nhau theo stage. Với *Supervised Fine-Tuning* (SFT), prompt yêu cầu model dự đoán đúng một advertiser duy nhất:

Predict 1 advertiser most likely to convert

Output ở stage này là free-text hoặc advertiser name đơn. Mục tiêu là học task chính xác nhất: từ user profile và behavior, chọn advertiser có khả năng convert tiếp theo.

Sau SFT, paper thử thêm *GRPO*-based reinforcement learning. Ở GRPO stage, prompt yêu cầu model sinh danh sách:

20 advertisers + 5 user interests

Output được yêu cầu theo XML format:

$\langle answer \rangle \langle interests \rangle \dots \langle /interests \rangle \langle advertiser_names \rangle \dots \langle /advertiser_names \rangle \langle /answer \rangle$

Việc sinh 20 advertisers thay vì 5 giúp reward có nhiều variance hơn trong quá trình GRPO.

Reward của GRPO được định nghĩa:

$$R_{total} = R_{match} - P_{adv_len} - P_{interest_len}$$

Trong đó R_{match} thưởng nếu advertiser đúng xuất hiện trong danh sách dự đoán và xuất hiện ở vị trí càng cao càng tốt. Nếu correct advertiser nằm ở vị trí i , reward gồm:

$$R_{match}(i) = R_{base}(i) + R_{bonus}(i)$$

với:

$$R_{base}(i) = 0.1(20 - i)$$

và:

$$R_{bonus}(i) = \begin{cases} 2.0, & i \leq 4 \\ 0, & otherwise \end{cases}$$

Ngoài ra, length penalty đảm bảo model tuân thủ format và số lượng advertiser/interests:

$$P_{len}(n, n^*) = \begin{cases} 0, & n = n^* \\ \min(0.1|n - n^*|, 1.0) + 1.0, & otherwise \end{cases}$$

Như vậy, GRPO không chỉ tối ưu recall advertiser đúng mà còn ép model giữ đúng output format.

Một thành phần kỹ thuật quan trọng khác là *Semantic ID* (SID) enhancement. Paper xây dựng SIDs từ multimodal PinCLIP embeddings bằng RQ-VAE, với 5 levels và 20248 codes mỗi level. Ý tưởng là SID giúp LLM nhận thêm tín hiệu semantic/multimodal về Pin hoặc item mà text thuần không mô tả hết được. SID được đưa vào prompt như một chuỗi tín hiệu gần đây của user.

Để tích hợp SID vào LLM mà không làm mất general knowledge và instruction following, paper dùng multi-phase post-training. Phase 1 chỉ học embedding của SID tokens, còn text token embeddings và transformer parameters được freeze. Mục tiêu là align SID token space với normal text token space. Phase 2 unfreeze toàn bộ model và tiếp tục pretraining trên dữ liệu recommendation có SID, trộn thêm general-domain data để giảm catastrophic forgetting. Phase 3 fine-tune model cho advertiser prediction task với prompt có thêm SID sequences.

Ở downstream integration, paper dùng LLM outputs theo hai cách. Thứ nhất là *retrieval*: predicted advertisers được dùng như targeting filters trong một candidate generator mới. Sau đó retrieval dưới các advertisers này được thực hiện bằng two-tower model tối ưu user engagement. Candidate generator này là kênh bổ sung, không thay thế các candidate generators chính. Mục tiêu là bổ sung traffic từ các advertisers có high conversion intent mà các kênh retrieval hiện tại chưa cover đủ.

Thứ hai là *ranking*: predicted advertisers và user interests được featurize rồi đưa vào downstream conversion models như *ctcvr* và *vtcvr*. Như vậy, LLM không trực tiếp quyết định rank cuối cùng, mà cung cấp prior/features cho model ads truyền thống.

Về serving, paper triển khai large-scale batch inference bằng distributed *vLLM* + *Ray*. Kiến trúc serving có prefix caching cho prompt templates lặp lại, paged attention để quản lý KV cache hiệu quả, continuous batching để tăng GPU utilization, checkpointing để resume khi inference job lỗi, và incremental update để chỉ re-infer những user có hoạt động mới. Điều này giúp LLM inference có thể vận hành ở quy mô production mà không chạy online per request.

Thực nghiệm được chia thành hai phiên bản dữ liệu chính. V0 là experimental dataset

gồm các user có sequence features đủ dài, ví dụ matched-conversion và attributed-conversion sequence length ít nhất 10. V1 gần với online serving traffic hơn, dùng labels là high-priority conversions trong cửa sổ $x + 1$ đến $x + 7$. V1 thực tế hơn nhưng feature ít expressiveness hơn.

Về advertiser prediction, paper dùng các metric:

$$Recall@1, \quad Recall@5, \quad Recall@20$$

Trên V0, zero-shot prompting đạt Recall@1 là 0.346, Recall@5 là 0.567, Recall@20 là 0.655. Sau SFT với beam search, kết quả tăng lên 0.480, 0.720, 0.780. GRPO không vượt rõ SFT beam ở V0, cho thấy post-training dạng supervised đã rất mạnh trong setting giàu feature này.

Trên V1, kết quả thể hiện rõ progression hơn. Zero-shot prompting đạt:

$$Recall@1 = 0.117, \quad Recall@5 = 0.301, \quad Recall@20 = 0.422$$

SFT với 20-advertiser prompt tăng nhẹ lên:

$$0.156, \quad 0.314, \quad 0.456$$

SFT với 1-advertiser prompt tăng mạnh hơn:

$$0.214, \quad 0.413, \quad 0.501$$

Khi thêm GRPO trên initialization từ 1-advertiser SFT, kết quả đạt:

$$0.223, \quad 0.461, \quad 0.683$$

Điều này cho thấy SFT 1-advertiser giúp cải thiện precision ở Recall@1, còn GRPO giúp mở rộng coverage ở Recall@20.

Khi thêm SID-enabled SFT + GRPO, kết quả tăng tiếp lên:

$$Recall@1 = 0.248, \quad Recall@5 = 0.515, \quad Recall@20 = 0.755$$

Mức tăng này cho thấy SID cung cấp thông tin bổ sung mạnh so với prompt text thuần. SID có thể encode multimodal content semantics và co-occurrence structure mà advertiser names, query text hoặc URL strings không thể biểu diễn đầy đủ.

Paper cũng thực hiện feature ablation trên zero-shot 4B setup. Kết quả cho thấy feature quan trọng nhất là *active advertisers with past conversions*; khi bỏ nhóm này, Recall@5 giảm 0.1000. Offsite URLs cũng quan trọng, làm giảm 0.0290 nếu bị loại bỏ. Offsite searches giảm 0.0140, matched conversions và onsite searches mỗi nhóm giảm

0.0098, top brands giảm 0.0079. User profile chỉ giảm 0.0020, cho thấy demographic profile ít quan trọng hơn behavior và commerce intent signals. Một số feature như top categories còn có thể gây nhiễu trong prompt hiện tại.

Về downstream conversion models, thêm LLM-derived advertiser features giúp cải thiện cả ctcvr và vtcvr. Với ctcvr, loss giảm 0.12%, AUC tăng 0.06%, PR-AUC tăng 0.71%. Với vtcvr, loss giảm 0.64%, AUC tăng 0.09%, PR-AUC tăng 1.64%. PR-AUC gain đặc biệt đáng chú ý vì conversion prediction thường là bài toán sparse positive, nơi PR-AUC nhạy hơn với chất lượng ranking ở nhóm positive hiếm.

Trong online retrieval experiment, LLM-based candidate generator được deploy trên Home Feed, Related Pins và Search cho U.S. opt-in users. Paper thử nhiều training objectives cho two-tower retrieval model: impressions as positives, clicks with duration-based weights, và conversions as positives. Kết quả cho thấy objective rất quan trọng. Impression objective tăng survival nhưng làm hại engagement. Conversion objective không ổn định do label sparsity. Clicks với duration-based weights cho trade-off tốt nhất giữa funnel survival và engagement.

Paper cũng nhấn mạnh cần tune quota của LLM-based candidate generator. Vì CG này tập trung vào advertisers có high conversion intent, candidates của nó thường có CTR/CVR score cao và có thể dominate candidate blending nếu quota quá lớn. Khi đó, sau de-duplication, advertiser diversity có thể bị giảm. Vì vậy, LLM CG cần được xem là complementary channel có quota kiểm soát, không phải replacement cho retrieval channels chính.

Online A/B test cho thấy trên U.S. Shopping Ads slice, candidate generator mới tăng Return on Ad Spend:

+4.94%

với $p = 0.021$, và trên treatment slice opt-in users tăng:

+6.69%

với $p = 0.029$. Đây là kết quả quan trọng vì nó chứng minh advertiser priors từ LLM không chỉ cải thiện offline recall, mà còn tạo business impact thực tế.

Một kết luận đáng chú ý của paper là explicit reasoning không thật sự hữu ích cho advertiser prediction. Task này không giống bài toán chain-of-thought reasoning dài; nó gần với preference aggregation và intent matching hơn. Vì vậy, SFT-style training hoặc GRPO không reasoning có thể đạt performance tương đương hoặc tốt hơn so với prompting có reasoning.

2 Conclusion

Hướng đi đã làm của bài báo là dùng fine-tuned LLM như một *complementary predictor* trong ads recommender system, thay vì dùng LLM làm ranker chính hoặc thay thế pipeline hiện có. LLM nhận user profile, conversion history, search history, URL signals, brands, categories và advertiser pool, sau đó dự đoán advertiser có khả năng convert cùng với user interests. Output này được dùng để hỗ trợ cả candidate generation và ranking.

Đóng góp kỹ thuật quan trọng nhất là biến bài toán đưa LLM vào ads system thành một task phụ trợ có cấu trúc: *next-advertiser prediction*. Cách này giải quyết phần nào mismatch giữa LLM và ads RecSys. LLM không cần học toàn bộ sparse ID ranking objective, mà chỉ cần tổng hợp heterogeneous user signals thành advertiser priors. Sau đó, các model retrieval/ranking truyền thống tiếp tục xử lý phần scoring và calibration.

Về mặt training, paper cho thấy post-training rất quan trọng. Zero-shot LLM đã có một số khả năng nhờ world knowledge, nhưng SFT cải thiện rõ rệt advertiser recall. GRPO giúp tăng Recall@20 khi output là danh sách 20 advertisers. SID enhancement tiếp tục tăng mạnh recall, chứng minh rằng semantic/multimodal identifiers có thể làm cầu nối giữa token-based LLM và ID-heavy recommendation systems.

Về mặt production, paper chứng minh rằng LLM-derived signals có thể được triển khai thực tế nếu inference được batch hóa và giới hạn đúng user segment. Distributed vLLM + Ray, prefix caching, paged attention, continuous batching, checkpointing và incremental updates giúp giảm chi phí daily inference. Downstream, LLM signal vừa cải thiện conversion model features, vừa tạo một candidate generator mới có online RoAS gain rõ ràng.

Hạn chế chính là phương pháp hiện vẫn phụ thuộc vào user segment có đủ conversion history và commerce signals. User cold-start hoặc user ít hoạt động có thể không nhận được lợi ích lớn. Ngoài ra, SID-enabled variant mới được chứng minh offline, chưa phải claim online chính. Candidate generator cũng cần quota tuning cẩn thận để tránh over-concentration và giảm advertiser diversity.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng advertiser prediction sang multi-task prediction, ví dụ dự đoán advertiser, category, product type, budget segment hoặc conversion objective cùng lúc. Thứ hai, có thể đưa SID-enabled model vào online A/B test để kiểm chứng liệu offline recall gain có chuyển thành RoAS hoặc conversion lift không. Thứ ba, có thể kết hợp LLM advertiser priors với các mô hình sequential hoặc graph-based retrieval để cải thiện coverage cho long-tail advertisers.

Ngoài ra, paper này rất phù hợp để kế thừa trong hướng *LLM-enhanced recommender systems*. Thay vì cố ép LLM làm toàn bộ recommender, một hướng thực tế hơn là dùng LLM để tạo các tín hiệu phụ trợ giàu semantic: advertiser prior, user interest summary, intent cluster, semantic ID prediction hoặc cold-start metadata enrichment. Các tín hiệu này có thể được đưa vào retrieval và ranking truyền thống, giúp tận dụng knowledge của

LLM mà vẫn giữ được latency, calibration và serving reliability của hệ ads production. “