

Paper

“latex

1 Summary

Bài báo *ACE: Anisotropy-Controllable Embedding for LLM-enhanced Sequential Recommendation* nghiên cứu bài toán cải thiện *Sequential Recommendation* (SR) bằng embedding sinh ra từ Large Language Models. Trong SR, hệ thống nhận chuỗi item mà user đã tương tác theo thứ tự thời gian và dự đoán item tiếp theo mà user có khả năng quan tâm. Gần đây, nhiều nghiên cứu dùng LLM để sinh item embeddings giàu semantic từ metadata như title, category, brand hoặc description, rồi dùng các embeddings này để khởi tạo item embedding table trong các backbone như SASRec, GRU4Rec hoặc BERT4Rec.

Hướng này thường được gọi là *LLM-as-Extractor*. Thay vì gọi LLM trực tiếp trong quá trình serving, hệ thống chỉ dùng LLM offline để encode item text thành vector. Sau đó, recommender model truyền thống tiếp tục fine-tune các vector này bằng collaborative signals từ interaction sequence. Cách làm này giúp tận dụng semantic knowledge của LLM mà không phải chịu chi phí inference lớn của LLM ở thời điểm online.

Tuy nhiên, bài báo chỉ ra rằng LLM-generated embeddings thường gặp vấn đề *anisotropy*. Nghĩa là các vector embedding không phân bố đều trong không gian, mà tập trung mạnh vào một vài hướng dominant. Khi hầu hết item vectors nằm trong một narrow cone, mô hình khó phân biệt item tốt, similarity bị méo, và quá trình fine-tuning với collaborative signals trở nên kém ổn định.

Về mặt hình học, anisotropy có thể quan sát qua covariance matrix của embedding matrix. Với embedding matrix:

$$E = [e_1, e_2, \dots, e_n]^\top \in \mathbb{R}^{n \times d}$$

ta xét covariance:

$$Cov(E) = \frac{1}{n}(E - \mu)^\top (E - \mu)$$

Nếu eigenvalue spectrum của covariance quá lệch, tức chỉ một vài eigenvalues rất lớn còn phần lớn rất nhỏ, embedding space bị anisotropic. Khi đó, một vài directions chi phối hầu hết variance của toàn bộ embedding space.

Các phương pháp trước như LLM2X dùng PCA để giảm chiều LLM embeddings trước khi đưa vào SR backbone. Một số phương pháp khác như LLMEmb, AlphaRec hoặc AlphaFuse tập trung vào việc học projection hoặc adaptation giữa semantic space của LLM và collaborative space của recommender. WhitenRec thì dùng whitening để giảm anisotropy bằng cách ép covariance trở thành identity matrix. Tuy nhiên, paper cho rằng whitening quá cực đoan vì nó làm phẳng hoàn toàn eigenvalue spectrum, khiến semantic hierarchy trong embedding bị phá vỡ.

Cụ thể, với mean-centered embedding matrix:

$$\tilde{E} = \tilde{U}\tilde{S}\tilde{V}^\top$$

whitening tạo:

$$E_{whiten} = \tilde{E}\tilde{V}\tilde{S}^{-1} = \tilde{U}$$

Khi đó:

$$Cov(E_{whiten}) = I$$

Nghĩa là mọi principal components đều được đưa về cùng variance. Cách này giảm anisotropy, nhưng đồng thời xóa đi sự khác biệt về mức độ quan trọng giữa các semantic directions. Một số direction có thể chứa semantic information quan trọng hơn direction khác, nhưng whitening đối xử tất cả như nhau.

Từ nhận xét này, bài báo đề xuất *Anisotropy-Controllable Embedding* (ACE). Mục tiêu của ACE là không ép embedding space thành hoàn toàn isotropic, mà kiểm soát anisotropy ở mức vừa phải. Nói cách khác, ACE cần giảm sự thống trị quá mạnh của các dominant directions, nhưng vẫn giữ lại semantic hierarchy cần thiết để phân biệt item.

ACE được xây dựng dựa trên *Linear Autoencoder* (LAE). Với LLM embedding matrix E , ACE định nghĩa một item-item similarity matrix:

$$B_{ACE} \in \mathbb{R}^{n \times n}$$

và tối ưu objective:

$$\mathcal{L}(B_{ACE}) = \min_{B_{ACE}} \|E^\top - E^\top B_{ACE}\|_F^2 + \lambda \|B_{ACE}\|_F^2$$

Trong đó, reconstruction loss giữ lại semantic structure ban đầu của LLM embeddings, còn L_2 regularization kiểm soát mức độ shrinkage của các spectral components. Hyperparameter λ đóng vai trò điều chỉnh mức độ anisotropy.

Objective trên có closed-form solution:

$$\hat{B}_{ACE} = (EE^\top + \lambda I)^{-1}EE^\top$$

Tuy nhiên, thay vì chỉ nhìn ở dạng ma trận, paper diễn giải ACE theo phổ singular value. Giả sử:

$$E = USV^\top$$

ACE tạo embedding mới bằng cách áp dụng shrinkage function lên singular values:

$$E_{ACE} = Ug_\lambda(S)$$

với:

$$g_\lambda(S) = \sqrt{\frac{S^2}{S^2 + \lambda I}} = \text{diag} \left(\sqrt{\frac{\sigma_1^2}{\sigma_1^2 + \lambda}}, \dots, \sqrt{\frac{\sigma_n^2}{\sigma_n^2 + \lambda}} \right)$$

Công thức này là phần kỹ thuật cốt lõi của ACE. Nó cho phép điều chỉnh từng singular direction theo magnitude của singular value. Các direction quá dominant bị giảm ảnh hưởng, nhưng không bị làm phẳng hoàn toàn như whitening.

Từ đó, linear operator tương ứng của ACE có dạng:

$$\hat{B}_{ACE} = E_{ACE}E_{ACE}^\top = U \frac{S^2}{S^2 + \lambda I} U^\top$$

hay:

$$\hat{B}_{ACE} = U \text{diag} \left(\frac{\sigma_1^2}{\sigma_1^2 + \lambda}, \dots, \frac{\sigma_n^2}{\sigma_n^2 + \lambda} \right) U^\top$$

Cách biểu diễn này cho thấy ACE hoạt động như một spectral shrinkage operator. Nó không loại bỏ semantic directions, mà điều chỉnh mức độ đóng góp của từng direction.

Vai trò của reconstruction loss là bảo toàn semantic directions của embedding gốc. Khi:

$$\lambda = 0$$

thì:

$$g_0(\sigma_i) = 1$$

với mọi i . Khi đó, embedding được biểu diễn hoàn toàn trong basis U , tương tự một dạng normalization của các principal components. Điều này giúp giữ lại directions chính mà LLM embeddings đã học được.

Vai trò của L_2 regularization là điều khiển mức độ anisotropy. Khi λ tăng, shrinkage function thay đổi liên tục và làm giảm sự mất cân bằng trong singular value spectrum. Nếu λ quá nhỏ, embedding có thể bị flatten quá mạnh, gần với whitening và làm mất semantic hierarchy. Nếu λ quá lớn, shrinkage quá yếu, embedding gần như giữ lại anisotropy ban đầu. Vì vậy, ACE cần chọn λ ở mức trung bình để cân bằng giữa geometric uniformity và semantic preservation.

Sau khi reshaping embedding bằng ACE, paper đưa embedding vào SR backbone như

một initialization. Với top- k singular directions, embedding dùng cho recommender là:

$$E_{ACE}^{(k)} = U^{(k)} g_{\lambda}(S^{(k)}) \cdot \gamma$$

Trong đó k là embedding dimension của recommender, ví dụ $k = 128$, còn γ là scaling factor để khôi phục scale của embedding sau shrinkage. Sau bước này, SR model được train như bình thường.

Điểm mạnh của ACE là nó không phụ thuộc vào một backbone cụ thể. Nó chỉ là một bước tiền xử lý hoặc khởi tạo embedding, nên có thể dùng với SASRec, GRU4Rec, BERT4Rec hoặc các sequential recommender khác. ACE cũng không yêu cầu gọi LLM trong training hoặc inference của recommender, vì LLM embeddings được tạo offline.

Thực nghiệm được tiến hành trên bốn benchmark datasets: Amazon Beauty, Amazon Toys, Yelp 2018 và MovieLens-20M. Các item textual metadata được encode bằng *text-embedding-3-large* của OpenAI. Paper cũng kiểm tra nhiều LLM encoders khác như F2LLM-4B, Qwen3-Embedding-8B và KaLM-Embedding-Gemma3-12B-2511 để xem ACE có phụ thuộc vào embedding model cụ thể hay không.

Evaluation dùng leave-one-out protocol. Với mỗi user, item cuối cùng trong sequence được dùng làm test, item trước đó làm validation, còn phần còn lại dùng training. Khi đánh giá, paper dùng full-sort ranking trên toàn bộ item set, không dùng candidate filtering. Metrics chính gồm:

$$Recall@K, \quad NDCG@K$$

với:

$$K \in \{10, 20\}$$

Baselines gồm nhiều phương pháp LLM-as-Extractor mạnh. *LLM2X* dùng PCA để giảm chiều LLM embeddings. *WhitenRec+* dùng whitening/group-wise whitening để xử lý anisotropy. *LLMEmb* và *AlphaRec* dùng MLP projection hoặc semantic adaptation. *AlphaFuse* giữ lại semantic subspace quan trọng và reinitialize phần còn lại để học collaborative signals.

Kết quả với SASRec backbone cho thấy ACE đạt performance tốt nhất trên hầu hết tất cả dataset và metric. Ví dụ trên Beauty, ACE đạt:

$$Recall@20 = 0.1288, \quad NDCG@20 = 0.0534$$

cao hơn AlphaFuse, AlphaRec, LLMEmb và WhitenRec+. Trên Toys, ACE đạt:

$$Recall@20 = 0.1342, \quad NDCG@20 = 0.0560$$

Trên Yelp, ACE đạt:

$$Recall@20 = 0.0892, \quad NDCG@20 = 0.0455$$

Trên MovieLens-20M, ACE đạt:

$$Recall@20 = 0.2825, \quad NDCG@20 = 0.1310$$

Một kết quả đáng chú ý là WhitenRec+ đôi khi kém hơn cả LLM2X. Điều này ủng hộ phân tích của paper rằng whitening tuy giảm anisotropy nhưng có thể phá semantic hierarchy. Trong khi đó, ACE không ép isotropy tuyệt đối, mà cho phép kiểm soát mức độ anisotropy bằng λ , nên giữ cân bằng tốt hơn.

Paper cũng kiểm tra ACE trên GRU4Rec và BERT4Rec. Trên Beauty với GRU4Rec, ACE đạt:

$$Recall@20 = 0.1107, \quad NDCG@20 = 0.0466$$

cao hơn AlphaRec và WhitenRec+. Trên Yelp với GRU4Rec, ACE đạt:

$$Recall@20 = 0.0860, \quad NDCG@20 = 0.0379$$

Với BERT4Rec, ACE cũng đạt kết quả tốt nhất hoặc gần tốt nhất trên Beauty và Yelp. Điều này chứng minh ACE là architecture-agnostic, không chỉ tối ưu cho SASRec.

Kết quả với nhiều LLM encoders khác nhau cũng cho thấy ACE ổn định. Trên Beauty với SASRec, ACE vượt các baseline khi dùng F2LLM-4B, Qwen3-Embedding-8B và KaLM-Embedding-Gemma3-12B-2511. Điều này cho thấy vấn đề anisotropy không chỉ thuộc về một embedding model cụ thể, và ACE có thể áp dụng rộng hơn cho nhiều loại LLM-generated embeddings.

Hyperparameter analysis với λ cho thấy performance tốt nhất xuất hiện ở các giá trị trung bình. Khi λ quá nhỏ, ACE làm spectrum quá phẳng, tương tự whitening, dẫn đến mất semantic hierarchy. Khi λ quá lớn, ACE không đủ shrinkage, anisotropy gốc vẫn còn mạnh. Do đó, bản chất của ACE là một cơ chế kiểm soát liên tục giữa hai cực: isotropic quá mức và anisotropic quá mức.

Hình 1 của paper minh họa trực quan ba embedding spaces trên Beauty dataset. PCA embedding vẫn bị kéo mạnh theo dominant directions. Whitened PCA làm không gian quá đều và có thể làm mất cấu trúc semantic. ACE tạo phân bố cân bằng hơn: giảm directional over-concentration nhưng vẫn giữ được cấu trúc có ý nghĩa. Hình 2 tiếp tục minh họa eigenvalue spectrum khi thay đổi λ , cho thấy λ nhỏ làm spectrum phẳng hơn, còn λ lớn giữ lại nhiều anisotropy hơn.

Tóm lại, bài báo cho rằng vấn đề quan trọng của LLM-enhanced SR không chỉ là làm sao đưa LLM embeddings vào recommender, mà còn là phải chuẩn hóa hình học

của embedding space trước khi fine-tune. Nếu embedding quá anisotropic, collaborative learning khó thích nghi; nếu làm isotropic quá mạnh, semantic information bị méo. ACE giải quyết khoảng giữa này bằng linear autoencoder và spectral shrinkage có điều khiển.

2 Conclusion

Hướng đi đã làm của bài báo là cải thiện LLM-enhanced sequential recommendation bằng cách xử lý trực tiếp vấn đề anisotropy của LLM-generated item embeddings. Thay vì chỉ học projection layer hoặc fine-tune recommender backbone, paper đặt câu hỏi nền tảng hơn: embedding từ LLM có hình học phù hợp để làm initialization cho sequential recommender hay không. Câu trả lời là chưa, vì embedding thường tập trung vào một vài dominant directions và gây khó khăn cho collaborative fine-tuning.

Đóng góp kỹ thuật quan trọng nhất là *Anisotropy-Controllable Embedding* (ACE). ACE dùng Linear Autoencoder để reshape embedding spectrum, trong đó reconstruction loss bảo toàn semantic directions còn L_2 regularization điều khiển mức độ shrinkage của singular values. Công thức:

$$g_\lambda(\sigma_i) = \sqrt{\frac{\sigma_i^2}{\sigma_i^2 + \lambda}}$$

cho phép ACE kiểm soát liên tục giữa hai cực: giữ nguyên anisotropy ban đầu và whitening quá mức. Nhờ đó, ACE giảm geometric imbalance nhưng vẫn giữ semantic hierarchy của LLM embeddings.

Kết quả thực nghiệm cho thấy ACE vượt các LLM-as-Extractor baselines trên nhiều dataset, backbone và embedding encoder. Điều này chứng minh ACE không phải là trick phụ thuộc vào SASRec hay một LLM embedding cụ thể, mà là một phương pháp tiền xử lý embedding có tính tổng quát. Đặc biệt, việc WhitenRec+ đôi khi kém hơn PCA baseline củng cố luận điểm rằng giảm anisotropy quá mạnh có thể làm hại semantic structure.

Ý nghĩa chính của paper là đưa góc nhìn hình học vào LLM-enhanced recommendation. Trong các hệ recommender dùng LLM embeddings, chất lượng không chỉ phụ thuộc vào LLM nào mạnh hơn, mà còn phụ thuộc vào phân bố vector sau khi encode. Một embedding model có semantic knowledge tốt nhưng anisotropic nặng vẫn có thể không phù hợp để fine-tune trực tiếp trong recommender. Vì vậy, geometry-aware embedding initialization là một hướng quan trọng.

Hạn chế của ACE là nó chủ yếu xử lý item embedding initialization, chưa trực tiếp mô hình hóa user-side context, temporal drift hoặc preference dynamics. Ngoài ra, phương pháp dựa trên SVD/linear autoencoder nên có thể cần tối ưu thêm nếu item catalog cực lớn. Việc chọn λ và scaling factor γ cũng vẫn cần tuning theo dataset và backbone.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể mở rộng ACE sang user embeddings hoặc session embeddings, không chỉ item embeddings. Thứ hai, có

thể kết hợp ACE với các phương pháp như AlphaFuse, trong đó ACE xử lý hình học ban đầu còn AlphaFuse xử lý cân bằng giữa semantic subspace và collaborative subspace. Thứ ba, có thể nghiên cứu adaptive λ , tức mỗi dataset, item group hoặc semantic cluster có mức anisotropy-control khác nhau.

Ngoài ra, ACE rất phù hợp để kế thừa trong hướng *LLM-as-Extractor for recommender systems*. Các paper trước thường tập trung vào cách lấy embedding từ LLM và đưa vào recommender, nhưng ACE cho thấy cần thêm một bước *embedding geometry calibration*. Trong tương lai, các pipeline LLM-enhanced SR có thể gồm ba bước: encode item bằng LLM, điều chỉnh anisotropy bằng ACE hoặc biến thể spectral control, sau đó fine-tune SR backbone bằng collaborative signals. Cách này giúp tận dụng semantic knowledge của LLM mà vẫn đảm bảo embedding space thích nghi tốt với hành vi người dùng. ““