

Paper

“latex

1 Summary

Bài báo *Towards User Preference Alignment in LLM Recommendation via Explicit Context Feedback* nghiên cứu một hạn chế quan trọng của recommender system hiện nay: phần lớn hệ thống vẫn học sở thích user chủ yếu từ *implicit feedback* như click, view, watch time, purchase hoặc rating, nhưng lại chưa khai thác đầy đủ *explicit contextual feedback* do user trực tiếp viết ra, ví dụ comment, review, critique, phản hồi tiêu cực hoặc câu giải thích lý do thích/không thích một item.

Luận điểm trung tâm của paper là implicit feedback chỉ cho biết user đã tương tác với cái gì, nhưng thường không cho biết vì sao user tương tác. Ví dụ, một user có thể mua một sản phẩm nhiều lần nhưng comment rằng “slightly sweet for my taste”. Nếu chỉ nhìn purchase signal, recommender có thể hiểu rằng user thích sản phẩm đó hoàn toàn. Nhưng explicit feedback cho thấy user có một constraint cụ thể: không thích vị quá ngọt. Do đó, nếu bỏ qua textual feedback, hệ thống dễ học sai preference thật của user.

Bài báo cho rằng explicit contextual feedback rất quan trọng cho *user preference alignment*. Khác với rating hoặc click vốn khá thô, feedback dạng ngôn ngữ tự nhiên chứa nhiều thông tin fine-grained như aspect-level sentiment, negative constraints, personal values, identity cues, item-level trade-offs và rationale đằng sau hành vi. Đây là loại thông tin mà LLM có khả năng xử lý tốt hơn các recommender truyền thống, vì LLM có năng lực hiểu và diễn giải ngôn ngữ tự nhiên.

Paper bắt đầu bằng việc nhìn lại các paradigm chính của recommender system. Nhóm thứ nhất là *content-based recommender system*, nơi user và item được biểu diễn bằng các feature mô tả như metadata, tags, category, textual description hoặc context feature. Các mô hình hiện đại như Wide&Deep, DeepFM, DCN và Two-Tower có thể học nonlinear feature interaction và dense embeddings. Tuy nhiên, các mô hình này vẫn phụ thuộc vào feature pipeline cố định và thường bỏ qua rationale thực sự nằm trong lời nói của user.

Nhóm thứ hai là *collaborative filtering* và *graph-based recommender system*. Collaborative filtering dựa trên nguyên lý homophily: user có hành vi giống nhau trong quá khứ sẽ có xu hướng thích item giống nhau trong tương lai. Các phương pháp như Matrix

Factorization, Neural Collaborative Filtering và LightGCN học latent representation từ user-item interaction graph. Tuy nhiên, chúng vẫn chỉ thấy sự tồn tại của interaction, không thấy lý do phía sau interaction. Vì vậy, cùng một rating hoặc cùng một click có thể mang ý nghĩa khác nhau với các user khác nhau.

Nhóm thứ ba là *sequential recommender system* và *LLM-based recommender system*. Sequential recommender như RNN-based model, SASRec hoặc BERT4Rec học thứ tự hành vi để dự đoán next item. LLM-based recommender tiếp tục mở rộng hướng này bằng cách dùng LLM làm content encoder, sequence model hoặc zero-shot recommender. Tuy nhiên, paper nhận xét rằng ngay cả nhiều LLM-based recommender vẫn chủ yếu dùng item metadata và interaction logs, chưa tận dụng đúng năng lực cốt lõi của LLM là hiểu user-generated text.

Bài báo đưa ra nhiều ví dụ để cho thấy explicit feedback giúp mô hình hiểu preference sâu hơn. Ví dụ thứ nhất là một user không thích phim horror nhưng comment rằng “Too many jump scares, I prefer psychological horror”. Nếu chỉ nhìn implicit signal, hệ thống có thể tránh toàn bộ horror genre. Nhưng nếu hiểu explicit feedback, hệ thống biết user không ghét horror, mà chỉ không thích jump scare; từ đó có thể recommend psychological thriller hoặc suspense movie phù hợp hơn.

Ví dụ thứ hai là một user review smartphone: “The screen is stunning, but the battery drains too fast”. Một recommender chỉ nhìn rating 4 sao có thể xem đây là positive feedback. Nhưng explicit review cho thấy user thích màn hình đẹp và không thích pin yếu. Điều này giúp hệ thống recommend smartphone có màn hình tốt nhưng pin dài hơn, thay vì tiếp tục recommend các thiết bị có cùng điểm yếu.

Ví dụ thứ ba là user-specific attribute hoặc value cue, chẳng hạn “As a vegetarian, I love their plant-based options”. Đây là tín hiệu dài hạn về user identity/context, có thể ảnh hưởng đến nhiều domain như restaurant, grocery, recipe hoặc food delivery. Tương tự, một user nói “I prefer human-written pieces over AI-generated ones” thì đây là value-based constraint, không thể suy ra dễ dàng chỉ từ click hoặc dwell time.

Từ các ví dụ trên, paper lập luận rằng explicit contextual feedback cho phép recommender system học được “why behind user actions”. Điều này giúp hệ thống tạo recommendation vừa chính xác hơn, vừa explainable hơn. Ví dụ, hệ thống có thể giải thích: “You mentioned you dislike jump scares, so we avoided movies with that style.” Đây là hướng khác biệt so với recommender truyền thống, vốn thường chỉ dựa trên similarity score hoặc historical pattern.

Về benchmark và evaluation, paper cho rằng các benchmark truyền thống như MovieLens hoặc Amazon Review thường tập trung vào prediction accuracy cho held-out interactions hoặc ratings. Các metric như RMSE, Recall và NDCG không trực tiếp đo việc recommendation có align với stated preference của user hay không. Vì vậy, paper đề xuất cần xây dựng *feedback-enriched datasets*, trong đó mỗi interaction đi kèm textual feedback như review, comment hoặc critique.

Một hướng benchmark cụ thể là *continuous sequential recommendation with user feedback*. Trong setting này, hệ thống nhận timeline gồm interaction và explicit feedback theo thời gian. Sau mỗi feedback mới, model phải cập nhật user profile và thay đổi recommendation tương ứng. Setting này phản ánh thực tế tốt hơn vì user preference không tĩnh; nó được cập nhật dần qua các phản hồi tự nhiên của user.

Paper cũng đề xuất các metric mới cho *preference alignment*. Một metric là *dislike avoidance rate*, đo tỷ lệ recommended items không chứa các attribute mà user đã explicit dislike. Ví dụ, nếu user nói không thích jump scare, hệ thống bị phạt khi recommend phim nhiều jump scare. Một metric khác là *preference fulfillment score*, đo tỷ lệ các aspect user đã explicit thích xuất hiện trong top-N recommendation. Ví dụ, nếu user nói thích movie có twist ending, metric kiểm tra top-N có nhiều movie kiểu đó hay không.

Ngoài alignment, paper nhấn mạnh cần đánh giá *diversity*, *novelty*, và *dynamic preference adaptation*. Explicit feedback có thể giúp hệ thống thoát khỏi filter bubble vì nó nói rõ user thích hoặc không thích aspect nào, thay vì chỉ lặp lại những gì user từng click. Khi user cung cấp phản hồi mới, recommender cần thay đổi theo, không tiếp tục optimize trên historical implicit pattern cũ.

Bài báo phân loại explicit contextual feedback thành bốn nhóm chính. Nhóm thứ nhất là *preferred and positive signals*. Đây là các câu user trực tiếp khen hoặc thể hiện sở thích, ví dụ “Loved the cleanliness and friendly staff”. Các tín hiệu này có thể được LLM extract thành aspect preference như cleanliness, friendly staff, quiet environment hoặc fast delivery. Sau đó hệ thống có thể cập nhật user-aspect embedding hoặc user profile.

Nhóm thứ hai là *dislikes and negative signals*. Đây là các constraint user nói rõ nên tránh, ví dụ “Terrible battery life”, “Too sweet for my taste”, hoặc “no jump scares”. Negative feedback rất quan trọng vì implicit non-click không nói rõ user không thích gì. Paper gợi ý có thể xây dựng *negative preference graph*, nơi user được nối với các aspect bị ghét bằng aversion edges. LLM cũng có thể phân biệt hard constraints và soft preferences, ví dụ dị ứng đậu phộng là hard constraint, còn “reduce caffeine” là soft preference.

Nhóm thứ ba là *user-specific attributes and contextual factors*. Đây là các tín hiệu user tự khai báo về bản thân hoặc hoàn cảnh, ví dụ vegetarian, professional photographer, student, parent, hoặc một tình huống ngắn hạn như travelling. Các tín hiệu này giúp personalization minh bạch hơn vì recommendation có thể dựa trên user-declared context thay vì suy đoán gián tiếp từ hành vi.

Nhóm thứ tư là *item-level comments and quality feedback*. Đây là các review mô tả trade-off của item, ví dụ “great for the price, but overheats quickly and the fan is loud”. Loại feedback này vừa chứa positive aspect vừa chứa negative aspect, đồng thời giúp xây dựng item representation tốt hơn. Khi nhiều user cùng comment về một item, hệ thống có thể tổng hợp thành community-level knowledge về item quality, usability, price, durability hoặc flaw.

Về framework, paper đề xuất một kiến trúc LLM-based RecSys với explicit feedback

gồm bốn stage lớn. Stage thứ nhất là *constructing and updating user profiles from context*. LLM đóng vai trò memory manager, đọc review/comment của user và cập nhật user profile dạng natural language hoặc structured representation. Ví dụ, câu “too sweet for my taste” được chuyển thành một dislike aspect: excessive sweetness.

Stage thứ hai là *context-aware retrieval and interest discovery*. Thay vì retrieval chỉ dựa trên item similarity hoặc historical click, hệ thống dùng explicit user profile gồm likes, dislikes, constraints và rationale để chọn candidate. LLM có thể tạo reasoning-infused embedding, ví dụ user thích sci-fi vì philosophical themes chứ không phải space battles. Retrieval khi đó sẽ tìm item match với rationale, không chỉ match với category.

Stage thứ ba là *reranking and rule model adaptation*. Sau khi có candidates, hệ thống cần rerank theo cả engagement likelihood và explicit alignment. Hard constraints như allergy có thể lọc item trực tiếp. Soft preferences như “reduce caffeine” có thể giảm score tương ứng. LLM có thể đóng vai trò evaluator để so sánh item features với user rationale và tạo score phụ trợ cho reranker.

Stage thứ tư là *asynchronous taxonomy and tag alignment*. Đây là giải pháp để cân bằng giữa khả năng hiểu sâu của LLM và latency constraint của recommender system. LLM chạy ở backend để đọc explicit feedback và map nó thành taxonomy tags như:

#LongBatteryLife, #LightWeightPhone, #NoJumpScare

Mỗi tag có affinity score thể hiện user thích hoặc không thích. Khi serving online, retrieval/ranking chỉ cần dùng các precomputed tag features, không cần gọi LLM real-time. Cách này giúp tích hợp LLM understanding vào hệ thống production mà vẫn giữ latency thấp.

Hình 1 trong paper minh họa rõ framework này. Phần trên cho thấy recommender hiện tại thường cover implicit feedback như click/like, nhưng bỏ qua explicit feedback như comments/reviews. Phần dưới đề xuất RecSys framework với explicit context feedback, gồm user profile update, context-aware retrieval, reranking rule model adaptation, scalability inference cost và evaluation với benchmark/dataset, preference metrics, diversity metrics, dynamic evaluation.

Tóm lại, paper không đề xuất một thuật toán cụ thể có thực nghiệm như các bài model-based khác, mà đóng vai trò như một vision paper. Nó đề xuất rằng explicit context feedback nên trở thành primary data modality trong thế hệ LLM-based recommender tiếp theo. LLM nên được dùng để hiểu user rationale, cập nhật profile, kiểm soát constraint, tạo explanation và hỗ trợ retrieval/ranking theo preference thật của user.

2 Conclusion

Hướng đi đã làm của bài báo là chuyển trọng tâm của recommender system từ *implicit behavior prediction* sang *explicit preference alignment*. Paper lập luận rằng các tín hiệu như click, view, watch time và purchase chỉ phản ánh hành vi quan sát được, còn review, comment và critique mới chứa nhiều lý do thật sự đằng sau hành vi đó. Vì vậy, thể hệ LLM-based RecSys tiếp theo nên ưu tiên khai thác explicit contextual feedback.

Đóng góp chính của bài báo nằm ở việc hệ thống hóa vai trò của explicit feedback. Paper phân loại feedback thành bốn nhóm: positive preference, negative constraint, user-specific attribute/context, và item-level quality feedback. Mỗi nhóm cung cấp một loại thông tin khác nhau cho user modeling: user thích gì, không thích gì, họ là ai hoặc đang ở hoàn cảnh nào, và item có ưu/nhược điểm gì theo trải nghiệm cộng đồng.

Về mặt kỹ thuật, paper đề xuất một framework gồm user profile construction, context-aware retrieval, adaptive reranking và asynchronous taxonomy/tag alignment. LLM được dùng như một comprehension engine để biến natural-language feedback thành structured preference representation. Sau đó các representation này có thể được dùng trong retrieval, ranking, reranking hoặc explanation. Đặc biệt, cơ chế asynchronous tag alignment cho phép dùng LLM ở backend nhưng vẫn giữ serving online đủ nhanh.

Ý nghĩa quan trọng của paper là nó chỉ ra một khoảng trống trong LLM-based recommendation hiện nay. Nhiều hệ thống đã dùng LLM để encode item metadata, generate recommendation hoặc xử lý interaction history, nhưng chưa thật sự tận dụng lời nói trực tiếp của user. Trong khi đó, explicit feedback có thể giúp giảm filter bubble, tăng diversity, tăng explainability và làm recommendation align hơn với giá trị cũng như constraint thật của user.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, cần xây dựng benchmark mới có cả interaction logs và explicit textual feedback theo thời gian, để đánh giá khả năng update preference sau mỗi phản hồi của user. Thứ hai, cần phát triển metric mới như dislike avoidance rate, preference fulfillment score, alignment-aware NDCG, diversity và dynamic adaptation metrics. Thứ ba, cần thiết kế mô hình có khả năng phân biệt hard constraint và soft preference để tránh over-filtering hoặc over-personalization.

Ngoài ra, paper này rất phù hợp để kế thừa cho hướng *LLM-based context-aware recommender systems*. Explicit feedback có thể được xem là một loại context giàu semantic hơn các context truyền thống như time, location hoặc device. Khi kết hợp explicit feedback với temporal context, session context, persona context hoặc KG-RAG, hệ thống có thể hiểu không chỉ user đã làm gì, mà còn hiểu user muốn gì, không muốn gì, vì sao họ thích/ghét một item, và preference đó có ổn định hay chỉ là tạm thời. Đây là nền tảng quan trọng để xây dựng recommender có tính cá nhân hóa, minh bạch và đáng tin cậy hơn. ““