

Paper

“`latex`

1 Summary

Bài báo *A Survey on Fairness-aware Recommender Systems* là một khảo sát toàn diện về vấn đề công bằng trong recommender systems. Bối cảnh chính của bài báo là recommender systems đã trở thành thành phần quan trọng trong nhiều domain như e-commerce, education, social media, music, news, job recommendation và financial services. Tuy nhiên, khi người dùng và nhà cung cấp phụ thuộc ngày càng nhiều vào recommender systems, các hệ thống này có thể tạo ra hoặc khuếch đại unfairness, ví dụ phân biệt giới tính trong job recommendation, thiên vị merchant lớn trong e-commerce, hoặc giảm exposure của teacher đến từ quốc gia ít phổ biến trong MOOC recommendation.

Luận điểm trung tâm của survey là fairness không phải là một thuộc tính phụ, mà là một thành phần cốt lõi của *trustworthy recommender systems*. Một recommender system không công bằng có thể gây hại cho nhiều bên: user nhận recommendation kém phù hợp hoặc bị giới hạn trong filter bubble; item provider hoặc content creator bị thiếu exposure; còn platform có thể mất trust dài hạn. Vì recommender systems vận hành theo feedback loop, unfairness không chỉ xuất hiện một lần mà có thể được tích lũy và khuếch đại qua thời gian.

Về mặt hình thức, paper xem recommender system là một hàm dự đoán mức độ ưa thích của user u đối với item v :

$$y_{u,v} = f(u, v)$$

trong đó U là tập user, V là tập item, và $f(\cdot)$ là recommendation model. Hệ thống học từ dữ liệu user, item và interaction để tạo personalized recommendation. Tuy nhiên, nếu dữ liệu đầu vào, mô hình học hoặc feedback loop có bias, hàm f sẽ phản ánh và khuếch đại bias đó.

Paper mô tả lifecycle của recommender system gồm ba pha: *data collection phase*, *model learning phase*, và *feedback loop phase*. Hình 2 trong paper minh họa lifecycle này: dữ liệu được thu từ user, đưa vào model learning, model tạo recommendation, user phản hồi lại, và phản hồi này tiếp tục đi vào dữ liệu. Điểm quan trọng là bias có thể xuất hiện ở cả ba pha. Data collection có thể chứa user bias, exposure bias, time bias và cold-start

bias. Model learning có thể chứa ranking bias. Feedback loop có thể khuếch đại popularity bias.

Nhóm bias đầu tiên là *data bias*. Trong đó, *user bias* gồm user attribute bias và user selection bias. User attribute bias xảy ra khi các thuộc tính nhạy cảm như age, gender, race, location hoặc profession ảnh hưởng đến recommendation. Ví dụ trong job recommendation, nam và nữ có thể nhận exposure khác nhau đối với high-paying jobs. User selection bias xảy ra khi feedback user không phản ánh đúng sở thích thật, ví dụ user bấm nhầm like hoặc rating không nhất quán.

Exposure bias xảy ra khi user chỉ được tiếp xúc với một phần nhỏ của item set. Vì user chỉ có thể click hoặc mua item đã được expose, interaction data không phản ánh toàn bộ preference space. Trong music recommendation, các artist phổ biến thường được expose nhiều hơn, nên model tiếp tục học rằng chúng nên được recommend nhiều hơn. Điều này làm giảm cơ hội của niche items và long-tail providers.

Time bias liên quan đến việc dữ liệu mới hoặc item mới có thể được over-represent hoặc under-represent theo thời gian. Ví dụ trong job recommendation, job ads mới có thể nhận nhiều click hơn đơn giản vì chúng mới xuất hiện, không nhất thiết vì phù hợp hơn. Nếu hệ thống chỉ ưu tiên recent clicks, nó có thể bỏ qua long-term career preference của job seekers.

Cold-start bias xảy ra khi hệ thống thiếu dữ liệu về user hoặc item mới. Để giải quyết cold-start, model thường dùng prior knowledge từ warm-start data. Tuy nhiên, nếu warm-start data đã biased, bias này sẽ được truyền sang cold-start recommendation. Vì item mới thường cần exposure ban đầu để tích lũy interaction, cold-start unfairness có thể kéo dài và tích lũy trong suốt vòng đời item.

Nhóm bias thứ hai là *model bias*. Survey nhấn mạnh *ranking bias*, trong đó loss function hoặc optimization objective có thể làm tăng unfairness. Ví dụ MSE loss hoặc BPR loss có thể nhạy với popular items, khiến popular items nhận score cao hơn và tiếp tục được ưu tiên trong ranking. Khi đó model không chỉ học bias từ data, mà còn khuếch đại bias qua objective.

Nhóm bias thứ ba là *feedback bias*, đặc biệt là *popularity bias*. Khi một số item phổ biến được recommend nhiều, chúng nhận thêm clicks, purchases hoặc ratings. Những interactions mới này lại được đưa vào training data, làm model càng tin rằng các item phổ biến nên được recommend nhiều hơn. Đây là cơ chế “rich get richer”, tương tự Matthew effect, làm long-tail items ngày càng khó được expose.

Về khái niệm fairness, paper phân loại theo nhiều trục. Trục thứ nhất là *individual fairness* và *group fairness*. Individual fairness yêu cầu hai user tương tự nên nhận recommendation tương tự:

$$f(u_i, v) \approx f(u_j, v)$$

với u_i và u_j là hai user tương tự. Group fairness yêu cầu protected group và advantaged

group nhận treatment tương đương. Một dạng phổ biến là demographic parity:

$$Pr(y_{U_i,v} = 1|U_i) = Pr(y_{U_j,v} = 1|U_j)$$

trong đó U_i và U_j là hai nhóm user khác nhau.

Trục thứ hai là *static fairness* và *dynamic fairness*. Static fairness xem protected group hoặc fairness constraint là cố định tại một thời điểm. Dynamic fairness xét sự thay đổi theo thời gian của recommendation environment. Một dạng biểu diễn dynamic fairness là:

$$Pr(y_{u,v_t} = 1|v_t) = Pr(y_{u,v_{t+1}} = 1|v_{t+1})$$

hoặc trong thực tế có thể dùng slack factor:

$$\frac{Pr(y_{u,v_t} = 1|v_t)}{Pr(y_{u,v_{t+1}} = 1|v_{t+1})} < \xi$$

Điều này quan trọng vì recommender systems là hệ động, trong đó user preference, item popularity và exposure distribution thay đổi liên tục.

Trục thứ ba là *single-sided fairness* và *multi-sided fairness*. Single-sided fairness chỉ bảo vệ lợi ích của một phía, ví dụ user fairness. Multi-sided fairness xét nhiều stakeholder cùng lúc, ví dụ user muốn nhận item phù hợp, còn provider muốn item của mình được expose công bằng. Trong e-commerce hoặc content platforms, multi-sided fairness rất quan trọng vì platform phải cân bằng utility của user, merchant, creator và chính hệ thống.

Ngoài ra, paper còn thảo luận *ranking fairness*, *causal fairness*, *long-term fairness*, và *envy-freeness fairness*. Ranking fairness yêu cầu các group hoặc item tương tự nhận visibility tương tự trong ranking. Causal fairness xét liệu recommendation có bị ảnh hưởng bởi sensitive attributes trong causal graph hay không. Long-term fairness xét tác động dài hạn của fairness intervention. Envy-freeness yêu cầu mỗi user thích recommendation của chính mình hơn recommendation của user khác.

Đóng góp kỹ thuật lớn nhất của survey là phân loại phương pháp fairness-aware recommender systems theo ba stage của pipeline: *pre-processing*, *in-processing*, và *post-processing*. Hình 3 trong paper minh họa rõ taxonomy này. Pre-processing can thiệp vào dữ liệu trước khi training. In-processing can thiệp vào quá trình học model. Post-processing can thiệp vào output ranking sau khi model đã train xong.

Nhóm *pre-processing methods* gồm ba loại: *data re-labeling*, *data re-sampling*, và *data modification*. Data re-labeling thay đổi label trong training data để giảm noise hoặc bias. Ví dụ trong implicit feedback, click không phải lúc nào cũng là positive preference và no-click không phải lúc nào cũng là negative preference. Re-labeling có thể tạo pseudo labels để giảm sai lệch giữa observed behavior và true preference.

Data re-sampling thay đổi phân phối dữ liệu bằng cách over-sample hoặc under-sample các nhóm nhất định để giảm imbalance. Ví dụ nếu một protected group hoặc item group

bị thiếu dữ liệu, re-sampling có thể cân bằng training set. Một số phương pháp negative sampling cũng được thiết kế để tạo negative samples gần với exposure distribution hơn, từ đó giảm exposure bias.

Data modification chỉnh sửa hoặc augment dữ liệu để giảm bias. Với textual recommender, data modification có thể gồm word segmentation, stopword removal, synonym substitution, term filtering hoặc xử lý missing/noisy text. Với collaborative filtering, data modification có thể xử lý ma trận user-item quá sparse bằng latent factor methods hoặc imputation.

Nhóm *in-processing methods* là nhóm phong phú nhất, gồm regularization, causal inference, adversarial learning, reinforcement learning, ranking optimization và một số hướng khác. Mục tiêu chung là học model ít bias hơn trong quá trình training, thay vì chỉ sửa dữ liệu hoặc sửa output.

Regularization-based methods thêm fairness regularizer vào loss:

$$\mathcal{L} = \mathcal{L}_{per}(u, v) + \mathcal{L}_{reg}(\theta)$$

trong đó $\mathcal{L}_{per}$ tối ưu recommendation performance, còn $\mathcal{L}_{reg}$ phạt model nếu vi phạm fairness constraint. Regularizer có thể là norm-based, matrix-based, correlation-based hoặc orthogonality-based. Ví dụ correlation regularization có thể phạt nếu prediction residual tương quan mạnh với protected group:

$$\mathcal{L}_{reg} = |Corr(A, B)|$$

Orthogonality regularization có thể tách bias-aware embedding và bias-free embedding:

$$\mathcal{L}_{reg}(u^b, u^d) = \left| \frac{u^b \cdot u^d}{\|u^b\| \cdot \|u^d\|} \right|$$

để giảm sensitive information trong representation.

Causal-inference-based methods tìm nguồn gây bias trong causal graph rồi dùng kỹ thuật như inverse propensity score, backdoor adjustment hoặc counterfactual inference để giảm bias. Với IPS, các samples được reweight để bù lại bias do exposure hoặc confounding. Ý tưởng là nếu một biến lịch sử h ảnh hưởng cả user representation và item representation, ta cần reweight phân phối quan sát được để tiệm cận phân phối không bị confounding:

$$Pr(h, u, v, r) = \frac{Pr(h)}{Pr(u|h)Pr(v|h)} \hat{Pr}(h, u, v, r)$$

Backdoor adjustment thì dùng $do(\cdot)$ operation để cắt các đường causal gây bias:

$$Pr(y|do(u), do(v)) = Pr(y|u, v)$$

Counterfactual inference kiểm tra liệu prediction có đổi khi thay sensitive attribute hay

không. Nếu thay gender, race hoặc age mà recommendation thay đổi mạnh, hệ thống có thể không counterfactually fair.

Adversarial-learning-based methods học representation không chứa sensitive attributes. Framework thường gồm generator tạo user/item embeddings và discriminator dự đoán sensitive attribute từ embedding. Generator được huấn luyện để vừa giữ recommendation performance vừa làm discriminator thất bại. Loss tổng quát:

$$\mathcal{L} = \mathcal{L}_{per}(z, y) + \mathcal{L}_{adv}(y, s)$$

trong đó s là prediction của discriminator về sensitive attribute. Khi discriminator không còn dự đoán được sensitive feature, representation được xem là fair hơn.

Reinforcement-learning-based methods xem recommendation là sequential decision-making. Hướng này phù hợp với fairness động và long-term fairness vì mỗi recommendation ảnh hưởng đến future exposure và future feedback. RL có thể tối ưu reward kết hợp giữa accuracy, exposure fairness, provider fairness hoặc long-term user utility. Tuy nhiên, reward design khó vì fairness và engagement có thể xung đột.

Ranking-optimization-based methods thiết kế loss hoặc ranking objective để giảm bias ngay khi học ranking. Ví dụ một số phương pháp phân tích nhược điểm của BPR hoặc pairwise loss trong việc khuếch đại popular items, rồi đề xuất unbiased ranking loss. Một ví dụ là CPR loss, dùng cross pair-wise interactions để cancel exposure bias trong training samples.

Nhóm *post-processing methods* xử lý output sau khi model đã tạo recommendation list. Recommender model được xem như black box; phương pháp post-processing chỉ rearrange hoặc rerank danh sách để thỏa fairness constraint. Có hai loại: *non-parametric re-ranking* và *parametric re-ranking*. Hình 9 trong paper mô tả pipeline của re-ranking: lấy recommendation list ban đầu, thêm fairness constraints, rồi giải bài toán re-ranking.

Non-parametric re-ranking không học thêm parameters, thường chuyển bài toán thành integer programming hoặc heuristic search. Với top- k recommendation ban đầu, mục tiêu có thể viết:

$$\begin{aligned} \arg \max_{I_{uv}} \sum_{u=1}^n \sum_{v=1}^N I_{uv} S_{uv} \\ s.t. \quad C(g_1, g_2) < \xi, \quad I_{uv} \in [0, 1] \end{aligned}$$

Trong đó S_{uv} là score gốc, I_{uv} biểu thị item v có được recommend cho user u hay không, còn $C(g_1, g_2)$ là fairness constraint giữa hai group. Các thuật toán có thể dùng greedy search, knapsack formulation, max-flow hoặc solver như Gurobi.

Parametric re-ranking thì học một model hoặc scoring function mới để điều chỉnh recommendation list. Ưu điểm là linh hoạt và có thể học pattern phức tạp hơn; nhược điểm là cần training data và có thể khó kiểm soát fairness constraint tuyệt đối.

Về evaluation, paper nhấn mạnh rằng fairness-aware recommender không thể chỉ dùng

accuracy metrics như RMSE, Recall hoặc NDCG. Cần thêm các metric đo fairness theo user, item, group, exposure, ranking position hoặc long-term dynamics. Ví dụ fairness có thể được đo bằng exposure balance giữa item groups, demographic parity giữa user groups, ranking fairness trong top- k prefix, diversity, serendipity hoặc novelty. Paper cũng tổng hợp datasets thường dùng trong literature để đánh giá fairness-aware recommender systems.

Về ứng dụng công nghiệp, survey thảo luận ba nhóm lớn: e-commerce, education và social activities. Trong e-commerce, fairness liên quan đến việc không để merchant lớn hoặc popular products chiếm toàn bộ exposure. Trong education, fairness liên quan đến việc course hoặc teacher từ các quốc gia/nhóm ít phổ biến không bị under-exposed. Trong social activities, fairness liên quan đến việc recommendation không làm tăng discrimination hoặc polarization giữa các nhóm user.

Một phần quan trọng của survey là quan hệ giữa fairness và các nguyên tắc khác của trustworthy recommender systems. Fairness có thể tương tác với *explainability*, *robustness*, *privacy* và các khía cạnh đạo đức khác. Ví dụ explainability có thể giúp user hiểu vì sao họ nhận recommendation và phát hiện bias. Robustness giúp hệ thống không dễ bị attack hoặc data perturbation làm lệch fairness. Privacy lại tạo trade-off: để kiểm tra fairness, hệ thống có thể cần sensitive attributes, nhưng dùng sensitive attributes lại gây rủi ro privacy.

Paper chỉ ra rằng nhiều nghiên cứu hiện tại cải thiện fairness nhưng chưa xét đầy đủ tác động lên các trustworthy dimensions khác. Một phương pháp làm tăng fairness có thể làm giảm accuracy, làm giảm privacy hoặc làm hệ thống khó explain hơn. Do đó, fairness-aware recommender systems cần được thiết kế theo hướng holistic trustworthiness, không chỉ tối ưu một fairness metric đơn lẻ.

Trong phần future directions, paper chia thành bốn hướng chính. Thứ nhất là *concepts*: cần chuẩn hóa và tùy biến khái niệm fairness cho từng recommendation scenario, vì fairness trong job recommendation, news recommendation, e-commerce và education không giống nhau. Thứ hai là *frameworks*: chưa có một framework one-size-fits-all cho mọi fairness concern, nên cần chọn đúng phương pháp cho đúng loại bias và scenario. Thứ ba là *trade-off*: cần cân bằng fairness và recommendation performance. Thứ tư là *trustworthiness*: cần nghiên cứu sâu hơn quan hệ giữa fairness và các thuộc tính trustworthy khác.

Tóm lại, paper này đóng vai trò như một bản đồ tổng quan cho fairness-aware recommender systems. Nó không chỉ liệt kê các phương pháp, mà còn đặt fairness vào toàn bộ lifecycle của recommender system: bias có thể sinh ra từ dữ liệu, mô hình, ranking, feedback loop và deployment. Vì vậy, giải pháp fairness cũng cần được thiết kế ở nhiều tầng, từ dữ liệu đến training và post-processing.

2 Conclusion

Hướng đi đã làm của bài báo là tổng hợp và hệ thống hóa nghiên cứu về *fairness-aware recommender systems*. Survey bắt đầu từ việc định nghĩa recommender system và fairness, sau đó phân tích nguồn gây unfairness trong toàn bộ lifecycle: data collection, model learning và feedback loop. Tiếp theo, paper phân loại các phương pháp xử lý fairness thành pre-processing, in-processing và post-processing, đồng thời kết nối fairness với evaluation metrics, industrial applications và broader trustworthy AI.

Đóng góp kỹ thuật quan trọng nhất của survey là taxonomy theo pipeline. Ở pre-processing, hệ thống có thể giảm bias bằng re-labeling, re-sampling và data modification. Ở in-processing, hệ thống có thể học fair representation hoặc fair ranking bằng regularization, causal inference, adversarial learning, reinforcement learning và ranking optimization. Ở post-processing, hệ thống có thể re-rank recommendation list để thỏa fairness constraint mà không cần sửa model gốc. Taxonomy này giúp người nghiên cứu chọn phương pháp phù hợp với vị trí của bias trong hệ thống.

Ý nghĩa chính của paper là fairness trong recommender systems không thể được hiểu đơn giản như fairness trong classification. Recommender systems có nhiều stakeholder, có ranking exposure, có temporal dynamics và có feedback loop. Vì vậy, fairness cần được xét theo nhiều chiều: individual/group, static/dynamic, single-sided/multi-sided, ranking fairness, causal fairness và long-term fairness. Nếu chỉ dùng một metric đơn giản, hệ thống có thể cải thiện fairness ở một góc nhưng làm xấu fairness ở góc khác.

Hạn chế hiện tại của lĩnh vực, theo survey, là khái niệm fairness chưa thống nhất, benchmark và metric còn phân tán, trade-off giữa fairness và accuracy chưa được xử lý thỏa đáng, và mối quan hệ giữa fairness với trustworthiness còn thiếu nghiên cứu. Đặc biệt, nhiều phương pháp chỉ đánh giá fairness ở short-term setting, trong khi recommender systems thực tế vận hành lâu dài và liên tục tác động đến user behavior cũng như item exposure.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, cần xây dựng fairness definitions theo từng domain, ví dụ e-commerce cần provider exposure fairness, job recommendation cần demographic fairness, education cần geographic fairness, còn content recommendation cần diversity và filter-bubble mitigation. Thứ hai, cần phát triển dynamic fairness framework để đo và tối ưu fairness qua nhiều vòng feedback, thay vì chỉ đo trên một snapshot tĩnh. Thứ ba, cần thiết kế multi-objective learning để cân bằng accuracy, fairness, diversity, novelty, privacy và explainability.

Ngoài ra, survey này rất phù hợp để kế thừa cho các hướng recommender hiện đại như LLM-based recommendation, RAG-based recommendation, proactive recommendation và time-aware recommendation. Trong LLM/RAG recommender, fairness có thể liên quan đến exposure của long-tail items, bias trong retrieved evidence, hoặc bias trong generated explanation. Trong time-aware recommender, fairness có thể gắn với dynamic exposure

và long-term preference shaping. Vì vậy, một hướng nghiên cứu mới có thể là xây dựng *fairness-aware LLM-based recommender systems*, nơi hệ thống không chỉ tối ưu accuracy hoặc personalization, mà còn kiểm soát exposure bias, popularity bias, provider fairness và long-term fairness trong toàn bộ pipeline. “