

Paper

1 Summary

Bài báo *Large Language Model Enhanced Recommender Systems: A Survey* khảo sát hướng *LLM-Enhanced Recommender Systems* (LLMERS), tức các hệ recommender truyền thống được tăng cường bởi Large Language Models nhưng không cần gọi LLM trong giai đoạn online serving. Đây là điểm khác biệt quan trọng so với các hướng *LLM as Recommender System*, nơi LLM trực tiếp sinh recommendation trong lúc inference. Paper cho rằng hướng dùng LLM trực tiếp làm recommender thường khó triển khai thực tế vì latency của LLM có thể tính bằng giây, trong khi recommender system công nghiệp cần xử lý lượng request rất lớn với độ trễ rất thấp.

Luận điểm chính của survey là LLM có khả năng ngôn ngữ, semantic reasoning và world knowledge rất mạnh, nhưng không nên nhất thiết đặt LLM vào online inference path. Thay vào đó, LLM có thể được dùng ở giai đoạn offline để tạo thêm tri thức, tạo dữ liệu bổ sung, khởi tạo embedding, hướng dẫn training hoặc distill tri thức sang model nhỏ hơn. Sau đó, hệ thống online vẫn chỉ dùng recommender model nhẹ như collaborative filtering, sequential recommender, CTR model hoặc graph-based recommender.

Paper định nghĩa LLMERS như sau: recommender system truyền thống được tăng cường bởi LLM thông qua hỗ trợ trong training hoặc bổ sung dữ liệu, nhưng không cần LLM inference trong giai đoạn service. Cách định nghĩa này loại bớt các hệ thống dùng LLM như chatbot recommender trực tiếp, và tập trung vào các phương pháp thực tế hơn cho production. Đây cũng là lý do paper nhấn mạnh vấn đề latency, memory và deployment cost.

Về mặt cấu trúc recommender system, paper chia hệ thống truyền thống thành hai phần chính: *interaction data* và *recommendation model*. Interaction data gồm feature và interaction. Feature có thể là thuộc tính user, thuộc tính item, text, category hoặc metadata. Interaction là các hành vi user-item như click, view, purchase, rating hoặc watch. Recommendation model thường có dạng:

Embedding Layer $\rightarrow$ Deep Network

Embedding layer chuyển raw features thành dense representations, còn deep network học user preference và feature interactions.

Từ cấu trúc này, paper chỉ ra ba thách thức của recommender truyền thống. Thứ nhất, feature thường được mã hóa thành numerical hoặc categorical values nên thiếu reasoning và semantic understanding. Thứ hai, interaction data thường thưa, đặc biệt với cold-start users/items hoặc long-tail items. Thứ ba, recommendation model chủ yếu học collaborative signals nhưng khó tận dụng tri thức ngôn ngữ và semantic information.

Dựa trên ba thách thức này, survey đưa ra taxonomy gồm ba hướng chính của LLMERS:

Knowledge Enhancement

Interaction Enhancement

Model Enhancement

Hình 1 trong paper minh họa taxonomy này: LLM có thể tăng cường phần feature/knowledge, phần interaction data hoặc chính recommendation model. Đây là khung phân loại trung tâm của bài báo.

1.1 Knowledge Enhancement

Nhóm thứ nhất là *Knowledge Enhancement*. Mục tiêu của nhóm này là dùng khả năng reasoning và world knowledge của LLM để tạo thêm knowledge features cho user hoặc item. Ví dụ, từ browsing history của user, hệ thống có thể prompt LLM:

Given a user who has viewed ... , explain what he/she is interested in

LLM sinh ra textual preference summary, sau đó summary này được encode bằng text encoder như BERT và đưa vào recommender model như feature bổ sung.

Paper chia Knowledge Enhancement thành ba nhánh: *Summary Text*, *Knowledge Graph*, và *Combination*. Điểm chung là các knowledge artifacts có thể được tạo và lưu trước, nên không cần gọi LLM trong online serving.

Nhánh *Summary Text* sử dụng LLM để tóm tắt đặc điểm user hoặc item. Ở phía user, LLM có thể sinh profile như “user thích phim khoa học viễn tưởng có yếu tố triết học” hoặc “user quan tâm đến sản phẩm công nghệ giá rẻ”. Ở phía item, LLM có thể sinh mô tả semantic giàu thông tin hơn từ title, metadata hoặc content. Sau đó các text này được encode thành vector và dùng trong RS model.

Một số phương pháp chỉ tăng cường user side, ví dụ LANE hoặc LLM-BRec, nơi LLM tạo multi-preference summaries của user. Một số phương pháp chỉ tăng cường item side, ví dụ ONCE dùng LLM như content summarizer cho news recommendation; LAMAR dùng LLM để sinh factual properties của movies; MMRec và X-Reflect dùng multimodal LLM để chuyển visual features thành textual descriptions. Một số phương pháp tăng cường cả user và item, ví dụ KAR tạo reasoning knowledge của user và factual knowledge của item,

sau đó tích hợp vào CTR models như DeepFM hoặc DIN.

Nhánh *Knowledge Graph* dùng LLM để generate, complete hoặc fuse knowledge graph cho recommender. Với KG generation, LLM có thể sinh interaction graph, user-interest hypergraph hoặc job entity graph từ lịch sử tương tác, mô tả item hoặc CV/job description. Với KG completion/fusion, LLM được dùng để nhận diện quan hệ bổ sung trong KG hiện có, ví dụ complementary relationships giữa items. Ý tưởng là KG cung cấp tri thức có cấu trúc, dễ tích hợp vào graph-based hoặc knowledge-aware recommender.

Nhánh *Combination* kết hợp summary text và KG. Ví dụ KELLMRec dùng KG để xây prompt nhằm giảm hallucination khi LLM sinh summary text. SKarRec liên kết entity trong KG với textual prompt để sinh KG-aware knowledge cho concept recommendation. Hướng này tận dụng cả hai ưu điểm: KG có cấu trúc và summary text dễ đưa vào language encoder.

1.2 Interaction Enhancement

Nhóm thứ hai là *Interaction Enhancement*. Mục tiêu là dùng LLM để tạo thêm user-item interactions hoặc xử lý noisy interactions, từ đó giảm data sparsity. Vì augmented interactions chỉ được dùng trong training của recommender truyền thống, nhóm này cũng không làm tăng chi phí online inference.

Paper chia Interaction Enhancement thành hai nhánh: *text-based* và *score-based*. Với text-based methods, LLM trực tiếp sinh tên item mà user có thể tương tác. Ví dụ, dựa trên lịch sử user, LLM được yêu cầu recommend news hoặc item mới; item được sinh ra được thêm vào training data như pseudo interaction. ONCE là một trong các phương pháp đầu tiên theo hướng này.

Tuy nhiên, text-based generation có hai vấn đề. Thứ nhất, nếu item catalog rất lớn, LLM khó chọn chính xác item thuộc catalog. Thứ hai là *out-of-corpus problem*: LLM có thể sinh tên item không tồn tại trong item set. Vì vậy, các phương pháp sau thường thu hẹp candidate set trước. Ví dụ, một recommender truyền thống tạo shortlist item, rồi LLM chọn item phù hợp trong shortlist. Cách này giúp giảm lỗi hallucination item và tăng độ chính xác của augmented interactions.

Với *score-based methods*, LLM không nhất thiết sinh item name trực tiếp. Thay vào đó, LLM tạo semantic embedding hoặc confidence score cho user-item pairs, rồi hệ thống rank candidate items theo score để chọn pseudo interactions. Ví dụ LLM-InS dùng LLM để tạo semantic embeddings của user và item, sau đó tính similarity để sinh augmented interactions. LLM4DSR dùng token probability hoặc embedding similarity để phát hiện noisy items và sinh dữ liệu mới.

Điểm quan trọng của Interaction Enhancement là LLM đóng vai trò *data augmentor*. Nó không thay thế recommendation model, mà tạo dữ liệu bổ sung để model truyền thống học tốt hơn trong các trường hợp dữ liệu thưa, noisy feedback hoặc cold-start item.

1.3 Model Enhancement

Nhóm thứ ba là *Model Enhancement*. Đây là nhóm phong phú nhất trong survey vì LLM không chỉ tạo thêm dữ liệu hoặc feature, mà trực tiếp ảnh hưởng đến cách học của recommender model. Paper chia Model Enhancement thành bốn nhánh:

Model Initialization

Model Distillation

Embedding Utilization

Embedding Guidance

Model Initialization dùng tri thức từ LLM để khởi tạo model hoặc embedding layer của recommender. Ý tưởng là pretrained weights hoặc semantic embeddings từ LLM giúp model hội tụ tốt hơn và chứa sẵn semantic relationships giữa items. Có hai dạng: khởi tạo toàn bộ model và khởi tạo embedding layer.

Ở dạng khởi tạo toàn bộ model, các phương pháp như CTRL và FLIP xem semantic representation từ LLM và collaborative representation từ RS model như hai modality khác nhau. Sau đó, chúng dùng contrastive alignment hoặc masked modeling tasks để align hai không gian, rồi dùng tham số sau alignment làm initialization cho recommender model.

Ở dạng khởi tạo embedding, LLM được dùng để encode item title, item attributes hoặc item text thành item embeddings. Các embeddings này khởi tạo embedding layer của sequential recommender hoặc CTR model. Ví dụ LLM2X dùng item title đưa vào large text embedding model; LEARN dùng hidden states của frozen open-source LLM; SAID và TSLRec fine-tune LLM bằng item attribute generation hoặc information reconstruction để làm embedding phù hợp hơn với recommendation task; LLMEmb thêm attribute-level contrastive task để học semantic relationships fine-grained giữa items.

Model Distillation dùng LLM hoặc LLM-enhanced model làm teacher để truyền tri thức sang recommender model nhỏ hơn. Paper chia thành feature-based và response-based distillation. Feature-based distillation truyền hidden states hoặc intermediate representations từ LLM sang RS model. Ví dụ LEADER distill hidden state cuối của LLM qua trainable adapter; SLMRec giữ cấu trúc transformer nhưng giảm số layer, rồi distill nhiều tầng transformer từ LLM sang model nhỏ.

Response-based distillation dùng output ranking list hoặc response của LLM làm teacher signal. Ví dụ DLLM2Rec fine-tune LLM cho recommendation task, sau đó lấy ranking list của LLM để train RS model bằng ranking distillation loss. Cách này phù hợp khi LLM có semantic ranking tốt nhưng không thể phục vụ online vì chi phí cao.

Embedding Utilization là nhánh dùng trực tiếp LLM embeddings như semantic supplementary

features. Thay vì sinh text rồi encode lại, hệ thống lấy hidden states hoặc embeddings từ LLM và đưa vào recommender. Nhánh này được chia thành User Only, Item Only, và User & Item.

Ở User Only, LLM sinh representation của user preference. Ví dụ LLM-CF fine-tune LLM để tạo Chain-of-Thought reasoning nhằm tăng cường user preference representation. Tuy nhiên, user-side LLM embedding thường khó vì lịch sử user dài, prompt dễ vượt token limit và dễ nhiễu.

Ở Item Only, LLM encoding thường dễ hơn vì item metadata ngắn và ổn định hơn. Đây là hướng phổ biến trong sequential recommendation. TedRec dùng LLaMA để encode item text rồi fuse semantic embedding với ID embedding. LLM-ESR và AlphaRec giữ frozen LLM embeddings và học adapter để duy trì semantic information. NoteLLM và NoteLLM-2 dùng LLM để tạo item embeddings cho item-item recommendation, trong đó NoteLLM-2 mở rộng sang multimodal item features. HLLM xây hierarchical framework: item LLM encode item text, sau đó user LLM sử dụng item representations để recommendation.

Ở User & Item, một số phương pháp dùng similarity trực tiếp giữa user and item LLM embeddings. Một số phương pháp khác dùng cả user/item embeddings như extra features trong content-based RS. Ví dụ Laser dùng user/item LLM embeddings với adapter để tăng cường feature; LARR dùng LLM embeddings như extra features nhưng nhấn mạnh việc fine-tune LLM cho real-time scene recommendation.

Embedding Guidance khác với Embedding Utilization ở chỗ LLM embeddings không nhất thiết được dùng như feature online. Thay vào đó, chúng hướng dẫn training hoặc parameter synthesis. Ví dụ LLM4SBR dùng LLM embeddings để xác định representative items cho short-term và long-term preference trong session-based recommendation. LLM-ESR dùng LLM embeddings để retrieve similar users nhằm tăng cường long-tail users trong training. RLMLRec thêm alignment loss để collaborative embeddings của user/item gần với LLM embeddings tương ứng. DaRec disentangle shared và specific parts giữa LLM embeddings và collaborative embeddings, rồi chỉ align phần shared để đạt performance tốt hơn.

1.4 Trend Analysis

Paper cũng phân tích xu hướng phát triển của LLMERS. Hình 6 trong paper đặt các công trình theo hai trục: *open-source vs closed-source LLM* và *explicit vs implicit semantics*. Explicit semantics là tri thức dạng ngôn ngữ tự nhiên như summary, explanation hoặc generated text. Implicit semantics là hidden states, embeddings hoặc representation không trực tiếp đọc được.

Xu hướng thứ nhất là LLMERS đang dịch chuyển từ *explicit semantics* sang *implicit semantics*. Ở giai đoạn đầu, nhiều công trình prompt LLM để sinh text summary hoặc KG explanation vì dễ hiểu và dễ giải thích. Tuy nhiên, explicit text có thể mất thông tin

khi encode lại và phụ thuộc nhiều vào prompt. Các công trình gần đây ưu tiên embeddings hoặc hidden states vì chúng giữ semantic signal tốt hơn và dễ tích hợp trực tiếp vào model.

Xu hướng thứ hai là các công trình ngày càng ưu tiên *open-source LLM*. Lý do đầu tiên là giảm chi phí API. Lý do quan trọng hơn là open-source LLM có thể fine-tune cho recommendation task. Vì LLM general-purpose không tối ưu cho user-item prediction, fine-tuning giúp align LLM với collaborative signals và item semantics tốt hơn.

Xu hướng thứ ba là *Model Enhancement* ngày càng được quan tâm nhiều hơn. So với Knowledge Enhancement và Interaction Enhancement, Model Enhancement tận dụng tốt hơn implicit semantics và fine-tuned LLM. Nó cũng phù hợp với production vì có thể loại bỏ LLM khỏi online path bằng initialization, distillation, cached embedding hoặc training-time guidance.

1.5 Efficiency and Applications

Paper nhấn mạnh efficiency là khác biệt quan trọng giữa LLMERS và LLM-as-RS. Với Knowledge Enhancement, LLM được dùng offline để sinh summaries hoặc KGs, sau đó các artifacts được cache. Chi phí online chỉ còn text/KG encoding hoặc feature lookup. Với Interaction Enhancement, LLM chỉ tạo augmented interactions cho training, nên inference hoàn toàn không đổi. Với Model Enhancement, LLM có thể được dùng trong initialization, distillation hoặc embedding guidance ở training phase; còn embedding utilization có thể cache embeddings trước inference.

Về ứng dụng, LLMERS phù hợp nhất với domain có nhiều side information hoặc nhiều text. E-commerce có nhiều user/item profile features và item attributes mà LLM có thể hiểu. News recommendation có nhiều văn bản dài để LLM summarize. Movie, book, POI, video, job và online retail cũng là các domain phù hợp vì chúng có metadata hoặc textual content giàu thông tin.

1.6 Future Directions

Paper đề xuất một số hướng nghiên cứu tiếp theo. Thứ nhất là mở rộng LLMERS sang nhiều recommendation tasks hơn. Hiện nhiều công trình tập trung vào collaborative filtering, sequential recommendation hoặc CTR prediction, nhưng còn nhiều task khác như session-based, multi-scenario, group recommendation, bundle recommendation hoặc conversational recommendation có thể được tăng cường bởi LLM.

Thứ hai là *multimodal recommender systems*. Khi nhiều nền tảng có image, video, audio và text, multimodal LLM có thể giúp encode và fuse nhiều modality tốt hơn. Đây là hướng quan trọng vì multimodal RS truyền thống thường gặp khó trong feature extraction và fusion.

Thứ ba là *user-side enhancement*. Hiện tại item-side enhancement phổ biến hơn vì item text thường ngắn và ổn định. User-side enhancement khó hơn vì lịch sử user dài, có

thứ tự thời gian, nhiều noise và dễ vượt token limit. Do đó, cần các kỹ thuật như session summarization, hierarchical encoding, memory compression hoặc user profile distillation.

Thứ tư là *explainability*. Vì LLM hiểu semantic content của user và item, nó có thể giúp recommender tạo explanation tự nhiên và đáng tin hơn. Tuy nhiên, cần đảm bảo explanation phản ánh đúng cơ chế recommendation, không chỉ là post-hoc rationalization.

Thứ năm là *benchmark*. Paper nhấn mạnh rằng LLMERS còn rất mới và chưa có benchmark chuẩn. Việc xây dựng benchmark thống nhất là cần thiết để so sánh công bằng giữa các phương pháp, nhất là khi mỗi paper dùng dataset, backbone, LLM, prompt và evaluation protocol khác nhau.

2 Conclusion

Hướng đi đã làm của bài báo là tổng hợp và hệ thống hóa các nghiên cứu về *Large Language Model Enhanced Recommender Systems*. Survey đặt trọng tâm vào hướng thực tế: LLM được dùng để hỗ trợ training, tạo knowledge, augment interaction hoặc tăng cường model, nhưng không cần chạy LLM trong online serving. Đây là cách tận dụng semantic reasoning của LLM mà vẫn đáp ứng yêu cầu latency và throughput của recommender system công nghiệp.

Đóng góp kỹ thuật quan trọng nhất của survey là taxonomy ba nhóm: *Knowledge Enhancement*, *Interaction Enhancement*, và *Model Enhancement*. Knowledge Enhancement dùng LLM để tạo summary text, KG hoặc kết hợp cả hai nhằm bổ sung semantic features. Interaction Enhancement dùng LLM để sinh pseudo interactions hoặc score user-item pairs nhằm giảm sparsity và noisy feedback. Model Enhancement đưa tri thức LLM vào model qua initialization, distillation, embedding utilization hoặc embedding guidance.

Ý nghĩa chính của paper là chỉ ra rằng LLM không nhất thiết phải thay thế recommender system truyền thống. Trong nhiều production settings, hướng hợp lý hơn là dùng LLM như một semantic engine offline, còn online recommender vẫn là model nhỏ, nhanh và dễ triển khai. Điều này nổi trực tiếp với các bài gần đây về LoopFM, Rec-Distill, LLM advertiser predictor hoặc ACE: tất cả đều theo logic dùng LLM/FMs để tăng cường representation hoặc training signal, nhưng vẫn giữ serving efficient.

Paper cũng chỉ ra xu hướng hiện tại của lĩnh vực: từ explicit semantics sang implicit semantics, từ closed-source API sang fine-tuned open-source LLM, và từ data/knowledge augmentation sang model enhancement. Điều này cho thấy LLMERS đang chuyển từ giai đoạn prompt-based exploration sang giai đoạn representation/model-level integration thực tế hơn.

Hạn chế hiện tại của lĩnh vực là vẫn thiếu benchmark chuẩn, thiếu đánh giá production-scale, thiếu nghiên cứu user-side enhancement, và chưa khai thác đầy đủ multimodal/contextual information. Ngoài ra, nhiều phương pháp còn khó so sánh vì khác LLM backbone, khác cách encode text, khác RS backbone và khác dataset.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, có thể xây dựng benchmark chuẩn cho LLMERS, bao gồm nhiều task như sequential recommendation, CTR prediction, cold-start recommendation và multimodal recommendation. Thứ hai, có thể phát triển user-side LLM enhancement bằng memory compression hoặc hierarchical user modeling để xử lý lịch sử dài. Thứ ba, có thể kết hợp LLMERS với fairness, explainability và privacy để xây dựng trustworthy LLM-enhanced recommender systems.

Ngoài ra, survey này rất phù hợp để làm nền tảng cho hướng nghiên cứu recommender mới: *LLM-enhanced but serving-efficient recommendation*. Thay vì hỏi “LLM có thể recommend trực tiếp không”, câu hỏi thực tế hơn là “LLM có thể tạo ra tri thức, embedding, interaction hoặc training signal nào để model recommender nhỏ hơn hoạt động tốt hơn không”. Đây là hướng có khả năng kế thừa mạnh trong các hệ thống e-commerce, ads, news, video, music và content recommendation quy mô lớn. ““