

Paper

“latex

1 Summary

Bài báo *A Survey on Large Language Models in Multimodal Recommender Systems* khảo sát hướng kết hợp *Large Language Models* (LLMs) với *Multimodal Recommender Systems* (MRS). Trong MRS, hệ thống gợi ý không chỉ dùng user-item interactions, mà còn khai thác nhiều nguồn dữ liệu khác nhau như văn bản, hình ảnh, dữ liệu bảng, metadata có cấu trúc, knowledge graph, video, audio hoặc lịch sử hành vi của user.

Vấn đề chính của MRS truyền thống là các modality khác nhau thường có không gian biểu diễn khác nhau, mức độ nhiễu khác nhau và semantic granularity khác nhau. Ví dụ, text description có thể chứa semantic intent rõ ràng, image chứa visual style, còn tabular metadata chứa các thuộc tính rời rạc như brand, category, price hoặc rating. Nếu chỉ dùng encoder riêng cho từng modality rồi fusion đơn giản, hệ thống có thể gặp các vấn đề như modality misalignment, cold-start, data sparsity và khó giải thích recommendation.

Sự xuất hiện của LLM mở ra một hướng mới cho MRS. Khác với các pretrained language models trước đây như BERT hoặc RoBERTa, LLM như GPT, PaLM hoặc LLaMA có khả năng reasoning, in-context learning, prompt-based control và xử lý input linh hoạt hơn. Vì vậy, LLM không chỉ là một text encoder, mà có thể đóng vai trò như một reasoning agent, một data adapter, một semantic aligner hoặc một module tạo tri thức bổ sung cho recommender.

Điểm khác biệt của survey này so với các survey MRS trước là nó không lấy encoder, loss function hoặc fusion architecture làm trục phân loại chính. Thay vào đó, paper xây dựng taxonomy theo các chức năng đặc thù của LLM trong MRS:

LLM Methods

MRS-specific Techniques

Trends and Future Directions

Trong đó, *LLM Methods* gồm prompting, training strategy và data type adaptation. *MRS-specific Techniques* gồm disentanglement, alignment và fusion. Đây là taxonomy phù hợp

hơn với thời kỳ LLM vì LLM có thể can thiệp vào pipeline ở nhiều vị trí khác nhau, không chỉ ở tầng encoder.

1.1 LLM Methods

Nhóm đầu tiên là *LLM Methods*, gồm ba nhánh lớn: *Prompting*, *Training*, và *Data Type Adaptation*. Ba nhánh này mô tả cách đưa dữ liệu multimodal vào LLM hoặc cách điều chỉnh LLM cho recommendation task.

1.1.1 Prompting

Prompting là một chiến lược trung tâm trong LLM-based MRS vì nó cho phép điều khiển LLM mà không cần cập nhật toàn bộ tham số. Prompting đặc biệt hữu ích trong cold-start, multi-task recommendation, hoặc khi chỉ có quyền truy cập black-box API. Paper chia prompting thành bốn nhóm: hard prompting, soft prompting, hybrid prompting và control logic prompting.

Hard prompting dùng các prompt cố định, có thể đọc được bởi con người. Ví dụ, hệ thống có thể chuyển user profile và item metadata thành câu:

This is a user, gender is female, age is 18, who recently watched Titanic and Avatar.

Sau đó LLM sử dụng prompt này để dự đoán item, giải thích preference hoặc tạo candidate. Ưu điểm của hard prompting là đơn giản, dễ triển khai, phù hợp với black-box LLM. Nhược điểm là prompt rất nhạy với cách diễn đạt; thay đổi nhỏ trong template có thể làm output thay đổi mạnh.

Trong hard prompting, paper còn phân biệt *manual prompt engineering*, *structured template prompts* và *reasoning-based prompts*. Manual prompt engineering dựa trên thiết kế thủ công. Structured template prompts dùng format nhất quán để encode user/item features, tabular records hoặc sequential logs. Reasoning-based prompts dùng chain-of-thought, in-context learning hoặc task decomposition để giúp LLM xử lý các recommendation task phức tạp hơn.

Soft prompting thay prompt dạng text bằng các vector embedding học được. Thay vì viết prompt thủ công, hệ thống học một tập soft tokens:

$$P = [p_1, p_2, \dots, p_m]$$

rồi prepend chúng vào input embedding của LLM. Soft prompt không đọc được bởi con người nhưng có khả năng thích nghi tốt hơn với downstream task. Trong MRS, soft prompting hữu ích để đưa structured signals như user ID, item ID, GUI interaction graph, hoặc visual features vào LLM.

Một dạng quan trọng của soft prompting là *semantic ID prompting*. Thay vì dùng raw user/item ID, hệ thống map ID thành semantic token hoặc continuous embedding. Điều này giúp LLM xử lý ID-based recommendation tốt hơn, vì LLM vốn không hiểu các ID rời rạc nếu chỉ biểu diễn chúng như string ngẫu nhiên.

Hybrid prompting kết hợp hard prompt và soft prompt. Hard prompt giữ tính diễn giải và cấu trúc rõ ràng, còn soft prompt mang thông tin cá nhân hóa hoặc multimodal signal khó biểu diễn bằng text. Ví dụ, một hệ thống có thể đưa item title, category và textual description vào hard prompt, đồng thời thêm visual embedding hoặc user history embedding dưới dạng soft tokens. Cách này cân bằng giữa interpretability và adaptability.

Control logic prompting là các pipeline prompt nhiều bước, có điều kiện hoặc có cấu trúc dạng tree/graph. Thay vì gọi LLM một lần, hệ thống chia task thành nhiều subtask như extract feature, rank feature, validate output, refine knowledge hoặc generate explanation. Cách này phù hợp với MRS phức tạp, nơi hệ thống cần phối hợp nhiều loại dữ liệu hoặc nhiều tool khác nhau.

1.1.2 Training

Nhánh thứ hai là *Training*. Do LLM lớn, chi phí huấn luyện cao và nhiều LLM chỉ có API black-box, các phương pháp adaptation trong MRS thường tránh full pretraining. Paper chia training strategy thành bốn nhóm: *Parameter Adaptation*, *Zero-Tuning Usage*, *Pretrained MLLMs*, và *Agents*.

Parameter Adaptation gồm các phương pháp cập nhật một phần tham số của LLM hoặc thêm module nhẹ. Các kỹ thuật phổ biến gồm:

Adapters, LoRA, QLoRA

LoRA là kỹ thuật phổ biến vì nó không cập nhật toàn bộ ma trận trọng số W , mà học hai ma trận hạng thấp:

$$W' = W + BA$$

trong đó A và B có rank nhỏ. Cách này giúp fine-tune LLM cho recommendation task với chi phí thấp hơn nhiều so với full fine-tuning.

Nhóm này còn gồm *instruction tuning*, *task-specific fine-tuning*, *pretraining-fine-tuning pipelines*, *RL-augmented tuning*, và *prompt-enhanced tuning*. Ví dụ, LLM có thể được fine-tune để hiểu user behavior sequence, sinh job description phù hợp CV, hoặc tạo recommendation theo instruction format.

Zero-Tuning Usage dùng LLM ở trạng thái frozen, không cập nhật tham số. LLM có thể đóng vai trò encoder, profile generator, tag extractor, content enricher hoặc reasoning module trong RAG pipeline. Cách này rẻ hơn, dễ triển khai hơn, đặc biệt khi dùng closed-source LLM. Tuy nhiên, vì không có task-specific tuning, khả năng phù hợp với

recommendation objective có thể bị giới hạn.

Các kiểu zero-tuning gồm frozen encoder-based representation, black-box prompting for profile generation, black-box tagging/attribute extraction, content enrichment và RAG/tool usage. Ví dụ, LLM có thể được dùng để sinh user profile từ lịch sử hành vi, extract product attributes từ image/text, hoặc enrich item descriptions trước khi đưa vào recommender model.

Pretrained MLLMs là các multimodal large language models có khả năng xử lý text, image và structured signals. Trong MRS, pretrained MLLMs có thể được dùng để encode multimodal item content, sinh dữ liệu huấn luyện, hoặc đóng vai trò module chính trong end-to-end architecture. Tuy nhiên, vấn đề lớn của MLLM là inference latency và chi phí serving.

Agents là một xu hướng mới, trong đó LLM được xem như agent có thể lập kế hoạch, dùng tool, phản hồi môi trường hoặc mô phỏng user behavior. Trong recommender system, agent có thể được dùng để mô phỏng user có personality khác nhau, chọn agent phù hợp với prompt, hoặc điều phối nhiều bước reasoning. Đây là hướng còn mới nhưng có tiềm năng cho controllability và interpretability.

1.1.3 Data Type Adaptation

Nhánh thứ ba là *Data Type Adaptation*. Vì LLM nhận input tự nhiên nhất ở dạng text/token, các modality không phải text cần được chuyển đổi sang dạng LLM-compatible. Paper chia data adaptation thành nhiều nhóm: KG-based conversion, semantic ID conversion, tabular-to-text conversion, image summarisation, behavior-to-text summarisation, prompt-based fusion, adapted multimodal fusion và code-like structural conversion.

KG-based conversion dùng knowledge graph như một lớp trung gian để hợp nhất dữ liệu đa modality. KG có thể biểu diễn entity, relation, item attribute, user preference hoặc domain knowledge. Sau đó, LLM có thể truy vấn KG, đọc subgraph hoặc dùng KG để giảm hallucination. Ưu điểm là có cấu trúc và dễ giải thích; nhược điểm là xây KG chất lượng cao tốn công và khó mở rộng theo domain.

Semantic ID conversion map user/item IDs sang semantic tokens hoặc continuous embeddings. Đây là cách giải quyết khoảng cách giữa ID-based recommender và language model. Thay vì để LLM xử lý ID vô nghĩa, hệ thống tạo semantic ID có cấu trúc hoặc embedding có ý nghĩa hơn.

Tabular-to-text conversion chuyển dữ liệu bảng thành prompt tự nhiên hoặc structured text. Ví dụ:

User age: 25, gender: female, city: London, favorite category: fashion.

Cách này giúp LLM đọc được categorical và numerical features mà không cần thay đổi kiến trúc.

Image summarisation for LLM input chuyển image thành text description bằng MLLM hoặc vision-language model. Ví dụ, item image được mô tả thành “a red leather handbag with gold chain strap”. Sau đó text này được đưa vào LLM hoặc recommender. Ưu điểm là tương thích với text-only LLM; nhược điểm là có thể mất các visual details fine-grained.

Behavior-to-text summarisation chuyển lịch sử hành vi user thành natural-language summary. Ví dụ, một sequence click/view/purchase có thể được tóm tắt thành:

The user often browses budget smartphones, gaming laptops, and accessories.

Cách này giúp LLM hiểu long user history tốt hơn, nhưng phụ thuộc vào chất lượng summarization và có thể mất thông tin thứ tự thời gian.

Prompt-based fusion dùng prompt như giao diện chung để kết hợp nhiều modality. Các modality khác nhau được chuyển thành text hoặc token sequence rồi đưa vào cùng một prompt. Hướng này nhẹ và linh hoạt nhưng nhạy với prompt template.

Adapted multimodal fusion dùng pretrained encoders, adapters hoặc projection networks để đưa vision, text và structured data vào cùng không gian trước khi cấp cho LLM. Ví dụ, visual features từ CLIP có thể được project vào language token space, sau đó đưa vào LLM như soft tokens.

Code-like structural conversion biểu diễn dữ liệu dưới dạng JSON, dictionary hoặc Python-like objects. Ví dụ:

```
{"title": "Blade Runner 2049", "genre": "Sci-Fi", "visual_style": "neo-noir"}
```

Cách này vừa dễ parse vừa giữ schema rõ ràng, phù hợp với LLM có khả năng xử lý code/structured input.

1.2 MRS-Specific Techniques

Nhóm thứ hai trong taxonomy là các kỹ thuật đặc thù của MRS: *Disentanglement*, *Alignment*, và *Fusion*. Đây là các vấn đề cốt lõi của multimodal recommendation, nhưng được xem lại dưới lens của LLM.

1.2.1 Disentanglement

Disentanglement nhằm tách thông tin shared giữa các modality và thông tin riêng của từng modality. Trong MRS, nếu text, image và metadata bị trộn quá sớm, model có thể học các correlation giả hoặc phụ thuộc quá mức vào một modality. Disentanglement giúp tăng interpretability, robustness và generalization.

Paper chia disentanglement thành nhiều nhóm.

Nhóm thứ nhất là *contrastive methods*. Các phương pháp này dùng positive/negative pairs để align hoặc tách các representation. Ví dụ, text và image của cùng item là positive

pair, còn image đã bị thay đổi thuộc tính quan trọng có thể là hard negative. Loss thường có dạng contrastive:

$$\mathcal{L}_{CL} = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\exp(\text{sim}(z_i, z_i^+)/\tau) + \sum_j \exp(\text{sim}(z_i, z_j^-)/\tau)}$$

Cách này giúp mô hình học được shared semantics nhưng vẫn giữ modality-specific differences.

Nhóm thứ hai là *attention-based methods*. Attention được dùng để reweight modality contribution theo user, item hoặc context:

$$z = \sum_{m=1}^M \alpha_m z_m$$

trong đó z_m là representation của modality m , còn α_m là trọng số attention. Nếu user quan tâm visual style, image modality có thể được tăng trọng số; nếu user quan tâm nội dung text, text modality được ưu tiên hơn.

Nhóm thứ ba là *clustering-based methods*. Các phương pháp này cluster item tokens, user interests hoặc modality-specific representations để tạo prototype. Prototype giúp tách các interest khác nhau, ví dụ visual preference, textual theme hoặc collaborative group.

Nhóm thứ tư là *VAE-based methods*. VAE học latent factors có cấu trúc:

$$q_\phi(z|x), \quad p_\theta(x|z)$$

và dùng regularization như KL divergence để học latent space có tính tách biệt. Trong MRS, VAE có thể tách content-driven factors khỏi collaborative factors, hoặc tách uncertainty theo từng modality.

Nhóm thứ năm là *architecture-driven methods*. Các phương pháp này thiết kế encoder riêng, routing module hoặc mixture-of-experts để kiểm soát modality-specific và shared signals. Ví dụ, một MoE có thể gồm collaborative expert, text expert và aligned expert, sau đó dùng gating network:

$$h = \sum_{e=1}^E g_e(x) h_e(x)$$

để chọn expert phù hợp theo từng input.

1.2.2 Alignment

Alignment nhằm đưa các modality khác nhau vào một không gian semantic chung hoặc làm cho chúng tương tác nhất quán. Đây là vấn đề rất quan trọng vì LLM hoạt động chủ yếu trong language/semantic space, trong khi MRS có image, graph, tabular và behavior

signals.

Paper đề cập nhiều nhóm alignment. *Contrastive alignment* dùng contrastive learning để kéo gần representation của cùng entity qua các modality và đẩy xa entity khác. *Adapter/projection alignment* dùng projection layer để map visual hoặc structured representation vào LLM token space:

$$z_{lang} = W z_{vision}$$

hoặc:

$$z_{lang} = \text{Adapter}(z_{modality})$$

RL-enhanced alignment dùng reward model hoặc reinforcement learning để align generation/recommendation với feedback hoặc downstream objective. *NLP-based alignment* dùng instruction tuning, prompt tuning hoặc textual conversion để đưa heterogeneous signals vào representation nội bộ của LLM.

Điểm quan trọng là alignment không chỉ là bài toán kỹ thuật embedding. Trong LLM-based MRS, alignment còn bao gồm việc làm cho LLM hiểu đúng ý nghĩa của modality sau khi chuyển đổi. Ví dụ, một image caption không chỉ cần đúng mô tả hình ảnh, mà còn phải giữ những attribute có liên quan đến recommendation như style, brand, occasion hoặc user preference.

1.2.3 Fusion

Fusion là cách kết hợp nhiều modality để tạo representation hoặc prediction cuối cùng. Paper kế thừa cách chia truyền thống gồm early fusion, intermediate fusion và late fusion, nhưng bổ sung góc nhìn mới về vị trí của LLM trong pipeline.

Early fusion kết hợp dữ liệu ở mức input hoặc feature thô:

$$x = [x_{text}; x_{image}; x_{tabular}]$$

Cách này đơn giản nhưng có thể bỏ qua modality-specific structure.

Intermediate fusion kết hợp sau khi mỗi modality đã qua encoder riêng:

$$h = \text{Fusion}(h_{text}, h_{image}, h_{graph})$$

Fusion có thể dùng MLP, attention, transformer hoặc gating. Đây là cách phổ biến vì giữ được đặc trưng riêng trước khi trộn.

Late fusion kết hợp ở mức score hoặc decision:

$$s = \lambda_1 s_{text} + \lambda_2 s_{image} + \lambda_3 s_{collab}$$

Cách này dễ kiểm soát và modular, nhưng có thể không học được interaction sâu giữa modality.

Với LLM-based MRS, fusion có thể xảy ra trước LLM, trong LLM, song song với LLM hoặc sau LLM. Ví dụ, image và metadata có thể được chuyển thành text rồi đưa vào LLM; visual embedding có thể được project vào token space; hoặc LLM output có thể được fuse với collaborative score của recommender truyền thống. Do đó, fusion trong thời kỳ LLM không chỉ là vấn đề kiến trúc, mà còn là vấn đề interface giữa modality và language model.

1.3 Evaluation Metrics and Datasets

Paper cung cấp tài nguyên mở rộng về datasets và evaluation metrics. Về dataset, survey tổng hợp nhiều bộ dữ liệu multimodal trong các domain như e-commerce, fashion, food, movie, music, image recommendation, book, academic graph và games. Các modality được ghi nhận gồm:

C : categorical/structured features

I : image

T : text

N : numerical

G : graph

Tab : tabular

Điều này hữu ích vì LLM-based MRS thường cần dataset có nhiều side information, không chỉ interaction matrix.

Về metric, paper nhấn mạnh MRS không nên chỉ dùng accuracy hoặc ranking metrics truyền thống. Ngoài Recall@K, NDCG@K, MRR hoặc Hit Rate, cần xét thêm diversity, novelty, coverage, fairness, explainability, multimodal alignment quality và NLG metrics nếu output là text. Với LLM-generated recommendation, các metric như BLEU, ROUGE, BERTScore, BLEURT hoặc LLM-as-judge cũng có thể được dùng, nhưng cần thận trọng vì chúng không luôn phản ánh recommendation utility thật.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một survey tập trung vào vai trò của LLM trong multimodal recommender systems. Thay vì chỉ xem LLM như một encoder mới, paper cho rằng LLM thay đổi toàn bộ design space của MRS: từ cách biểu diễn dữ liệu, cách prompt, cách fine-tune, cách align modality, cách fusion, đến cách đánh giá hệ thống.

Đóng góp kỹ thuật quan trọng nhất của bài báo là taxonomy LLM-centric cho MRS. Taxonomy này gồm ba trục lớn. Trục thứ nhất là *LLM Methods*, bao gồm prompting, training strategy và data type adaptation. Trục thứ hai là *MRS-specific Techniques*, gồm

disentanglement, alignment và fusion. Trục thứ ba là *Trends and Future Directions*, giúp xác định các khoảng trống nghiên cứu trong LLM-based MRS.

Bài báo cũng chỉ ra rằng các kỹ thuật từ các nhánh recommender khác có thể được chuyển sang MRS. Ví dụ, behavior-to-text summarization từ sequential recommendation, KG-RAG từ knowledge-aware recommendation, semantic ID từ generative recommendation, hoặc prompt-based user modeling từ conversational recommendation đều có thể trở thành thành phần của multimodal recommendation khi được kết hợp với text, image và structured data.

Ý nghĩa chính của paper là MRS trong thời kỳ LLM không còn là bài toán “encode từng modality rồi fusion”. LLM cho phép chuyển dữ liệu sang ngôn ngữ tự nhiên, dùng prompt làm interface chung, dùng reasoning để xử lý context phức tạp, dùng adapters hoặc soft prompts để đưa modality vào token space, và dùng agent/tool để tương tác với KG hoặc external systems. Điều này làm MRS linh hoạt hơn nhưng cũng phức tạp hơn.

Hạn chế hiện tại của lĩnh vực là còn thiếu benchmark chuẩn cho LLM-based MRS, thiếu evaluation thống nhất cho multimodal reasoning, và nhiều phương pháp vẫn phụ thuộc vào prompt hoặc API black-box. Ngoài ra, việc chuyển image, graph hoặc tabular data thành text có thể gây mất thông tin; ngược lại, dùng MLLM trực tiếp có thể tăng latency và chi phí triển khai.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, cần xây dựng benchmark LLM-MRS có nhiều modality thật sự, gồm text, image, tabular, graph và user behavior, thay vì chỉ text + interaction. Thứ hai, cần phát triển các phương pháp modality adaptation ít mất thông tin hơn, ví dụ kết hợp semantic ID, structured JSON, soft prompt và learned projection. Thứ ba, cần nghiên cứu fusion-aware LLM architecture, trong đó LLM không chỉ đọc modality đã chuyển thành text mà còn tương tác trực tiếp với multimodal embeddings.

Ngoài ra, paper này rất phù hợp để kế thừa cho hướng *LLM-enhanced context-aware recommendation*. Các modality như image, metadata, KG, behavior sequence và tabular context có thể được xem là các nguồn context khác nhau. Một hướng phát triển hợp lý là xây dựng hệ recommender vừa multimodal, vừa time-aware, vừa persona/context-aware, trong đó LLM đóng vai trò semantic adapter hoặc reasoning controller, còn ranking model nhỏ hơn vẫn đảm bảo latency thấp cho production serving. ““