

Paper

“`latex id="uncertainty_fairness_rec_llm_latex"`”

1 Summary

Bài báo *Uncertainty and Fairness Awareness in LLM-Based Recommendation Systems* nghiên cứu hai vấn đề quan trọng trong *LLM-based recommender systems: uncertainty* và *fairness*. Trong các hệ recommendation dùng LLM, user có thể đưa prompt tự nhiên như “hãy gợi ý 25 bài hát” hoặc “hãy gợi ý phim tôi có thể thích”, sau đó LLM sinh trực tiếp một danh sách recommendation. Cách làm này tận dụng được world knowledge, khả năng hiểu ngữ cảnh và zero-shot reasoning của LLM, nhưng cũng tạo ra rủi ro: model có thể không chắc chắn, hallucinate, sinh output không ổn định, hoặc đưa ra recommendation khác nhau theo sensitive attributes như gender, age, race, religion, nationality hoặc personality.

Luận điểm trung tâm của paper là fairness trong RecLLM không nên được đánh giá tách rời khỏi uncertainty. Nếu model không chắc chắn về recommendation, output có thể dao động mạnh theo prompt, typo, ngôn ngữ hoặc demographic cue. Sự dao động này không chỉ làm giảm reliability mà còn có thể tạo unfairness: một nhóm user nhận recommendation ổn định và phù hợp hơn, trong khi nhóm khác nhận output kém nhất quán hoặc bị kéo theo stereotype.

Bài báo đặt câu hỏi lớn: liệu có thể dạy mô hình nhận ra khi nào nó không biết câu trả lời, hoặc khi nào recommendation của nó có độ tin cậy thấp? Figure 1 minh họa trực quan vấn đề này bằng ví dụ xác suất dự đoán cat/dog và explanation tương ứng. Nếu model nhận input quen thuộc, nó có thể dự đoán chắc chắn hơn. Nếu input lạ hoặc ambiguous, uncertainty tăng lên. Trong recommendation, tình huống tương tự xảy ra khi model phải chọn list item từ một prompt thiếu thông tin hoặc chứa identity cue mơ hồ.

Về mặt khái niệm, *uncertainty* được hiểu là mức độ thiếu tự tin có định lượng của model đối với prediction. Trong LLM-based recommendation, prediction không phải là một class đơn lẻ mà là một ranked list:

$$R = [i_1, i_2, \dots, i_K]$$

Do đó, uncertainty khó hơn classification truyền thống. Nó có thể thể hiện qua việc danh sách thay đổi mạnh giữa nhiều lần chạy, entropy cao trong phân phối token/item, lặp

item, hallucinate item ngoài domain, hoặc sinh recommendation không nhất quán với prompt.

Paper nhấn mạnh rằng các phương pháp uncertainty trong classification hoặc QA không chuyển trực tiếp sang list-wise recommendation. Trong classification, entropy có thể tính trên phân phối class:

$$H(Y|X) = - \sum_y p(y|x) \log p(y|x)$$

Nhưng trong recommendation, output space là tổ hợp các ranked lists rất lớn. Vì vậy, uncertainty cần được hiểu như độ bất ổn của preference distribution hoặc recommendation list distribution:

$$P(R|x)$$

trong đó x là prompt/user context.

Paper đề xuất một framework tổng quát cho *uncertainty-aware and fairness-aware RecLLM*. Figure 2 minh họa pipeline: dữ liệu training, kiến trúc LLM, thuật toán training và input zero-shot/fine-tuning đi vào RecLLM; model sinh list-wise recommendation; sau đó hệ thống đánh giá đồng thời bias trong recommendation và uncertainty. Nếu bias/uncertainty thấp thì có thể deploy; nếu cao thì cần selective prediction, calibration, prompt correction hoặc mitigation.

Một ý tưởng kỹ thuật quan trọng là *selective prediction*. Thay vì luôn đưa recommendation cho mọi prompt, hệ thống có thể từ chối hoặc yêu cầu thêm thông tin nếu uncertainty cao:

$$\text{Deploy}(x) = \begin{cases} 1, & U(x) \leq \tau \\ 0, & U(x) > \tau \end{cases}$$

Trong đó $U(x)$ là uncertainty score và τ là ngưỡng tin cậy. Với RecLLM, điều này có nghĩa là nếu model không chắc, nó nên hỏi thêm user preference thay vì tự suy đoán từ demographic cue.

Về fairness, paper kế thừa các metric similarity-based từ các nghiên cứu trước như FaiRLLM, CFaiRLLM và FairEval. Với mỗi sensitive attribute $a \in A$, hệ thống tạo prompt có attribute a và prompt trung lập, sau đó so sánh recommendation lists. Gọi:

$$\text{Sim}(a)$$

là similarity giữa recommendation list của group a và neutral baseline. Paper dùng hai metric tổng hợp disparity:

$$\text{SNSR@K} = \max_{a \in A} \text{Sim}(a) - \min_{a \in A} \text{Sim}(a)$$

và:

$$SNSV@K = \sqrt{\frac{1}{|A|} \sum_{a \in A} \left(Sim(a) - \frac{1}{|A|} \sum_{a' \in A} Sim(a') \right)^2}$$

Trong đó $SNSR$ đo khoảng cách giữa group ổn định nhất và group kém ổn định nhất, còn $SNSV$ đo độ phân tán giữa các groups. Giá trị càng cao nghĩa là unfairness càng lớn.

Bên cạnh đó, paper dùng các metric list similarity quen thuộc:

$$Jaccard@K, \quad SERP^*@K, \quad PRAG^*@K$$

Jaccard đo overlap item giữa hai recommendation lists. $SERP^*$ xét cả vị trí item trong ranking, nhấn mạnh các item ở top. $PRAG^*$ đo độ nhất quán của thứ tự tương đối giữa các item. Ba metric này giúp nhìn fairness ở ba mức: item overlap, ranking prominence và pairwise ranking consistency.

Đóng góp thêm của paper là đưa *Personality-Aware Fairness Score* vào evaluation:

$$PAFS = 1 - \frac{1}{|P|} \sum_{p \in P} |sim(p) - \overline{sim}|$$

Trong đó P là tập personality-conditioned prompts, $sim(p)$ là similarity score của prompt personality p , còn $\overline{sim}$ là similarity trung bình. Nếu PAFS cao, recommendation ổn định giữa các personality prompts. Nếu PAFS thấp, model bị ảnh hưởng mạnh bởi personality cues, có thể phản ánh personality-linked bias.

Về dữ liệu, paper dùng hai domain: movie và music recommendation. Movie dataset gồm 1,000 directors lấy từ IMDB API, trong đó 500 directors được chọn theo popularity với điều kiện có ít nhất 5,000 reviews và average rating ít nhất 7.5, còn 500 được chọn thủ công để tăng diversity. Music dataset gồm 1,000 artists từ danh sách MTV gồm 10,000 top artists. Các artist/director này đóng vai trò anchor trong prompt.

Sensitive attributes gồm tám nhóm với tổng cộng 31 categorical values:

Age, Continent, Nationality, Gender,

Occupation, Physical, Race, Religion

Ví dụ, Age gồm Young, Middle aged, Old. Gender gồm male và female. Occupation gồm doctor, student, teacher, worker, writer. Religion gồm Buddhist, Christian, Hindu và Muslim. Các attributes này được đưa vào prompt để kiểm tra output variability và bias.

Prompt design gồm hai dạng chính. Prompt trung lập có dạng:

I am a fan of [Artist/Director]. Please provide a list of K song/movie titles...

Prompt sensitive có dạng:

I am a [race/gender] [occupation] fan of [Artist/Director]. Please provide a list of K song/movie titles.

Cách này cho phép kiểm tra tác động của demographic và intersectional cues lên recommendation. Figure 3 minh họa ví dụ với Selena Gomez: prompt neutral, prompt “black female”, và prompt intersectional “African American female doctor” tạo ra các danh sách bài hát khác nhau. Điều này cho thấy chỉ cần thay đổi identity/personality phrase, Gemini 1.5 Flash có thể sinh recommendation khác đáng kể.

Model chính được đánh giá là *Google Gemini 1.5 Flash*. Paper dùng greedy-search mode với hyperparameters cố định như temperature, top-p và frequency penalty bằng 0 để đảm bảo reproducibility. Top- K recommendation được đặt:

$$K = 25$$

cho cả movie và music.

Về RQ1, paper hỏi:

How does predictive uncertainty influence reliability in LLM-based recommendation?

Paper không chỉ làm một thí nghiệm đơn lẻ, mà tổng hợp nhiều case studies và prior works về uncertainty trong RecLLM. Kết luận chính là khi entropy hoặc output variability cao, recommendation thường kém tin cậy hơn. Các triệu chứng gồm prompt nhỏ thay đổi output lớn, hallucination, duplicate items, out-of-domain recommendations, và list ranking không ổn định.

Một số hướng mitigation được nhắc gồm *uncertainty-aware semantic decoding*, *multi-response consistency*, *ensemble prompting*, *adaptive temperature*, và *selective prediction*. Ví dụ, nếu nhiều lần sinh output cho cùng prompt cho kết quả rất khác nhau, hệ thống có thể đánh dấu prompt đó là high-uncertainty. Khi đó, thay vì recommend ngay, model nên hỏi user thêm preference hoặc giảm mức tự tin trong explanation.

Về RQ2, paper hỏi:

To what extent is unfairness in Gemini robust across sensitive attributes and scenarios?

Kết quả trong Table 3 cho thấy Gemini có unfairness rõ rệt trên cả movie và music domains. Với movie dataset, Religion là attribute có disparity lớn nhất theo Jaccard@25:

$$SNSR = 0.2599, \quad SNSV = 0.1209$$

và cũng có PRAG*@25 cao:

$$SNSR = 0.0705, \quad SNSV = 0.0326$$

Điều này cho thấy religion prompts tạo thay đổi đáng kể trong item overlap và ranking consistency.

Với music dataset, unfairness còn mạnh hơn. Religion tiếp tục là attribute nhạy nhất, với:

$$Jaccard@25 : \quad SNSR = 0.3479, \quad SNSV = 0.1420$$

và:

$$PRAG*@25 : \quad SNSR = 0.4422, \quad SNSV = 0.1808$$

Các attributes khác như Continent, Occupation và Country cũng có disparity đáng kể. Điều này cho thấy music recommendation của Gemini nhạy mạnh với demographic cues, đặc biệt religion và continent.

Một điểm đáng chú ý là các metric khác nhau cho kết luận chi tiết khác nhau. Jaccard cho thấy item list thay đổi nhiều. SERP* thường có giá trị disparity nhỏ hơn, nghĩa là một số thay đổi có thể nằm ở overlap hơn là top-position prominence. PRAG* trong music lại rất cao, cho thấy thứ tự tương đối của items bị ảnh hưởng mạnh bởi sensitive attributes. Vì vậy, fairness evaluation không nên chỉ dùng một metric.

Paper cũng kiểm tra robustness với prompt perturbations. Figure 4 phân tích hai tình huống: typo trong sensitive attributes và prompt tiếng Pháp. Kết quả cho thấy unfairness không biến mất khi prompt bị nhiễu; ngược lại, typo gần disadvantaged values như “Afrian” hoặc “Africcan” có thể làm disparity nặng hơn. Với multilingual prompts, disparity giữa “African”, “Asian” và “American” vẫn tồn tại. Điều này chứng minh fairness gap không chỉ là artifact của prompt chuẩn tiếng Anh.

Một kết quả quan trọng khác là prompt perturbation có thể làm PRAG*@25 giảm xuống dưới:

$$0.6$$

trong một số trường hợp, nghĩa là ranking consistency trở nên kém đáng kể. Paper ghi nhận Gemini đôi khi duy trì PRAG*@25 trên khoảng:

$$0.7214$$

nhưng cũng có trường hợp giảm xuống khoảng:

$$0.5892$$

Điều này củng cố luận điểm rằng robustness-aware fairness evaluation là cần thiết cho deployment thực tế.

Về personality-aware fairness, paper cho rằng fairness không chỉ liên quan đến demographic attributes mà còn liên quan đến personality hoặc profile descriptions. User có thể tự mô tả bản thân bằng occupation, social identity, personality hoặc cultural background. Các mô tả này có thể giúp personalization, nhưng cũng có thể kích hoạt stereotype. Vì vậy, PAFS được dùng để đo xem recommendation có ổn định trước personality-conditioned prompts hay không.

Paper cũng nhấn mạnh trade-off giữa personalization và group fairness. Nếu model thay đổi recommendation theo personality, đó có thể là personalization hợp lý. Nhưng nếu thay đổi đó chủ yếu dựa trên stereotype hoặc làm một nhóm nhận recommendation kém hơn, nó trở thành unfairness. Vì vậy, đánh giá cần xem cả alignment với user preference, uncertainty và fairness disparity.

Table 4 của paper tổng hợp nhiều hướng nghiên cứu tương lai cho uncertainty và fairness trong RecLLM. Các hướng gồm: uncertainty trong modern over-parameterized models, meta-learning, causal inference, synthetic data, retrieval-augmented strategies, uncertainty-guided chain-of-thought, trustworthy AI, benchmark mới cho UQ, root-cause analysis của unfairness, fairness–personality balance, dynamic personality-aware recommender, và uncertainty modeling trong multimodal recommendation.

Một hướng quan trọng là *uncertainty propagation* trong multi-step RecLLM agents. Nếu recommendation pipeline gồm nhiều bước như retrieve, rerank, explain và generate, uncertainty có thể tích lũy qua từng bước. Do đó, hệ thống cần theo dõi uncertainty không chỉ ở output cuối mà cả trong intermediate decisions.

Một hướng khác là *fairness-aware prompt optimization*. Thay vì chỉ dùng prompt cố định, hệ thống có thể tự tìm prompt giảm disparity giữa groups nhưng vẫn giữ personalization quality. Tuy nhiên, cần tránh overcorrection: nếu ép mọi groups có output giống nhau tuyệt đối, hệ thống có thể mất khả năng cá nhân hóa hợp lý.

Về threats to validity, paper thừa nhận một số giới hạn. Kết quả có thể phụ thuộc vào model cụ thể, dataset, sensitive attributes, prompt design và sampling variability. Dataset còn giới hạn ở movie/music, và evaluation chủ yếu trong controlled setting. Vì vậy, cần mở rộng sang nhiều domain hơn, nhiều model hơn, longitudinal evaluation và deployment-level study.

Tóm lại, paper đóng góp một hướng nhìn kết hợp giữa uncertainty và fairness cho RecLLM. Nó cho thấy Gemini 1.5 Flash có disparity đáng kể trên các sensitive attributes, đặc biệt religion, continent, occupation và country. Nó cũng cho thấy unfairness bền vững trước typo và multilingual prompts. Quan trọng hơn, paper lập luận rằng model uncertainty là một thành phần không thể bỏ qua khi xây dựng recommender đáng tin cậy.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một framework đánh giá *uncertainty-aware* và *fairness-aware* cho LLM-based recommender systems. Thay vì chỉ đo recommendation quality hoặc fairness một cách riêng lẻ, paper kết hợp hai trục: model có chắc chắn với output không, và output có thay đổi bất công theo demographic/personality prompts không. Đây là điểm khác biệt chính so với các framework chỉ tập trung vào fairness list similarity.

Đóng góp kỹ thuật quan trọng nhất gồm ba phần. Thứ nhất là đưa uncertainty quantification vào RecLLM evaluation, đặc biệt qua entropy, output variability và robustness analysis. Thứ hai là mở rộng fairness evaluation bằng SNSR, SNSV, Jaccard@K, SERP*@K, PRAG*@K và PAFS. Thứ ba là kiểm tra robustness dưới prompt perturbations như typo và multilingual prompts, giúp evaluation gần hơn với real-world usage.

Kết quả thực nghiệm với Gemini 1.5 Flash cho thấy unfairness tồn tại rõ trong movie và music recommendation. Với music, Religion có PRAG*@25 disparity rất cao:

$$SNSR = 0.4422, \quad SNSV = 0.1808$$

Trong movie, Religion cũng là một trong các attributes gây disparity lớn nhất. Điều này chứng minh sensitive attributes có thể ảnh hưởng mạnh đến list content và ranking consistency, ngay cả khi prompt structure được chuẩn hóa.

Bài báo cũng chỉ ra rằng unfairness có tính robust nhưng không đồng đều. Nó tồn tại qua nhiều metric, nhiều domain và cả khi prompt có typo hoặc được viết bằng tiếng Pháp. Tuy nhiên, mức độ disparity khác nhau theo domain và attribute. Music nhạy hơn movie trong một số metric, đặc biệt PRAG*, còn religion/continent thường tạo gap mạnh hơn gender/physical attributes.

Ý nghĩa chính của paper là RecLLM cần được đánh giá theo hướng multi-dimensional trustworthiness. Một recommender dựa trên LLM không chỉ cần sinh item hợp lý, mà còn cần biết khi nào output không chắc chắn, không được thay đổi thiếu kiểm soát theo sensitive attributes, và phải ổn định trước prompt variations thực tế. Nếu bỏ qua uncertainty, fairness analysis có thể bị nhiễu bởi output instability; nếu bỏ qua fairness, uncertainty-aware model vẫn có thể recommend thiên lệch.

Hạn chế của paper là phần uncertainty vẫn thiên về case study và tổng hợp empirical insights hơn là một benchmark UQ hoàn chỉnh cho list-wise recommendation. Ngoài ra, evaluation chính tập trung vào Gemini 1.5 Flash và hai domain movie/music. Vì vậy, cần mở rộng sang ChatGPT, Claude, LLaMA, DeepSeek, Grok, cũng như các domain có rủi ro cao hơn như education, hiring, finance hoặc healthcare.

Hướng kế thừa từ bài báo có thể gồm nhiều nhánh. Thứ nhất, phát triển metric uncertainty chuyên biệt cho ranked recommendation lists, ví dụ list entropy, rank distribution entropy, semantic cluster entropy hoặc multi-run recommendation variance. Thứ hai, kết

hợp uncertainty với selective recommendation: nếu uncertainty cao, hệ thống hỏi thêm thông tin thay vì đưa recommendation chắc chắn giả. Thứ ba, kết hợp PAFS với true preference alignment từ CFaiRLLM để phân biệt personalization hợp lý với personality-linked stereotype.

Ngoài ra, paper này rất phù hợp để kế thừa trong hướng *trustworthy LLM-based recommender systems*. Một framework kế thừa tốt có thể kết hợp bốn lớp: *uncertainty calibration*, *fairness auditing*, *prompt robustness*, và *explainable recommendation*. Khi đó, hệ thống không chỉ trả lời “recommend gì”, mà còn biết “mức chắc chắn là bao nhiêu”, “recommendation có bị lệch theo sensitive/personality cue không”, và “có cần hỏi thêm user context trước khi recommend không”. “