

Paper

“latex

1 Summary

Bài báo *Revealing Potential Biases in LLM-Based Recommender Systems in the Cold Start Setting* nghiên cứu vấn đề bias trong *LLM-based recommender systems* ở bối cảnh *cold start*. Đây là một setting quan trọng vì khi user mới tham gia hệ thống, platform thường chưa có lịch sử tương tác như click, rating, purchase hoặc watch history. Khi thiếu dữ liệu hành vi, hệ thống có thể phải dựa vào các tín hiệu rất ít như age, gender, nationality, language hoặc một số mô tả ngắn về user.

Vấn đề chính của bài báo là trong zero-context hoặc low-context recommendation, LLM có thể không còn dựa vào preference thật của user mà dựa vào các stereotype đã học từ dữ liệu pretraining. Ví dụ, nếu prompt chỉ nói user là “a girl” hoặc “a boy”, mô hình có thể mặc định gợi ý các thể loại phim khác nhau dựa trên khuôn mẫu giới tính. Tương tự, nếu user được mô tả là “Japanese”, “Chinese”, “American” hoặc “African”, mô hình có thể thay đổi danh sách phim theo các giả định văn hóa thay vì dựa trên preference cụ thể.

Bài báo nhấn mạnh rằng các nghiên cứu trước như FairEval, FaiRLLM hoặc CFaiRLLM đã phân tích fairness trong RecLLM, nhưng thường cung cấp nhiều contextual cues hơn, ví dụ user là fan của một artist, thích một genre cụ thể, hoặc có một preference statement rõ ràng. Trong khi đó, paper này muốn cô lập cold-start setting: khi chỉ có sensitive attributes, LLM sẽ recommend như thế nào? Đây là câu hỏi quan trọng vì nó cho thấy model đang dựa vào stereotype hay preference thật.

Đóng góp chính của bài báo là một benchmark và pipeline modular để đánh giá bias trong *cold-start recommendation*. Framework này cho phép người dùng cấu hình ba thành phần: dataset, sensitive attributes và open-source LLM cần kiểm tra. Pipeline có thể chạy với các model trên Hugging Face Hub thông qua *vLLM*, giúp việc benchmark mở rộng hơn so với các nghiên cứu chỉ dùng closed API như ChatGPT.

Figure 1 của paper minh họa pipeline tổng thể. Người dùng cung cấp item dataset và danh sách sensitive attributes. Pipeline tự động tạo benchmark prompts gồm neutral prompt và attribute-conditioned prompts. Sau đó LLM được yêu cầu chọn và xếp hạng

một tập item. Output của LLM được parse thành recommendation sets, rồi so sánh recommendation theo từng sensitive attribute với neutral baseline để tính bias score. Cuối cùng pipeline tạo bảng và biểu đồ để phân tích bias theo dataset và attribute.

Khác với các framework trước thường yêu cầu LLM tự sinh danh sách item, paper này thiết kế bài toán dưới dạng *re-ranking task*. Cụ thể, hệ thống cung cấp cho LLM một catalog gồm N items, sau đó yêu cầu LLM chọn và xếp hạng top- k items phù hợp với user. Với dataset thực tế rất lớn có kích thước N_{real} , paper chỉ lấy một tập nhỏ hơn:

$$N \ll N_{real}$$

do giới hạn context window của LLM. Trong thí nghiệm, paper dùng:

$$N = 500, \quad k = 20$$

tức model nhận 500 items và chọn top-20 recommendations.

Cách thiết kế re-ranking này có hai lợi ích. Thứ nhất, nó thực tế hơn với nhiều hệ recommender công nghiệp, nơi retrieval stage tạo candidate set rồi ranker xếp hạng lại. Thứ hai, nó tránh vấn đề LLM hallucinate item không có trong catalog, vì model phải chọn từ danh sách item đã được cung cấp.

Về mặt hình thức, với neutral user, LLM sinh ra ordered list:

$$I_{Neu.}^k$$

Với user có sensitive attribute a , LLM sinh ra:

$$I_a^k$$

Hai danh sách này được so sánh bằng một similarity function:

$$Sim(I_a^k, I_{Neu.}^k)$$

Nếu hai danh sách giống nhau hoàn toàn, similarity bằng 1. Nếu chúng khác nhau mạnh, similarity thấp hơn. Bias đối với attribute a được định nghĩa là phần bù của similarity:

$$B_{Sim}^k(a) = 1 - Sim(I_a^k, I_{Neu.}^k)$$

Do đó, bias càng gần 0 thì recommendation càng ít thay đổi khi thêm sensitive attribute; bias càng cao thì sensitive attribute càng làm recommendation lệch khỏi neutral baseline.

Bài báo sử dụng ba metric similarity chính, kế thừa từ các benchmark fairness trước.

Metric thứ nhất là *IOU* hay Jaccard similarity, không xét thứ tự:

$$B_{IOU}^k(a) = 1 - \frac{|I_a^k \cap I_{Neu.}^k|}{|I_a^k| + |I_{Neu.}^k| - |I_a^k \cap I_{Neu.}^k|}$$

Metric này đo item overlap giữa danh sách neutral và danh sách sensitive. Nếu attribute-conditioned list chứa nhiều item khác neutral list, IOU divergence sẽ cao.

Metric thứ hai là *SERP divergence*, có xét vị trí ranking:

$$B_{SERP}^k(a) = 1 - \sum_{i \in I_a^k} \frac{2 \cdot \mathbf{1}_{i \in I_{Neu.}^k} \cdot (k - r_a(i) + 1)}{k(k+1)}$$

Trong đó $r_a(i)$ là rank của item i trong list có attribute a . SERP coi các item ở vị trí cao quan trọng hơn. Nếu các item trùng với neutral list nhưng bị đẩy xuống thấp, metric vẫn phản ánh sự thay đổi.

Metric thứ ba là *PRAG divergence*, đo sự nhất quán thứ tự tương đối giữa hai ranked lists:

$$B_{PRAG}^k(a) = 1 - \sum_{\substack{i_1, i_2 \in I_a^k \\ i_1 \neq i_2}} \frac{\mathbf{1}_{i_1 \in I_{Neu.}^k} \cdot \mathbf{1}_{r_{Neu.}(i_1) < r_{Neu.}(i_2)} \cdot \mathbf{1}_{r_a(i_1) < r_a(i_2)}}{k(k+1)}$$

Metric này nhạy với thay đổi trong preference hierarchy. Hai list có thể có nhiều item overlap, nhưng nếu thứ tự tương đối của các item bị đảo, PRAG divergence sẽ tăng.

Paper diễn giải recommendation list theo góc nhìn xác suất. I_a^k có thể được xem như top- k items được chọn từ:

$$P(item \mid a)$$

còn neutral list đến từ:

$$P(item)$$

Do đó:

$$B^k(a)$$

do mức độ phân phối recommendation bị thay đổi khi điều kiện hóa trên sensitive attribute a . Đây là cách nhìn quan trọng vì nó biến fairness evaluation thành counterfactual comparison giữa distribution có attribute và distribution không có attribute.

Dataset của benchmark gồm ba domain. Domain thứ nhất là *Movie*, được tạo từ TMDB API và IMDb highest-rated movies, giữ lại title tiếng Anh. Domain thứ hai là *Music*, được tạo bằng Spotify Web API và Spotipy, lấy các bài hát nổi bật từ các playlist theo thập niên, sau đó chuẩn hóa thành dạng:

$$[\text{Song title}] \text{ by } [\text{Artist name}]$$

Domain thứ ba là *College*, được tạo từ QS World University Rankings 2023. College là

đóng góp domain mới của paper, vì recommendation trong giáo dục có tác động cao hơn so với movie/music: nếu hệ thống gợi ý đại học theo bias văn hóa, quốc gia hoặc giới tính, nó có thể ảnh hưởng đến cơ hội học tập và nghề nghiệp.

Thí nghiệm chính sử dụng bốn instruction-tuned open-source LLMs:

Llama 3.2 3B Instruct

Gemma 3 1B Instruct

Gemma 3 4B Instruct

Gemma 3 12B Instruct

Mỗi model được đưa một catalog gồm 500 items và được yêu cầu chọn top-20 items cho neutral user hoặc user có sensitive attribute. Kết quả được trung bình trên 5 independent generation seeds để giảm nhiễu do sampling.

Paper đặt ra bốn giả thuyết chính.

Giả thuyết thứ nhất là:

$H1$: Larger LLMs exhibit less bias.

Tức model lớn hơn có thể công bằng hơn vì có khả năng hiểu instruction tốt hơn và có world knowledge phong phú hơn. Tuy nhiên, kết quả không ủng hộ quan hệ tuyến tính này. Khi so sánh Gemma 1B, 4B và 12B, Gemma 4B thường có divergence thấp nhất trên Music và Movie, trong khi Gemma 12B lại có divergence cao hơn. Điều này cho thấy model lớn hơn không nhất thiết ít bias hơn. Model lớn có thể nhạy hơn với sensitive attributes và làm attribute-conditioned recommendation lệch mạnh hơn neutral baseline.

Ví dụ, trên Music dataset, Gemma 4B có IOU divergence khoảng:

0.27

trong khi Gemma 12B khoảng:

0.66

và Gemma 1B khoảng:

0.73

Trên Movie dataset, Gemma 4B cũng thấp hơn:

0.55

so với Gemma 12B:

0.75

và Gemma 1B:

0.78

Điều này cho thấy quan hệ giữa model size và fairness là *non-monotonic*. Model nhỏ có thể bias cao vì task fidelity thấp; model quá lớn có thể bias cao vì sensitivity với attribute mạnh hơn; model trung bình có thể đạt cân bằng tốt hơn.

Giả thuyết thứ hai là:

H2 : LLMs replicate societal stereotypes.

Paper kiểm tra stereotype giới tính trong movie recommendation bằng cách đo tỷ lệ action movies trong top-20 recommendations của Gemma 3 4B cho các prompt như neutral, “a boy”, “a girl”, “a male”, “a female”. Kết quả cho thấy neutral user nhận khoảng:

35.0%

action movies. Với “a boy”, tỷ lệ tăng lên:

40.5%

Trong khi đó, với “a girl”, tỷ lệ giảm mạnh còn:

14.8%

và với “a female”, còn:

18.0%

Kết quả này cho thấy model có xu hướng gợi ý nhiều action movies hơn cho boy/male và ít hơn cho girl/female, phù hợp với stereotype giới tính phổ biến trong movie domain.

Figure 2 minh họa rõ kết quả này: thanh “boy” cao hơn neutral, còn “girl” và “female” thấp hơn rõ rệt. Điều này cho thấy chỉ một attribute giới tính, khi không có preference context cụ thể, đã đủ để thay đổi genre distribution của recommendation.

Giả thuyết thứ ba là:

H3 : Adding context to a user mitigates bias.

Ý tưởng là nếu cung cấp một preference signal rõ ràng, ví dụ user là “action movie fan”, model sẽ dựa vào preference này thay vì stereotype. Paper kiểm tra bằng Gemma 3 12B trên Movie dataset vì model này khá nhạy với attribute.

Kết quả trong Figure 3 cho thấy khi thêm context “action movie fan”, IOU divergence giảm ở nhiều sensitive attributes. Trên spider plot, đường có context nằm gần trung tâm hơn đường không có context, cho thấy bias giảm. Hiệu ứng đặc biệt rõ với các attributes

ban đầu có divergence cao như “girl”. Điều này ủng hộ giả thuyết rằng task-relevant context có thể làm giảm reliance của LLM vào stereotype trong zero-context setting.

Kết quả này cũng có ý nghĩa thực tiễn: trong cold-start recommendation, thay vì hỏi hoặc suy luận sensitive attributes, hệ thống nên ưu tiên thu thập preference context trực tiếp như genre yêu thích, mục tiêu học tập, ngân sách, location preference hoặc constraint cụ thể. Context preference rõ ràng có thể giảm bias tốt hơn việc để model tự suy đoán từ identity cues.

Giả thuyết thứ tư là:

$H4$: LLMs are biased towards Western content.

Paper kiểm tra cultural bias bằng cách đo tỷ lệ Western movies được recommend bởi Gemma 3 12B theo các attributes khác nhau. Western content được định nghĩa là nội dung chủ yếu đến từ North America, Europe, Australia và New Zealand.

Kết quả cho thấy neutral user nhận danh sách recommendation có:

91.3%

Western movies. Đây là một kết quả rất quan trọng: khi không nói gì về nationality/culture, model mặc định neutral user gần với Western preference. Các prompt gắn với Western countries cũng có tỷ lệ cao, ví dụ:

American : 94.0%

German : 91.3%

British : 89.3%

Với một số non-Western attributes, tỷ lệ Western content giảm nhưng vẫn còn đáng kể, ví dụ:

Chinese : 48.0%

Asian : 45.3%

Japanese : 22.0%

Tuy nhiên, có các kết quả bất thường như “African” đạt:

96.0%

Western content, cho thấy model có thể hiểu sai hoặc bị artifact từ training data.

Figure 4 trên page 9 minh họa tỷ lệ Western movies theo từng attribute. Neutral baseline rất cao, gần các Western identities, cho thấy *neutral prompt* không thực sự trung

lập về văn hóa. Điều này có ý nghĩa lớn cho fairness evaluation: nếu neutral baseline đã mang Western bias, việc so sánh sensitive prompt với neutral prompt có thể che giấu một số bias nền.

Bài báo cũng so sánh Gemma 3 4B và Llama 3.2 3B trước khi chọn model chính cho hypothesis testing. Dù Llama có một số divergence metric khác nhau, qualitative analysis cho thấy Llama outputs kém ổn định hơn, có hiện tượng repetition artifacts như lặp lại cùng một bài hát nhiều lần. Điều này có thể làm divergence bị inflate không phải vì bias thật, mà vì output không ổn định. Vì vậy, paper chọn Gemma 3 làm trọng tâm phân tích sâu hơn.

Về discussion, paper nêu một số giới hạn và hướng mở rộng. Thứ nhất, có thể đảo chiều bài toán từ *ranking items for a user* sang *ranking users for an item*. Cách này có thể phù hợp với các domain nhạy cảm như job recommendation hoặc college recommendation, nơi bias trong việc chọn user cho item cũng rất quan trọng.

Thứ hai, benchmark hiện tại tập trung vào re-ranking với fixed catalog. Một hướng mở rộng là retrieval task, trong đó LLM có thể dùng search hoặc online data để recommend các item mới hơn, ví dụ newly released movies. Điều này sẽ làm benchmark gần hơn với real-world recommendation nhưng cũng khó kiểm soát hơn.

Thứ ba, paper đặt vấn đề về bias mitigation bằng prompt engineering. Ví dụ, có thể thêm instruction:

provide recommendations while avoiding unfair bias based on [sensitive attribute]

Nhưng cần kiểm tra liệu instruction này có giảm bias mà không làm mất helpful personalization hay không. Ngoài ra, model lớn hơn có thể hiểu fairness instruction tốt hơn model nhỏ, nên bias mitigation cũng có thể phụ thuộc vào model scale.

Thứ tư, paper thảo luận vấn đề đạo đức: không phải mọi khác biệt theo attribute đều là unfairness. Nếu hệ thống recommend Italian movies cho một Italian-speaking user, đó có thể là personalization hợp lý. Nhưng nếu hệ thống dùng gender để mặc định recommend romance movies cho women và action movies cho men, điều này có thể củng cố stereotype. Vì vậy, cần phân biệt giữa beneficial personalization và harmful bias.

Tóm lại, paper đóng góp một benchmark cold-start fairness có tính modular, reproducible và open-source-oriented. Nó cho thấy trong zero-context setting, LLM-based recommender có thể biểu hiện bias rõ rệt theo gender, culture, nationality và domain. Đồng thời, nó chỉ ra rằng model scale không giải quyết bias một cách đơn giản, và việc thêm task-relevant user context có thể là một hướng giảm bias hiệu quả hơn.

2 Conclusion

Hướng đi đã làm của bài báo là xây dựng một benchmark và pipeline tự động để đánh giá bias của LLM-based recommender systems trong *cold-start setting*. Khác với các framework trước thường có nhiều contextual cues, paper cố ý đặt model vào zero-context scenario, nơi chỉ có sensitive attributes hoặc neutral prompt. Cách này giúp quan sát rõ hơn liệu LLM có dựa vào stereotype hoặc cultural priors khi thiếu dữ liệu preference hay không.

Đóng góp kỹ thuật quan trọng nhất là thiết kế bài toán dưới dạng *re-ranking benchmark*. LLM nhận một catalog gồm 500 items và phải chọn top-20 items cho neutral user hoặc user có sensitive attribute. Recommendation lists được so sánh bằng IOU, SERP và PRAG divergence:

$$B_{Sim}^k(a) = 1 - Sim(I_a^k, I_{Neu.}^k)$$

Công thức này biến fairness evaluation thành counterfactual comparison giữa recommendation distribution không điều kiện và recommendation distribution có điều kiện theo attribute.

Kết quả thực nghiệm cho thấy LLMs có thể tái tạo societal stereotypes trong cold-start recommendation. Với movie recommendation, Gemma 3 4B recommend nhiều action movies hơn cho “boy” và ít hơn đáng kể cho “girl” hoặc “female”. Điều này chứng minh rằng khi thiếu preference context, gender attribute có thể làm model thay đổi genre distribution theo khuôn mẫu xã hội.

Paper cũng phát hiện cultural bias mạnh. Neutral user nhận đến khoảng 91.3% Western movies từ Gemma 3 12B, gần với các Western identities như American, German hoặc British. Điều này cho thấy neutral prompt không nhất thiết là cultural-neutral; nó có thể phản ánh Western default trong dữ liệu pretraining, đặc biệt khi model được huấn luyện nhiều trên English-language internet corpus.

Một phát hiện quan trọng khác là quan hệ giữa model size và fairness không tuyến tính. Gemma 3 4B thường ít divergence hơn Gemma 1B và 12B trên Music/Movie. Model nhỏ có thể sai vì task fidelity yếu, còn model lớn có thể nhạy hơn với sensitive attributes và over-condition theo chúng. Vì vậy, giả định “larger model = fairer model” không đủ chính xác trong LLM-based recommendation.

Hướng kế thừa trực tiếp từ bài báo có thể gồm nhiều nhánh. Thứ nhất, mở rộng benchmark sang retrieval setting, nơi LLM không chỉ re-rank catalog cố định mà còn tìm item mới từ external data. Thứ hai, mở rộng sang high-stakes recommendation như job, scholarship, healthcare provider hoặc housing, nơi cold-start bias có hậu quả xã hội lớn hơn. Thứ ba, kiểm tra nhiều model hơn, đặc biệt các model lớn trên 70B parameters và các model không được huấn luyện chủ yếu trên English/Western corpora.

Ngoài ra, paper này rất phù hợp để kế thừa cùng FairEval và CFaiRLLM. FairEval mạnh ở personality-aware fairness và prompt robustness; CFaiRLLM mạnh ở true preference alignment; còn paper này mạnh ở cold-start/zero-context bias isolation. Một benchmark

kế thừa tốt có thể kết hợp cả ba: kiểm tra bias trong cold-start, thêm personality và multilingual perturbations, đồng thời dùng ground-truth preference hoặc explicit user context để phân biệt harmful bias với legitimate personalization.

Về hướng phát triển hệ thống, bài báo gợi ý rằng cách giảm bias tốt nhất trong cold-start có thể không phải là bỏ qua user context, mà là thu thập đúng loại context. Khi thêm preference rõ ràng như “action movie fan”, divergence giảm trên nhiều attributes. Vì vậy, một recommender đáng tin cậy nên ưu tiên hỏi user về preference, goal và constraints thay vì suy luận từ sensitive attributes. Đây là hướng quan trọng để xây dựng LLM-based recommender vừa cá nhân hóa tốt, vừa giảm nguy cơ stereotype trong cold-start. ““